

Os extremos de renda: o critério, aberto

Como um setor censitário vira SUSPEITO, EXTREMO ou NORMAL · Anexo à EDA Central · Índice de Vulnerabilidade da Saúde intraurbano · Censo Demográfico 2022 · 70 municípios do ELSI-Brasil
Pedro Dias Soares · Iniciação Científica · Fiocruz Minas, Instituto René Rachou

O que este documento acrescenta ao que está na apresentação

O deck resume a classificação em um slide e meio e mostra o resultado. Aqui está a regra inteira: onde exatamente cai o corte de extremo, por que ele é calculado dentro de cada município, quais são os três testes de coerência e o limiar de cada um, quantos dos 66 suspeitos cada teste pegou sozinho, e as duas colunas de diagnóstico que ficam fora da classificação de propósito. Nada aqui muda a apresentação nem os números já apresentados.

1 Por que a renda precisa de um tratamento próprio

A renda média do responsável, V06004, é a componente do IVS com a distribuição mais torta: assimetria de 3,74 no recorte urbano, contra 2,38 a 3,42 das três variáveis de saneamento. Os extremos dela não têm todos a mesma natureza, e é essa a razão de existir um critério em vez de uma regra única.

São três coisas diferentes com a mesma aparência. Há **erro de dado**, como o setor de favela em Belo Horizonte com R\$ 170.418,06 de renda média por responsável. Há **extremo genuíno**, o bairro rico cuja renda alta o entorno inteiro sustenta. E há **setor pequeno com média instável**, onde poucos domicílios fazem a média oscilar. Excluir os três ou manter os três perde informação nos dois sentidos: no primeiro caso some a desigualdade real que o índice existe para medir, no segundo o erro entra no cálculo.

2 O procedimento, etapa a etapa

A regra está em `src/ivs_censo/renda.py`, na função `rastrear_outliers_renda`. Ela rotula em quatro etapas, e as constantes citadas abaixo são importadas do módulo por este gerador, de modo que o texto não pode descrever uma versão diferente da que roda.

2.1 Etapa 1: onde cai o corte de extremo

O corte é o limite superior de Tukey, $q_3 + k \times (q_3 - q_1)$, com **$k = 3,0$** . Essa escolha merece atenção porque o valor usual, e o que aparece na tabela de outliers da apresentação, é $k = 1,5$. Com $k = 1,5$ rotula-se a cauda inteira; a intenção aqui não é descrever a cauda, e sim isolar o extremo distante, então o critério usa o corte de outlier extremo. Os dois limiares convivem no projeto para finalidades diferentes: $k = 1,5$ descreve a forma da distribuição de cada componente, $k = 3,0$ seleciona casos para inspeção.

2.2 Etapa 2: o corte é calculado dentro de cada município

O quartil e o intervalo interquartil saem da distribuição do próprio município, não do país. O IVS é um índice intraurbano, que compara setores dentro da mesma cidade: R\$ 20 mil é um valor comum em São Paulo e uma anomalia em Autazes. Um corte nacional mede a distância entre cidades, que não é o objeto da análise. A seção 6 mostra o quanto os dois critérios divergem na prática.

2.3 Etapa 3: a trava dos municípios pequenos

Em município com poucos setores o quartil não é confiável, então a regra não rotula por ele: quando o município tem menos de **20 setores**, o limite superior fica indefinido e nenhum setor de lá pode ser marcado. Isso tem consequência concreta e não está na apresentação: **12 dos 70 municípios**, somando **118 setores**, estão estruturalmente fora da detecção. 58 municípios são efetivamente avaliados.

Município	Região	Setores urbanos
São Raimundo do Doca Bezerra	Nordeste	3
Orizânia	Sudeste	5
São Paulo das Missões	Sul	6

Município	Região	Setores urbanos
Japoatã	Nordeste	7
Santa Maria do Oeste	Sul	8
Urandi	Nordeste	9
Jaqueira	Nordeste	9
Coroaci	Sudeste	11
Vicentinópolis	Centro-Oeste	11
Groaíras	Nordeste	14
Placas	Norte	16
Arara	Nordeste	19

Fonte: exclusao_rural_conferencia.csv, recorte urbano elegível. Um erro de renda num desses setores passa despercebido pela regra, e é uma limitação a declarar.

2.4 Etapa 4: os três testes de coerência

Passado o corte, o setor é extremo. A pergunta seguinte é se o resto do perfil dele sustenta a renda declarada. O que levanta suspeita não é o valor em si, e sim a **incoerência** entre a renda e o restante do setor. São três testes, e cada um compara o setor com o próprio município:

Teste	Condição exata	Limiar
e_favela	CD_TIPO = 1, ou seja, Favela e Comunidade Urbana	não é limiar, é categoria
pct_analfab_acima	analfabetismo do setor acima do do município	mediana (p50) local
pct_raca_pretpardind_acima	proporção preta, parda ou indígena acima da do município	terceiro quartil (p75) local

Os dois limiares são diferentes, e a apresentação diz apenas 'acima da mediana do município' para os dois. O de cor/raça é o p75, não a mediana.

Basta **um** dos três disparar para o setor ser considerado incoerente. Daí a classificação: extremo e incoerente é SUSPEITO; extremo e coerente é EXTREMO; o resto é NORMAL. Setor sem renda informada não é outlier de renda e fica em NORMAL.

O que a regra não faz

Ela rotula, não remove. Nenhuma observação é excluída da base pelo módulo, e as duas versões da análise, com e sem os suspeitos, ficam publicadas lado a lado. A decisão de excluir é de quem analisa, e é justamente para sustentá-la que as duas versões existem.

3 O resultado: as três classes

Classe	Setores	% da base	Renda mediana	Renda média	Renda máxima
SUSPEITO	66	0,063%	R\$ 10.167,85	R\$ 18.332,37	R\$ 170.418,06
EXTREMO	3.292	3,162%	R\$ 14.106,20	R\$ 15.716,64	R\$ 140.172,64
NORMAL	100.750	96,775%	R\$ 2.505,16	R\$ 3.801,38	R\$ 23.854,81

Fonte: renda_classes_resumo.csv. Recorte urbano elegível, 104.108 setores.


Um detalhe da tabela que vale explicitar, porque é fácil ler ao contrário: a renda mediana dos SUSPEITOS, R\$ 10.167,85, é **menor** que a dos EXTREMOS, R\$ 14.106,20. Isso é coerente com o desenho: o critério não seleciona os valores mais altos, seleciona os valores altos **no lugar errado**.

4 O que cada teste efetivamente pegou

Esta é a abertura que o deck não traz. Dos 66 suspeitos, a coluna motivos registra quais testes dispararam em cada um. A distribuição é bastante desigual.

Combinação de testes que disparou	Setores
pct_analfab_acima	40
e_favela	11
e_favela + pct_analfab_acima + pct_raca_pretpardind_acima	6
e_favela + pct_analfab_acima	5
pct_raca_pretpardind_acima	3
pct_analfab_acima + pct_raca_pretpardind_acima	1

Fonte: renda_outliers_rastreados.csv, coluna motivos.



À esquerda, quantos suspeitos cada teste marcou, contando também os setores em que mais de um disparou. À direita, o coeficiente de variação da renda nas duas classes.

Três leituras. Primeira: **54 dos 66 suspeitos dispararam um único teste**, e apenas 6 dispararam os três. A suspeita, na maioria dos casos, se apoia num sinal só.

Segunda: esse sinal único costuma ser o mais fraco dos três. 40 setores são flagrados apenas por ter analfabetismo acima da mediana do município, e estar acima da mediana é, por construção, um evento de cerca de metade dos setores. Esses casos merecem inspeção individual antes de qualquer exclusão, não tratamento de bloco.

Terceira: 22 dos 66 são favela, o que corresponde aos 33% citados na apresentação. Como e_favela é um dos testes, nenhum setor de favela pode cair em EXTREMO. A frase 'nenhum dos extremos coerentes é favela' repete a regra, não a confirma, e por isso não deve ser usada como evidência a favor do critério.

4.1 Os maiores suspeitos

Setor	Município	Bairro	Renda	Mediana mun.	Razão	Dom.	CV	Testes
310620005650366	Belo Horizonte	Senhor dos Passos	170.418	3.060	55,7×	186	5,26	favela + analfab + PPI
150140255000432	Belém	Guamá	78.444	1.803	43,5×	87	8,66	favela + analfab
354520905000248	Salto	—	60.597	3.040	19,9×	183	7,90	analfab
330455705330089	Rio de Janeiro	Rocinha	42.148	2.702	15,6×	109	8,90	favela + analfab + PPI
355030881000403	São Paulo	—	40.275	3.109	13,0×	53	6,88	analfab
292740805220740	Salvador	Beiru / Tancredo Neves	36.672	1.638	22,4×	218	13,49	favela
355030806000114	São Paulo	—	32.867	3.109	10,6×	100	3,08	analfab
330455705290362	Rio de Janeiro	Barra da Tijuca	29.941	2.702	11,1×	91	0,54	analfab

Renda e mediana municipal em reais. Razão = renda do setor ÷ mediana do município. CV = $\sqrt{V06005 \div V06004}$.

5 Os dois diagnósticos que ficam fora da classificação

O módulo calcula mais duas colunas que **não** entram na classificação. Isso é deliberado: a regra de três classes já foi apresentada, e mudá-la por conta própria alteraria números já vistos. As colunas existem para mostrar onde a regra não enxerga.

5.1 cv_renda: a média depende de quantas declarações?

O arquivo do IBGE traz V06005, a variância do rendimento no setor, e com ela dá para calcular o coeficiente de variação, $\sqrt{V06005 \div V06004}$. Ele mede o quanto a média do setor depende de poucas declarações. A mediana nacional é 0,78, o p99 é 2,53 e o p99,9 é 8,12.

Entre os suspeitos a mediana do CV é 1,48, contra 0,82 entre os extremos coerentes: quase o dobro. É a evidência independente de que os dois grupos não são a mesma coisa, e ela não vem do critério, vem de uma variável que o critério não usa.

Por que isto derruba a hipótese da vírgula fora do lugar

A leitura de que o valor de Belo Horizonte seria R\$ 1.704,18, ou seja, 170.418,06 dividido por 100, é testável com essa variável. Se apenas a média tivesse deslizado uma casa decimal, o coeficiente de variação do setor seria da ordem de 526. Ele é 5,26. A variância publicada pelo IBGE é coerente com a média alta, o que significa que o dado não indica erro de digitação: indica um setor com uma ou poucas declarações enormes puxando a média. A consequência é diferente e mais incômoda, porque não se corrige dividindo por 100 nem se resolve excluindo 66 setores. Argumenta-se por estatística robusta, posto ou logaritmo, para a variável inteira.

5.2 razao_implausivel: o ponto cego da regra

O teste de coerência não enxerga erro de dado em bairro rico, porque ali o entorno sustenta a renda alta e o setor sai como EXTREMO. A coluna `razao_implausivel` é o contrapeso: marca o setor cuja renda supera **20 vezes a mediana do município**, independentemente do perfil do entorno. Ela marca 13 setores classificados como EXTREMO e 3 já classificados como SUSPEITO.

Os 13 da tabela abaixo são os casos que a regra atual não pega. O primeiro deles é o segundo maior valor de renda de toda a base.

Setor	Município	Bairro	Renda	Mediana mun.	Razão	Dom.	CV
355030832000202	São Paulo	—	140.173	3.109	45,1×	78	6,85
261160605200257	Recife	Vasco da Gama	67.237	1.779	37,8×	190	10,77
292740805090354	Salvador	Patamares	61.671	1.638	37,7×	397	4,69
351880005000793	Guarulhos	São João	65.032	2.362	27,5×	148	11,41
130260305110044	Manaus	Aleixo	50.803	1.853	27,4×	159	1,69
355030868000461	São Paulo	—	77.469	3.109	24,9×	73	7,76
355030883000206	São Paulo	—	73.199	3.109	23,5×	85	7,43
292740805270142	Salvador	Barra	37.428	1.638	22,9×	132	8,72

Setor	Município	Bairro	Renda	Mediana mun.	Razão	Dom.	CV
292740805070406	Salvador	Horto Florestal	36.766	1.638	22,4×	92	0,63
130260305130065	Manaus	Ponta Negra	40.720	1.853	22,0×	81	0,88
261160605230448	Recife	Cohab	39.151	1.779	22,0×	211	11,23
211130005001268	São Luís	—	37.914	1.745	21,7×	215	4,19
330455705110034	Rio de Janeiro	Lagoa	54.926	2.702	20,3×	148	7,55

Fonte: renda_outliers_rastreados.csv, filtrando classe EXTREMO com razao_implausivel verdadeiro. Promover esta coluna a critério é decisão de método, e por isso não foi feita sem sua arbitragem.

6 Por que o corte é municipal, em números

A escolha entre corte global e corte municipal não é detalhe: os dois selecionam conjuntos bastante diferentes. O critério global marca 3.988 setores, o municipal marca 3.358, e apenas **1.673** estão nos dois. São 2.315 marcados só pelo global e 1.685 só pelo municipal.

Região	Setores	Global	% global	Municipal	% municipal	Coincidem
Norte	5.915	78	1,32%	438	7,40%	78
Nordeste	19.497	318	1,63%	1.239	6,35%	318
Centro-Oeste	9.490	550	5,80%	227	2,39%	154
Sudeste	61.989	2.860	4,61%	1.377	2,22%	1.062
Sul	7.217	182	2,52%	77	1,07%	61

Fonte: renda_critério_global_vs_municipal.csv.

A inversão entre Norte e Sudeste é o argumento inteiro. O critério global marca 4,61% dos setores do Sudeste e só 1,32% dos do Norte, porque responde à pergunta 'este setor é rico para o Brasil?'. O critério municipal inverte, com 7,40% no Norte e 2,22% no Sudeste, porque responde a 'este setor destoa da própria cidade?'. Para um índice intraurbano, a segunda pergunta é a certa, e a primeira encontraria anomalia onde há apenas riqueza.

7 A relação com o tamanho do setor

A hipótese de que os valores exorbitantes se concentram em setores pequenos se confirma pela metade, e a distinção importa. O valor em si não depende do tamanho: o Spearman entre número de domicílios e renda é -0,031, e o maior valor da base está num setor de 186 domicílios, que é o tamanho mediano. Já a taxa de suspeita depende, e bastante.

Faixa de domicílios	Setores	% da base	Renda mediana	Renda máxima	CV	Suspeitos	% suspeitos
1 a 50	4.531	4,35%	2.028	59.643	1,109	12	0,265%
51 a 100	11.121	10,68%	2.489	140.173	1,128	13	0,117%
101 a 200	47.197	45,33%	2.761	170.418	0,974	23	0,049%
201 a 400	39.966	38,39%	2.478	61.671	0,913	18	0,045%
mais de 400	1.293	1,24%	2.386	25.898	0,899	0	0,000%

Fonte: renda_setores_pequenos.csv. CV é o coeficiente de variação da renda dentro da faixa, não o CV do setor.

A taxa de suspeita cai de 0,265% nos setores de até 50 domicílios para 0,045% nos de 201 a 400, seis vezes menos, e o coeficiente de variação acompanha, de 1,109 para 0,913. O mecanismo é o esperado: média de poucos domicílios oscila mais. Ele existe, está medido, e não é o que produz o maior valor da base.

8 As quatro limitações do critério, nomeadas

Limitação	O que ela significa
A separação favela / não favela é definição	e_favela é um dos testes, então todo setor de favela que seja outlier municipal cai obrigatoriamente em SUSPEITO e nenhum pode cair em EXTREMO. A coluna 'São favela?' da apresentação repete a regra; ela não a valida.
O sinal do analfabetismo é fraco	Estar acima da mediana do município é evento de cerca de 50% por construção, e 40 dos 66 suspeitos são flagrados só por ele. São os casos que mais precisam de inspeção individual.

Limitação	O que ela significa
Erro em bairro rico é invisível	A regra detecta incoerência de contexto, não implausibilidade de magnitude. Os 13 setores da seção 5.2 saem como EXTREMO porque o entorno sustenta renda alta, e só <code>razao_implausivel</code> os denuncia.
Municípios pequenos ficam fora	12 municípios e 118 setores não são avaliados, porque abaixo de 20 setores o quartil do município não é confiável. Um erro de renda nesses setores não é detectado.

9 O que eu recomendo, e o que depende da senhora

Minha recomendação continua sendo que os 66 suspeitos saiam do cálculo do índice e fiquem na EDA como achado de qualidade do dado, com as duas versões publicadas. O argumento não é o efeito na média nem na correlação, que é pequeno, e sim o efeito na normalização min-max por município, que é o insumo do índice: em Autazes um único valor ruim comprime 81,4% dos setores no primeiro decil da escala, e sem ele são 14,3%. Dos 63 municípios avaliados nessa tabela, 23 têm ao menos um suspeito.

Três decisões seguem em aberto e são de método, não de execução:

#	Decisão	Minha leitura
1	Promover <code>razao_implausivel</code> a critério, em vez de deixá-la como diagnóstico	Pegaria os 13 casos da seção 5.2, que hoje escapam. Muda números já apresentados, então não fiz sem sua palavra.
2	Inspecionar individualmente os 40 suspeitos de sinal único	É trabalho manual e finito. Reduziria a chance de excluir setor legítimo por um teste que dispara em metade da base por construção.
3	Transformar a variável, em log ou em posto, em vez de tratar caso a caso	Mesmo removendo os 66, Belo Horizonte fica com 70,8% dos setores no primeiro decil. O que quebra a escala é a assimetria de 3,74, não os 66 valores.

Onde está cada coisa

A regra: `src/ivs_censo/renda.py`. A execução e as tabelas: `scripts/auditoria_renda.py`. Os 3.358 setores extremos, um por linha e com identificação completa: `banco_de_dados/eda/renda_outliers_rastreados.csv`. Este PDF é gerado por `scripts/gerar_pdf_outliers_renda.py`, que recalcula todos os números a partir dos CSVs e importa as constantes do módulo.