

# Guia de apoio

## Os slides da análise fatorial, explicados do zero

Índice de Vulnerabilidade à Saúde (IVS) intraurbano · Censo Demográfico 2022 · 70 municípios do ELSI-Brasil

Iniciação Científica · Fiocruz Minas — Instituto René Rachou · Pedro Dias Soares · setembro de 2026

### PARA QUE SERVE ESTE DOCUMENTO

O deck da análise fatorial foi escrito para quem já sabe o que é uma carga fatorial. Este guia supõe o contrário: que você nunca viu análise fatorial e não acompanhou o projeto. Ele cobre um a um os slides marcados com **EXPLICAR SLIDE**, mais a Parte 8 inteira.

Cada verbete tem sempre quatro partes, na mesma ordem: **o que está no slide** · **o conceito, do zero** · **como ler os números** · **o que dizer se perguntarem**. Se o tempo for curto, leia só a última — ela está em caixa, no fim de cada verbete, e é uma resposta pronta.

### A ÚNICA COISA QUE VOCÊ PRECISA SABER ANTES DE ABRIR O DECK

O projeto mede a vulnerabilidade de um setor censitário com **sete indicadores**: água inadequada, esgoto inadequado, lixo inadequado, razão de moradores por domicílio, analfabetismo, renda e proporção de pessoas pretas, pardas ou indígenas. Para virar um índice único, cada um precisa de um **peso**. A pergunta do Notebook 04 é uma só: **quanto cada indicador deve pesar, e por quê?** Tudo no deck existe para responder isso.

## Parte 0 — O vocabulário, em uma página

Seis palavras aparecem o tempo todo no deck. Se estas seis estiverem claras, o resto se lê sozinho. Nenhuma delas exige matemática para ser entendida.

### 1. VARIÁVEL LATENTE (ou CONSTRUTO)

Algo que existe mas não se mede diretamente. Ninguém tem um aparelho que meça "vulnerabilidade" de um bairro. O que se mede são **sintomas**: falta de esgoto, renda baixa, analfabetismo. A vulnerabilidade é a coisa por trás deles. Inteligência é o exemplo clássico: não se mede inteligência, medem-se respostas a questões, e se supõe que a inteligência as produz.

### 2. FATOR

É o nome que a técnica dá à variável latente quando ela é estimada a partir dos dados. Se sete indicadores variam juntos de um jeito organizado, a análise fatorial diz: **existem duas coisas por trás deles** — e chama essas duas coisas de Fator 1 e Fator 2. Quem dá nome aos fatores é o pesquisador, olhando quais indicadores andam com qual. Neste projeto, o Fator 1 ficou sendo a **dimensão socioeconômica** e o Fator 2, o **saneamento**.

### 3. CARGA FATORIAL

**É o número mais importante do deck inteiro.** A carga mede o quanto um indicador pertence a um fator, numa escala de -1 a 1. Carga alta significa que aquele indicador é uma boa manifestação daquele fator; carga perto de zero significa que ele não tem nada a ver com aquele fator. No projeto, a renda tem carga 0,915 no Fator 1 — é quase uma tradução direta da dimensão socioeconômica — e apenas 0,137 no Fator 2.

### 4. COMUNALIDADE

Quanto da variação de um indicador os fatores conseguem explicar. Também vai de 0 a 1. Comunalidade alta quer dizer "este indicador está bem representado pela estrutura"; comunalidade baixa quer dizer "este indicador tem vida própria, os fatores não dão conta dele". É por comunalidade que se descobre que um indicador não pertence ao conjunto.

### 5. ROTAÇÃO

Uma etapa que **não muda a qualidade da solução, só a torna legível**. A primeira solução que o computador devolve costuma ter todos os indicadores carregando um pouco em todos os fatores, o que não se interpreta. A rotação gira os eixos até que cada indicador carregue alto em **um** fator e baixo nos outros. É como girar um mapa até o norte ficar para cima: a cidade não mudou de lugar, ficou mais fácil de ler.

### 6. ESCORE FATORIAL

Depois de saber quanto cada indicador pesa, aplica-se isso a cada setor censitário e sai um número por setor — o escore. É o que vira o índice. O deck mostra duas maneiras de calculá-lo, e compara as duas.

#### E A PALAVRA QUE VOCÊ VAI OUVIR MAIS: "ADEQUABILIDADE"

Antes de rodar a análise, há testes que dizem se ela **faz sentido naqueles dados**. Se os sete indicadores não tiverem nada a ver uns com os outros, não existe fator comum para encontrar, e a técnica devolveria um resultado sem significado. Os dois testes que aparecem no deck são o **KMO** (quanto maior, melhor; acima de 0,70 é bom) e o **teste de Bartlett**. No projeto o KMO deu 0,783, então a base passa.

## Parte 1 — Os slides que você marcou

Na ordem do deck. Cada um é independente: dá para ler só o que for perguntado.

### Slide 15 · Divergência 2 — a técnica de extração

#### O QUE ESTÁ NO SLIDE

Uma tabela com duas colunas de números quase iguais, chamadas **ACP** e **eixo principal**, e uma terceira coluna com a diferença entre elas.

#### O CONCEITO, DO ZERO

Existem duas maneiras de extrair fatores, e a diferença entre elas cabe numa frase: **o que cada uma faz com a parte da variação que é só daquele indicador.**

Imagine que a variação de cada indicador tem duas partes: a que ele *compartilha* com os outros seis, e a que é *só dele*. A **ACP** (análise de componentes principais) usa tudo — compartilhado e próprio. A **análise fatorial propriamente dita**, aqui chamada de eixo principal, usa só a parte compartilhada, porque é essa que revela a coisa comum por trás.

Na maior parte dos casos as duas dão quase o mesmo resultado, e o projeto vinha supondo isso. O livro da Enap traz uma advertência de Stevens (1992) que desfaz a suposição: com **menos de 20 variáveis** e comunalidades baixas, elas podem divergir. O projeto tem 6 variáveis. Por isso o teste virou obrigatório.

#### COMO LER OS NÚMEROS

A coluna da diferença é o que importa. Ela é **grande onde o indicador compartilha pouco com os outros** — a água (0,241) e a razão de moradores — e **pequena onde compartilha muito**: a renda difere só 0,019. Isso é exatamente o que Stevens previu, e é sinal de que a implementação está certa, não de que há problema.

#### SE A ORIENTADORA PERGUNTAR

“Existem duas técnicas parecidas, e a literatura diz que elas só divergem quando há poucas variáveis. Nós temos seis, então testamos em vez de supor. Divergem, sim — e divergem justamente nas variáveis que menos se relacionam com as outras, que é onde a teoria manda esperar. Reportamos as duas soluções.”

### Slide 16 · Divergência 3 — a regra de comunalidade

#### O QUE ESTÁ NO SLIDE

Uma citação do livro em destaque, e dois números soltos sobre a variável **razão de moradores**.

#### O CONCEITO, DO ZERO

Muitos manuais ensinam uma regra simples: **se a comunalidade de um indicador for menor que 0,50, exclua-o**. A ideia é que os fatores não estão dando conta daquele indicador, então ele não pertence ao conjunto.

O problema é aplicar a regra sozinha, como se fosse automática. O livro da Enap diz explicitamente, na página 58, que esse critério “não deve ser utilizado isoladamente e de maneira muito rígida” — e no próprio exemplo dele mantém um item abaixo do corte, porque a carga fatorial dele era alta.

É o caso da razão de moradores neste projeto, e por isso o slide existe: ela ficaria de fora por uma regra mecânica, e fica dentro por uma razão declarada.

#### COMO LER OS NÚMEROS

Comunalidade 0,380 — abaixo do corte de 0,50. Carga 0,532 no fator socioeconômico — bem acima do limite de 0,40 que torna uma variável relevante. Os dois números vão reportados juntos, sempre: é a condição para manter a variável de forma honesta.

### SE A ORIENTADORA PERGUNTAR

“A regra do 0,50 existe, e nós a conhecemos. O livro que adotamos como referência diz que ela não deve ser aplicada isoladamente, e mantém um item abaixo do corte no próprio exemplo. Mantivemos a razão de moradores pelo mesmo motivo: a carga dela é alta. E reportamos os dois números lado a lado, para ninguém precisar descobrir sozinho.”

## Slide 17 · As cargas, nas duas rotações

### O QUE ESTÁ NO SLIDE

Duas grades de números coloridos, lado a lado, chamadas **Varimax** e **promax**. Seis linhas (as variáveis) e duas colunas (os fatores) em cada.

### O CONCEITO, DO ZERO

Este é o resultado central da análise: **quanto cada variável pertence a cada fator**. Tom quente é carga positiva, tom frio é negativa, cinza é perto de zero — e o valor vai impresso em cada célula, para a leitura não depender de enxergar cor.

As duas grades são a mesma solução vista de dois jeitos. **Varimax** supõe que os dois fatores são independentes um do outro. **Promax** permite que eles sejam correlacionados. O livro recomenda a segunda em Ciências Humanas, porque nessa área quase nada é independente de verdade — e de fato, aqui, os dois fatores se correlacionam a 0,521.

### COMO LER OS NÚMEROS

Leia por coluna. No Fator 1 as cargas altas são renda, analfabetismo e cor/raça — é o bloco socioeconômico. No Fator 2 são água e esgoto — é o saneamento. Nenhuma variável tem carga acima de 0,40 nas duas colunas ao mesmo tempo, e isso tem nome: **estrutura simples**. É o sinal de que a solução é interpretável.

### SE A ORIENTADORA PERGUNTAR

“Esta é a estrutura que os dados devolveram: um bloco socioeconômico e um bloco de saneamento, que é exatamente a divisão que o IVS-BH 2012 já usava. Mostramos as duas rotações porque a literatura recomenda a oblíqua, e queríamos ver se a conclusão mudava. Não muda.”

## Slide 20 · Os pesos do IVS

### O QUE ESTÁ NO SLIDE

A tabela final: cada variável com o seu peso em porcentagem, somando 100%.

### O CONCEITO, DO ZERO

Aqui está o produto do trabalho. A conta que transforma carga em peso tem dois passos, e os dois são simples.

**Primeiro, quanto cada dimensão pesa.** Soma-se o quadrado das cargas de cada fator. Quanto mais as variáveis carregam num fator, mais aquele fator explica, e mais ele pesa. Deu **65,0% para a socioeconômica** e **35,0% para o saneamento**.

**Segundo, quanto cada variável pesa dentro da sua dimensão.** Mesma lógica: proporcional ao quadrado da carga. Uma variável que representa bem a dimensão pesa mais que uma que a representa mal.

Por que não dar peso igual a todas? Porque renda, cor/raça e analfabetismo medem, em boa parte, **a mesma coisa** — eles se correlacionam entre 0,63 e 0,78. Peso igual daria três votos à posição social e um só ao saneamento, sem que ninguém tivesse decidido isso.

| Variável           | Dimensão       | Carga | Peso   |
|--------------------|----------------|-------|--------|
| Água inadequada    | Saneamento     | 0,903 | 22,32% |
| Renda (invertida)  | Socioeconômica | 0,915 | 21,21% |
| Analfabetismo 15+  | Socioeconômica | 0,868 | 19,09% |
| Cor/raça PPI       | Socioeconômica | 0,833 | 17,57% |
| Esgoto inadequado  | Saneamento     | 0,679 | 12,64% |
| Razão de moradores | Socioeconômica | 0,532 | 7,17%  |

## COMO LER OS NÚMEROS

A referência da literatura — o IVS de Belo Horizonte de 2012 — usa **60% e 40%**. Nós chegamos a 65,0 e 35,0 **sem olhar para ela**, só a partir dos dados. Cinco pontos de diferença entre um peso empírico e um peso da literatura é convergência, não conflito — e é o argumento mais forte do slide.

### SE A ORIENTADORA PERGUNTAR

“Os pesos saem da estrutura que os próprios dados mostraram, não de escolha nossa. E o resultado bate com o IVS-BH 2012 dentro de cinco pontos percentuais, o que é uma validação: duas rotas independentes chegaram quase ao mesmo lugar.”

## Slide 21 · Os pesos são estáveis

### O QUE ESTÁ NO SLIDE

Uma tabela com um intervalo ao lado de cada carga, e um número em destaque: o intervalo da repartição entre as dimensões.

### O CONCEITO, DO ZERO

O livro faz uma crítica dura ao tipo de índice que o projeto planeja: diz que ele é “muito instável por depender fortemente da amostra em particular que está sendo analisada”. Traduzindo: **se você tivesse sorteado outros setores, será que os pesos seriam outros?**

A resposta honesta a essa crítica não é discordar — é medir. A técnica usada chama-se **bootstrap**, e a ideia é quase artesanal: sorteia-se, com reposição, um novo conjunto de setores do mesmo tamanho, refaz-se a análise inteira, e anota-se o resultado. Mil vezes. No fim, vê-se o quanto os pesos balançaram.

## COMO LER OS NÚMEROS

A repartição entre as dimensões ficou entre **64,7% e 65,3%** nas mil repetições — uma amplitude de **0,59 ponto percentual**. Na prática, os pesos não se movem. Com 87 mil setores, a incerteza de amostragem é desprezível; o que limita esta análise não é a quantidade de setores, é a quantidade de variáveis.

### SE A ORIENTADORA PERGUNTAR

“Essa crítica é do próprio livro que adotamos, e nós a levamos a sério: medimos. Mil reamostragens movem os pesos em menos de meio ponto percentual. A instabilidade que a literatura teme não apareceu nesta amostra.”

## Slide 22 · O índice e o escore refinado concordam menos que o previsto

### O QUE ESTÁ NO SLIDE

Três números grandes — 0,924, 0,945 e 0,950 — e dois blocos de texto explicando por que os dois primeiros ficaram abaixo do terceiro.

### O CONCEITO, DO ZERO

Há duas maneiras de transformar os pesos num número por setor.

A **primeira** é a que o projeto planeja usar: põe cada variável numa escala de 0 a 1, multiplica pelo peso, soma. Simples, interpretável, e é o que o IVS-BH faz. O livro chama esse método de “**não refinado**”.

A **segunda** é o método da regressão, que o livro chama de refinado. Ele é mais estável estatisticamente, mas devolve um número abstrato, sem escala natural, e exige a matriz completa para ser reproduzido por outra pessoa.

O plano era calcular os dois e usar a **concordância entre eles** como validação: se ordenassem os setores do mesmo jeito, o método simples estaria justificado. O corte combinado era 0,95.

### COMO LER OS NÚMEROS

Deu **0,924** e **0,945**, conforme a variante. Os dois abaixo do corte — e é aqui que o slide fica interessante. A causa não é instabilidade: é que o índice 0–1 trabalha com os **valores** das variáveis e o modelo fatorial foi estimado sobre os **postos** delas (a posição de cada setor na fila, não o valor). São duas escalas diferentes. Quanto mais coerente o escore fica com o modelo, mais ele se afasta do índice planejado.

#### SE A ORIENTADORA PERGUNTAR

“Essa é a questão técnica mais aberta que saiu do Notebook 04. Os dois métodos concordam em 92%, o que é alto mas ficou abaixo do que combinamos como validação. Sabemos exatamente por quê — é uma diferença de escala, não de qualidade — e há três saídas possíveis. Qual adotar é decisão que trazemos para a senhora.”

## Slide 24 · Contra os setores de favela

### O QUE ESTÁ NO SLIDE

Uma curva subindo da esquerda para a direita, uma diagonal tracejada, e um número grande: **AUC 0,813**.

### O CONCEITO, DO ZERO

Todos os testes anteriores dizem se as variáveis se **organizam** bem. Nenhum deles diz se o índice **acerta**. Para isso é preciso comparar o índice com algo que já se saiba ser verdade, e que não tenha sido usado para construí-lo.

O projeto tem esse marcador: o IBGE classifica oficialmente quais setores são **Favela e Comunidade Urbana**. Nenhuma das seis variáveis do índice foi usada nessa classificação — ela é totalmente externa.

A **curva ROC** responde: se eu ordenar todos os setores pelo índice, os setores de favela aparecem no topo? A área embaixo dessa curva, a **AUC**, resume isso num número entre 0,5 e 1. **0,5 é o acaso** — equivale a sortear. **1 é a separação perfeita**. Uma leitura direta: a AUC é a probabilidade de que, sorteando um setor de favela e um setor comum, o de favela tenha índice maior.

### COMO LER OS NÚMEROS

O índice deu **0,813** e o escore refinado, **0,862**. O corte que o plano fixou como “separação nítida” era 0,75, e o patamar abaixo do qual haveria problema de validade era 0,65. Os dois passam com folga. Em palavras: sorteando um setor de favela e um setor comum, o de favela tem índice maior em 81,3% das vezes.

#### SE A ORIENTADORA PERGUNTAR

“Este é o teste mais forte que temos, porque o marcador é externo: a lista de favelas é do IBGE e nenhuma variável do índice entrou nela. A área sob a curva é 0,813 — bem acima do 0,75 que fixamos como critério. O índice separa os territórios que sabidamente são vulneráveis.”

## Slide 25 · O custo de cada escolha, em setores

### O QUE ESTÁ NO SLIDE

Uma tabela com três cenários e, em cada um, quantos setores mudam de faixa de risco.

### O CONCEITO, DO ZERO

Várias decisões do projeto ainda estão em aberto, e todas têm defensores dos dois lados. A pergunta que este slide responde é diferente de “qual está certa”: é “**quanto custa errar**”.

A métrica foi escolhida de propósito. Não é variância explicada nem nenhuma estatística interna — é **quantos setores mudam de faixa de risco**. Um índice serve para classificar território e orientar política pública; o que importa é se a escolha metodológica muda a classificação de quem vai receber essa política.

Os setores são divididos em quatro faixas por quartis: o quarto menos vulnerável, o seguinte, e assim por diante. Cada cenário recalcula o índice de outro jeito e conta quantos setores trocaram de faixa.

### COMO LER OS NÚMEROS

**Pesos 60/40 em vez de 65/35:** mudam 2.196 setores, 2,5% — o menor custo dos três. **Sem o analfabetismo:** 6.587 setores, 7,5%. **Um fator em vez de dois:** 7.668 setores, 8,8%.

#### SE A ORIENTADORA PERGUNTAR

“O objetivo deste bloco não é escolher — é mostrar o preço de cada opção. A decisão sobre os pesos, que parecia a mais dramática, move só 2,5% dos setores de faixa. Isso a torna a menos crítica das três, e é um resultado publicável por si só.”

## Slide 27 · A renda sem o extremo não muda nada

### O QUE ESTÁ NO SLIDE

Uma tabela com duas colunas quase idênticas e três números em destaque, entre eles um **0,0000**.

### O CONCEITO, DO ZERO

Em uma rodada anterior da análise exploratória descobriu-se um setor de Belo Horizonte com renda média absurdamente alta — provável erro de dado. Toda a análise exploratória foi refeita sem ele, criando uma segunda coluna de renda.

A análise fatorial é **anterior** a essa correção: ela usa a coluna original. Ficou a dúvida: será que a fatorial inteira precisa ser refeita?

Este slide responde. Um setor em 87 mil não deveria mudar nada — mas a renda é a variável de maior carga do índice, e o valor extremo era grande o bastante para ter motivado uma rodada inteira da EDA. Era barato medir em vez de supor.

### COMO LER OS NÚMEROS

A maior diferença entre as cargas é **0,0000**: elas batem até a quarta casa decimal. O KMO muda na quinta casa. E apenas **278 setores** de 87.544 mudam de faixa — 0,32% —, com correlação de 0,999976 entre os dois índices.

#### SE A ORIENTADORA PERGUNTAR

“Verificamos: trocar a coluna de renda não muda a estrutura, não muda os pesos e praticamente não muda a classificação. As cargas batem até a quarta casa decimal. A pendência está fechada — podemos manter como está ou migrar, sem custo.”

## Slide 42 · As seis decisões — o porquê de cada uma

Você marcou este slide pedindo **o porquê de cada decisão**. Elas estão abaixo na ordem do slide, cada uma com o que está em jogo, o argumento de cada lado e o que a evidência do projeto diz. **Nenhuma foi fechada** — o papel do Notebook 04 foi produzir o custo de cada opção, não escolher.

### 1 · Pesos empíricos ou os 60/40 da literatura?

**O que está em jogo:** usar os pesos que os dados devolveram (65,0/35,0) ou os que o IVS-BH 2012 usa (60/40).

**A favor dos empíricos:** o livro (p. 71) diz que os itens contribuem de maneira desigual e que a carga mede essa contribuição — peso igual seria uma escolha disfarçada de neutralidade.

**A favor dos 60/40:** comparabilidade direta com o IVS-BH 2012, que é a metodologia-fonte do projeto.

**O que a evidência diz:** os dois convergem, e trocar um pelo outro move 2,5% dos setores de faixa. É a decisão de menor custo das seis.

### 2 · O indicador de lixo entra no índice?

**O que está em jogo:** o lixo é um dos sete indicadores originais, herdado da metodologia do IVS-BH 2012.

**A favor de tirar:** ele não acompanha nenhum dos outros seis. Pelo método da análise fatorial propriamente dita, a comunalidade dele é **0,052** — quase nada da variação dele é compartilhada com o construto. Sem ele, a variância explicada sobe de 62,1% para 70,0% **com menos variáveis**, e a água recupera a representação que havia perdido.

**A favor de manter:** fidelidade literal ao *Cálculo IVS2012*, que o projeto adotou como fonte.

**Cuidado:** esta decisão **se inverte** se o IVS for entendido como índice formativo em vez de construto reflexivo — é o assunto dos slides 28 e 29.

### 3 · O que fazer com o sigilo no analfabetismo?

**O que está em jogo:** o IBGE oculta o dado de analfabetismo em setores pequenos, para proteger a identidade dos moradores. Exigir a variável custa **16.563 setores**, que ficam sem índice.

**A favor de manter a variável:** ela é um dos três pilares do bloco socioeconômico, com carga alta.

**A favor de retirá-la:** recupera os 16.563 setores.

**O que a evidência diz:** retirá-la move 7,5% dos setores de faixa. E há um problema declarado: o sigilo **não é aleatório**, incide sobre os setores de melhor situação — então a base analisada é enviesada para os mais vulneráveis.

### 4 · Um fator ou dois?

**O que está em jogo:** o índice tem uma dimensão ou duas.

**A favor de um:** é o que os critérios estatísticos indicam. Na solução sem o lixo, tanto o critério de Kaiser quanto a análise paralela de Horn retêm um só fator. E com um fator a discussão de rotação desaparece inteira.

**A favor de dois:** a teoria. O IVS-BH 2012 define duas dimensões, e a leitura por dimensões é o que permite dizer “este setor é vulnerável por saneamento” em vez de só “é vulnerável”.

**O que a evidência diz:** a troca move 8,8% dos setores — o maior custo das três. É a decisão mais delicada, porque estatística e teoria apontam para lados opostos.

### 5 · Rotação ortogonal ou oblíqua?

**O que está em jogo:** supor que as duas dimensões são independentes (ortogonal) ou aceitar que se correlacionam (oblíqua).

**A favor da oblíqua:** é o que o livro recomenda (p. 38), e com ela se obtém a correlação entre os fatores — uma evidência que a solução ortogonal não pode produzir. Aqui deu 0,521, positiva e moderada, que é o que a teoria da vulnerabilidade prevê.

**A favor da ortogonal:** é mais simples de reportar e é o que a literatura do IVS usa.

**O que a evidência diz:** a escolha muda os pesos em 0,8 ponto percentual. Praticamente indiferente para o resultado.

### 6 · O índice oficial será o 0–1 ou o escore refinado?

**O que está em jogo:** qual dos dois números vai para os mapas e para o artigo.

**A favor do 0–1:** interpretável, comparável com o IVS-BH, e reproduzível por terceiros com uma tabela de seis pesos.

**A favor do refinado:** é o que o livro recomenda, é mais estável, e separa melhor os setores de favela (0,862 contra 0,813).

**O que a evidência diz:** a concordância entre os dois ficou em 0,924, abaixo do 0,95 que validaria o primeiro sem ressalva — é o assunto do slide 22.

#### SE PERGUNTAREM POR QUE NADA FOI DECIDIDO

“Porque não são decisões técnicas — são decisões de projeto, e algumas têm consequência para o que o índice significa. O que o Notebook 04 podia fazer era tirá-las do terreno da opinião: cada uma agora tem o custo medido em quantos setores mudam de faixa. Trago as seis para a senhora com esse número na mão.”

## Slide 43 · O que fica declarado como limitação

### O QUE ESTÁ NO SLIDE

Uma tabela com nove linhas: cada limitação e onde ela afeta o resultado.

### O CONCEITO, DO ZERO

Declarar limitação não é confessar erro — é dizer onde o resultado vale e onde não vale. Um artigo sem seção de limitações costuma ser lido com **mais** desconfiança, não menos. As nove se agrupam em três famílias:

**Limites do método estatístico (1 a 3).** O teste de Bartlett não informa nada numa base de 87 mil setores, porque com amostra grande ele sempre dá significativo; a análise foi feita sobre os postos das variáveis, não sobre os valores; e duas variáveis do bloco socioeconômico são muito correlacionadas entre si.

**Limites dos dados (4, 7 e 8).** O sigilo do IBGE remove setores de forma não aleatória; a padronização usada é provisória, porque a definitiva pertence a uma etapa posterior; e a análise usa a coluna de renda original.

**Limites do desenho (5, 6 e 9).** Setores vizinhos não são independentes, e a técnica supõe que sejam; as conclusões valem para territórios e não para pessoas; e há uma questão conceitual em aberto sobre a natureza do índice.

### COMO LER OS NÚMEROS

Dois merecem ser ditas em voz alta na apresentação. A **falácia ecológica** (linha 6): tudo o que o índice diz é sobre *setores*, nunca sobre pessoas — dizer que “moradores de setores vulneráveis são analfabetos” seria erro grave, e o projeto se protege disso explicitamente. E a **dependência espacial** (linha 5): setores vizinhos se parecem, o que infla a força aparente da estrutura. Não há solução simples; a medida do problema virá com o I de Moran, na etapa de geoprocessamento.

### SE A ORIENTADORA PERGUNTAR

“Essas nove estão declaradas de propósito. Três são limites do método que a própria literatura aponta, três são dos dados e três são do desenho do estudo. A que mais importa para a leitura dos resultados é a falácia ecológica: o índice descreve territórios, e nada do que ele diz se transfere para indivíduos.”

## Parte 2 — A Parte 8 do deck, inteira (slides 30 a 40)

Você marcou a Parte 8 por extenso. Ela tem onze slides e um objetivo só: mostrar que a análise não saiu de uma caixa-preta. Esta parte do guia explica **por que esses slides existem** e o que cada um está dizendo, sem exigir que você leia código.

### ANTES DE TUDO: POR QUE TEM CÓDIGO NUMA APRESENTAÇÃO DE MÉTODO

Porque a análise foi **escrita à mão**, e não chamada de uma biblioteca pronta. Isso é incomum e a pergunta vai aparecer. A Parte 8 é a resposta antecipada: ela mostra que cada conta é conhecida, verificável e escrita em cinco a quinze linhas — e termina mostrando como fazer a mesma análise em R, que é a linguagem da bibliografia da área. Se a orientadora quiser conferir por outro caminho, o caminho está no deck.

### Slide 31 · Por que numpy puro, e não uma biblioteca pronta

**A situação:** existem bibliotecas que fazem análise fatorial com uma linha de comando. O projeto não usou nenhuma — escreveu as contas usando só ferramentas básicas de matemática.

**A razão prática:** o projeto declara cinco pacotes como dependência. Cada pacote a mais é uma coisa a instalar, a versionar e a justificar na dissertação. Tudo que a análise precisa é álgebra linear que as ferramentas básicas já fazem.

**A razão que apareceu depois, e é a melhor:** quem escreve a conta à mão **precisa saber a conta**. Foi escrevendo que ficou claro, por exemplo, por que uma solução com fatores correlacionados produz *duas* tabelas de cargas em vez de uma. Isso não se aprende chamando uma função.

### SE PERGUNTAREM

“Teria sido mais rápido usar uma biblioteca, e o resultado seria o mesmo. O que ganhamos foi poder responder a qualquer pergunta sobre o método sem dizer ‘a biblioteca faz’. Numa iniciação científica isso vale mais do que as horas economizadas. E os slides seguintes mostram a equivalência com o pacote padrão da área, em R.”

### Slide 32 · O caminho, em nove passos

É o mapa da Parte 8. Nove passos, e ao lado de cada um a função que o faz no projeto e a que faria o mesmo em R. **É o slide para mostrar se a pergunta for “você fizeram tudo isso mesmo?”** — a coluna da direita mostra que cada passo corresponde a uma função padrão da área.

Os nove passos são, em português: (1) medir como as variáveis andam juntas; (2 e 3) testar se faz sentido procurar fatores nesses dados; (4) checar se duas variáveis não são quase a mesma coisa; (5) decidir quantos fatores; (6) extrair; (7 e 8) girar os eixos para a solução ficar legível; (9) transformar tudo num número por setor.

### Slides 33 a 36 · As quatro contas, linha a linha

Quatro slides no mesmo formato: o código à esquerda, e à direita o que cada linha faz e **por que ela está ali**. Não é preciso entender o código para conduzir a conversa — o que cada um dos quatro resolve cabe em um parágrafo.

| Slide | A conta  | O que ela resolve, em uma frase                                                                                                                                                                           |
|-------|----------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 33    | KMO      | Compara o quanto duas variáveis andam juntas com o quanto elas continuam andando juntas depois de descontar todas as outras. Se sobra muita relação própria, não há fator comum — e o KMO cai.            |
| 34    | Extração | Encontra, a partir da tabela de correlações, quais são os fatores e quanto cada variável pertence a cada um. Quatro linhas, e a terceira é a que transforma o resultado matemático em algo interpretável. |

| Slide | A conta         | O que ela resolve, em uma frase                                                                                                                                                              |
|-------|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 35    | Rotação Varimax | Gira os eixos até que cada variável carregue alto em um fator só. Não muda a qualidade da solução, muda a legibilidade — como girar um mapa até o norte ficar para cima.                     |
| 36    | Rotação promax  | Faz o mesmo, mas deixando os eixos se inclinarem, o que permite que os fatores sejam correlacionados. É a rotação que o livro recomenda, e a única que produz a correlação entre os fatores. |

#### O DETALHE DO SLIDE 35 QUE VALE GUARDAR

Há um aviso em vermelho no slide da Varimax: o R, por padrão, aplica uma normalização que o código do projeto não aplica. **Rodar a mesma análise nas duas ferramentas sem saber disso dá números levemente diferentes**, e a pessoa conclui que alguém errou. Ninguém errou — é uma opção padrão diferente. Se a orientadora rodar em R e vier com números que não batem na terceira casa decimal, é quase certo que seja isso.

### Slides 37, 38 e 39 · A mesma análise em R

Três slides com o código em R que reproduz a análise inteira, usando o pacote **psych** — que é o padrão da área e é o que a bibliografia usa, inclusive os exemplos do próprio livro da Enap.

**Por que isso está no deck:** por dois motivos. Primeiro, porque mostra que cada passo do projeto corresponde a uma função reconhecida — não se inventou método. Segundo, e mais importante: rodar a mesma análise em duas implementações independentes é, ele próprio, **um teste**. Se as duas concordam, é improvável que ambas estejam erradas do mesmo jeito.

**O que dizer:** que o script está pronto e versionado, e que basta rodar. Vale ser honesto num ponto: **ele ainda não foi executado**. Está documentado, não conferido.

### Slide 40 · O que esperar de diferente entre as duas

Fecha a Parte 8 com cinco pontos em que Python e R divergem por opção padrão, não por erro: a normalização da rotação, o sinal dos fatores, a ordem deles, o modo como a análise paralela sorteia os dados, e a correlação de Spearman (que é idêntica nos dois).

**A regra que o slide estabelece, e é a parte útil dele:** se os números divergirem além desses cinco pontos, o problema é real e vale investigar. Não se atribui divergência à diferença de linguagem sem antes conferir a lista.

#### SE A ORIENTADORA PERGUNTAR POR QUE NÃO FIZERAM EM R DESDE O COMEÇO

“A pipeline inteira do projeto é em Python — extração, tratamento do sigilo, os indicadores, a EDA. Trazer a análise fatorial para R significaria manter duas linguagens e duas versões dos dados. Escrevemos em Python e documentamos o equivalente em R, que fica disponível como conferência independente sempre que a senhora quiser.”

## Parte 3 — Cola de bolso

Uma página só. Os números que sustentam a apresentação inteira, e o que dizer se travar.

### OS NÚMEROS QUE VOCÊ PRECISA TER NA PONTA DA LÍNGUA

| Número      | O que é                            | Se perguntarem, responda                                                                                   |
|-------------|------------------------------------|------------------------------------------------------------------------------------------------------------|
| 65,0 / 35,0 | a repartição dos pesos             | socioeconômica e saneamento; a literatura usa 60/40, e nós chegamos aqui sem olhar para ela                |
| 0,783       | o KMO                              | mede se faz sentido procurar fatores nestes dados; acima de 0,70 é bom                                     |
| 0,813       | a AUC contra as favelas            | sorteando um setor de favela e um comum, o de favela tem índice maior em 81,3% das vezes                   |
| 0,521       | a correlação entre os dois fatores | as duas dimensões andam juntas, o que a teoria previa — e é por isso que a rotação oblíqua é a recomendada |
| 0,59 ponto  | a incerteza dos pesos              | mil reamostragens movem os pesos em menos de meio ponto percentual                                         |
| 2,5%        | o custo de trocar os pesos         | só isso dos setores muda de faixa entre 65/35 e 60/40                                                      |
| 87.545      | os setores analisados              | de 104.108 no recorte urbano; a diferença é o sigilo do IBGE                                               |
| 0,052       | a comunalidade do lixo             | quase nada da variação dele é compartilhada com o resto — por isso a proposta de retirá-lo                 |

### AS TRÊS FRASES QUE RESUMEM O TRABALHO

1. “Os pesos do IVS são 65,0% para a dimensão socioeconômica e 35,0% para saneamento, e eles saem da estrutura que os próprios dados mostraram.”
2. “Esses pesos são estáveis: mil reamostragens os movem em menos de meio ponto percentual.”
3. “E o índice funciona: separa os setores de favela com AUC de 0,813, usando uma classificação oficial do IBGE que não entrou na construção dele.”

#### SE VOCÊ TRAVAR NUMA PERGUNTA TÉCNICA

Três saídas honestas, em ordem de preferência.

1. **“Esse número está no arquivo, posso abrir.”** Tudo o que está no deck sai de uma tabela em `banco_de_dados/eda/fatorial/`. Abrir o arquivo na frente dela é resposta melhor do que arriscar de memória.
2. **“Essa é uma das decisões que trago para a senhora.”** Vale para as seis do slide 42. Não é escapatória — é o que o notebook foi desenhado para fazer.
3. **“Não sei, vou verificar e volto.”** É a melhor resposta quando for verdade. O projeto tem a rastreabilidade para cumprir a promessa: cada número tem um arquivo, e cada arquivo tem o código que o gerou.

### ONDE ESTÁ CADA COISA

| Se precisar de...                                   | Está em                                                                  |
|-----------------------------------------------------|--------------------------------------------------------------------------|
| a EDA Central inteira, dentro deste mesmo deck      | slides 44 a 94 — a numeração impressa neles é a original da EDA (1 a 51) |
| o relatório escrito da análise fatorial             | <code>docs/Relatorio_Analise_Fatorial_NB04.md</code>                     |
| o código comentado linha a linha, com a versão em R | <code>docs/Codigo_Analise_Fatorial_Comentado.md</code>                   |
| as tabelas com todos os números                     | <code>banco_de_dados/eda/fatorial/nb04_*.csv</code>                      |
| as figuras em alta resolução                        | <code>banco_de_dados/eda/fatorial/figuras/</code>                        |