PROJETO IVS · CENSO 2022 · FIOCRUZ MINAS — INSTITUTO RENÉ RACHOU

Guia das apresentações de outubro, explicado do zero

A cronologia do projeto (43 slides) e as demandas de setembro (42 slides): o que cada slide mostra, o que cada termo quer dizer, como ler os números e o que responder se perguntarem.

Pedro Dias Soares · Iniciação Científica · gerado em 05/10/2026

Como usar este guia

Este guia explica, um por um, os 85 slides das duas apresentações de outubro: a **cronologia do projeto** (43 slides) e as **demandas de setembro** (42 slides). Ele foi escrito para quem não sabe nada do assunto — nem o que é um setor censitário, nem o que é uma análise fatorial, nem o que é um commit. Nada é dado como sabido: cada termo é explicado na primeira vez em que aparece, e o glossário, no fim, repete todos em ordem alfabética.

O guia tem quatro partes. A **Parte A** é o mínimo para entender tudo: o projeto, os dados, o que é um índice, o que é uma análise fatorial, como se valida um índice e como o trabalho fica registrado no computador. Leia uma vez, com calma, antes dos slides. A **Parte B** explica a cronologia, slide a slide. A **Parte C** explica as demandas de setembro, slide a slide. A **Parte D** é o glossário: consulte quando uma palavra travar a leitura.

Como cada slide é explicado

Todo verbete das Partes B e C tem a mesma estrutura, de propósito, para você saber onde procurar:

- **A miniatura do slide**, no alto — é o próprio slide, para você saber de qual se trata.
- **Em uma frase**: a ideia do slide, se você só tiver tempo para uma coisa.
- **O que aparece no slide**: cada elemento, na ordem em que o olho lê.
- **O que isso quer dizer, do zero**: os conceitos por trás, sem pressupor nada.
- **Como ler os números**: o que cada número significa e se ele é bom, ruim ou neutro (só quando há números).
- **Como apresentar**: uma fala possível, em linguagem de reunião.
- **Se perguntarem**: as perguntas mais prováveis, com resposta.

Se o tempo for curto

Leia a Parte A inteira — ela é a base de tudo. Depois, de cada slide, leia só "Em uma frase" e "Como apresentar". Na véspera de apresentar, releia os "Se perguntarem" dos slides com números.

> **DE ONDE VÊM OS NÚMEROS DESTE GUIA**
> Nenhum número que vem de planilha foi copiado à mão: o programa que gera este guia lê os mesmos arquivos de dados e o mesmo histórico do git que geram os slides, e escreve os números nos textos na hora. Se um dado mudar, basta gerar o guia de novo, e ele muda junto com os slides. Os números que só existem em documento — decisões de método registradas no GUIA do projeto, contagens das auditorias, as demandas de julho — aparecem como estão no documento citado. Este guia foi gerado em 05/10/2026.

Sumário

Como usar este guia 2

Parte A — O mínimo para entender tudo 6

A.1 O projeto, em palavras simples . . . 6
A.2 De onde vêm os dados: o Censo e o setor censitário . . . 7
A.3 Por que 70 municípios: o ELSI-Brasil . . . 8
A.4 Indicador: numerador, denominador e porcentagem . . . 8
A.5 O índice composto: como sete números viram um . . . 9
A.6 Análise fatorial, sem fórmula . . . 10
A.7 O índice funciona? A validação contra as favelas . . . 11
A.8 Quanto o resultado depende de detalhes: a sensibilidade . . . 12
A.9 Especificação, grade, elegível e referência . . . 12
A.10 O código, o git e os commits . . . 13
A.11 As duas apresentações, lado a lado . . . 14

Parte B — A cronologia, slide a slide 15

1. Cronologia do projeto . . . 16
2. Como ler este deck . . . 17
3. O projeto em uma página . . . 18
4. Os dados: oito arquivos do Censo 2022 . . . 19
5. Quantos setores ficam a cada etapa . . . 20
6. A linha do tempo em uma página . . . 22
7. O ritmo do trabalho . . . 23
8. As apresentações que ficaram pelo caminho . . . 24
9. Março a maio — a base . . . 25
10. Março a maio . . . 26
11. Março a maio (continuação) . . . 27
12. Junho — a EDA cresce . . . 28
13. Junho . . . 29
14. Junho (continuação) . . . 30
15. Julho e agosto — retomada e módulo . . . 31
16. Julho e agosto . . . 32
17. Julho e agosto (continuação) . . . 33
18. Setembro, primeira quinzena . . . 34
19. Setembro, 1 a 17 . . . 35
20. Setembro, 1 a 17 (continuação) . . . 36

21. 25 de setembro — a revisão e as demandas . . . 38
22. 25 de setembro . . . 39
23. 25 de setembro (continuação) . . . 40
24. 26 e 27 de setembro — os testes e o IVS final . . . 41
25. 26 e 27 de setembro . . . 42
26. 26 e 27 de setembro (continuação) . . . 43
27. De 30/09 até hoje . . . 44
28. De 30/09 até hoje . . . 45
29. As decisões de método, em ordem . . . 46
30. As decisões consolidadas do GUIA . . . 47
31. As regras de setembro, e o que não é decisão minha . . . 48
32. Os achados, em ordem . . . 49
33. Os achados . . . 50
34. Os achados (continuação) . . . 51
35. Os achados (continuação) . . . 52
36. A organização, em ordem . . . 53
37. A organização . . . 54
38. A organização (continuação) . . . 55
39. O repositório hoje . . . 56
40. Onde o projeto está . . . 57
41. O cronograma contra o realizado . . . 58
42. O que vem depois . . . 59
43. De onde saiu esta cronologia . . . 60

Parte C — As demandas de setembro, slide a slide 61

1. As demandas de setembro . . . 62
2. O roteiro . . . 63
3. O pedido e como foi lido . . . 64
4. As onze demandas . . . 65
5. Como li o que tinha mais de uma leitura . . . 66
6. Como o trabalho foi feito . . . 67
7. O ponto de partida: o NB04 . . . 68
8. O índice do NB04, em seis números . . . 69
9. Demandas 1 e 2 — a renda e o quadro . . . 70
10. Demanda 1: a renda com a mediana . . . 71
11. Demanda 2: o quadro de indicadores . . . 72
12. Demandas 3 e 5 a 11 — a fatorial ampliada . . . 74
13. Os cenários: o que entra em cada um . . . 75

14. Demandas 3 e 11: sem rotação, Varimax e promax . . . 76
15. O plano fatorial do S6 . . . 77
16. Demandas 5, 6 e 7: uma variável nova por vez . . . 78
17. Demanda 9: a moradia não convencional . . . 79
18. Demanda 8: tudo isso junto . . . 80
19. Demanda 10: o lixo . . . 81
20. A incerteza: um município de fora por vez . . . 82
21. A validação contra as favelas, cenário a cenário . . . 83
22. Demanda 4 — a apresentação revista . . . 84
23. Separar o útil do inútil . . . 85
24. Os testes seguintes . . . 86
25. Os nove itens da etapa seguinte . . . 87
26. O banheiro graduado . . . 88
27. O IVS final — a grade do Notebook 05 . . . 89
28. A grade: 324 especificações . . . 90
29. Quem passa nos critérios, base a base . . . 91
30. Rotação e esquema de peso . . . 92
31. Os pesos na solução oblíqua . . . 93
32. A AUC de cada especificação . . . 94
33. O que o índice acrescenta à renda . . . 95
34. A renda sozinha contra o índice . . . 96
35. A referência proposta — e por que desconfiar . . . 97
36. Quatro leituras, quatro propostas . . . 98
37. Por que desconfiar da principal . . . 99
38. As faixas da referência . . . 100
39. O que fica para decidir . . . 101
40. As sete escolhas . . . 102
41. As perguntas de método . . . 103
42. Onde está cada resultado . . . 104

Parte D — Glossário **105**

Como este guia foi feito . . . 108

Parte A — O mínimo para entender tudo

Leia uma vez, antes dos slides

Esta parte junta, em ordem, tudo o que é preciso saber para que os slides façam sentido. Ela começa pelo problema que o projeto quer resolver, passa pelos dados e pelas contas, e termina no modo como o trabalho fica registrado. Não há fórmula que não venha acompanhada de um exemplo.

A.1 O projeto, em palavras simples

Imagine que a secretaria de saúde de uma cidade precisa decidir para onde mandar mais equipes, mais agentes comunitários, mais vacinação. Ela quer saber em quais pedaços da cidade as pessoas estão mais expostas a adoecer por causa das condições em que vivem: casa sem esgoto, água que não chega pela torneira, lixo que não é recolhido, muita gente dividindo poucos cômodos, adultos que não sabem ler, renda baixa. Nenhuma dessas coisas, sozinha, diz tudo. E ninguém mede "vulnerabilidade" diretamente — não existe um termômetro para isso.

O que se faz, então, é juntar vários desses sinais num número só, um **índice**. É isso que o projeto constrói: o **Índice de Vulnerabilidade à Saúde**, o **IVS**. Ele é **intraurbano**, ou seja, compara pedaços de uma mesma cidade entre si (um bairro com outro, um quarteirão com outro), e não uma cidade com outra.

A ideia não é nova. Em 2012, a Secretaria Municipal de Saúde de Belo Horizonte publicou o seu IVS, calculado com os dados do Censo de 2010 — no projeto, ele é chamado de **IVS-BH 2012** e é a referência de método. O projeto refaz esse índice com os dados do **Censo de 2022** e o estende para **70 municípios** de todas as regiões do país: os municípios do estudo ELSI-Brasil (explicado em A.3).

Item	Detalhe
Quem	Pedro Dias Soares, bolsista de Iniciação Científica (IC)
Onde	Fiocruz Minas — Instituto René Rachou (IRR), em Belo Horizonte
Quando	março de 2026 a fevereiro de 2027
O que entrega	um Relatório Final de IC e um artigo científico submetido a uma revista

Iniciação Científica é o programa em que um estudante de graduação trabalha num projeto de pesquisa sob a orientação de um pesquisador — a **orientadora**, que aparece muito nos slides, porque é ela quem pede as análises (as **demandas**) e quem toma as decisões de método.

A.2 De onde vêm os dados: o Censo e o setor censitário

O **Censo Demográfico** é a contagem de toda a população do país, feita pelo **IBGE** (Instituto Brasileiro de Geografia e Estatística). Recenseadores visitam cada domicílio e fazem perguntas: quantas pessoas moram ali, de onde vem a água, para onde vai o esgoto, quem sabe ler, quanto ganha a pessoa responsável. A edição usada aqui é a de 2022.

Para proteger as pessoas, o IBGE não publica as respostas de cada casa. Ele publica **contagens por área pequena**. A menor dessas áreas é o **setor censitário**: um pedaço de território desenhado para que um único recenseador consiga percorrê-lo. Na cidade, um setor costuma ser um conjunto de poucos quarteirões. O Brasil inteiro tem 468.099 setores. Os 70 municípios do projeto têm, juntos, 109.032 setores.

Cada setor tem um código de 15 dígitos. Nos slides aparece o setor `310620005650366`: os sete primeiros dígitos (`3106200`) são o código do município — Belo Horizonte —, e o resto identifica o setor dentro dele.

O setor é a **unidade de análise** do projeto: o IVS é calculado para cada setor, não para cada pessoa e não para cada cidade.

As variáveis: códigos que são contagens

Cada informação do Censo vem numa coluna com um código, como `V00001` ou `V00901`. Quase todas são **contagens** — "quantos domicílios deste setor têm tal coisa" ou "quantas pessoas deste setor são assim". As que mais aparecem nos slides:

- `V00001` — **domicílios particulares permanentes ocupados**. Domicílio *particular* é o de uma família (não é hotel, asilo ou presídio, que são *coletivos*); *permanente* é o construído para morar (não é uma barraca, que seria *improvisado*); *ocupado* é o que tinha morador na data do Censo. É o total de casas "normais" com gente dentro — o denominador mais usado no projeto.
- `V00900` e `V00901` — pessoas de 15 anos ou mais que *sabem* e que *não sabem* ler e escrever.
- `V06004` — rendimento médio mensal da pessoa responsável pelo domicílio, no setor.
- `V00236`, `V00237`, `V00238` e `V00495` — as partes da falta de banheiro, explicadas na Parte C.
- `V00199` — domicílios com água canalizada (que chega por cano até dentro de casa).

O sigilo

Quando uma contagem é muito pequena — por exemplo, um setor em que só duas pessoas não sabem ler —, publicar o número poderia permitir identificar essas pessoas. Nesses casos o IBGE troca o número por um "X": é o **sigilo**. No projeto, o X vira **dado ausente**, nunca zero. Por quê? Porque zero seria uma mentira (há gente ali, só não se sabe quantos), e porque o sigilo não cai ao acaso: ele cai justamente onde a contagem é pequena. No analfabetismo, por exemplo, o sigilo aparece nos setores com poucos analfabetos — os de melhor situação. Trocar o X por zero empurraria esses setores para uma situação ainda melhor do que a real; trocar por qualquer outro número seria inventar dado.

A consequência prática aparece em vários slides: toda vez que uma variável com muito sigilo entra na análise, setores "caem" da base, porque ficam com algum dado ausente.

Os oito arquivos

O IBGE publica os dados por setor em vários arquivos, um por tema. O projeto usa oito: o básico (identificação e população), dois de características do domicílio (o primeiro com os totais de domicílios, o segundo com água, esgoto, lixo e banheiro), alfabetização, cor ou raça, renda do responsável, demografia (idade) e parentesco. O de parentesco era usado no começo, por causa da variável `V01042`, e foi abandonado em maio — a história está na Parte B.

A.3 Por que 70 municípios: o ELSI-Brasil

O **ELSI-Brasil** é o Estudo Longitudinal da Saúde dos Idosos Brasileiros, coordenado pela Fiocruz. Ele acompanha uma amostra de pessoas de 50 anos ou mais que moram em **70 municípios** espalhados pelas cinco regiões do país. *Longitudinal* quer dizer que as mesmas pessoas são entrevistadas de novo de tempos em tempos, para ver como a saúde delas muda.

O projeto calcula o IVS para todos os setores desses 70 municípios. Com isso, a vulnerabilidade do lugar onde cada participante mora pode, por exemplo, ser relacionada à saúde dele. É por isso que os slides falam em "recorte ELSI", "base ELSI" e "70 municípios".

O recorte urbano

O IVS é intraurbano, então só os setores **urbanos** entram na análise. Cada setor tem, no Censo, a sua **situação** (`SITUACAO`): urbana ou rural. O filtro é aplicado na hora da análise, e não na hora de extrair os dados — a base completa continua guardada, para que dê para conferir e desfazer. Dos setores dos 70 municípios, 104.108 são urbanos.

A.4 Indicador: numerador, denominador e porcentagem

Um **indicador** é uma conta que transforma contagens em algo comparável. Pense em dois setores: o setor A tem 30 domicílios sem esgoto, o setor B tem 300. O B está pior? Depende do tamanho. Se o B tiver 3.000 domicílios, são 10%; se o A tiver 60, são 50%. Por isso se divide pelo total:

- o **numerador** é o que se quer medir (domicílios sem esgoto);
- o **denominador** é o total de referência (todos os domicílios do setor);
- o resultado é uma **proporção**, um número entre 0 e 1 — que, vezes 100, é a porcentagem.

Nos nomes das colunas do projeto, `pct_` quer dizer proporção (de "percentual"): `pct_esgoto_inad` é a proporção de domicílios com esgoto inadequado; `pct_analfab`, a de analfabetos entre as pessoas de 15 anos ou mais.

> **POR QUE O DENOMINADOR IMPORTA**
> Em maio, o projeto trocou o denominador de `V01042` (que conta *pessoas responsáveis*, no arquivo de parentesco) por `V00001` (que conta *domicílios*). Parece detalhe, mas não é: o IVS-BH 2012 dividia por domicílios, e só com o mesmo denominador os dois índices ficam comparáveis. Trocar o denominador muda todos os indicadores de uma vez.

Taxa e razão

Uma **taxa** tem no denominador a população inteira de referência: analfabetos ÷ (todas as pessoas de 15 anos ou mais). Ela nunca passa de 1 (100%). Uma **razão** divide uma coisa por outra que não a contém: analfabetos ÷ alfabetizados. Ela pode passar de 1 — num setor com 60 analfabetos e 40 alfabetizados, dá 1,5. A primeira versão do projeto calculava o analfabetismo como razão, e isso foi corrigido em maio.

A **razão de moradores** (`razao_moradores`) é uma razão de propósito: moradores ÷ domicílios, a média de pessoas por casa — um sinal de aperto.

O complemento

Às vezes é mais fácil contar quem *tem* do que quem *não tem*. O Censo conta bem os domicílios *com* água canalizada (`V00199`), uma contagem grande que quase nunca cai em sigilo. A proporção *sem* água canalizada sai então pelo **complemento**: 1 − (com água ÷ total). Se 92% têm, 8% não têm.

A.5 O índice composto: como sete números viram um

Um **índice composto** junta vários indicadores numa nota só, como uma média de boletim que junta as notas de várias matérias. Montá-lo tem quatro passos.

1. Escolher os componentes

O IVS-BH 2012 usa sete indicadores, e por isso o projeto chama essa base de **IVS-7**. Eles se dividem em duas **dimensões** (dois grandes temas):

Dimensão	Indicador	O que mede
Saneamento	água inadequada (`pct_agua_inad`)	domicílios sem abastecimento de água adequado
Saneamento	esgoto inadequado (`pct_esgoto_inad`)	domicílios sem rede de esgoto ou fossa adequada
Saneamento	lixo inadequado (`pct_lixo_inad`)	domicílios sem coleta de lixo porta a porta
Socioeconômica	razão de moradores (`razao_moradores`)	pessoas por domicílio: o aperto
Socioeconômica	analfabetismo (`pct_analfab`)	pessoas de 15+ que não sabem ler e escrever
Socioeconômica	renda (`renda_media`)	rendimento médio do responsável — entra invertida
Socioeconômica	cor ou raça (`pct_raca_pretpardind`)	pessoas pretas, pardas e indígenas

Quando o lixo sai, a base vira **IVS-6**. Nos slides aparecem outras bases, com variáveis a mais (água que não chega, falta de banheiro, moradia não convencional) — a Parte C explica cada uma.

2. Pôr tudo na mesma régua: a normalização

Os indicadores estão em escalas diferentes: proporções vão de 0 a 1, a renda vai de algumas centenas a dezenas de milhares de reais, a razão de moradores fica em torno de 3. Para somar, é preciso pôr todos na mesma régua. A **normalização min-max** faz isso: em cada indicador, o pior setor vira 1, o melhor vira 0, e os outros ficam no meio, na proporção certa. A conta é (valor − mínimo) ÷ (máximo − mínimo).

> **EXEMPLO DE NORMALIZAÇÃO**
> Três setores com esgoto inadequado de 10%, 30% e 60%. O mínimo é 10%, o máximo é 60%, e a distância entre eles é 50 pontos. O primeiro fica em (10 − 10) ÷ 50 = 0; o segundo em (30 − 10) ÷ 50 = 0,4; o terceiro em (60 − 10) ÷ 50 = 1.

Dois detalhes importam nos slides. Primeiro, a **renda entra invertida**: renda alta é boa, ao contrário dos outros indicadores, em que mais é pior; invertendo, todos passam a dizer "mais = mais vulnerável". Segundo, a normalização pode ser feita **no município** (mínimo e máximo de cada cidade) ou de forma **global** (mínimo e máximo de todos os setores juntos). No município, o índice diz quem está pior *dentro da sua cidade*; no global, compara todo mundo com todo mundo.

E um alerta: um valor extremo estraga a régua. Se um setor tem renda de R$ 170 mil e o segundo mais rico tem R$ 45 mil, o de R$ 170 mil vira o máximo e todos os outros ficam espremidos perto de zero. É a história do "setor extremo" de Belo Horizonte, nos dois decks.

3. Dar pesos e somar

O índice é a soma dos indicadores normalizados, cada um multiplicado por um **peso**. Os pesos dizem quanto cada parte conta. Podem vir de uma regra fixa — por exemplo, 60% para a dimensão socioeconômica e 40% para o saneamento (o "60/40") ou metade para cada uma (o "50/50") — ou podem vir dos próprios dados, por uma análise fatorial (A.6). Escolher os pesos é uma das decisões que ficam com a orientadora.

4. Cortar em faixas

O índice final vai de 0 a 1. Para usar na prática, ele é cortado em **faixas de risco**: baixo, médio, elevado e muito elevado. Há duas regras em teste:

- a **regra do IVS-BH 2012**, que usa a média e o desvio-padrão. O **desvio-padrão** mede o quanto os valores costumam se afastar da média. Quem fica muito acima da média cai em "muito elevado", e assim por diante. Com essa regra, as faixas têm tamanhos diferentes;
- os **quartis municipais**: dentro de cada município, os setores são ordenados e divididos em quatro grupos do mesmo tamanho. Cada faixa fica com um quarto dos setores.

A.6 Análise fatorial, sem fórmula

A análise fatorial é a técnica que o projeto usa para descobrir **como os indicadores se agrupam** e, daí, **quanto cada grupo deve pesar**. É o assunto mais técnico dos dois decks. Aqui vai a ideia, passo a passo.

Variáveis que andam juntas

Pense nas notas de um aluno em matemática, física e química. Elas costumam subir e descer juntas, porque refletem uma mesma coisa que ninguém mede diretamente — algo como "facilidade com exatas". Na análise fatorial, essa coisa escondida se chama **fator**.

Com os setores acontece o mesmo. Onde a renda é baixa, o analfabetismo tende a ser alto e a casa tende a ser mais cheia: esses indicadores andam juntos e formam um fator **socioeconômico**. Onde falta esgoto, costuma faltar água: formam um fator de **saneamento**. A análise fatorial encontra esses fatores nos dados, sem que ninguém diga de antemão quais são.

Correlação, e por que Spearman

O quanto duas variáveis andam juntas se mede pela **correlação**, um número de -1 a 1. Perto de 1: sobem juntas; perto de -1: uma sobe quando a outra desce; perto de 0: não têm relação. O projeto usa a **correlação de Spearman**, que em vez dos valores usa as **posições** (os **postos**: primeiro, segundo, terceiro…). Assim, um setor com renda absurda conta como "o primeiro", e não como um valor gigante que distorce tudo.

Os dados servem para isso? KMO, MSA e Bartlett

Antes de procurar fatores, testa-se se os dados se prestam a isso:

- o **KMO** (de Kaiser-Meyer-Olkin) vai de 0 a 1 e diz se as correlações são *compartilhadas* por várias variáveis, e não só por pares isolados. Abaixo de 0,5 é inaceitável; de 0,7 para cima, bom; de 0,8 para cima, muito bom;
- o **MSA** é o KMO de cada variável, separado: mostra qual variável conversa pouco com as outras;
- o **teste de Bartlett** verifica se existe alguma correlação. Se as variáveis fossem independentes, não haveria fator para achar. Com dezenas de milhares de setores, ele sempre dá "sim".

Quantos fatores: autovalor, Kaiser e Horn

Cada fator encontrado resume uma parte da informação de todas as variáveis. O **autovalor** mede quanto: um autovalor de 3 quer dizer que aquele fator vale por três variáveis. Para decidir quantos fatores manter, há duas regras:

- a **regra de Kaiser**: fica o fator com autovalor maior que 1 (que vale por mais de uma variável);
- a **regra de Horn** (ou análise paralela): gera dados aleatórios do mesmo tamanho, calcula os autovalores que o puro acaso produziria, e só mantém o fator que supera o acaso. É mais exigente.

Nos slides, "Fatores K/H" mostra o que cada regra indica: "2 / 2" é dois por Kaiser e dois por Horn. O gráfico desses autovalores, em ordem decrescente, se chama **scree plot** (gráfico de cotovelo).

Cargas e comunalidade

A **carga fatorial** diz o quanto uma variável "pertence" a um fator: vai de −1 a 1, e perto de 1 quer dizer muito. A **comunalidade** diz quanto de uma variável os fatores conseguem explicar, juntos: vai de 0 a 1. Uma variável com comunalidade de 0,25 tem só um quarto do seu comportamento explicado pelos fatores; o resto é dela, não conversa com as outras. No projeto, uma especificação só é aceita se toda variável tiver comunalidade de pelo menos 0,30 e carga máxima de pelo menos 0,40.

Rotação: Varimax e promax

Depois de achar os fatores, os eixos podem ser "girados" para que cada variável fique perto de um fator só — o que torna o resultado mais fácil de interpretar. Isso é a **rotação**.

- **Sem rotação**, o primeiro fator costuma pegar quase tudo: é o fator "geral".
- A **Varimax** gira mantendo os fatores independentes entre si, como eixos em ângulo reto: a correlação entre eles é zero.
- A **promax** deixa os fatores se correlacionarem, como eixos que não formam ângulo reto (rotação **oblíqua**). A correlação entre os fatores se chama **Φ** (a letra grega "fi"). Com rotação oblíqua surgem duas tabelas de cargas: a **matriz padrão**, com o efeito próprio de cada fator, e a **matriz estrutura**, com a correlação simples entre variável e fator — que inclui a parte que os dois fatores compartilham.

Dos fatores aos pesos

Cada fator tem uma "força": a **soma dos quadrados das cargas**, abreviada **SS** (do inglês *sum of squares*). Dividindo a força de cada fator pela soma das forças, saem os pesos em porcentagem. Por exemplo, 65% para o fator socioeconômico e 35% para o de saneamento. Na promax, a força pode ser calculada com a matriz padrão ou com a estrutura, e dá números diferentes. Outras regras repartem pelas **comunalidades**, ou fixam o peso (50/50, 60/40).

> **TRÊS TERMOS QUE APARECEM DE PASSAGEM**
> **Eixo principal** e **componentes principais** são dois jeitos de extrair os fatores; não é preciso conhecer a diferença para ler os slides. Um **caso de Heywood** é quando a conta dá uma comunalidade acima de 1, o que é impossível e indica problema. Os **escores** são as notas de cada setor em cada fator.

A.7 O índice funciona? A validação contra as favelas

Como saber se o índice mede o que promete? Uma forma é compará-lo com algo que não foi usado para construí-lo. O projeto usa a classificação de **Favelas e Comunidades Urbanas**, a **FCU**: o IBGE marca cada setor que é favela ou comunidade urbana (no campo `CD_TIPO`, valor 1). Se o índice mede vulnerabilidade, os setores de favela deveriam, em geral, ter índice mais alto.

A AUC, explicada com um sorteio

Sorteie um setor de favela e um setor que não é favela, e veja qual dos dois tem o índice maior. Repita isso milhares de vezes. A **AUC** é a proporção de vezes em que o setor de favela ganhou.

- AUC de 0,5: o índice acerta tanto quanto uma moeda — não separa nada;
- AUC de 1,0: o setor de favela ganha sempre;
- AUC de 0,8: o setor de favela tem índice maior em 80% dos pares.

O nome vem do gráfico de onde ela sai, a **curva ROC**: AUC é a "área sob a curva" (*area under the curve*). Uma curva que sobe rápido para o canto de cima, à esquerda, tem área grande; a diagonal é o acaso.

A comparação que importa: a renda sozinha

Nos slides, a AUC do índice é sempre posta ao lado da AUC da **renda invertida sozinha**. Se a renda, sozinha, separa as favelas melhor do que o índice, o índice não está ajudando a *separar favelas*. Isso não quer dizer que o índice não serve: um índice de vulnerabilidade mede mais do que a condição de favela. Mas é um sinal importante, e os decks mostram que é o que acontece.

Há também uma ressalva de **circularidade**: para marcar um setor como favela, o IBGE olha em parte as mesmas condições de infraestrutura (água, esgoto) que entram no índice. Um índice com saneamento leva uma vantagem "de graça" nessa comparação.

Comparar só o comparável: dentro do município e dentro da faixa de renda

A AUC **global** compara setores de todos os municípios juntos. A AUC **dentro do município** compara cada favela só com setores da mesma cidade, e depois resume (pela mediana). A AUC **dentro dos decis de renda** vai além: em cada município, os setores são divididos em dez grupos de renda parecida (os **decis**), e só se comparam setores do mesmo grupo. Ali a renda já não ajuda, porque é quase igual — e o que sobra mostra se o índice traz informação *além* da renda.

Regressão logística, deviance e z

A **regressão logística** é um modelo que estima a chance de um setor ser favela a partir de outras variáveis. Ajusta-se primeiro um modelo só com a renda, depois um com a renda e o índice. Se acrescentar o índice melhora o modelo, o índice traz informação nova. A **deviance** mede o quanto o modelo erra (menor é melhor), e a **estatística z** mede se a contribuição do índice é maior do que o acaso explicaria. Como regra prática, z acima de 2 já é considerado significativo.

A.8 Quanto o resultado depende de detalhes: a sensibilidade

Todo resultado estatístico tem alguma incerteza. Uma técnica comum para medi-la é o **bootstrap**: refazer a análise centenas de vezes, cada vez com uma amostra sorteada dos próprios dados, e ver quanto o resultado oscila. Ele faz sentido quando os dados são uma amostra. Aqui não são: o projeto tem todos os setores urbanos dos 70 municípios.

A pergunta útil é outra: **quanto o resultado depende de um município?** Para responder, a análise é refeita tirando um município de cada vez: uma rodada com todos e mais 70, uma sem cada município, num total de 71 rodadas. Se tirar São Paulo muda muito os pesos, o resultado depende demais de São Paulo. Isso é a **sensibilidade por município**.

As diferenças entre porcentagens se medem em **pontos percentuais** (p.p.): de 65% para 63% são 2 p.p. (e não "2%").

A.9 Especificação, grade, elegível e referência

Para construir o IVS final, há várias escolhas em aberto: qual versão da renda usar, se o lixo entra, se a falta de banheiro entra (e em qual versão), qual rotação, como dividir os pesos, como normalizar. Cada combinação dessas escolhas é uma **especificação**. Testar todas as combinações é montar uma **grade**: são 324 especificações.

Uma especificação é **elegível** quando passa em critérios mínimos de qualidade (KMO, MSA, comunalidade e carga), fixados *antes* de rodar a grade — para que ninguém escolha a especificação olhando o resultado. Das 324, 192 são elegíveis.

Entre as elegíveis, a **referência proposta** é a de melhor **posição média** em três critérios com o mesmo peso: **estabilidade** (quanto o peso muda ao tirar um município), **validação** (a AUC dentro do município) e

parcimônia (menos variáveis é melhor). É uma *proposta*, não uma decisão: escolher a especificação final é papel da orientadora.

A.10 O código, o git e os commits

O projeto inteiro mora numa pasta no computador, o **repositório**, com os dados, os programas, os documentos e as apresentações. O **git** é o programa que guarda a história dessa pasta.

Cada vez que um trabalho fica pronto, ele é registrado num **commit**: uma "foto" das mudanças, com data, autor e uma mensagem que diz o que mudou. Cada commit tem um identificador curto, o **hash** (por exemplo, `2d0c909`), que permite voltar exatamente àquela versão. A cronologia se apoia nessas fotos: é por isso que ela tem datas tão precisas.

As mensagens dos commits começam com um prefixo que diz o tipo de mudança:

- `feat` — uma funcionalidade nova (uma análise, um script, uma coluna);
- `fix` — uma correção;
- `docs` — documentação (relatórios, guias, READMEs);
- `chore` — manutenção (configurações, organização);
- `data` ou `dados` — dados regerados;
- `test` ou `teste` — testes automáticos;
- `refactor` — reorganização do código sem mudar o resultado.

Um **branch** é uma linha de trabalho dentro do repositório; a principal se chama `main`.

Notebooks, scripts, módulos e testes

- Um **notebook** (Jupyter) é um documento que mistura texto, código e resultados — tabelas e gráficos — na ordem em que a análise acontece. Os do projeto são numerados: NB01 (extração dos dados e filtro dos 70 municípios), NB02 (análise descritiva), NB04 (análise fatorial), NB04b (fatorial ampliada) e NB05 (o IVS final).
- Um **script** é um programa que roda sozinho e grava um resultado (uma tabela, um gráfico, um deck). Ficam na pasta `scripts/`.
- Um **módulo** é código compartilhado, usado por vários notebooks e scripts. O do projeto é `src/ivs_censo`, onde vivem as fórmulas de todos os indicadores — assim, a fórmula é a mesma em todo lugar.
- Um **CSV** é uma tabela salva como texto, com os valores separados por vírgula ou ponto e vírgula. A maioria dos números dos slides sai de arquivos CSV.
- Um **teste** é um pequeno programa que confere se o código dá o resultado esperado. O projeto tem 103 testes.
- **EDA** (do inglês *exploratory data analysis*) é a análise exploratória: descrever os dados, medir, comparar e procurar problemas antes de construir qualquer modelo.

Decks gerados por script

Nos slides aparece muito a expressão "gerado por script". Quer dizer que ninguém digitou os números no slide: um programa lê as tabelas e monta a apresentação. Se uma tabela muda, roda-se o programa de novo e o slide muda junto — sem chance de o slide ficar com um número velho. Os dois decks de outubro foram feitos assim, e este guia também.

As **anotações do apresentador** são o texto escondido embaixo de cada slide. No PowerPoint, aparecem em *Exibir › Anotações* e, durante a apresentação, só na tela de quem apresenta. Os dois decks trazem ali detalhes que não couberam no slide.

A.11 As duas apresentações, lado a lado

	Cronologia do projeto	Demandas de setembro
Pergunta que responde	O que aconteceu, quando e por quê?	O que foi pedido, o que foi feito e o que os números dizem?
Para quem	Quem precisa entender a trajetória inteira	A reunião de decisão com a orientadora
Organização	Por data: sete capítulos e três leituras transversais	Por demanda: dez partes, da pergunta à decisão
De onde vêm os dados	Histórico do git, GUIA do projeto e CSVs	CSVs da fatorial ampliada e da grade do NB05
Tamanho	43 slides	42 slides

As duas seguem a mesma identidade visual dos outros decks do projeto: fundo branco, letra serifada, uma régua fina sob o título e o vermelho reservado ao que merece destaque. Todo slide com dado tem, no pé, uma linha "Fonte:" dizendo de qual arquivo saiu o que está ali. As divisórias de parte trazem um número grande em vermelho; o número pequeno no canto inferior direito é o número do slide.

Parte B — A cronologia, slide a slide

Cronologia_Projeto_IVS_2026-10.pptx · 43 slides

A cronologia conta o projeto como um filme: do primeiro commit, em 12/03/2026, até hoje. Ela abre com oito slides de contexto (o projeto, os dados, a linha do tempo, o ritmo do trabalho, as apresentações antigas), segue com sete capítulos em ordem de data, e fecha com três leituras transversais — as decisões de método, os achados e a organização — e com o estado atual do projeto.

Os capítulos são feitos de páginas de **diário**: cada linha tem uma data em vermelho, à esquerda, o fato em negrito e um detalhe em cinza. Quando um capítulo tem mais fatos do que cabem num slide, ele continua no seguinte, com "(continuação)" no título.

CRONOLOGIA · SLIDE 1

Cronologia do projeto



> *A capa: diz o que é o deck — o processo inteiro do projeto, em ordem — e quanto histórico há por trás dele.*

O QUE APARECE NO SLIDE

No alto, em letras pequenas e espaçadas, a identificação: Projeto IVS, Censo 2022, Fiocruz Minas — Instituto René Rachou. Abaixo, o título grande, "Cronologia do projeto", e um subtítulo que resume o conteúdo: o que mudou, quando, por quê, o que se descobriu e como o repositório foi organizado, de março a outubro de 2026. No pé da página, o autor e o tamanho do histórico: 167 commits, de 12/03/2026 a 01/10/2026.

O QUE ISSO QUER DIZER, DO ZERO

Um **commit** é um registro de mudança no projeto, com data e descrição (Parte A, seção A.10). A capa dá o número de commits porque ele mede o quanto de trabalho registrado sustenta a cronologia: cada data dos slides seguintes vem de um desses registros, ou de um documento do projeto quando o trabalho foi feito antes de ser registrado.

COMO APRESENTAR

“Esta apresentação conta o projeto em ordem de data: o que foi feito, por que foi feito e o que mudou no caminho. Ela não é uma apresentação de resultados — é o mapa de como chegamos até aqui. Cada data vem do histórico do projeto, então dá para conferir qualquer uma delas.”

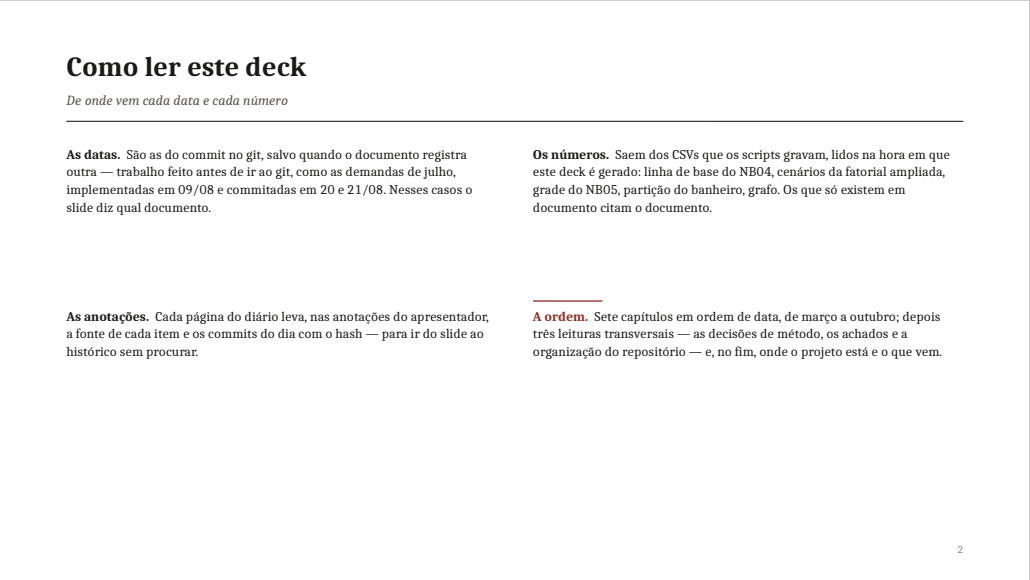
SE PERGUNTAREM

Por que o histórico começa em março?

Porque é quando o repositório foi criado. O período da bolsa também começa em março de 2026, com o Programa de Inserção do IRR.

CRONOLOGIA · SLIDE 2

Como ler este deck


Como ler este deck

De onde vem cada data e cada número

As datas. São as do commit no git, salvo quando o documento registra outra — trabalho feito antes de ir ao git, como as demandas de julho, implementadas em 09/08 e commitadas em 20 e 21/08. Nesses casos o slide diz qual documento.

Os números. Saem dos CSVs que os scripts gravam, lidos na hora em que este deck é gerado: linha de base do NB04, cenários da fatorial ampliada, grade do NB05, partição do banheiro, grafo. Os que só existem em documento citam o documento.

As anotações. Cada página do diário leva, nas anotações do apresentador, a fonte de cada item e os commits do dia com o hash — para ir do slide ao histórico sem procurar.

A ordem. Sete capítulos em ordem de data, de março a outubro; depois três leituras transversais — as decisões de método, os achados e a organização do repositório — e, no fim, onde o projeto está e o que vem.

2

> *As regras do jogo: de onde vem cada data, de onde vem cada número e como o deck está organizado.*

O QUE APARECE NO SLIDE

Quatro blocos de texto, em duas colunas. **As datas**: são as do commit, salvo quando um documento registra outra. **Os números**: saem dos CSVs gravados pelos scripts, lidos na hora em que o deck é gerado. **As anotações**: cada página de diário tem, nas anotações do apresentador, a fonte de cada item e os commits do dia. **A ordem**: sete capítulos por data, três leituras transversais e o estado atual. O último bloco tem um filete vermelho em cima, para marcar que é o mapa do resto.

O QUE ISSO QUER DIZER, DO ZERO

Há duas datas possíveis para um fato: a do dia em que o trabalho foi feito e a do dia em que ele foi registrado no git. Quase sempre são a mesma. A exceção mais importante são as demandas de julho: o GUIA do projeto registra que foram implementadas em 09/08, mas só entraram no git em 20 e 21/08. Nesses casos o slide usa a data do documento e diz qual é o documento.

"Os números saem dos CSVs" quer dizer que nenhum valor foi digitado no slide: um programa lê as tabelas produzidas pelas análises e escreve os números. Um **CSV** é uma tabela salva como texto. Se a tabela mudar, basta gerar o deck de novo.

As **anotações do apresentador** são o texto escondido embaixo de cada slide; no PowerPoint, aparecem em Exibir › Anotações.

COMO APRESENTAR

“Antes de começar, duas regras. As datas são as do histórico do projeto; quando um trabalho foi feito antes de ser registrado, eu uso a data do documento e digo qual é. E nenhum número foi digitado: todos saem das tabelas das análises. Se precisarem conferir qualquer item, as anotações deste deck trazem a fonte e o registro de cada um.”

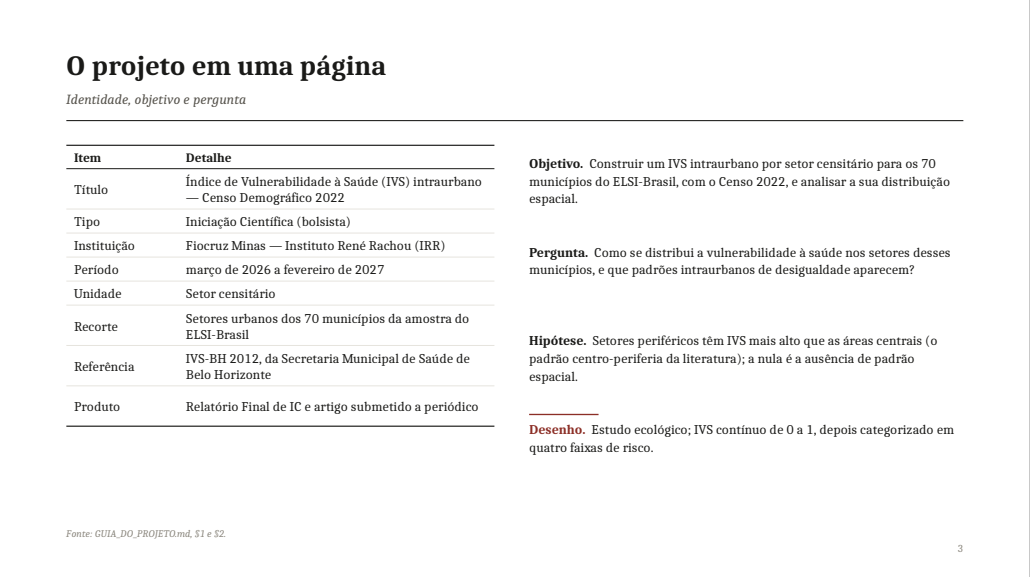
SE PERGUNTAREM

O que é um "capítulo" e o que é uma "leitura transversal"?

Os capítulos contam o tempo: março a maio, junho, julho e agosto, e assim por diante. As leituras transversais cortam o tempo por tema: todas as decisões de método juntas, todos os achados juntos, toda a organização junta.

CRONOLOGIA · SLIDE 3

O projeto em uma página



O projeto em uma página

Identidade, objetivo e pergunta

Item	Detalhe
Título	Índice de Vulnerabilidade à Saúde (IVS) intraurbano — Censo Demográfico 2022
Tipo	Iniciação Científica (bolsista)
Instituição	Fiocruz Minas — Instituto René Rachou (IRR)
Período	março de 2026 a fevereiro de 2027
Unidade	Setor censitário
Recorte	Setores urbanos dos 70 municípios da amostra do ELSI-Brasil
Referência	IVS-BH 2012, da Secretaria Municipal de Saúde de Belo Horizonte
Produto	Relatório Final de IC e artigo submetido a periódico

Objetivo. Construir um IVS intraurbano por setor censitário para os 70 municípios do ELSI-Brasil, com o Censo 2022, e analisar a sua distribuição espacial.

Pergunta. Como se distribui a vulnerabilidade à saúde nos setores desses municípios, e que padrões intraurbanos de desigualdade aparecem?

Hipótese. Setores periféricos têm IVS mais alto que as áreas centrais (o padrão centro-periferia da literatura); a nula é a ausência de padrão espacial.

Desenho. Estudo ecológico; IVS contínuo de 0 a 1, depois categorizado em quatro faixas de risco.

Fonte: GUIA_DO_PROJETO.md, §1 e §2.

3

Quem, onde, quando, o quê e para quê: a identidade do projeto, o objetivo, a pergunta, a hipótese e o desenho do estudo.

O QUE APARECE NO SLIDE

À esquerda, uma tabela de oito linhas: título, tipo (Iniciação Científica), instituição (Fiocruz Minas — Instituto René Rachou), período (março de 2026 a fevereiro de 2027), unidade (setor censitário), recorte (setores urbanos dos 70 municípios do ELSI-Brasil), referência (IVS-BH 2012) e produto (relatório final e artigo). À direita, quatro blocos: objetivo, pergunta, hipótese e desenho — este último com o filete vermelho.

O QUE ISSO QUER DIZER, DO ZERO

- **IVS intraurbano**: um índice que compara pedaços de uma mesma cidade (Parte A, A.1).
- **Setor censitário**: a menor área com dados do Censo, em geral poucos quarteirões (A.2).
- **ELSI-Brasil**: o estudo de saúde dos idosos cujos 70 municípios definem o recorte (A.3).
- **IVS-BH 2012**: o índice de Belo Horizonte, feito com o Censo de 2010, que serve de modelo de método.
- **Hipótese**: a resposta que se espera encontrar. Aqui, que setores da periferia tenham IVS mais alto que os do centro — o "padrão centro-periferia" descrito em estudos de cidades brasileiras. A **hipótese nula** é a ausência de padrão: se os dados não mostrarem diferença, fica-se com ela.
- **Estudo ecológico**: um estudo em que a unidade é um grupo (aqui, o setor), e não a pessoa. Ele permite dizer que um *setor* é vulnerável, mas não que cada pessoa dele é. Tirar conclusões individuais de dados de grupo é um erro conhecido, a *falácia ecológica*.
- **Quatro faixas de risco**: baixo, médio, elevado e muito elevado (A.5).

COMO APRESENTAR

“O projeto constrói um índice de vulnerabilidade à saúde para cada setor censitário urbano dos 70 municípios do ELSI-Brasil, com o Censo de 2022, seguindo o método do IVS de Belo Horizonte de 2012. A pergunta é como essa vulnerabilidade se distribui dentro das cidades; a expectativa é encontrar o padrão centro-periferia. É um estudo ecológico: falamos de lugares, não de pessoas.”

SE PERGUNTAREM

Por que só setores urbanos?

Porque o índice é intraurbano — compara pedaços de cidade — e porque as variáveis de saneamento têm outro significado no campo (lá, poço e fossa podem ser a solução adequada).

O índice vai dizer quem está doente?

Não. Ele mede as condições do lugar que expõem as pessoas a adoecer. Para falar de pessoas, é preciso cruzar com dados individuais, como os do ELSI-Brasil.

CRONOLOGIA · SLIDE 4

Os dados: oito arquivos do Censo 2022



Os dados: oito arquivos do Censo 2022

Agregados por setor censitário, publicados pelo IBGE

Arquivo (Agregados por Setores, Censo 2022)	Dimensão	Variáveis-chave
…_basico_BR_20250417.csv	Identificação e população	CD_SETOR, NM_MUN, v0001, v0005
…_caracteristicas_domicilio1_BR.csv	Denominador habitacional	V00001, V00002, V00005, V00006
…_caracteristicas_domicilio2_BR_20250417.csv	Saneamento	Água, esgoto, lixo, banheiro
…_alfabetizacao_BR.csv	Educação	V00900 (sabe ler, 15+), V00901 (não sabe, 15+)
…_cor_ou_raca_BR.csv	Cor ou raça	V01318, V01320, V01321
…_renda_responsavel_BR.csv	Renda	V06004 (rendimento médio mensal do responsável)
…_demografia_BR.csv	Idade	V01031–V01033 (0 a 14 anos)
…_parentesco_BR.csv	Responsáveis	V01042 (o denominador abandonado em maio)

Fonte: GUIA_DO_PROJETO.md, §7 (os 8 arquivos-fonte).

4

De onde vêm os dados: oito arquivos do IBGE, um por tema, todos com contagens por setor censitário.

O QUE APARECE NO SLIDE

Uma tabela de oito linhas, uma por arquivo. A primeira coluna tem o nome do arquivo (abreviado com "…" no começo, porque os nomes completos são longos), a segunda o tema e a terceira as variáveis mais importantes daquele arquivo. A última linha, a do arquivo de parentesco, traz a observação "o denominador abandonado em maio".

O QUE ISSO QUER DIZER, DO ZERO

O IBGE publica os dados do Censo por setor em arquivos separados por tema, como capítulos de um livro:

- **básico**: o código do setor (`CD_SETOR`), o nome do município (`NM_MUN`) e a população;
- **características do domicílio 1**: os totais de domicílios e de moradores (`V00001`, `V00002`, `V00005`, `V00006`) — os denominadores;
- **características do domicílio 2**: água, esgoto, lixo e banheiro — o saneamento;

- **alfabetização**: quem sabe (`V00900`) e quem não sabe (`V00901`) ler e escrever, entre as pessoas de 15 anos ou mais;
- **cor ou raça**: as contagens de pessoas por cor ou raça (`V01318`, `V01320`, `V01321`) — no índice, pretos, pardos e indígenas;
- **renda do responsável**: `V06004`, o rendimento médio mensal da pessoa responsável pelo domicílio;
- **demografia**: as idades, usadas nos indicadores de envelhecimento;
- **parentesco**: a relação de cada morador com o responsável. Dele vinha `V01042`, o número de responsáveis, que foi o primeiro denominador do projeto e foi trocado em maio (slide 11).

Todos os arquivos usam o mesmo código de setor, e é por ele que são juntados numa tabela só.

COMO APRESENTAR

"Tudo vem de oito arquivos do Censo de 2022, publicados pelo IBGE por setor censitário. Eles são juntados pelo código do setor. A linha de baixo lembra uma mudança importante de maio: o denominador deixou de vir do arquivo de parentesco."

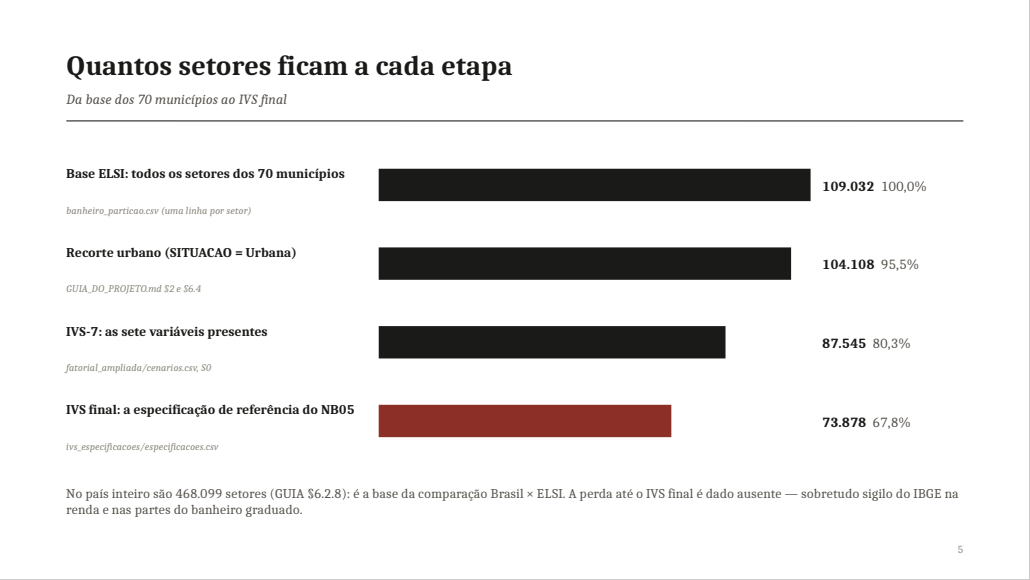
SE PERGUNTAREM

Os dados são das pessoas ou dos setores?

Dos setores. O IBGE não publica respostas individuais: publica contagens por setor, e o índice é calculado para cada setor.

CRONOLOGIA · SLIDE 5

Quantos setores ficam a cada etapa



Da base inteira dos 70 municípios ao IVS final, quantos setores sobram a cada filtro — de 109.032 a 73.878.

O QUE APARECE NO SLIDE

Quatro barras horizontais, uma por etapa, com o número de setores e a porcentagem em relação à base. Debaixo de cada rótulo, em cinza, o arquivo de onde o número saiu. As três primeiras barras são pretas; a última, a do IVS final, é vermelha. No pé, uma frase lembra que o Brasil inteiro tem 468.099 setores e que a perda até o IVS final é dado ausente.

As etapas: a base com todos os setores dos 70 municípios (109.032, 100%); o recorte urbano (104.108); o IVS-7 com as sete variáveis presentes (87.545); e a especificação de referência do IVS final (73.878).

O QUE ISSO QUER DIZER, DO ZERO

Cada etapa é um filtro, como peneiras cada vez mais finas:

- **base ELSI**: todos os setores dos 70 municípios, urbanos e rurais;
- **recorte urbano**: só os setores que o IBGE classifica como urbanos (A.3);
- **IVS-7**: só os setores em que os sete indicadores do índice existem ao mesmo tempo. Basta um deles estar sob sigilo para o setor sair;
- **IVS final**: só os setores com todas as variáveis da especificação de referência do NB05 — que inclui as partes do banheiro graduado, com mais sigilo.

A perda não é um defeito do método: é a consequência de tratar o sigilo como dado ausente, e não como zero (A.2).

COMO LER OS NÚMEROS

A porcentagem ao lado de cada número é em relação à base: o IVS-7 fica com cerca de quatro em cada cinco setores; a referência do IVS final, com cerca de dois em cada três (73.878 setores). Os 468.099 setores do país aparecem só em texto, porque são a base de comparação "Brasil × ELSI" e não passam pelos filtros.

COMO APRESENTAR

“A base tem 109.032 setores. Ficam os urbanos, depois só os que têm todos os indicadores, e a especificação de referência do IVS final cobre 73.878. O que se perde no caminho é dado sob sigilo do IBGE, que nós tratamos como ausente — nunca como zero.”

> **SE PERGUNTAREM**
>
> **Perder um terço dos setores não enviesa o índice?**
>
> Pode enviesar, e por isso o número está à vista. O sigilo cai mais onde as contagens são pequenas. Os decks comparam as versões numa amostra comum de setores justamente para que a comparação não dependa de quem perdeu mais.

CRONOLOGIA · SLIDE 6

A linha do tempo em uma página



A linha do tempo em uma página

Os marcos de cada mês; o número abaixo do mês é o de commits

Março e abril	Maio	Junho	Julho	Agosto	Set. 1–17	Set. 18–30	Outubro
4 commits	29 commits	25 commits	1 commit	10 commits	29 commits	68 commits	1 commit
12/3 Repositório e a primeira pipeline	06 Fase 2: o fluxo multidimensional	12 EDA refeita com V00001	08 Primeiro grafo do projeto	09 Demandas de julho feitas	02 Auditoria; renda sem o extremo	25 Revisão geral; demandas de setembro	01 O grafo lê os documentos; branch main
16/3 Auditoria em SQLite	14 O GUIA do projeto	18 Indicadores novos; a caçamba	Sete demandas da orientadora	20 Módulo src/ivs_censo	13 O livro da Enap	26 V00237: banheiro graduado	05 Estas apresentações
25/3 Variáveis multidimensionais	15 Fase 3: filtro ELSI e a 1ª EDA	19 Pipeline comentada		21 Água pelo V00199; EDA Central	17 NB04: a fatorial; auditoria integral	27 NB05: o IVS final	
abr Inserção no IRR e curso introdutório	22 Denominador V00001			24 1º diagnóstico fatorial		30 Estrutura do deck consertada	
	25 Bases à orientadora						

Fonte: git log (commits por período); sem commit: GUIA_DO_PROJETO.md §6.4 e §11; graphify-out/cost.json.

6

> *O projeto inteiro numa folha: uma coluna por mês, com os marcos principais e o número de commits de cada período.*

O QUE APARECE NO SLIDE

Oito colunas, da esquerda para a direita: março e abril, maio, junho, julho, agosto, setembro (dias 1 a 17), setembro (dias 18 a 30) e outubro. No alto de cada coluna, o nome do período e, embaixo, o número de commits: 4, 29, 25, 1, 10, 29, 68 e 1. Debaixo de uma régua preta vêm os marcos, cada um com o dia em vermelho. Setembro foi partido em dois porque concentra quase metade do histórico.

O QUE ISSO QUER DIZER, DO ZERO

É o resumo visual dos sete capítulos que vêm depois. Alguns marcos para guardar:

- **maio**: o projeto se reorganiza (Fase 2), ganha o documento mestre (o GUIA) e começa a Fase 3, a atual, com o filtro dos 70 municípios. No dia 22, troca o denominador;
- **junho**: a análise descritiva cresce, com indicadores novos e a decisão sobre a caçamba de lixo;
- **julho e agosto**: as sete demandas de julho, o módulo de fórmulas compartilhado e a primeira análise fatorial;
- **setembro**: a auditoria de agosto, a renda sem o valor extremo, a análise fatorial completa (NB04), a revisão geral e as demandas de setembro, e o IVS final (NB05);
- **outubro**: o grafo do projeto e estas apresentações.

Abril não tem commit: é o mês do Programa de Inserção do IRR e do curso introdutório, atividades do cronograma do bolsista que não passam pelo repositório.

COMO APRESENTAR

“Esta é a linha do tempo em uma página. Maio é a reorganização; junho, a análise descritiva; julho e agosto, as primeiras demandas da orientadora e o código compartilhado; setembro, a análise fatorial e o IVS final. Os números embaixo de cada mês mostram onde o trabalho se concentrou.”

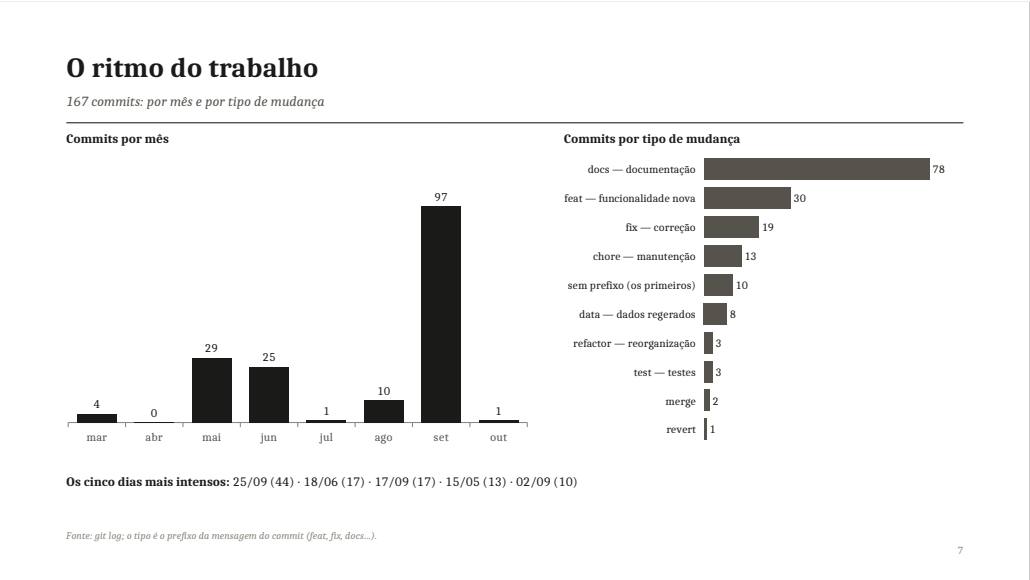
SE PERGUNTAREM

Por que julho tem só um commit?

Porque as demandas de julho foram trabalhadas em julho e começo de agosto e registradas no git só em 20 e 21/08. O commit de julho é o do primeiro grafo do projeto.

CRONOLOGIA · SLIDE 7

O ritmo do trabalho



Dois gráficos de barras: quantos commits por mês e de que tipo — e os cinco dias mais intensos.

O QUE APARECE NO SLIDE

À esquerda, um gráfico de colunas com os commits de cada mês, de março a outubro, com o número em cima de cada coluna. À direita, um gráfico de barras deitadas com os commits por tipo de mudança, do mais frequente para o menos frequente: documentação (78), funcionalidade nova (30), correção (19), manutenção (13), sem prefixo (10), dados regerados (8) e os demais. Embaixo, uma linha com os cinco dias de mais commits: 25/09 (44) · 18/06 (17) · 17/09 (17) · 15/05 (13) · 02/09 (10).

O QUE ISSO QUER DIZER, DO ZERO

O **tipo** de cada commit vem do prefixo da mensagem (A.10): `docs` é documentação, `feat` é coisa nova, `fix` é correção, `chore` é manutenção, `data` é dado regerado, `test` é teste, `refactor` é reorganização. Os primeiros commits, de março, ainda não usavam prefixo — por isso a barra "sem prefixo".

Ler um gráfico de colunas é simples: a altura da coluna é a quantidade. A coluna de setembro é de longe a mais alta. O gráfico da direita mostra que a maior parte do trabalho registrado é documentação: relatórios, guias, registros de decisão. Isso é coerente com um projeto em que cada decisão de método precisa ficar escrita e justificada.

COMO LER OS NÚMEROS

O dia mais intenso, 25/09, tem 44 commits: é o dia em que a revisão geral do repositório e as demandas de setembro foram executadas, em seis fases (capítulo 5). Os outros picos — 18/06, 17/09, 15/05 e 02/09 — são os dias de entrega de cada etapa: a análise descritiva ampliada, a análise fatorial, o começo da Fase 3 e a auditoria de agosto.

COMO APRESENTAR

“O ritmo não foi uniforme: o trabalho vem em ondas, e cada pico é uma entrega. Setembro concentra quase metade dos registros. E a maior parte dos registros é documentação, porque cada decisão de método fica escrita, com a justificativa, antes de virar número.”

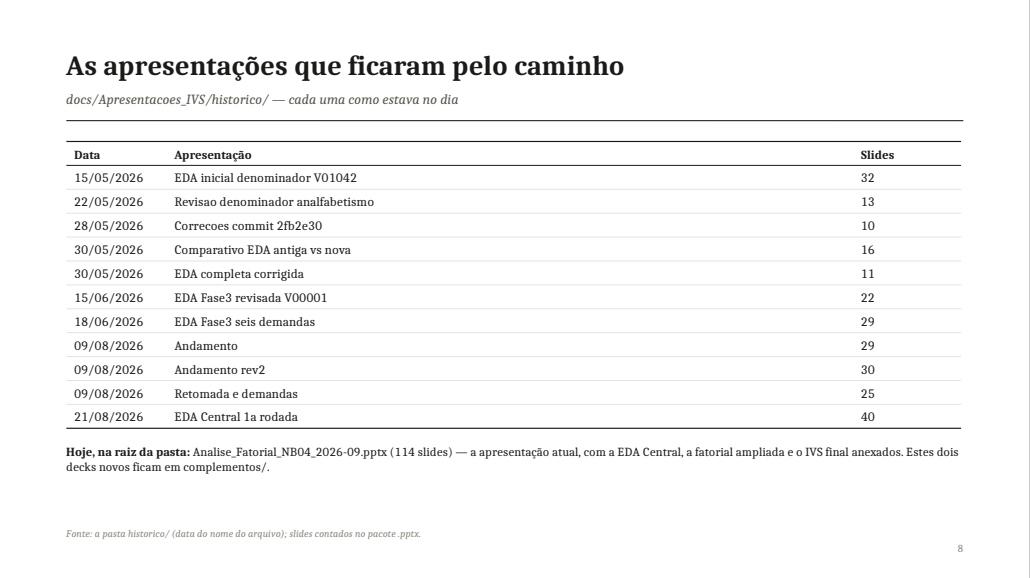
SE PERGUNTAREM

Muito commit num dia não é sinal de pressa?

Não necessariamente: cada commit é uma mudança pequena e com um tema só, para que dê para voltar atrás em cada uma separadamente. Muitos commits num dia é sinal de trabalho bem fatiado.

CRONOLOGIA · SLIDE 8

As apresentações que ficaram pelo caminho



As apresentações que ficaram pelo caminho

docs/Apresentacoes_IVS/historico/ — cada uma como estava no dia

Data	Apresentação	Slides
15/05/2026	EDA inicial denominador V01042	32
22/05/2026	Revisao denominador analfabetismo	13
28/05/2026	Correcoes commit 2fb2e30	10
30/05/2026	Comparativo EDA antiga vs nova	16
30/05/2026	EDA completa corrigida	11
15/06/2026	EDA Fase3 revisada V00001	22
18/06/2026	EDA Fase3 seis demandas	29
09/08/2026	Andamento	29
09/08/2026	Andamento rev2	30
09/08/2026	Retomada e demandas	25
21/08/2026	EDA Central 1a rodada	40

Hoje, na raiz da pasta: Analise_Fatorial_NB04_2026-09.pptx (114 slides) — a apresentação atual, com a EDA Central, a fatorial ampliada e o IVS final anexados. Estes dois decks novos ficam em complementos/.

Fonte: a pasta historico/ (data do nome do arquivo); slides contados no pacote .pptx.

8

As 11 apresentações antigas, guardadas como estavam no dia em que foram mostradas — e qual é a atual.

O QUE APARECE NO SLIDE

Uma tabela com três colunas: a data, o nome da apresentação e o número de slides. São os decks da pasta `historico/`, de 15/05 a 21/08. Embaixo, um parágrafo diz qual é a apresentação atual: o deck da análise fatorial, na raiz da pasta, com 114 slides — com a EDA Central, a fatorial ampliada e o IVS final anexados — e que os dois decks novos ficam em `complementos/`.

O QUE ISSO QUER DIZER, DO ZERO

Cada deck antigo é uma fotografia do projeto num momento. O de 15/05 ainda usa o denominador antigo (`V01042`); o de 22/05 apresenta a troca; os de 28 e 30/05 mostram as correções e comparam a análise antiga com a nova; os de junho trazem a análise descritiva refeita; os de 09/08 são a retomada e o andamento das demandas de julho; o de 21/08 é a primeira rodada da EDA Central.

Eles não são apagados nem regerados porque são o registro do que foi efetivamente apresentado. A regra da pasta é ter **um arquivo só na raiz** — a apresentação atual —, para que ninguém abra uma versão velha por engano. Os de apoio vão para `complementos/`; os que saíram de circulação, para `historico/`.

COMO APRESENTAR

“Estas são as apresentações que já foram feitas, guardadas como estavam. Não uso nenhuma delas como fonte de número: os números de hoje são os do deck atual e destes dois novos.”

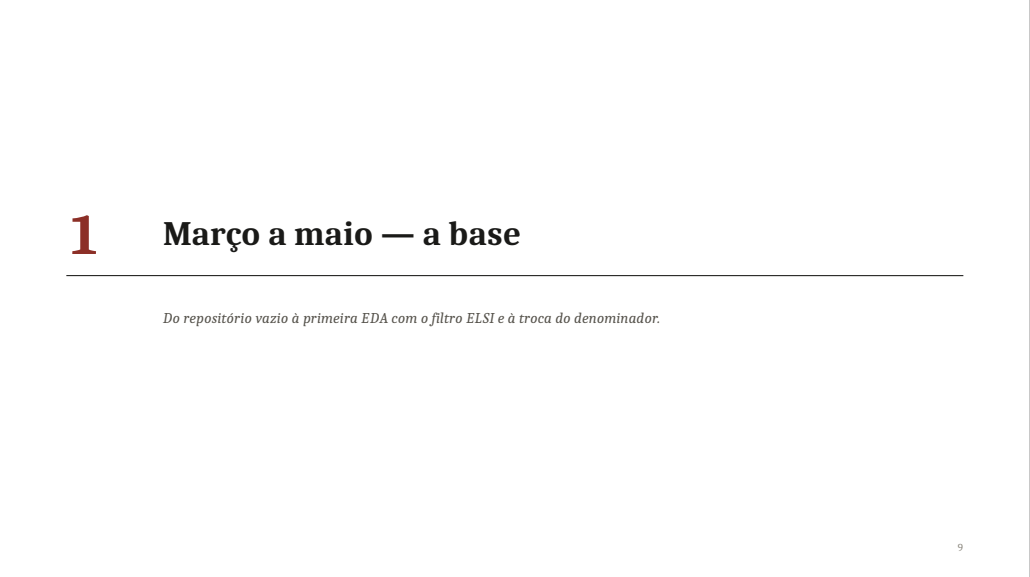
SE PERGUNTAREM

Por que não atualizar os decks antigos?

Porque eles registram o que foi mostrado em cada data. Atualizá-los apagaria a história — e um número antigo num deck antigo não engana ninguém, desde que fique claro que é histórico.

CRONOLOGIA · SLIDE 9

Março a maio — a base



A divisória do capítulo 1: os três primeiros meses, do repositório vazio à primeira análise com o filtro dos 70 municípios.

O QUE APARECE NO SLIDE

Um slide de divisória: o número 1, grande e em vermelho, o título "Março a maio — a base" e, embaixo de uma régua, o subtítulo: do repositório vazio à primeira EDA com o filtro ELSI e à troca do denominador.

O QUE ISSO QUER DIZER, DO ZERO

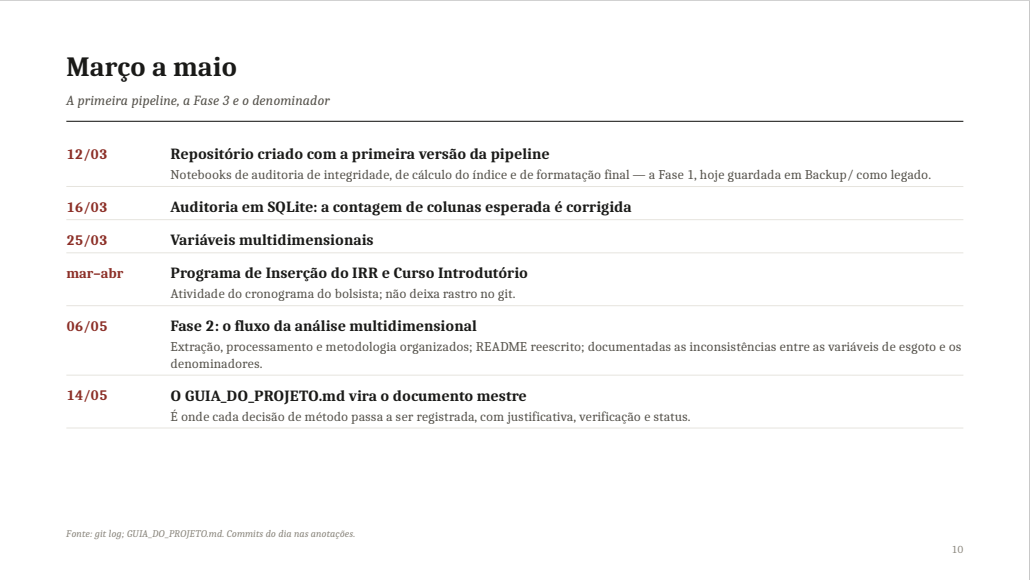
As divisórias marcam o começo de cada capítulo e não têm dados. Este capítulo cobre o período em que o projeto ganhou forma: as primeiras versões da análise (as Fases 1 e 2, hoje no `Backup/`), o documento mestre, a Fase 3 — a que vale hoje — e a primeira grande correção de método, a do denominador.

COMO APRESENTAR

“O primeiro capítulo vai de março a maio: é quando o projeto ganha a forma atual.”

CRONOLOGIA · SLIDE 10

Março a maio



Março a maio

A primeira pipeline, a Fase 3 e o denominador

12/03	**Repositório criado com a primeira versão da pipeline** Notebooks de auditoria de integridade, de cálculo do índice e de formatação final — a Fase 1, hoje guardada em Backup/ como legado.
16/03	**Auditoria em SQLite: a contagem de colunas esperada é corrigida**
25/03	**Variáveis multidimensionais**
mar–abr	**Programa de Inserção do IRR e Curso Introdutório** Atividade do cronograma do bolsista; não deixa rastro no git.
06/05	**Fase 2: o fluxo da análise multidimensional** Extração, processamento e metodologia organizados; README reescrito; documentadas as inconsistências entre as variáveis de esgoto e os denominadores.
14/05	**O GUIA_DO_PROJETO.md vira o documento mestre** É onde cada decisão de método passa a ser registrada, com justificativa, verificação e status.

Fonte: git log; GUIA_DO_PROJETO.md. Commits do dia nas anotações.

10

> *As primeiras versões da análise, o programa de inserção na Fiocruz e a reorganização de maio, com o documento mestre.*

O QUE APARECE NO SLIDE

Uma página de diário com seis entradas: 12/03 (repositório criado com a primeira versão da pipeline), 16/03 (auditoria em SQLite), 25/03 (variáveis multidimensionais), "mar–abr" (Programa de Inserção do IRR e Curso Introdutório), 06/05 (Fase 2) e 14/05 (o GUIA do projeto vira o documento mestre).

O QUE ISSO QUER DIZER, DO ZERO

- **12/03 — o começo**. O repositório nasce com três notebooks: um de *auditoria de integridade* (conferir se os dados chegaram completos e coerentes — se as somas batem, se não há setor duplicado), um de cálculo do índice e um de formatação final. Essa é a **Fase 1**. Uma **pipeline** é a sequência de etapas que leva o dado bruto ao resultado.
- **16/03 — SQLite**. SQLite é um banco de dados guardado num arquivo só. A auditoria conferia, entre outras coisas, se a tabela tinha o número esperado de colunas; o número esperado estava errado e foi corrigido.
- **25/03 — variáveis multidimensionais**. O começo do trabalho com as variáveis de várias dimensões (saneamento, renda, educação…).
- **março e abril — inserção no IRR**. O programa de entrada do bolsista no instituto e o curso introdutório. Não passa pelo repositório, mas é parte do cronograma.
- **06/05 — Fase 2**. O projeto organiza o fluxo da análise em extração, processamento e metodologia, reescreve o README (o texto de apresentação do repositório) e documenta inconsistências internas: variáveis de esgoto e denominadores que não batiam entre si.
- **14/05 — o GUIA**. Nasce o `GUIA_DO_PROJETO.md`, o documento mestre onde cada decisão de método passa a ser registrada com a justificativa, a verificação e o status. Boa parte das datas e decisões citadas nestes decks vêm dele.

COMO APRESENTAR

“O repositório começa em março com uma primeira versão da análise. Em maio, o projeto se reorganiza e ganha um documento mestre, o GUIA, onde toda decisão de método passa a ser registrada com justificativa. É esse registro que permite reconstruir tudo o que vem depois.”

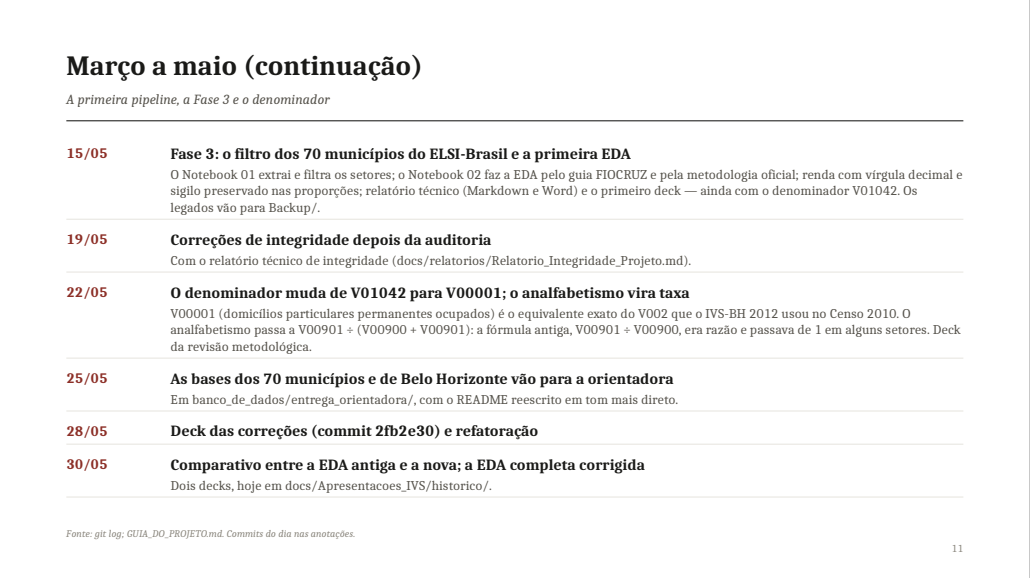
SE PERGUNTAREM

O que aconteceu com as Fases 1 e 2?

Foram substituídas pela Fase 3, a partir de 15/05, e guardadas na pasta Backup/ como histórico. A principal diferença é que a Fase 3 aplica o recorte dos 70 municípios desde o início.

CRONOLOGIA · SLIDE 11

Março a maio (continuação)



Março a maio (continuação)

A primeira pipeline, a Fase 3 e o denominador

15/05	**Fase 3: o filtro dos 70 municípios do ELSI-Brasil e a primeira EDA** O Notebook 01 extrai e filtra os setores; o Notebook 02 faz a EDA pelo guia FIOCRUZ e pela metodologia oficial; renda com vírgula decimal e sigilo preservado nas proporções; relatório técnico (Markdown e Word) e o primeiro deck — ainda com o denominador V01042. Os legados vão para Backup/.
19/05	**Correções de integridade depois da auditoria** Com o relatório técnico de integridade (docs/relatorios/Relatorio_Integridade_Projeto.md).
22/05	**O denominador muda de V01042 para V00001; o analfabetismo vira taxa** V00001 (domicílios particulares permanentes ocupados) é o equivalente exato do V002 que o IVS-BH 2012 usou no Censo 2010. O analfabetismo passa a V00901 ÷ (V00900 + V00901): a fórmula antiga, V00901 ÷ V00900, era razão e passava de 1 em alguns setores. Deck da revisão metodológica.
25/05	**As bases dos 70 municípios e de Belo Horizonte vão para a orientadora** Em banco_de_dados/entrega_orientadora/, com o README reescrito em tom mais direto.
28/05	**Deck das correções (commit 2fb2e30) e refatoração**
30/05	**Comparativo entre a EDA antiga e a nova; a EDA completa corrigida** Dois decks, hoje em docs/Apresentacoes_IVS/historico/.

Fonte: git log; GUIA_DO_PROJETO.md. Commits do dia nas anotações.

11

Maio decisivo: a Fase 3 começa, a primeira análise descritiva sai, o denominador é corrigido e as bases vão para a orientadora.

O QUE APARECE NO SLIDE

A continuação do diário, com seis entradas: 15/05 (a Fase 3 e a primeira EDA), 19/05 (correções de integridade depois da auditoria), 22/05 (a troca do denominador e a correção do analfabetismo), 25/05 (as bases entregues à orientadora), 28/05 (o deck das correções) e 30/05 (o comparativo entre a análise antiga e a nova).

O QUE ISSO QUER DIZER, DO ZERO

- **15/05 — a Fase 3**. É o dia mais intenso de maio. O Notebook 01 (NB01) extrai os dados e filtra os setores dos 70 municípios do ELSI-Brasil; o Notebook 02 (NB02) faz a primeira **EDA** — a análise exploratória: médias, distribuições, correlações, comparações entre regiões —, seguindo o guia de análises da Fiocruz e a metodologia oficial. Dois cuidados técnicos aparecem: a renda vinha com vírgula decimal (o padrão brasileiro), que o computador lia errado se não fosse avisado; e o sigilo foi preservado nas proporções (A.2). Saem um relatório técnico e o primeiro deck — ainda com o denominador antigo. As versões anteriores vão para o `Backup/`.
- **19/05 — integridade**. Uma auditoria aponta problemas e eles são corrigidos; o relatório de integridade registra o quê.
- **22/05 — o denominador**. A decisão mais importante do capítulo. O denominador dos indicadores de domicílio passa de `V01042` (número de *responsáveis*, do arquivo de parentesco) para `V00001` (número de *domicílios* particulares permanentes ocupados). O motivo: `V00001` é o equivalente, no Censo de 2022, do `V002` que o IVS-BH 2012 usou em 2010 — e só com a mesma unidade os dois índices são comparáveis. No mesmo dia, o analfabetismo deixa de ser uma *razão* (analfabetos ÷ alfabetizados, que passava de 1 em

alguns setores) e vira *taxa* (analfabetos ÷ todas as pessoas de 15 anos ou mais) — veja A.4.

- **25/05 — a entrega**. As bases dos 70 municípios e de Belo Horizonte vão para a orientadora, na pasta `entrega_orientadora/`.
- **28 e 30/05 — as correções apresentadas**. Um deck com as correções e dois que comparam a análise antiga com a nova e mostram a análise completa corrigida.

COMO APRESENTAR

"Em 15 de maio começa a Fase 3, a atual: o filtro dos 70 municípios e a primeira análise descritiva. Uma semana depois vem a correção mais importante do começo do projeto: o denominador passa a ser o número de domicílios, como no IVS de Belo Horizonte, e o analfabetismo passa a ser uma taxa de verdade. No fim do mês, as bases vão para a orientadora."

SE PERGUNTAREM

Qual era o problema com V01042?

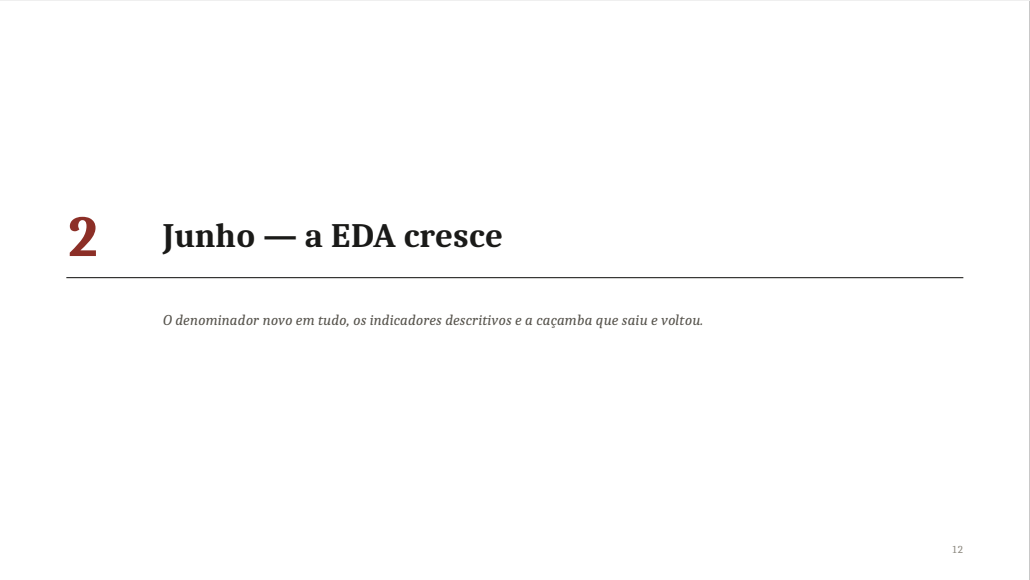
Ele conta responsáveis (pessoas), e não domicílios. O IVS-BH 2012 dividia por domicílios; para que os dois índices sejam comparáveis, o denominador tem de ser a mesma coisa.

Como a taxa de analfabetismo podia passar de 1?

Porque a fórmula antiga dividia analfabetos por alfabetizados. Num setor com mais analfabetos do que alfabetizados, essa razão passa de 1. A taxa divide pelo total de pessoas de 15 anos ou mais, e nunca passa de 1.

CRONOLOGIA · SLIDE 12

Junho — a EDA cresce



A divisória do capítulo 2: junho, quando a análise descritiva é refeita com o denominador novo e ganha indicadores.

O QUE APARECE NO SLIDE

O número 2 em vermelho, o título "Junho — a EDA cresce" e o subtítulo: o denominador novo em tudo, os indicadores descritivos e a caçamba que saiu e voltou.

O QUE ISSO QUER DIZER, DO ZERO

Junho é o mês de consolidar a análise descritiva (a EDA). Três assuntos: propagar o denominador novo para todos os resultados, criar indicadores que descrevem o território sem entrar no índice, e decidir o que fazer

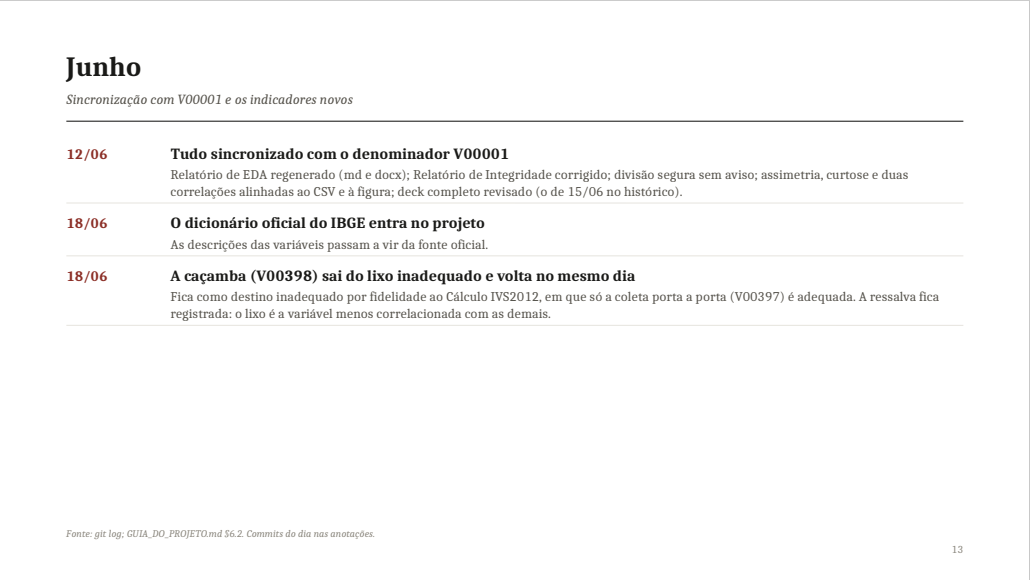
com a caçamba de lixo.

COMO APRESENTAR

“O segundo capítulo é junho: a análise descritiva cresce e uma decisão de método é tomada duas vezes no mesmo dia.”

CRONOLOGIA · SLIDE 13

Junho



> *Tudo é refeito com o denominador novo, o dicionário oficial do IBGE entra no projeto e a caçamba de lixo gera uma decisão de fidelidade ao método.*

O QUE APARECE NO SLIDE

Três entradas: 12/06 (tudo sincronizado com o denominador `V00001`), 18/06 (o dicionário oficial do IBGE) e 18/06 (a caçamba sai do lixo inadequado e volta no mesmo dia).

O QUE ISSO QUER DIZER, DO ZERO

- **12/06 — sincronizar**. Depois da troca do denominador, todos os produtos precisam ser refeitos: o relatório da EDA (em Markdown e em Word), o relatório de integridade, o deck. Duas correções técnicas entram junto: uma *divisão segura* (quando o denominador é zero, o resultado fica ausente, sem aviso de erro), e o alinhamento dos números de *assimetria* e *curtose* — medidas de formato de uma distribuição: a assimetria diz se os valores se acumulam de um lado; a curtose, se há muitos valores extremos — e de duas correlações, para que o texto, a tabela e o gráfico mostrassem o mesmo número.
- **18/06 — o dicionário**. O dicionário é a lista que diz o que cada código de variável significa. O oficial do IBGE passa a ser a fonte das descrições.
- **18/06 — a caçamba**. Caçamba é o contêiner comunitário onde os moradores deixam o lixo (`V00398`). Ela é destino adequado ou inadequado? No mesmo dia, a caçamba foi tirada do numerador do lixo inadequado e depois devolvida. Ficou como **inadequada**, por fidelidade ao método do IVS-BH 2012 (o documento "Cálculo IVS2012"), em que só a coleta porta a porta (`V00397`) é adequada. Mas a ressalva ficou escrita: a EDA mostrou que o lixo é a variável que menos se correlaciona com as outras.

COMO APRESENTAR

“Em junho, tudo foi refeito com o denominador novo. E houve uma decisão típica do projeto: a caçamba de lixo foi mantida como destino inadequado porque é assim no método de Belo Horizonte — mesmo com

indícios de que isso torna o lixo uma variável à parte. A decisão é de fidelidade; o indício ficou registrado e voltou em setembro.”

SE PERGUNTAREM

Por que manter a caçamba se os dados sugeriam outra coisa?

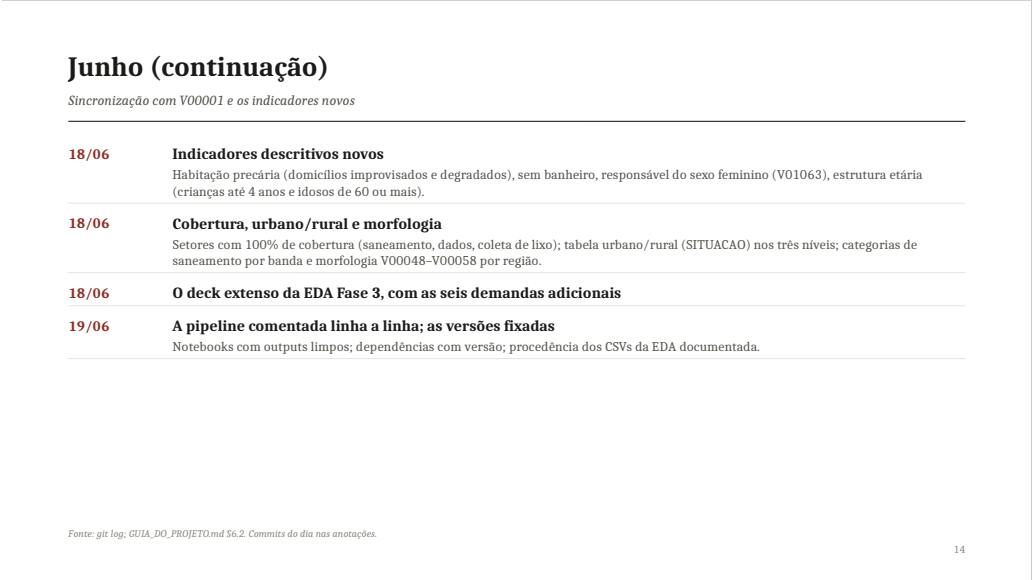
Porque o primeiro princípio do projeto é a fidelidade à metodologia de origem, o IVS-BH 2012. Mudar o método por conta própria quebraria a comparação. O indício foi registrado, e o lixo voltou a ser testado em setembro (demanda 10).

O que é o “numerador do lixo inadequado”?

A contagem de domicílios cujo lixo não tem destino adequado. Dividida pelo total de domicílios, dá a proporção de lixo inadequado do setor.

CRONOLOGIA · SLIDE 14

Junho (continuação)



Junho (continuação)

Sincronização com V00001 e os indicadores novos

18/06	**Indicadores descritivos novos**	Habitação precária (domicílios improvisados e degradados), sem banheiro, responsável do sexo feminino (V01063), estrutura etária (crianças até 4 anos e idosos de 60 ou mais).
18/06	**Cobertura, urbano/rural e morfologia**	Setores com 100% de cobertura (saneamento, dados, coleta de lixo); tabela urbano/rural (SITUACAO) nos três níveis; categorias de saneamento por banda e morfologia V00048–V00058 por região.
18/06	**O deck extenso da EDA Fase 3, com as seis demandas adicionais**	
19/06	**A pipeline comentada linha a linha; as versões fixadas**	Notebooks com outputs limpos; dependências com versão; procedência dos CSVs da EDA documentada.

Fonte: git log; GUIA_DO_PROJETO.md §6.2. Commits do dia nas anotações.

14

Indicadores que descrevem o território sem entrar no índice, tabelas de cobertura, e a pipeline comentada linha a linha.

O QUE APARECE NO SLIDE

Quatro entradas: 18/06 (indicadores descritivos novos), 18/06 (cobertura, urbano/rural e morfologia), 18/06 (o deck extenso da EDA com as seis demandas adicionais) e 19/06 (a pipeline comentada linha a linha; as versões fixadas).

O QUE ISSO QUER DIZER, DO ZERO

- **Indicadores descritivos**. Habitação precária (domicílios improvisados e degradados), falta de banheiro, domicílios chefiados por mulher (`V01063`), estrutura etária (crianças até 4 anos, idosos de 60 anos ou mais). Eles caracterizam o território, mas **não entram no índice**: um componente de índice precisa ter direção clara ("mais é pior"), e nem todos têm.
- **Cobertura**. Tabelas dos setores em que o serviço chega a 100% dos domicílios (saneamento, coleta de lixo): mostram onde a variável quase não varia.
- **Urbano/rural**. Uma tabela com a situação de cada setor, nos três níveis (setor, município, região), que preparou o recorte urbano de agosto.

- **Morfologia**. As variáveis `V00048` a `V00058` descrevem o tipo de domicílio — casa, apartamento, casa de vila ou condomínio, habitação precária… — e foram tabuladas por região.
- **O deck de 18/06**. Uma apresentação extensa da EDA, que respondia também a seis pedidos adicionais da orientadora; hoje está no `historico/`.
- **19/06 — reprodutibilidade**. Os notebooks foram comentados linha a linha e limpos de resultados antigos; as versões das bibliotecas foram fixadas (para que o mesmo código dê o mesmo resultado em outro computador); e foi documentado de onde vem cada tabela da EDA.

COMO APRESENTAR

"Junho também trouxe indicadores que descrevem o território — habitação precária, chefia feminina, idade — sem entrar no índice, porque nem todos têm uma direção clara de vulnerabilidade. E o mês fecha com a pipeline comentada e as versões fixadas: qualquer pessoa consegue refazer a análise."

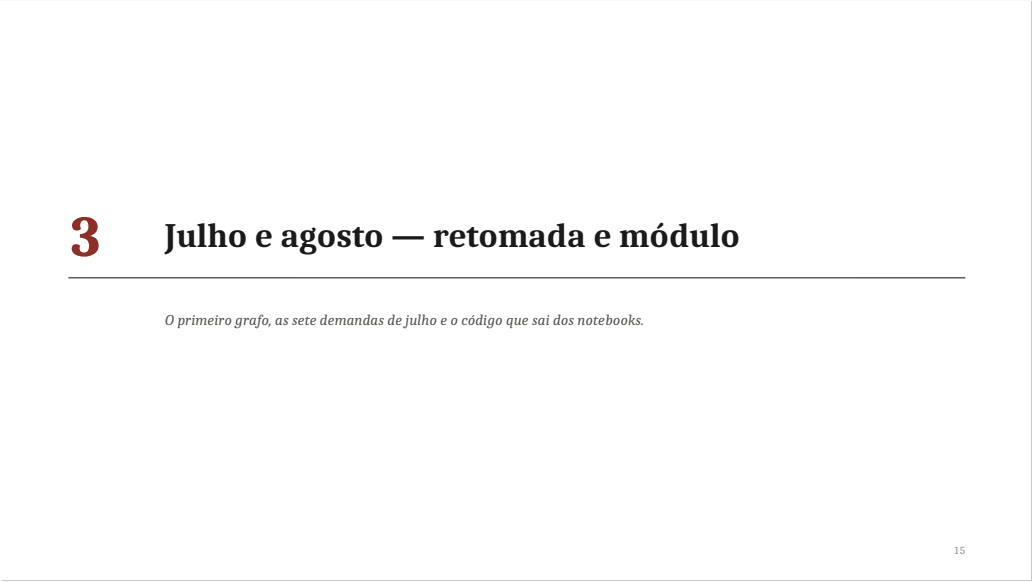
SE PERGUNTAREM

Por que um indicador sem direção não entra no índice?

Porque o índice soma coisas em que "mais é pior". O apartamento é o exemplo: há prédios de alto padrão e conjuntos habitacionais populares. Mais apartamentos não quer dizer mais vulnerabilidade.

CRONOLOGIA · SLIDE 15

Julho e agosto — retomada e módulo



A divisória do capítulo 3: as demandas de julho e o momento em que as fórmulas saem dos notebooks para um módulo compartilhado.

O QUE APARECE NO SLIDE

O número 3 em vermelho, o título "Julho e agosto — retomada e módulo" e o subtítulo: o primeiro grafo, as sete demandas de julho e o código que sai dos notebooks.

O QUE ISSO QUER DIZER, DO ZERO

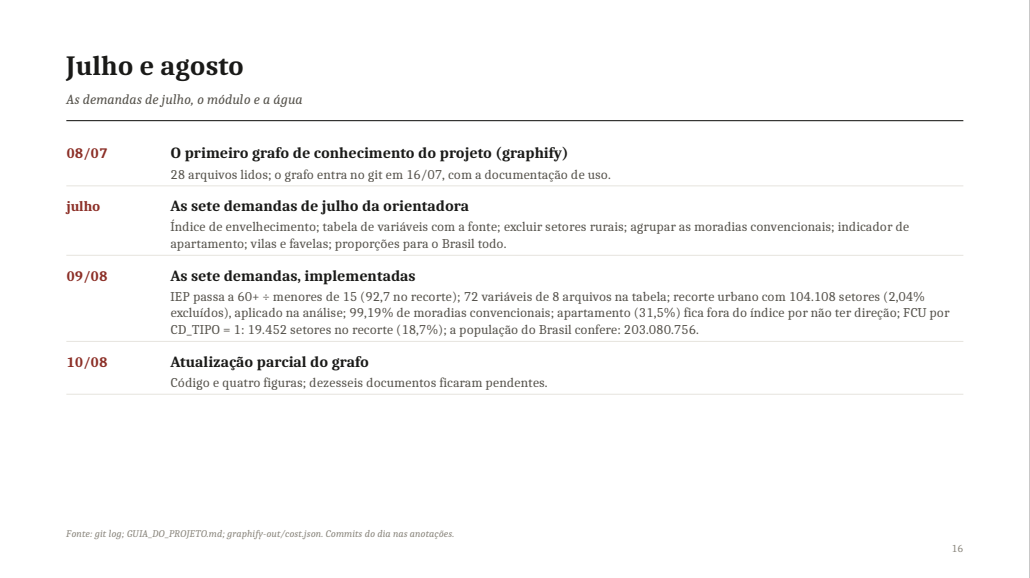
Depois de uma pausa nos registros em julho, o projeto é retomado com as sete demandas da orientadora e com uma mudança de organização importante: as fórmulas dos indicadores passam a morar num lugar só.

COMO APRESENTAR

"O terceiro capítulo cobre julho e agosto: as demandas de julho e a reorganização do código."

CRONOLOGIA · SLIDE 16

Julho e agosto



> *O primeiro grafo do projeto, as sete demandas de julho e o resultado de cada uma.*

O QUE APARECE NO SLIDE

Quatro entradas: 08/07 (o primeiro grafo de conhecimento do projeto), "julho" (as sete demandas da orientadora), 09/08 (as sete demandas implementadas, com os números de cada uma) e 10/08 (atualização parcial do grafo).

O QUE ISSO QUER DIZER, DO ZERO

- **08/07 — o grafo**. Um **grafo de conhecimento** é um mapa do projeto: cada conceito, arquivo ou função vira um ponto (um *nó*), e cada relação entre eles vira uma ligação (uma *aresta*). Serve para achar rapidamente onde cada coisa está. A primeira versão leu 28 arquivos.
- **As sete demandas de julho**: (1) ajustar o índice de envelhecimento; (2) fazer a tabela de variáveis com a fonte de cada uma; (3) excluir os setores rurais; (4) agrupar as moradias convencionais; (5) criar um indicador de apartamento; (6) contar os setores de vilas e favelas; (7) calcular as proporções para o Brasil inteiro, para comparar.
- **09/08 — os resultados**:
- o **índice de envelhecimento** (IEP) passa a ser pessoas de 60 anos ou mais ÷ menores de 15 anos, a definição usada na literatura (antes dividia por crianças de 0 a 4 anos, o que dava um número três vezes maior e incomparável); no recorte, ele vale 92,7 — 92,7 idosos para cada 100 jovens;
- a tabela de variáveis tem 72 variáveis, de 8 arquivos;
- o recorte urbano deixa 104.108 setores; 2,04% saem por serem rurais;
- 99,19% das moradias do recorte são convencionais;
- o apartamento (31,5% em média) fica **fora** do índice, por não ter direção (slide 14);
- os setores de favela e comunidade urbana passam a ser identificados pelo campo oficial `CD_TIPO = 1`: são 19.452 no recorte, 18,7% dos setores urbanos;
- a população do Brasil calculada pelo projeto confere com a oficial: 203.080.756 pessoas.
- **10/08**. O grafo é atualizado em parte: o código e quatro figuras; dezesseis documentos ficaram para depois.

COMO LER OS NÚMEROS

Quase todos os números deste slide vêm do GUIA do projeto (§6.4), porque as demandas de julho foram feitas antes de entrar no git. O de que a população do Brasil "confere" é uma verificação: somar a população de todos os setores do país dá o total oficial do Censo, sinal de que nenhum setor se perdeu na leitura.

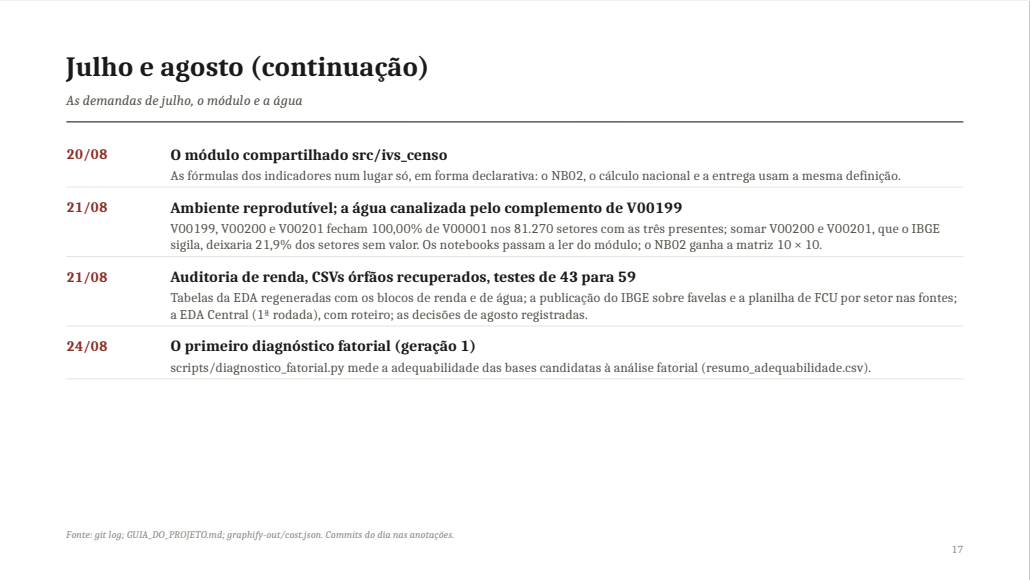
COMO APRESENTAR

“Em julho vieram sete demandas da orientadora, e em 9 de agosto as sete estavam prontas: o índice de envelhecimento pela definição da literatura, o recorte urbano, as favelas pelo campo oficial do IBGE, as proporções do Brasil inteiro. A população do país calculada por nós confere com a oficial.”

> **SE PERGUNTAREM**
>
> **Por que 19.452 favelas é um número importante?**
>
> Porque essas favelas são, depois, o padrão externo usado para validar o índice (Parte A, A.7). Quase um em cada cinco setores urbanos do recorte é favela ou comunidade urbana.

CRONOLOGIA · SLIDE 17

Julho e agosto (continuação)



> *As fórmulas vão para um módulo compartilhado, a água canalizada passa a ser medida pelo complemento e começa a análise fatorial.*

O QUE APARECE NO SLIDE

Quatro entradas: 20/08 (o módulo compartilhado `src/ivs_censo`), 21/08 (ambiente reprodutível; a água canalizada pelo complemento de `V00199`), 21/08 (auditoria de renda, tabelas órfãs recuperadas, testes de 43 para 59) e 24/08 (o primeiro diagnóstico fatorial).

O QUE ISSO QUER DIZER, DO ZERO

- **20/08 — o módulo**. Até então, a fórmula de cada indicador estava escrita dentro do notebook. Para calcular o Brasil inteiro, seria preciso copiá-la — e duas cópias divergem na primeira correção feita numa só. A solução foi um **módulo**, `src/ivs_censo`, onde cada fórmula está escrita uma vez e é usada por todos: o NB02, o cálculo do Brasil e a entrega à orientadora.
- **21/08 — a água**. O Censo divide os domicílios em três grupos: com água canalizada até dentro de casa (`V00199`), canalizada só até o terreno (`V00200`) e sem canalização (`V00201`). Os três somam o total — e isso foi conferido: fecham 100,00% nos 81.270 setores com os três presentes. O problema: `V00200` e `V00201` são

contagens pequenas e o IBGE as põe sob sigilo com frequência; somá-las deixaria 21,9% dos setores sem valor. A saída foi medir pelo **complemento**: sem água canalizada = 1 − `V00199` ÷ total (A.4).

- **21/08 — auditoria e testes**. Uma auditoria da renda; a recuperação de tabelas "órfãs" (CSVs que existiam sem que se soubesse qual programa os tinha gerado — passaram a ter um gerador conhecido); e os **testes automáticos** sobem de 43 para 59. Saem também a primeira rodada da EDA Central, com roteiro de fala, e o registro das decisões de agosto.
- **24/08 — a análise fatorial começa**. O script `diagnostico_fatorial.py` mede se as bases candidatas servem para análise fatorial (KMO, MSA, Bartlett — A.6). É a "geração 1" das saídas de fatorial.

COMO APRESENTAR

“Em agosto, o código ganha uma regra que vale até hoje: cada fórmula existe uma vez só, num módulo compartilhado. A água canalizada passa a ser medida pelo complemento, para não perder um quinto dos setores por sigilo. E no dia 24 começa a análise fatorial.”

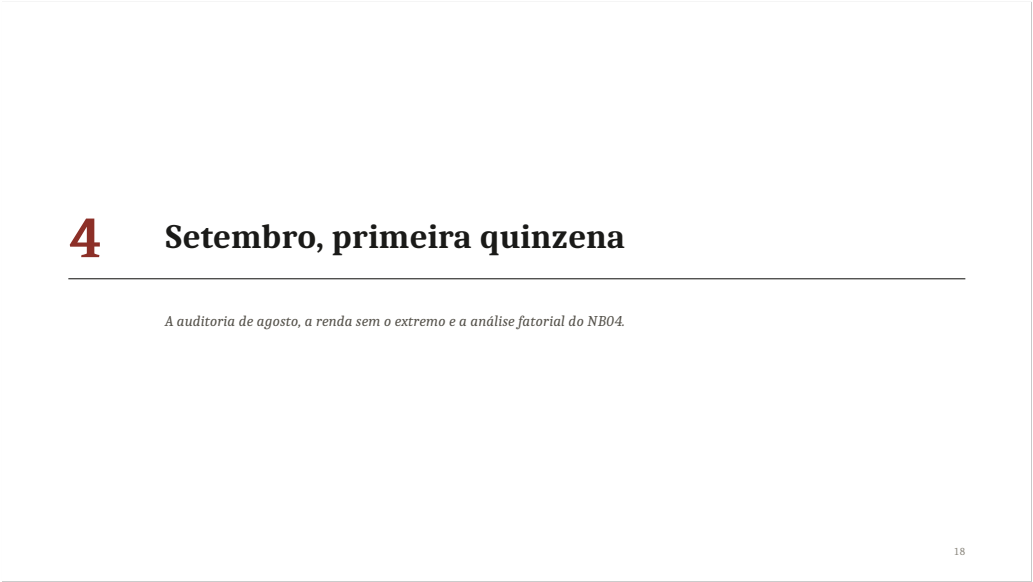
SE PERGUNTAREM

Por que medir pelo complemento não muda o resultado?

Porque as três variáveis somam exatamente o total. Medir “quem não tem” diretamente ou como “total menos quem tem” dá o mesmo número; a diferença é que o segundo jeito quase nunca esbarra no sigilo.

CRONOLOGIA · SLIDE 18

Setembro, primeira quinzena



> *A divisória do capítulo 4: a auditoria de agosto, a renda sem o valor extremo e a análise fatorial completa.*

O QUE APARECE NO SLIDE

O número 4 em vermelho, o título "Setembro, primeira quinzena" e o subtítulo: a auditoria de agosto, a renda sem o extremo e a análise fatorial do NB04.

O QUE ISSO QUER DIZER, DO ZERO

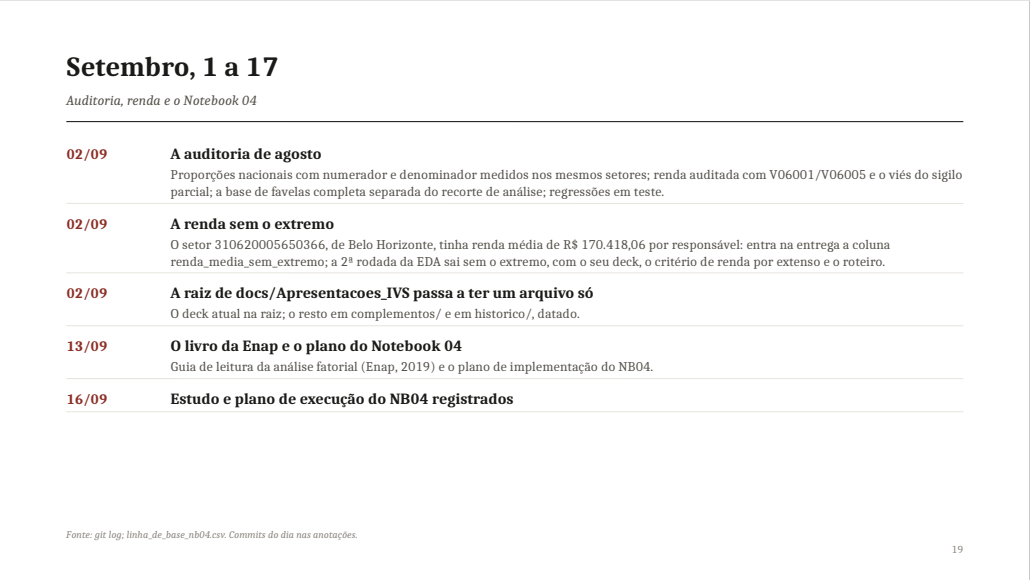
Os primeiros dezessete dias de setembro preparam e entregam a análise fatorial (o NB04), que define como os indicadores se agrupam e quanto cada grupo pesa.

COMO APRESENTAR

“O quarto capítulo é a primeira quinzena de setembro: a análise fatorial.”

CRONOLOGIA · SLIDE 19

Setembro, 1 a 17



> *A auditoria de agosto, o setor de renda extrema de Belo Horizonte e a preparação da análise fatorial.*

O QUE APARECE NO SLIDE

Cinco entradas: 02/09 (a auditoria de agosto), 02/09 (a renda sem o extremo), 02/09 (a raiz da pasta de apresentações com um arquivo só), 13/09 (o livro da Enap e o plano do NB04) e 16/09 (o plano de execução do NB04 registrado).

O QUE ISSO QUER DIZER, DO ZERO

- **A auditoria de agosto**. Uma revisão do trabalho de agosto que gerou correções: as proporções do Brasil passam a medir numerador e denominador nos mesmos setores (antes, um setor com o numerador sob sigilo podia entrar no denominador e baixar a proporção); a renda é conferida contra outras variáveis do arquivo de renda (`V06001` a `V06005`), e fica documentado o viés do *sigilo parcial* — quando parte da informação de renda de um setor está escondida; a base completa de favelas é separada do recorte usado na análise.
- **A renda sem o extremo**. Um setor de Belo Horizonte, o `310620005650366`, tinha renda média de R$ 170.418,06 por responsável — muito acima de todos os outros. Na normalização min-max (A.5), ele vira o máximo e espreme todos os outros setores perto de zero. A entrega ganha a coluna `renda_media_sem_extremo` (a renda com esse setor retirado), e a segunda rodada da EDA é feita sem ele, com um deck, o critério de renda por extenso e o roteiro.
- **Um arquivo só na raiz**. A pasta de apresentações passa a ter só a apresentação atual na raiz; o resto vai para `complementos/` e `historico/` (slide 8).
- **13 e 16/09 — o estudo**. Antes de programar a análise fatorial, o estudo: um guia de leitura do manual de análise fatorial da Enap (a Escola Nacional de Administração Pública) e o plano de execução do NB04.

COMO APRESENTAR

“No começo de setembro, a auditoria de agosto corrige as proporções do Brasil e a separação das favelas. E aparece o setor de renda extrema de Belo Horizonte: R$ 170.418,06 de renda média. Sozinho, ele distorce a

escala da renda inteira; por isso a entrega ganha uma coluna sem ele. Depois, duas semanas de estudo antes de programar a análise fatorial.”

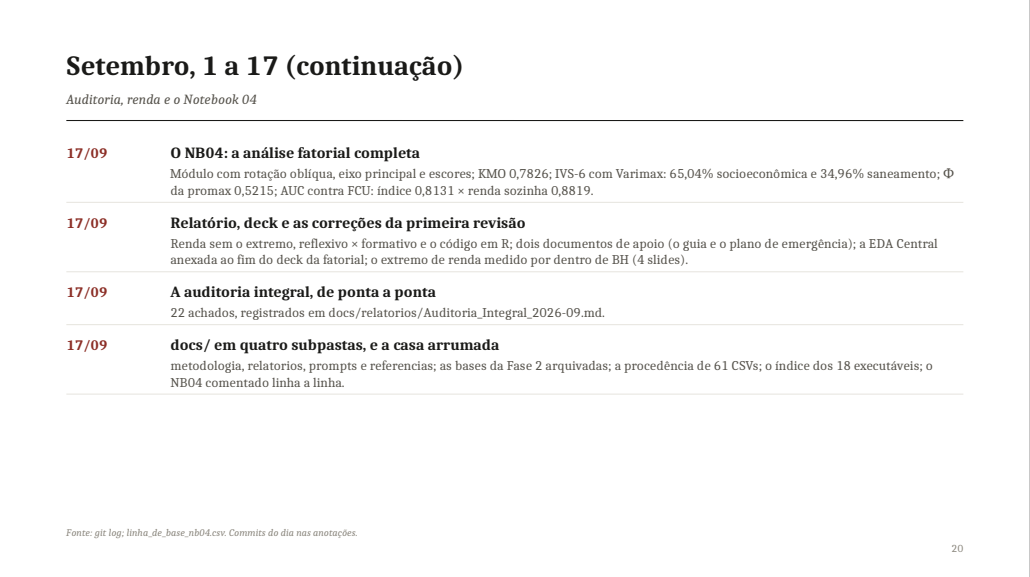
SE PERGUNTAREM

O setor extremo é um erro do IBGE?

Não dá para afirmar. Pode ser um setor pequeno, com poucos domicílios de renda altíssima. O ponto não é se ele é verdadeiro: é que, verdadeiro ou não, ele estraga a régua da normalização. Por isso o projeto mantém as versões da renda com e sem ele.

CRONOLOGIA · SLIDE 20

Setembro, 1 a 17 (continuação)



O NB04 entrega a análise fatorial completa — e um resultado incômodo: a renda sozinha separa as favelas melhor que o índice.

O QUE APARECE NO SLIDE

Quatro entradas, todas de 17/09, o segundo dia mais intenso do histórico: o NB04 com os números principais, o relatório e o deck com as correções da primeira revisão, a auditoria integral (22 achados) e a reorganização da pasta `docs/`.

O QUE ISSO QUER DIZER, DO ZERO

- **O NB04**. O notebook da análise fatorial (A.6). Um módulo novo faz rotação oblíqua (promax), extração pelo eixo principal e escores. Os números da entrada, um por um:
- **KMO 0,7826**: os dados servem bem para análise fatorial (acima de 0,7 é bom);
- **pesos do IVS-6 com Varimax: 65,04% socioeconômica e 34,96% saneamento**: sem o lixo, a análise encontra dois fatores, e o socioeconômico é quase duas vezes mais forte;
- **Φ da promax 0,5215**: quando se deixa os fatores se correlacionarem, a correlação entre eles é moderada — as duas dimensões não são independentes;
- **AUC contra FCU: índice 0,8131 × renda sozinha 0,8819**: o índice separa bem as favelas, mas a renda, sozinha, separa melhor (A.7).
- **Relatório e deck**. Com as correções de uma primeira revisão, a renda sem o extremo, a discussão *reflexivo* × *formativo* e o código traduzido para R. Num modelo **reflexivo**, os indicadores são consequências de uma

vulnerabilidade escondida, e a análise fatorial é a ferramenta natural; num **formativo**, os indicadores *compõem* a vulnerabilidade, e os pesos viriam da teoria. O projeto documentou as duas leituras. **R** é outra linguagem de estatística, usada por muitos pesquisadores. Saem também dois documentos de apoio para apresentar (um guia dos slides e um plano de estudo) e a EDA Central é anexada ao deck.

- **A auditoria integral**. Uma revisão de ponta a ponta do projeto, com 22 achados (problemas e pontos frágeis).
- **A casa arrumada**. A pasta `docs/` passa a ter subpastas por tipo de uso; as bases antigas vão para o arquivo; 61 tabelas ganham registro de procedência; os 18 programas executáveis ganham um índice; o NB04 é comentado linha a linha.

COMO LER OS NÚMEROS

O mais importante é o par de AUCs: 0,8131 contra 0,8819. Em palavras: sorteando um setor de favela e um que não é, o índice acerta qual é o de favela em cerca de 81% das vezes; a renda sozinha, em cerca de 88%. Esse resultado volta várias vezes nas demandas de setembro.

COMO APRESENTAR

“Em 17 de setembro sai a análise fatorial completa. Os dados servem bem, com KMO de 0,7826. Sem o lixo, a análise divide os pesos em 65,0% socioeconômico e 35,0% saneamento. E um resultado incômodo: a renda sozinha separa as favelas melhor que o índice. No mesmo dia, uma auditoria integral levanta 22 pontos para corrigir.”

SE PERGUNTAREM

Se a renda sozinha separa melhor, para que o índice?

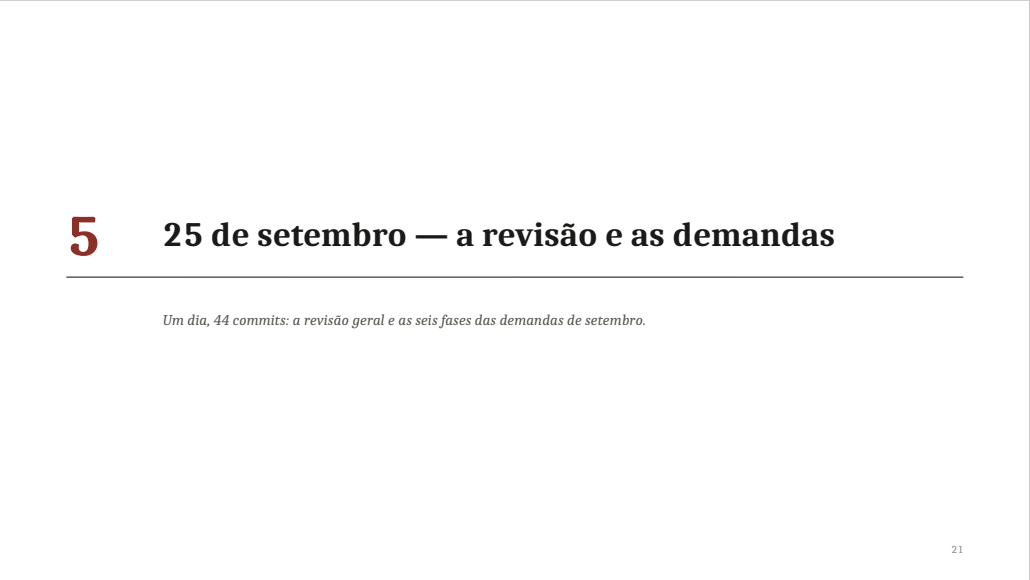
Porque separar favelas não é o objetivo do índice — é só um teste de validade. O índice mede condições que a renda não mede. As demandas de setembro (Parte C, parte 8) mostram que, entre setores de renda parecida, o índice separa melhor que a renda.

O que é o IVS-6?

O IVS-7 sem o lixo. Foi a base principal do NB04, porque o lixo, sozinho, formava um fator à parte.

CRONOLOGIA · SLIDE 21

25 de setembro — a revisão e as demandas



> *A divisória do capítulo 5: um único dia com 44 commits — a revisão geral do repositório e as demandas de setembro.*

O QUE APARECE NO SLIDE

O número 5 em vermelho, o título "25 de setembro — a revisão e as demandas" e o subtítulo: um dia, 44 commits, a revisão geral e as seis fases das demandas de setembro.

O QUE ISSO QUER DIZER, DO ZERO

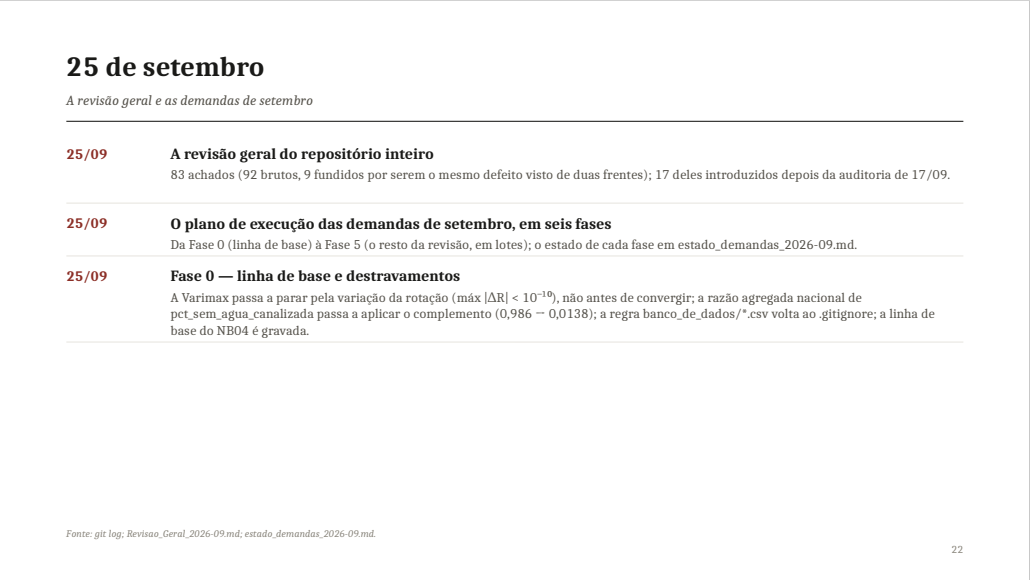
Este capítulo é um dia só. Nele, o repositório inteiro foi revisado e as onze demandas de setembro da orientadora foram executadas, organizadas em seis fases (0 a 5).

COMO APRESENTAR

“O quinto capítulo é um dia: 25 de setembro, o mais intenso do histórico.”

CRONOLOGIA · SLIDE 22

25 de setembro



> *A revisão geral encontra 83 problemas, as demandas de setembro ganham um plano em seis fases e a Fase 0 corrige o que travava o resto.*

O QUE APARECE NO SLIDE

Três entradas: a revisão geral do repositório inteiro, o plano de execução das demandas de setembro em seis fases e a Fase 0 (linha de base e destravamentos).

O QUE ISSO QUER DIZER, DO ZERO

- **A revisão geral**. Uma leitura crítica de todo o repositório: código, dados, notebooks, documentos, apresentações. Encontrou 83 achados — 92 brutos, dos quais 9 eram o mesmo defeito visto por dois caminhos e foram juntados. Dezessete tinham sido introduzidos *depois* da auditoria de 17/09 — trabalho novo também traz erro novo.
- **O plano em seis fases**. Da Fase 0 (a linha de base) à Fase 5 (o resto da revisão), com um arquivo de estado que registra o que cada fase fez.
- **A Fase 0**. O que travava o resto:
- a **Varimax** (A.6) é um processo de tentativas que gira os eixos aos poucos até parar de melhorar. Ela parava cedo demais, antes de chegar ao resultado final. A correção a faz parar só quando a rotação deixa de mudar (uma diferença menor que 10^{-10}, um número minúsculo);
- a proporção de domicílios sem água canalizada no **Brasil** saía invertida — 0,986 em vez de 0,0138 — porque o cálculo agregado esquecia o complemento (A.4). Ou seja: dizia que 98,6% dos domicílios do país não tinham água canalizada, quando o certo é 1,38%;
- uma regra que impedia arquivos de dados grandes de irem para o git tinha se perdido e foi restaurada;
- a **linha de base** do NB04 foi gravada: os números contra os quais todo cenário novo seria comparado.

COMO APRESENTAR

“No dia 25, o repositório inteiro foi revisado: 83 achados. Antes de atacar as demandas, a Fase 0 corrigiu o que travava o resto — a Varimax, que parava antes da hora, e a proporção nacional de água canalizada, que saía pelo avesso — e gravou a linha de base para comparar tudo depois.”

SE PERGUNTAREM

A Varimax errada mudou os resultados do NB04?

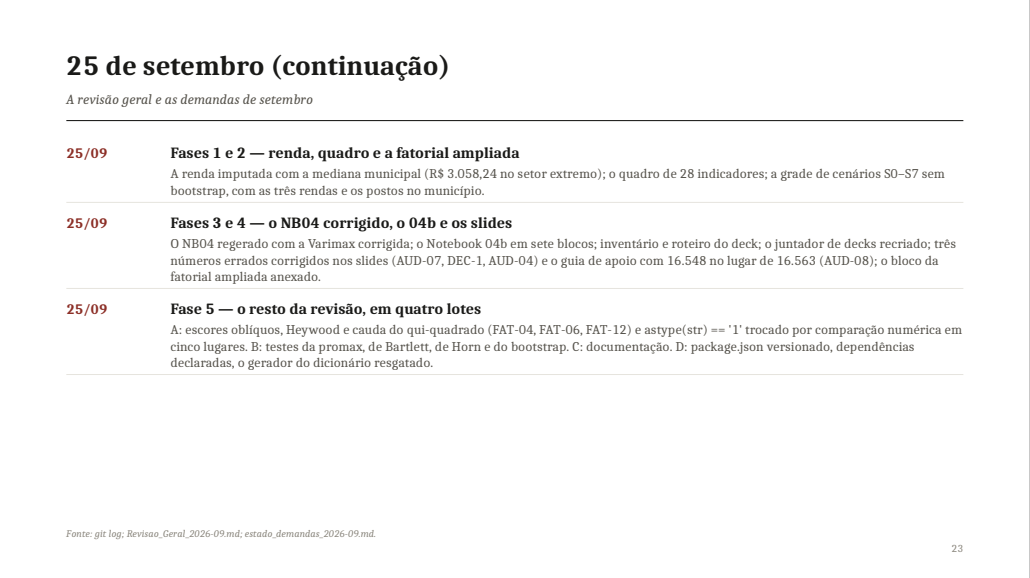
Mudou pouco, mas mudou; por isso o NB04 foi regerado com a versão corrigida na Fase 3 do mesmo dia. O número que importa é o de depois da correção.

Como um erro de 0,986 passou despercebido?

Era um número agregado do Brasil, usado só para comparação, e não entrava no índice. Foi a revisão sistemática que o achou — é para isso que ela existe.

CRONOLOGIA · SLIDE 23

25 de setembro (continuação)



As fases 1 a 5: a renda com a mediana, o quadro de indicadores, a fatorial ampliada, o NB04 corrigido, os slides e o resto da revisão.

O QUE APARECE NO SLIDE

Três entradas: Fases 1 e 2 (renda, quadro e fatorial ampliada), Fases 3 e 4 (o NB04 corrigido, o NB04b e os slides) e Fase 5 (o resto da revisão, em quatro lotes).

O QUE ISSO QUER DIZER, DO ZERO

- **Fases 1 e 2**. A **demanda 1** pedia uma coluna de renda com a mediana. A **mediana** é o valor do meio de uma lista ordenada; ao contrário da média, não é puxada por um valor extremo. A renda do setor extremo foi trocada pela mediana de Belo Horizonte sem ele (R$ 3.058,24) — isso é uma **imputação**: preencher um valor com uma estimativa. A **demanda 2** pedia o quadro de indicadores: saiu com 28 indicadores. E a **fatorial ampliada**: uma grade de cenários (S0 a S7, explicados na Parte C) que repete a análise fatorial com variáveis a mais ou a menos, sem bootstrap (A.8).
- **Fases 3 e 4**. O NB04 é regerado com a Varimax corrigida; um notebook novo, o NB04b, roda a fatorial ampliada em sete blocos. A apresentação é revista: um inventário do que existe, um roteiro, um programa que junta decks (o "juntador") e a correção de três números errados nos slides e de um no guia de apoio (16.548 no lugar de 16.563). Os códigos como AUD-07 e DEC-1 são os identificadores de cada achado nas auditorias.
- **Fase 5**. O resto da revisão, em quatro lotes: **A**, código frágil — por exemplo, um teste que comparava um número como texto (o texto "1" não é igual ao texto "1.0", mesmo que os números sejam iguais), trocado por comparação numérica em cinco lugares; **B**, testes automáticos novos; **C**, documentação; **D**,

organização do repositório.

COMO APRESENTAR

“O resto do dia foi executar as demandas. A renda ganha uma versão com a mediana, sai o quadro de indicadores, e a análise fatorial é repetida numa grade de cenários. O NB04 é corrigido, a apresentação é revista e os pontos que sobravam da revisão são resolvidos em quatro lotes.”

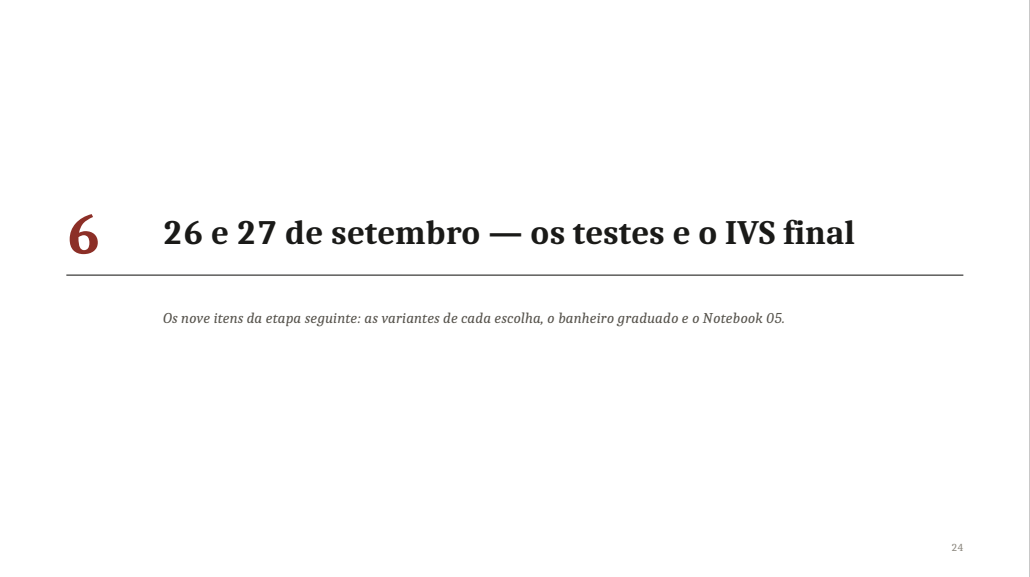
SE PERGUNTAREM

O que é a “fatorial ampliada”?

A mesma análise fatorial do NB04, repetida com conjuntos diferentes de variáveis — acrescentando as que a orientadora pediu ou tirando o lixo —, para ver o que muda. Cada conjunto é um cenário.

CRONOLOGIA · SLIDE 24

26 e 27 de setembro — os testes e o IVS final



A divisória do capítulo 6: dois dias para testar cada escolha em aberto, extrair uma variável nova do Censo e calcular o IVS final.

O QUE APARECE NO SLIDE

O número 6 em vermelho, o título "26 e 27 de setembro — os testes e o IVS final" e o subtítulo: os nove itens da etapa seguinte, as variantes de cada escolha, o banheiro graduado e o Notebook 05.

O QUE ISSO QUER DIZER, DO ZERO

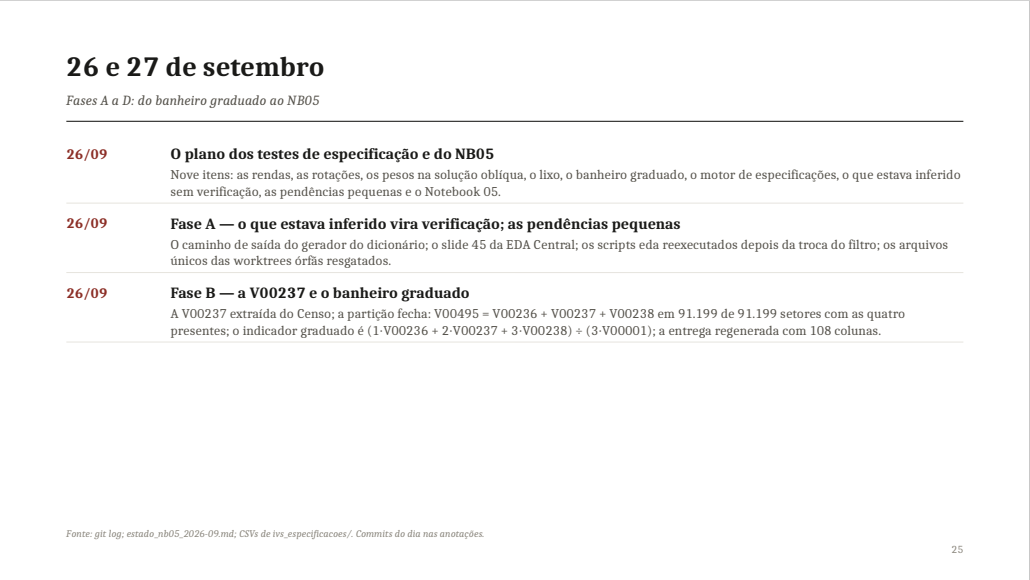
Depois das demandas, ficaram escolhas de método sem resposta: qual renda, qual rotação, como pesar, se o lixo entra, se o banheiro entra. Em vez de escolher, o projeto testou todas as combinações — e deixou a escolha para a orientadora.

COMO APRESENTAR

“O sexto capítulo são dois dias: 26 e 27 de setembro, os testes de cada escolha e o IVS final.”

CRONOLOGIA · SLIDE 25

26 e 27 de setembro



26 e 27 de setembro

Fases A a D: do banheiro graduado ao NB05

26/09	**O plano dos testes de especificação e do NB05** Nove itens: as rendas, as rotações, os pesos na solução oblíqua, o lixo, o banheiro graduado, o motor de especificações, o que estava inferido sem verificação, as pendências pequenas e o Notebook 05.
26/09	**Fase A — o que estava inferido vira verificação; as pendências pequenas** O caminho de saída do gerador do dicionário; o slide 45 da EDA Central; os scripts eda reexecutados depois da troca do filtro; os arquivos únicos das worktrees órfãs resgatados.
26/09	**Fase B — a V00237 e o banheiro graduado** A V00237 extraída do Censo; a partição fecha: V00495 = V00236 + V00237 + V00238 em 91.199 de 91.199 setores com as quatro presentes; o indicador graduado é (1·V00236 + 2·V00237 + 3·V00238) ÷ (3·V00001); a entrega regenerada com 108 colunas.

Fonte: git log; estado_nb05_2026-09.md; CSVs de ivs_especificacoes/. Commits do dia nas anotações.

25

> *O plano dos nove itens, as pendências resolvidas e a extração da variável V00237 para o banheiro graduado.*

O QUE APARECE NO SLIDE

Três entradas de 26/09: o plano dos testes de especificação e do NB05, a Fase A (o que estava inferido vira verificação; as pendências pequenas) e a Fase B (a `V00237` e o banheiro graduado).

O QUE ISSO QUER DIZER, DO ZERO

- **O plano**. Nove itens: as três versões da renda, as rotações, os pesos na rotação oblíqua, o lixo, o banheiro graduado, o motor que testa as especificações, a verificação do que estava inferido, as pendências pequenas e o Notebook 05.
- **Fase A — de inferência a verificação**. Três afirmações dos documentos tinham sido escritas sem uma conta que as comprovasse. Viraram verificação: (1) a correlação entre renda e cor/raça é −0,81 quando se usa cada par de variáveis com os dados que tiver (*par a par*), mas 0,784 quando se usa só os setores com todas as variáveis (*listwise*) — e a análise fatorial usa a segunda; dois documentos ganharam a nota; (2) dois números da matriz de correlação do NB02 foram recalculados por um programa independente e bateram; (3) o gerador do dicionário de variáveis teve o caminho de saída corrigido. As pendências pequenas: o caminho citado no slide 45 da EDA Central e a reexecução de scripts.
- **Fase B — o banheiro graduado**. O Censo divide a falta de banheiro exclusivo (`V00495`) em três partes: só banheiro de uso comum (`V00236`), só sanitário ou buraco (`V00237`) e nem banheiro nem sanitário (`V00238`). A `V00237` não estava na base e foi extraída. Conferido setor a setor: as três partes somam exatamente o total em 91.199 de 91.199 setores com as quatro presentes — uma **partição** perfeita. Daí sai o **banheiro graduado**, que dá peso 1, 2 e 3 a cada grau de falta (a fórmula está na Parte C). A entrega à orientadora é regerada, com 108 colunas.

COMO APRESENTAR

“No dia 26, três afirmações que estavam escritas sem conta viram verificação, e a falta de banheiro ganha uma versão em graus: banheiro de uso comum, só sanitário, nada. Para isso, uma variável nova foi extraída do Censo, e a soma das partes bate em todos os setores.”

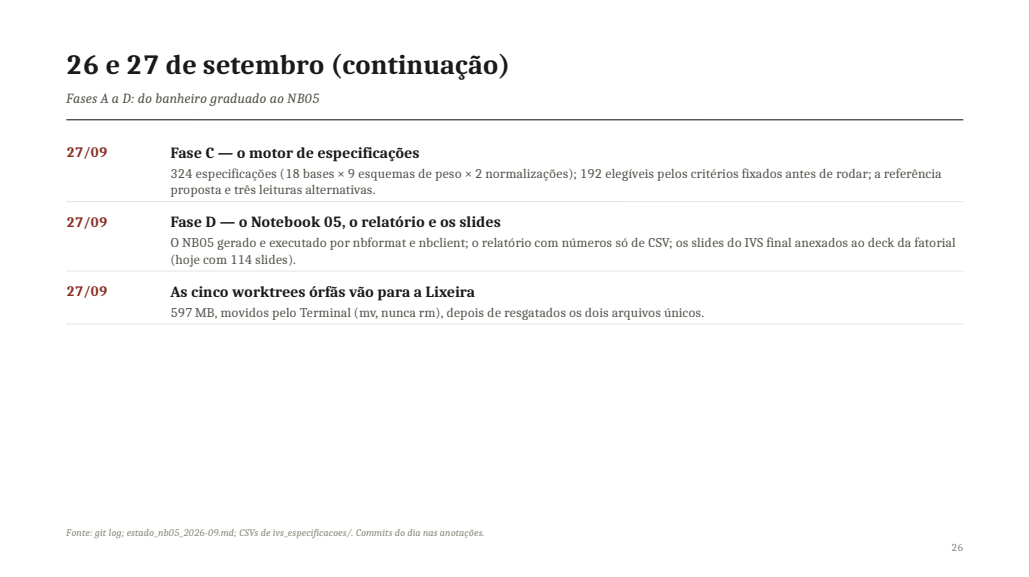
SE PERGUNTAREM

Por que "graduado"?

Porque não trata toda falta de banheiro igual: ter só um banheiro de uso comum é menos grave do que não ter nem sanitário. Cada grau recebe um peso diferente.

CRONOLOGIA · SLIDE 26

26 e 27 de setembro (continuação)



O motor de especificações testa 324 combinações, o NB05 calcula o IVS final e o repositório perde 597 MB de cópias esquecidas.

O QUE APARECE NO SLIDE

Três entradas de 27/09: a Fase C (o motor de especificações), a Fase D (o Notebook 05, o relatório e os slides) e as worktrees órfãs que vão para a Lixeira.

O QUE ISSO QUER DIZER, DO ZERO

- **Fase C — o motor**. Um programa que monta todas as combinações das escolhas em aberto: 3 rendas × 2 opções de lixo × 3 de banheiro = 18 bases; cada uma com 9 esquemas de rotação e peso e 2 normalizações = 324 especificações (A.9). 192 passam nos critérios de qualidade, fixados antes de rodar. Entre elas, o motor aponta uma referência proposta — e três leituras alternativas dos critérios.
- **Fase D — o NB05**. O Notebook 05 é escrito e executado por um programa (com as bibliotecas `nbformat` e `nbclient`), o que garante que ele rode do começo ao fim sem intervenção. Sai o relatório do IVS final, com todos os números lidos das tabelas, e os slides do IVS final são anexados ao deck principal, que fica com 114 slides.
- **As worktrees órfãs**. Uma **worktree** é uma cópia de trabalho paralela do repositório. Cinco delas tinham ficado esquecidas no disco, ocupando 597 MB. Depois de resgatados os dois arquivos que só existiam nelas, foram movidas para a Lixeira — movidas, e não apagadas, para que desse para voltar atrás.

COMO APRESENTAR

"No dia 27, um programa testa todas as combinações de escolhas: 324 especificações, das quais 192 passam nos critérios de qualidade. O Notebook 05 calcula o IVS final e propõe uma referência — uma proposta, porque as escolhas são da orientadora."

SE PERGUNTAREM

Por que testar todas as combinações em vez de escolher a melhor?

Porque cada escolha tem argumentos dos dois lados, e escolher olhando o resultado viciaria a análise. A grade mostra o que cada escolha muda; a decisão fica com quem tem a autoridade de método.

CRONOLOGIA · SLIDE 27

De 30/09 até hoje



> *A divisória do capítulo 7: os dias mais recentes — a estrutura do deck, o grafo do projeto e estas apresentações.*

O QUE APARECE NO SLIDE

O número 7 em vermelho, o título "De 30/09 até hoje" e o subtítulo: a estrutura do deck, o grafo do projeto e estas duas apresentações.

O QUE ISSO QUER DIZER, DO ZERO

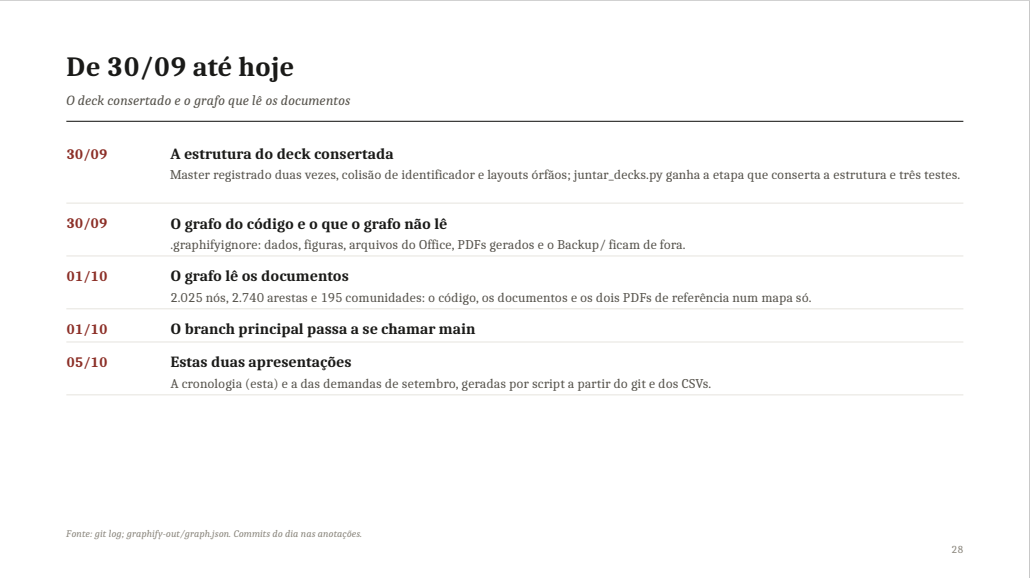
O último capítulo é de manutenção e de memória: consertar a estrutura do deck principal, atualizar o mapa do projeto e produzir estas duas apresentações.

COMO APRESENTAR

“O último capítulo vai de 30 de setembro até hoje.”

CRONOLOGIA · SLIDE 28

De 30/09 até hoje



> *O deck principal tem a estrutura interna consertada, o grafo passa a ler os documentos e o branch principal muda de nome.*

O QUE APARECE NO SLIDE

Cinco entradas: 30/09 (a estrutura do deck consertada), 30/09 (o grafo do código e o que o grafo não lê), 01/10 (o grafo lê os documentos), 01/10 (o branch principal passa a se chamar main) e a data de hoje (estas duas apresentações).

O QUE ISSO QUER DIZER, DO ZERO

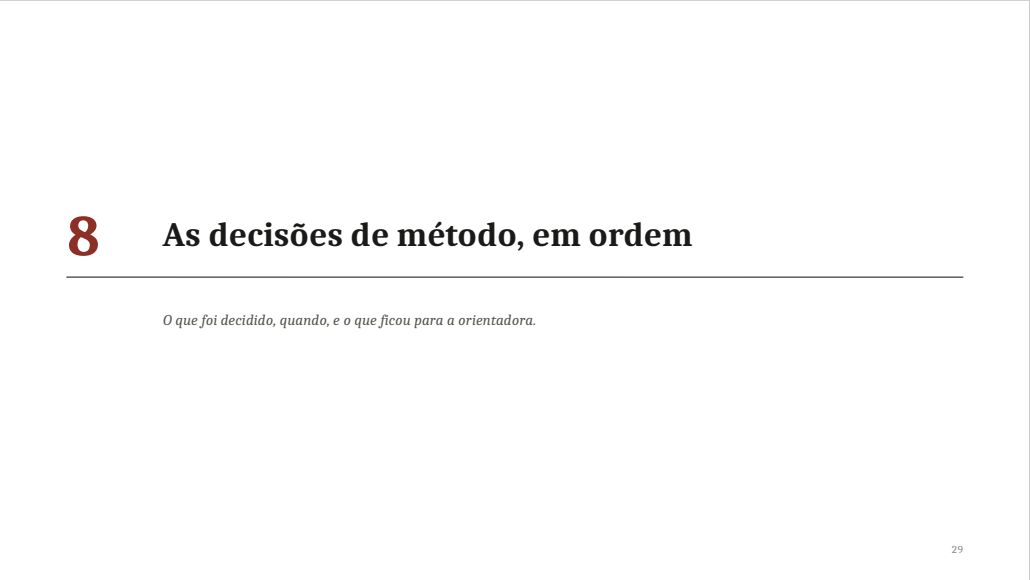
- **A estrutura do deck**. Um arquivo `.pptx` é, por dentro, um pacote de arquivos de texto (XML). Um deles, o *master*, é o molde de todos os slides; os *layouts* são variações dele. Ao juntar decks, o master tinha sido registrado duas vezes, dois elementos usavam o mesmo identificador e alguns layouts ficaram sem dono — o tipo de defeito que faz o PowerPoint pedir para "reparar" o arquivo. O programa que junta decks ganhou uma etapa que conserta isso, e três testes automáticos.
- **O grafo**. O mapa do projeto (slide 16) é atualizado. Primeiro o código; depois, a lista do que ele não deve ler (dados, figuras, arquivos do Office, PDFs gerados, o legado); por fim, os documentos. O grafo fica com 2.025 nós, 2.740 arestas e 195 comunidades. Uma **comunidade** é um grupo de nós muito ligados entre si — um assunto do projeto.
- **main**. O **branch** principal (A.10) passa a se chamar `main`, o nome padrão atual.
- **Estas apresentações**. A cronologia e a das demandas de setembro, geradas por programa a partir do git e das tabelas.

COMO APRESENTAR

“Nos últimos dias, consertei a estrutura interna do deck principal, para que o PowerPoint não precise repará-lo, e atualizei o mapa do projeto, que agora lê também os documentos. E estas duas apresentações foram geradas a partir do histórico e das tabelas.”

CRONOLOGIA · SLIDE 29

As decisões de método, em ordem



> *A divisória do capítulo 8, a primeira leitura transversal: todas as decisões de método juntas.*

O QUE APARECE NO SLIDE

O número 8 em vermelho, o título "As decisões de método, em ordem" e o subtítulo: o que foi decidido, quando, e o que ficou para a orientadora.

O QUE ISSO QUER DIZER, DO ZERO

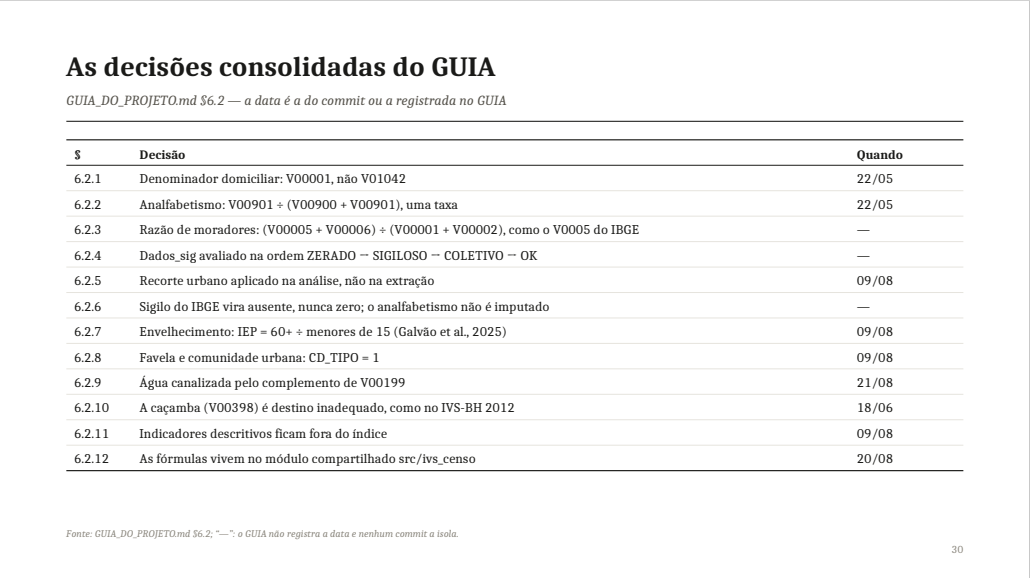
A partir daqui, o deck deixa de seguir o calendário e passa a cortar o projeto por tema. Esta leitura junta as decisões de método: as já consolidadas e as que esperam a orientadora.

COMO APRESENTAR

“Agora três leituras por tema. A primeira: as decisões de método.”

CRONOLOGIA · SLIDE 30

As decisões consolidadas do GUIA



As decisões consolidadas do GUIA

GUIA_DO_PROJETO.md §6.2 — a data é a do commit ou a registrada no GUIA

§	Decisão	Quando
6.2.1	Denominador domiciliar: V00001, não V01042	22/05
6.2.2	Analfabetismo: V00901 ÷ (V00900 + V00901), uma taxa	22/05
6.2.3	Razão de moradores: (V00005 + V00006) ÷ (V00001 + V00002), como o V0005 do IBGE	—
6.2.4	Dados_sig avaliado na ordem ZERADO → SIGILOSO → COLETIVO → OK	—
6.2.5	Recorte urbano aplicado na análise, não na extração	09/08
6.2.6	Sigilo do IBGE vira ausente, nunca zero; o analfabetismo não é imputado	—
6.2.7	Envelhecimento: IEP = 60+ ÷ menores de 15 (Galvão et al., 2025)	09/08
6.2.8	Favela e comunidade urbana: CD_TIPO = 1	09/08
6.2.9	Água canalizada pelo complemento de V00199	21/08
6.2.10	A caçamba (V00398) é destino inadequado, como no IVS-BH 2012	18/06
6.2.11	Indicadores descritivos ficam fora do índice	09/08
6.2.12	As fórmulas vivem no módulo compartilhado src/ivs_censo	20/08

Fonte: GUIA_DO_PROJETO.md §6.2; "—": o GUIA não registra a data e nenhum commit a isola.

30

> *As doze decisões de método já tomadas e registradas no GUIA do projeto, cada uma com a data em que foi tomada.*

O QUE APARECE NO SLIDE

Uma tabela com três colunas: o número da seção do GUIA (de 6.2.1 a 6.2.12), a decisão e a data. Onde o GUIA não registra a data e nenhum commit a isola, aparece um travessão.

O QUE ISSO QUER DIZER, DO ZERO

As doze decisões, em palavras simples:

- **6.2.1 — denominador**: os indicadores de domicílio dividem por `V00001` (domicílios), como o IVS-BH 2012, e não por `V01042` (responsáveis).
- **6.2.2 — analfabetismo**: taxa, e não razão (A.4).
- **6.2.3 — razão de moradores**: moradores ÷ domicílios, contando também os improvisados, exatamente como o IBGE calcula o número publicado — o que permite conferir.
- **6.2.4 — a ordem do rótulo de sigilo**: cada setor recebe um rótulo de qualidade do dado (`Dados_sig`). Testa-se primeiro se o setor tem população zero, depois se há sigilo, depois se é coletivo. Na ordem antiga, setores vazios (muitos são lagos e represas) eram contados como sigilosos.
- **6.2.5 — recorte urbano**: aplicado na análise, não na extração (A.3).
- **6.2.6 — sigilo**: o X vira ausente, nunca zero; o analfabetismo sob sigilo não é preenchido (A.2).
- **6.2.7 — envelhecimento**: idosos ÷ menores de 15, a definição da literatura (Galvão e colegas, 2025).
- **6.2.8 — favelas**: identificadas pelo campo oficial `CD_TIPO = 1`.
- **6.2.9 — água canalizada**: pelo complemento de `V00199` (slide 17).
- **6.2.10 — caçamba**: destino inadequado, como no IVS-BH 2012 (slide 13).
- **6.2.11 — indicadores descritivos**: ficam fora do índice, por não terem direção clara (slide 14).
- **6.2.12 — fórmulas**: num módulo compartilhado (slide 17).

COMO APRESENTAR

"Estas são as doze decisões de método já consolidadas, todas registradas no GUIA com a justificativa e a alternativa descartada. Quase todas seguem o mesmo princípio: ficar o mais perto possível do método do IVS

de Belo Horizonte, para que os índices sejam comparáveis.”

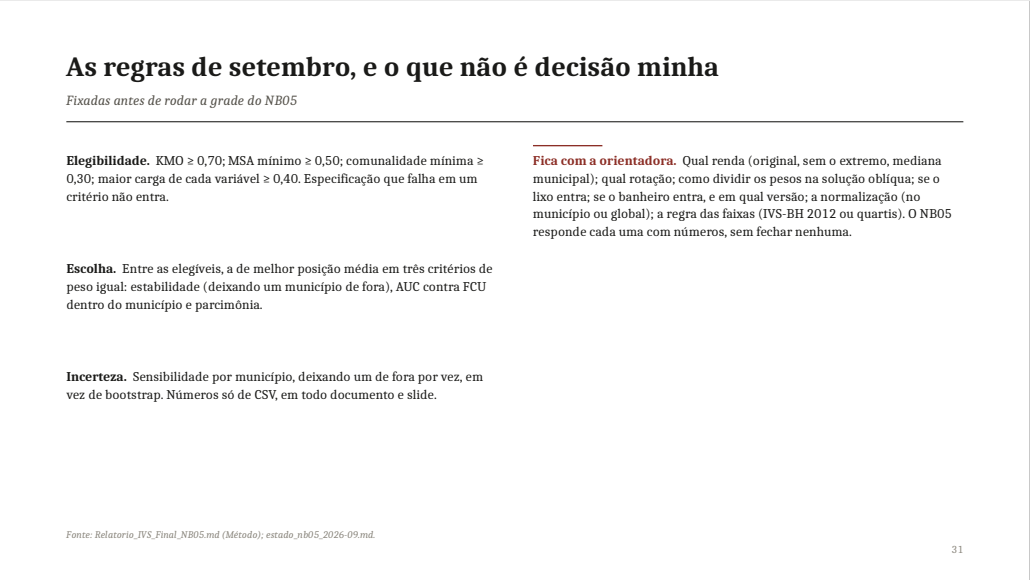
SE PERGUNTAREM

Alguma dessas decisões pode mudar?

Pode, se a orientadora pedir — e o GUIA registra a alternativa descartada de cada uma, justamente para que voltar atrás seja fácil. A da caçamba é a mais discutível, por causa do comportamento do lixo.

CRONOLOGIA · SLIDE 31

As regras de setembro, e o que não é decisão minha



As regras fixadas antes de rodar a grade do IVS final — e a lista do que fica com a orientadora.

O QUE APARECE NO SLIDE

Quatro blocos. À esquerda: **elegibilidade** (os quatro critérios mínimos), **escolha** (os três critérios para apontar a referência) e **incerteza** (sensibilidade por município, não bootstrap). À direita, com o filete vermelho: **fica com a orientadora** — as sete escolhas que o projeto não faz sozinho.

O QUE ISSO QUER DIZER, DO ZERO

- **Elegibilidade**: KMO de pelo menos 0,70, MSA de pelo menos 0,50, comunalidade de pelo menos 0,30 e carga máxima de pelo menos 0,40 (A.6). Basta falhar em um para a especificação sair.
- **Escolha**: entre as elegíveis, a de melhor posição média em três critérios com o mesmo peso: estabilidade, AUC dentro do município e parcimônia (A.9).
- **Incerteza**: medida tirando um município de cada vez (A.8).
- **O que fica com a orientadora**: qual renda (original, sem o extremo ou com a mediana municipal); qual rotação; como dividir os pesos na rotação oblíqua; se o lixo entra; se o banheiro entra, e em qual versão; a normalização (no município ou global); e a regra das faixas (a do IVS-BH 2012 ou quartis).

O ponto central é a ordem: as regras foram escritas *antes* de rodar a grade. Se fossem escritas depois, sempre se poderia ajustá-las até a especificação preferida ganhar.

COMO APRESENTAR

“As regras foram fixadas antes de rodar, para que o resultado não escolhesse a regra. E há sete escolhas que eu não faço: o NB05 mostra o que cada uma muda, com números, e a decisão é da orientadora.”

SE PERGUNTAREM

Por que o próprio pesquisador não escolhe?

Porque são escolhas de método com consequências para a comparação com o IVS-BH 2012 e para o artigo, e cabem a quem orienta. O papel da análise é mostrar, com números, o que cada opção muda.

CRONOLOGIA · SLIDE 32

Os achados, em ordem



A divisória do capítulo 9, a segunda leitura transversal: o que se descobriu sobre os dados e sobre o próprio código.

O QUE APARECE NO SLIDE

O número 9 em vermelho, o título "Os achados, em ordem" e o subtítulo: o que se descobriu sobre os dados e sobre o próprio código, na ordem em que apareceu.

O QUE ISSO QUER DIZER, DO ZERO

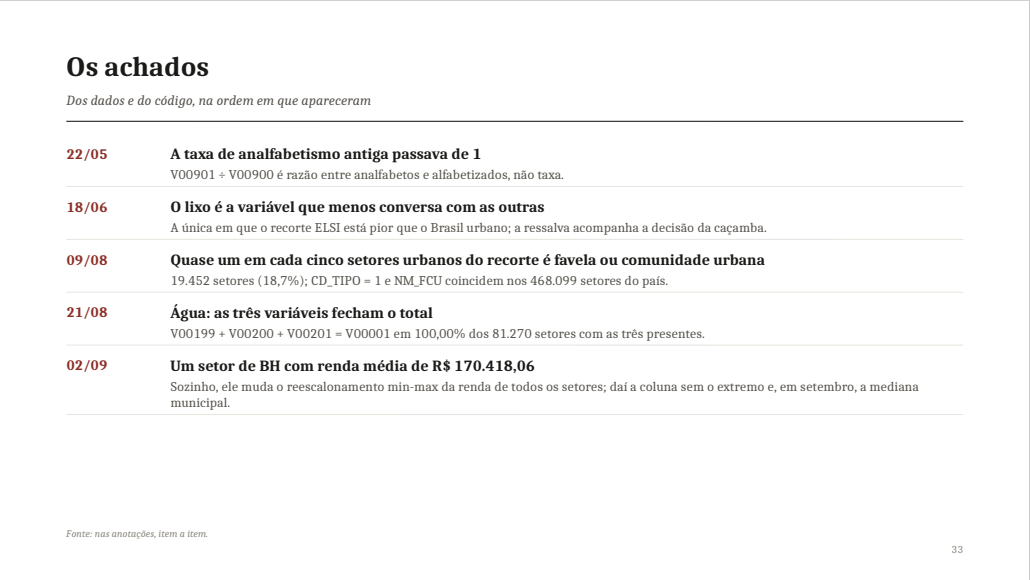
Um **achado** é um fato descoberto pela análise: um problema nos dados, um erro no código, um resultado que muda a interpretação. Esta leitura junta os treze principais.

COMO APRESENTAR

“A segunda leitura: os achados, na ordem em que apareceram.”

CRONOLOGIA · SLIDE 33

Os achados



> *Os cinco primeiros achados: o analfabetismo acima de 1, o lixo isolado, as favelas, a água que fecha a conta e o setor de renda extrema.*

O QUE APARECE NO SLIDE

Cinco entradas: 22/05, 18/06, 09/08, 21/08 e 02/09.

O QUE ISSO QUER DIZER, DO ZERO

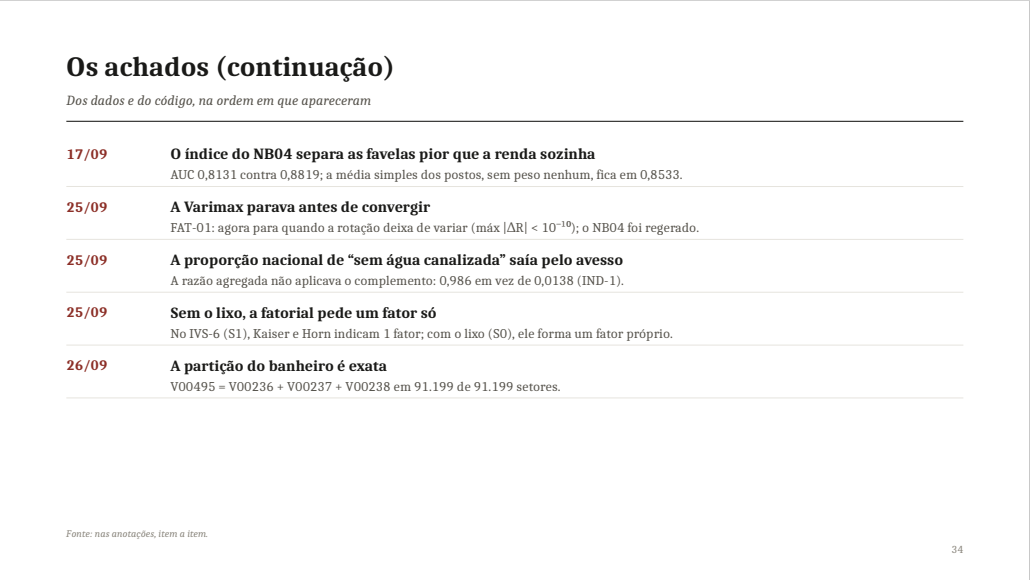
- **22/05 — o analfabetismo acima de 1**. Uma "taxa" que passava de 100% era sinal de fórmula errada: era uma razão (slide 11).
- **18/06 — o lixo isolado**. O lixo é a variável que menos se correlaciona com as outras, e a única em que os 70 municípios estão *pior* que o Brasil urbano. Esse achado acompanha a decisão da caçamba e volta na análise fatorial: o lixo tende a formar um fator sozinho.
- **09/08 — as favelas**. Quase um em cada cinco setores urbanos do recorte é favela ou comunidade urbana (19.452, 18,7%). E os dois jeitos de identificá-las — o campo `CD_TIPO = 1` e o nome da comunidade preenchido — coincidem nos 468.099 setores do país.
- **21/08 — a água fecha a conta**. As três categorias de abastecimento somam exatamente o total de domicílios em 100,00% dos 81.270 setores com as três presentes: dá para medir pelo complemento sem perder nada.
- **02/09 — o setor extremo**. Um único setor de Belo Horizonte, com renda média de R$ 170.418,06, muda a escala da renda de todos os setores na normalização. Daí a coluna sem ele e, em setembro, a versão com a mediana.

COMO APRESENTAR

“Os primeiros achados são sobre os dados: uma fórmula de analfabetismo errada, o lixo que não conversa com as outras variáveis, o tamanho das favelas no recorte, a água que fecha a conta e um setor de renda extrema que distorce a escala.”

CRONOLOGIA · SLIDE 34

Os achados (continuação)



Os achados (continuação)

Dos dados e do código, na ordem em que apareceram

17/09	**O índice do NB04 separa as favelas pior que a renda sozinha**	AUC 0,8131 contra 0,8819; a média simples dos postos, sem peso nenhum, fica em 0,8533.
25/09	**A Varimax parava antes de convergir**	FAT-01: agora para quando a rotação deixa de variar (máx $\|\Delta R\| < 10^{-10}$); o NB04 foi regerado.
25/09	**A proporção nacional de "sem água canalizada" saía pelo avesso**	A razão agregada não aplicava o complemento: 0,986 em vez de 0,0138 (IND-1).
25/09	**Sem o lixo, a fatorial pede um fator só**	No IVS-6 (S1), Kaiser e Horn indicam 1 fator; com o lixo (S0), ele forma um fator próprio.
26/09	**A partição do banheiro é exata**	V00495 = V00236 + V00237 + V00238 em 91.199 de 91.199 setores.

Fonte: nas anotações, item a item.

34

> *O índice contra a renda, dois erros de código corrigidos, o lixo que pede um fator só e a partição exata do banheiro.*

O QUE APARECE NO SLIDE

Cinco entradas: 17/09, três de 25/09 e 26/09.

O QUE ISSO QUER DIZER, DO ZERO

- **17/09 — o índice contra a renda**. O índice do NB04 separa as favelas com AUC 0,8131; a renda sozinha, com 0,8819. E mais: a **média simples dos postos** — ordenar os setores em cada indicador e tirar a média das posições, sem peso nenhum — chega a 0,8533, também acima do índice. Ou seja: na tarefa de separar favelas, os pesos da fatorial não ajudam.
- **25/09 — a Varimax**. Parava antes de convergir (slide 22); corrigida, o NB04 foi regerado.
- **25/09 — a água do Brasil**. A proporção nacional sem água canalizada saía 0,986 em vez de 0,0138, porque o cálculo agregado esquecia o complemento.
- **25/09 — sem o lixo, um fator só**. No IVS-6 (o IVS-7 sem o lixo), as duas regras de quantos fatores manter (A.6) indicam um fator só: a vulnerabilidade vira uma dimensão única. Com o lixo, ele ocupa um fator sozinho. É uma pista de que a estrutura em duas dimensões depende do lixo.
- **26/09 — a partição exata**. A falta de banheiro (`V00495`) é exatamente a soma das suas três partes em 91.199 de 91.199 setores (slide 25).

COMO APRESENTAR

"Em setembro, os achados ficam mais incômodos: a renda sozinha, e até uma média simples sem peso, separam as favelas melhor que o índice; e, sem o lixo, a análise fatorial enxerga uma dimensão só. Também apareceram dois erros de código, ambos corrigidos."

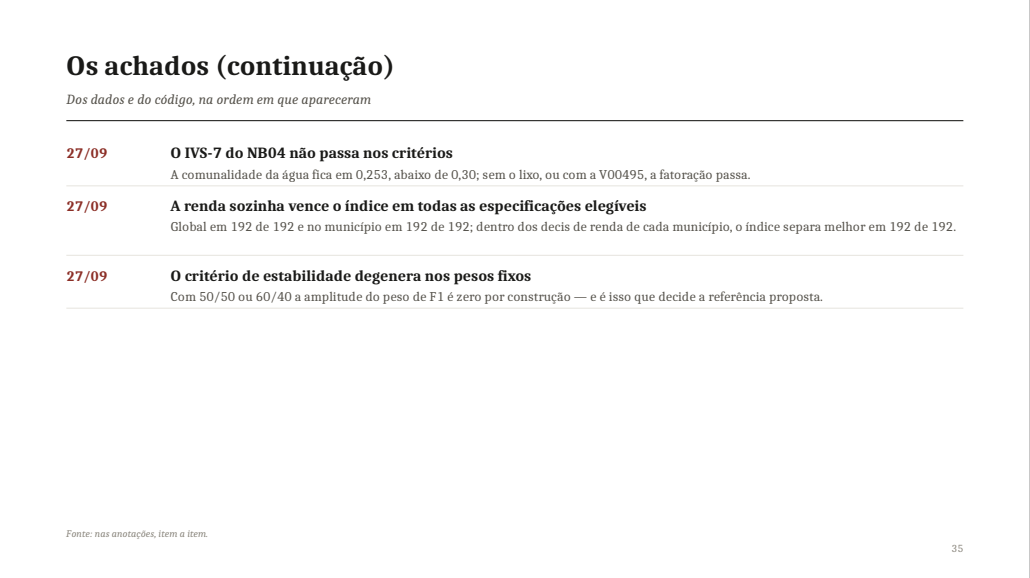
SE PERGUNTAREM

Se a média sem peso é melhor, a fatorial é inútil?

Não para o que ela faz — descobrir como os indicadores se agrupam. Mas o achado mostra que a validação contra favelas, sozinha, não justifica os pesos. Por isso a escolha da especificação usa três critérios, e não só a AUC.

CRONOLOGIA · SLIDE 35

Os achados (continuação)



> *Os três achados do IVS final: o IVS-7 não passa nos critérios, a renda vence em todas as especificações e o critério de estabilidade engana nos pesos fixos.*

O QUE APARECE NO SLIDE

Três entradas, todas de 27/09.

O QUE ISSO QUER DIZER, DO ZERO

- **O IVS-7 não passa**. A base do NB04, com os sete indicadores, falha num critério: a comunalidade da água fica em 0,253, abaixo do mínimo de 0,30 (A.6). A água conversa pouco com o resto quando o lixo está junto. Sem o lixo, ou acrescentando a falta de banheiro (`V00495`), a análise passa.
- **A renda vence em todas**. Nas 192 especificações elegíveis, a renda sozinha separa as favelas melhor que o índice — tanto comparando todos os setores juntos (192 de 192) quanto dentro de cada município (192 de 192). Mas, dentro de cada faixa de renda (os decis, A.7), o índice separa melhor em 192 de 192: ele traz informação que a renda não tem.
- **A estabilidade engana**. O critério de estabilidade mede quanto o peso do primeiro fator muda ao tirar um município. Com pesos fixos (50/50 ou 60/40), o peso não muda nunca — não porque seja estável, mas porque foi fixado. Essas especificações ganham o critério "de graça", e é isso que decide a referência proposta.

COMO APRESENTAR

“Os achados do IVS final são três: a base original não passa nos critérios de qualidade; a renda vence o índice em todas as especificações, mas o índice vence dentro de cada faixa de renda; e o critério de estabilidade favorece os pesos fixos sem mérito. Os três vão para a mesa da orientadora.”

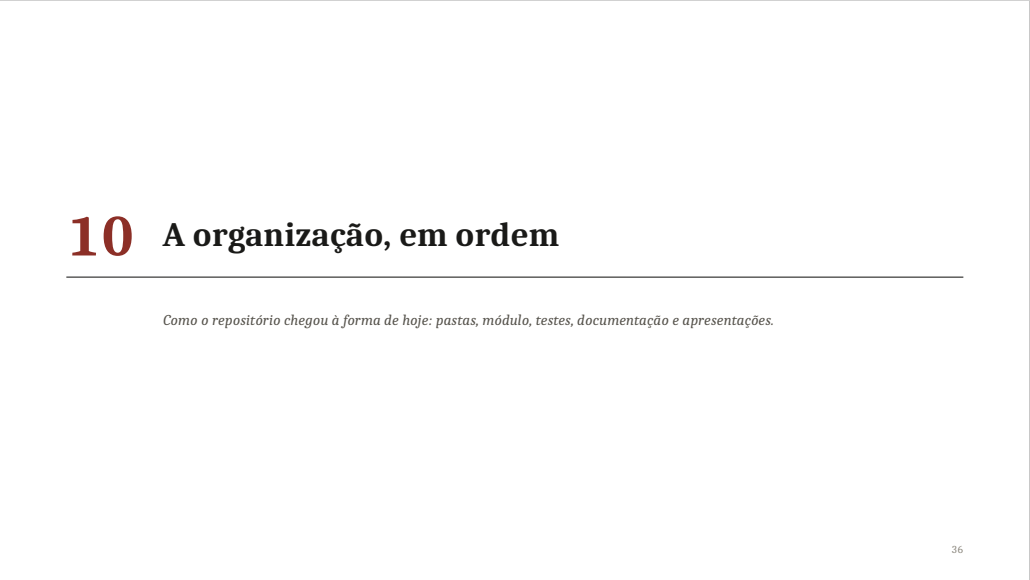
SE PERGUNTAREM

Isso invalida a referência proposta?

Não invalida, mas pede cautela: a referência ganhou em parte por um critério que não a testou. O deck das demandas mostra a alternativa que surge quando a estabilidade é medida de outro jeito.

CRONOLOGIA · SLIDE 36

A organização, em ordem



> *A divisória do capítulo 10, a terceira leitura transversal: como o repositório chegou à forma de hoje.*

O QUE APARECE NO SLIDE

O número 10 em vermelho, o título "A organização, em ordem" e o subtítulo: como o repositório chegou à forma de hoje — pastas, módulo, testes, documentação e apresentações.

O QUE ISSO QUER DIZER, DO ZERO

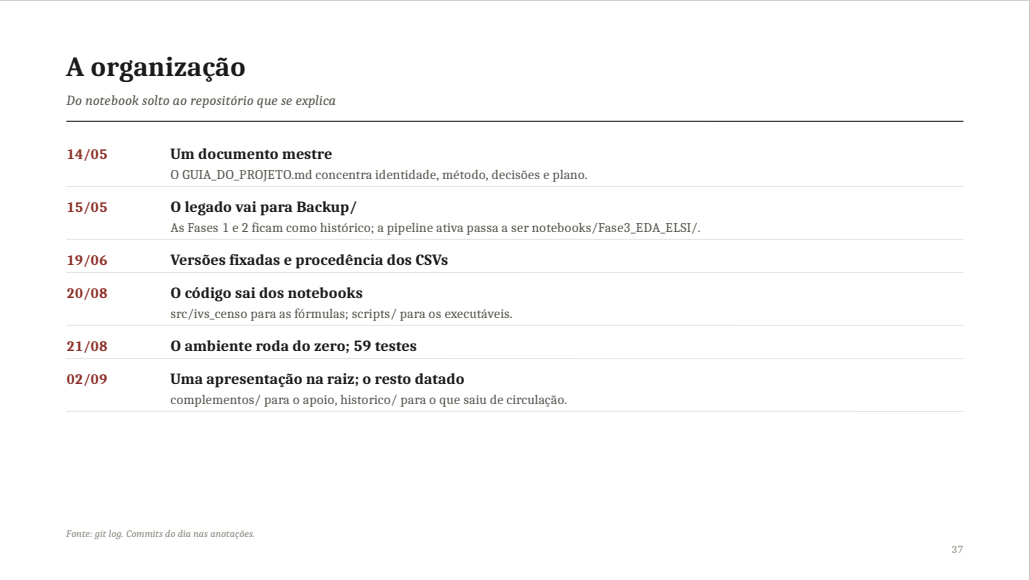
A organização é o que permite a outra pessoa — ou ao próprio autor, meses depois — achar cada coisa e refazer cada número. Esta leitura conta como ela foi construída.

COMO APRESENTAR

“A terceira leitura: a organização do projeto.”

CRONOLOGIA · SLIDE 37

A organização



> *Do documento mestre ao ambiente que roda do zero: como o projeto ficou reproduzível.*

O QUE APARECE NO SLIDE

Seis entradas: 14/05, 15/05, 19/06, 20/08, 21/08 e 02/09.

O QUE ISSO QUER DIZER, DO ZERO

- **14/05 — um documento mestre**: o GUIA concentra identidade, método, decisões e plano.
- **15/05 — o legado no Backup/**: as versões antigas saem do caminho, sem serem apagadas.
- **19/06 — versões fixadas**: as bibliotecas ficam com versão definida, e cada tabela da EDA tem a procedência registrada.
- **20/08 — o código sai dos notebooks**: as fórmulas vão para o módulo `src/ivs_censo`; os programas que rodam sozinhos, para `scripts/`.
- **21/08 — o ambiente roda do zero**: qualquer computador com as instruções consegue recriar o ambiente e rodar os notebooks; 59 testes automáticos.
- **02/09 — uma apresentação na raiz**: a atual fica à vista; o apoio vai para `complementos/`; o que saiu de circulação, para `historico/`.

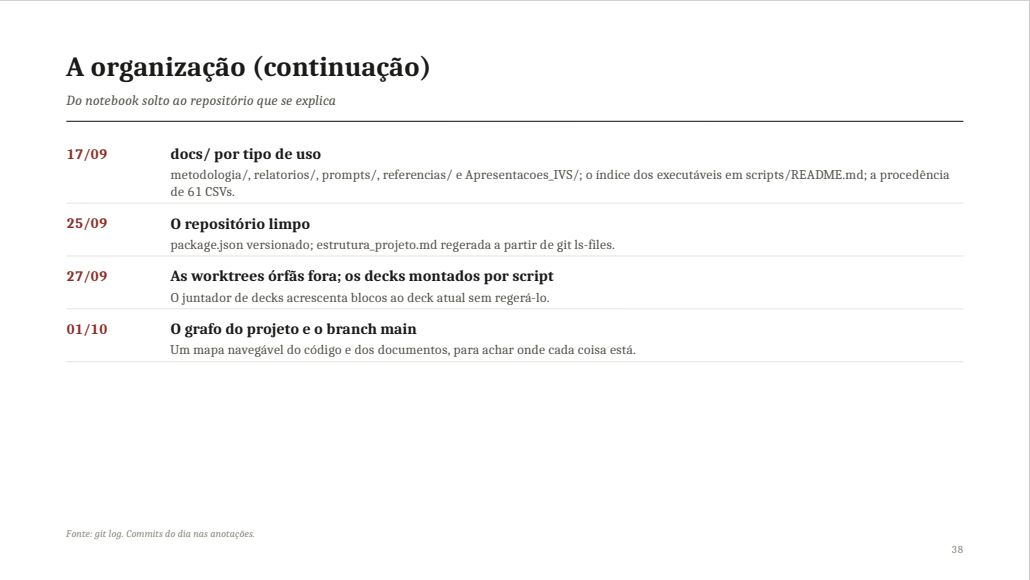
Reproduzível quer dizer que outra pessoa, com os mesmos dados e o mesmo código, chega aos mesmos números. É o padrão de qualidade da pesquisa atual.

COMO APRESENTAR

"A organização foi construída aos poucos, sempre com o mesmo objetivo: que qualquer pessoa consiga achar cada coisa e refazer cada número."

CRONOLOGIA · SLIDE 38

A organização (continuação)



A organização (continuação)

Do notebook solto ao repositório que se explica

17/09	**docs/ por tipo de uso** metodologia/, relatorios/, prompts/, referencias/ e Apresentacoes_IVS/; o índice dos executáveis em scripts/README.md; a procedência de 61 CSVs.
25/09	**O repositório limpo** package.json versionado; estrutura_projeto.md regerada a partir de git ls-files.
27/09	**As worktrees órfãs fora; os decks montados por script** O juntador de decks acrescenta blocos ao deck atual sem regerá-lo.
01/10	**O grafo do projeto e o branch main** Um mapa navegável do código e dos documentos, para achar onde cada coisa está.

Fonte: git log. Commits do dia nas anotações.

38

> *A documentação por tipo de uso, o repositório limpo, os decks montados por programa e o mapa do projeto.*

O QUE APARECE NO SLIDE

Quatro entradas: 17/09, 25/09, 27/09 e 01/10.

O QUE ISSO QUER DIZER, DO ZERO

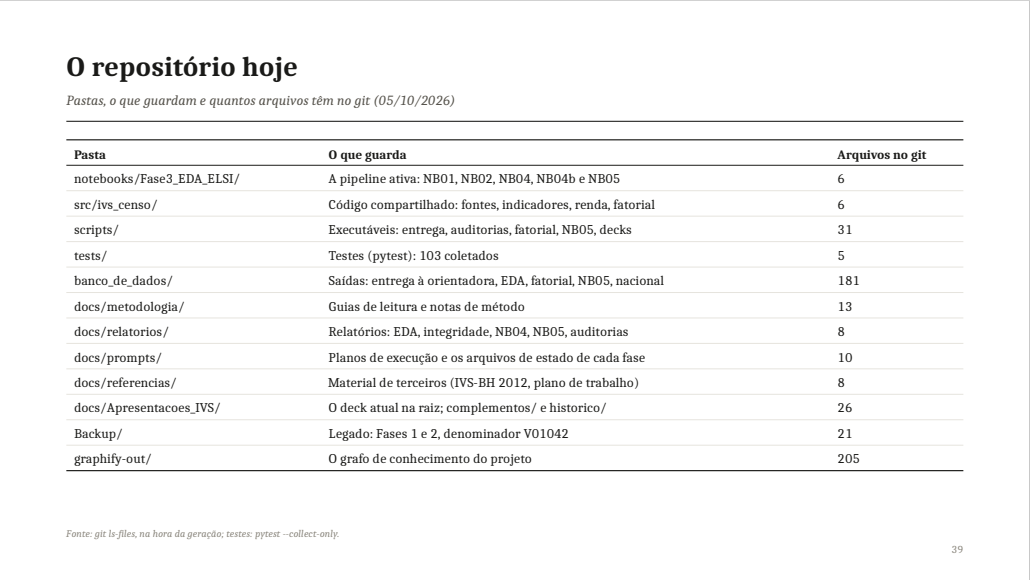
- **17/09 — documentação por tipo de uso**: `docs/` ganha subpastas — `metodologia/` (guias e notas de método), `relatorios/` (os relatórios), `prompts/` (planos de execução e arquivos de estado de cada fase), `referencias/` (material de terceiros) e `Apresentacoes_IVS/`. O índice dos executáveis fica em `scripts/README.md`, e 61 tabelas ganham procedência.
- **25/09 — o repositório limpo**: arquivos de configuração que deviam estar no git passam a estar, e a árvore de pastas documentada é regerada direto da lista de arquivos do git.
- **27/09 — decks por programa**: o deck principal não é mais regerado; recebe blocos novos, gerados por programa, pelo "juntador".
- **01/10 — o mapa**: o grafo do projeto passa a cobrir código e documentos, para achar onde cada coisa está.

COMO APRESENTAR

“Em setembro, a documentação foi separada por tipo de uso, e as apresentações passaram a ser montadas por programa — o que é a garantia de que nenhum número fica desatualizado num slide.”

CRONOLOGIA · SLIDE 39

O repositório hoje



O repositório hoje

Pastas, o que guardam e quantos arquivos têm no git (05/10/2026)

Pasta	O que guarda	Arquivos no git
notebooks/Fase3_EDA_ELSI/	A pipeline ativa: NB01, NB02, NB04, NB04b e NB05	6
src/ivs_censo/	Código compartilhado: fontes, indicadores, renda, fatorial	6
scripts/	Executáveis: entrega, auditorias, fatorial, NB05, decks	31
tests/	Testes (pytest): 103 coletados	5
banco_de_dados/	Saídas: entrega à orientadora, EDA, fatorial, NB05, nacional	181
docs/metodologia/	Guias de leitura e notas de método	13
docs/relatorios/	Relatórios: EDA, integridade, NB04, NB05, auditorias	8
docs/prompts/	Planos de execução e os arquivos de estado de cada fase	10
docs/referencias/	Material de terceiros (IVS-BH 2012, plano de trabalho)	8
docs/Apresentacoes_IVS/	O deck atual na raiz; complementos/ e historico/	26
Backup/	Legado: Fases 1 e 2, denominador V01042	21
graphify-out/	O grafo de conhecimento do projeto	205

Fonte: git ls-files, na hora da geração; testes: pytest --collect-only.

39

> *Uma tabela com cada pasta do projeto, o que ela guarda e quantos arquivos tem.*

O QUE APARECE NO SLIDE

Uma tabela com três colunas: a pasta, o que ela guarda e quantos arquivos ela tem no git, contados na hora em que o deck foi gerado. A linha dos testes informa 103 testes coletados.

O QUE ISSO QUER DIZER, DO ZERO

Um roteiro das pastas, de cima para baixo:

- `notebooks/Fase3_EDA_ELSI/` — os notebooks da análise: NB01, NB02, NB04, NB04b e NB05;
- `src/ivs_censo/` — o módulo com as fórmulas e as funções compartilhadas;
- `scripts/` — os programas que rodam sozinhos (entrega, auditorias, fatorial, NB05, decks e este guia);
- `tests/` — os testes automáticos, que conferem se o código dá o resultado esperado. "103 coletados" é quantos testes o programa de testes (o `pytest`) encontrou;
- `banco_de_dados/` — as saídas: a entrega à orientadora, as tabelas da EDA, da fatorial e do NB05;
- `docs/metodologia/`, `docs/relatorios/`, `docs/prompts/`, `docs/referencias/` — a documentação, por tipo;
- `docs/Apresentacoes_IVS/` — as apresentações;
- `Backup/` — o legado;
- `graphify-out/` — o grafo do projeto.

A pasta `dados/`, com os arquivos brutos do IBGE (vários gigabytes), não vai para o git: é baixada de novo quando necessário.

COMO LER OS NÚMEROS

O número de arquivos não mede importância: `banco_de_dados/` e `graphify-out/` têm muitos arquivos porque guardam saídas geradas automaticamente; `src/ivs_censo/` tem poucos, mas é o coração do cálculo.

COMO APRESENTAR

“É assim que o repositório está hoje: cada pasta com um papel, e um mapa completo no MANUAL do projeto.”

CRONOLOGIA · SLIDE 40

Onde o projeto está



> *A divisória do capítulo 11: o cronograma contra o que foi feito, e o que vem depois.*

O QUE APARECE NO SLIDE

O número 11 em vermelho, o título "Onde o projeto está" e o subtítulo: o cronograma contra o que foi feito, e o que vem depois.

O QUE ISSO QUER DIZER, DO ZERO

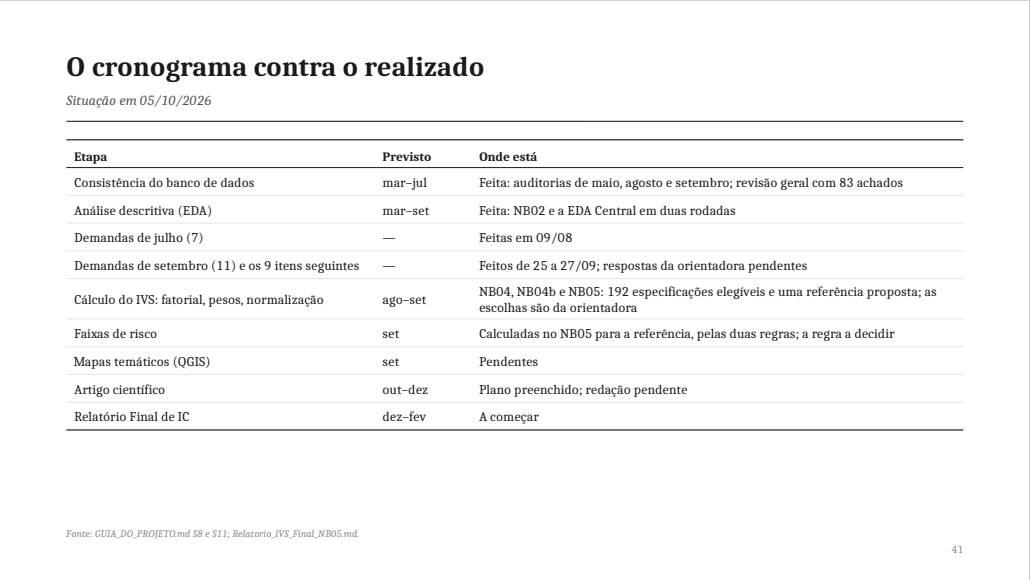
O fecho do deck volta ao calendário, mas olhando para a frente.

COMO APRESENTAR

“Para fechar, onde o projeto está e o que vem.”

CRONOLOGIA · SLIDE 41

O cronograma contra o realizado



O cronograma contra o realizado

Situação em 05/10/2026

Etapa	Previsto	Onde está
Consistência do banco de dados	mar–jul	Feita: auditorias de maio, agosto e setembro; revisão geral com 83 achados
Análise descritiva (EDA)	mar–set	Feita: NB02 e a EDA Central em duas rodadas
Demandas de julho (7)	—	Feitas em 09/08
Demandas de setembro (11) e os 9 itens seguintes	—	Feitos de 25 a 27/09; respostas da orientadora pendentes
Cálculo do IVS: fatorial, pesos, normalização	ago–set	NB04, NB04b e NB05: 192 especificações elegíveis e uma referência proposta; as escolhas são da orientadora
Faixas de risco	set	Calculadas no NB05 para a referência, pelas duas regras; a regra a decidir
Mapas temáticos (QGIS)	set	Pendentes
Artigo científico	out–dez	Plano preenchido; redação pendente
Relatório Final de IC	dez–fev	A começar

Fonte: GUIA_DO_PROJETO.md §8 e §11; Relatorio_IVS_Final_NB05.md.

41

> *Cada etapa do cronograma da bolsa, o período previsto e a situação de hoje.*

O QUE APARECE NO SLIDE

Uma tabela com nove linhas e três colunas: a etapa, o período previsto no cronograma e onde ela está.

O QUE ISSO QUER DIZER, DO ZERO

Linha a linha:

- **Consistência do banco de dados** (prevista de março a julho): feita, com auditorias em maio, agosto e setembro e a revisão geral.
- **Análise descritiva** (março a setembro): feita — o NB02 e a EDA Central, em duas rodadas.
- **Demandas de julho**: feitas em 09/08.
- **Demandas de setembro e os nove itens seguintes**: feitos de 25 a 27/09; faltam as respostas da orientadora.
- **Cálculo do IVS** (agosto e setembro): a análise fatorial e o NB05 estão prontos, com 192 especificações elegíveis e uma referência proposta; as escolhas são da orientadora.
- **Faixas de risco** (setembro): calculadas para a referência pelas duas regras; falta escolher a regra.
- **Mapas temáticos** (setembro): pendentes. Os mapas mostram o IVS de cada setor no mapa da cidade, num programa de geoprocessamento (o QGIS).
- **Artigo científico** (outubro a dezembro): o plano está preenchido; a redação, pendente.
- **Relatório Final de IC** (dezembro a fevereiro): a começar.

COMO APRESENTAR

“O cronograma está em dia até o cálculo do índice, que só depende das escolhas da orientadora. Os mapas estão atrasados em relação ao previsto, porque dependem do índice fechado. O artigo e o relatório final vêm depois.”

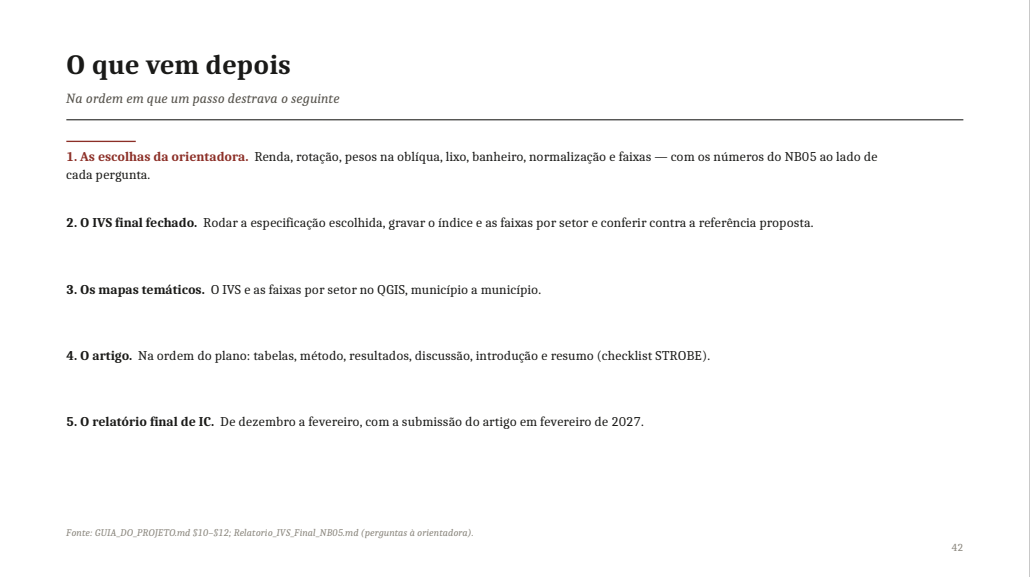
SE PERGUNTAREM

Por que os mapas ainda não foram feitos?

Porque mapear antes de fechar a especificação seria fazer o trabalho duas vezes: os mapas dependem do índice e das faixas finais.

CRONOLOGIA · SLIDE 42

O que vem depois



O que vem depois

Na ordem em que um passo destrava o seguinte

1. **As escolhas da orientadora.** Renda, rotação, pesos na oblíqua, lixo, banheiro, normalização e faixas — com os números do NB05 ao lado de cada pergunta.

2. **O IVS final fechado.** Rodar a especificação escolhida, gravar o índice e as faixas por setor e conferir contra a referência proposta.

3. **Os mapas temáticos.** O IVS e as faixas por setor no QGIS, município a município.

4. **O artigo.** Na ordem do plano: tabelas, método, resultados, discussão, introdução e resumo (checklist STROBE).

5. **O relatório final de IC.** De dezembro a fevereiro, com a submissão do artigo em fevereiro de 2027.

Fonte: GUIA_DO_PROJETO.md §10–§12; Relatorio_IVS_Final_NB05.md (perguntas à orientadora).

42

> *Os próximos cinco passos, na ordem em que um destrava o seguinte.*

O QUE APARECE NO SLIDE

Cinco blocos numerados, um embaixo do outro; o primeiro tem o filete vermelho.

O QUE ISSO QUER DIZER, DO ZERO

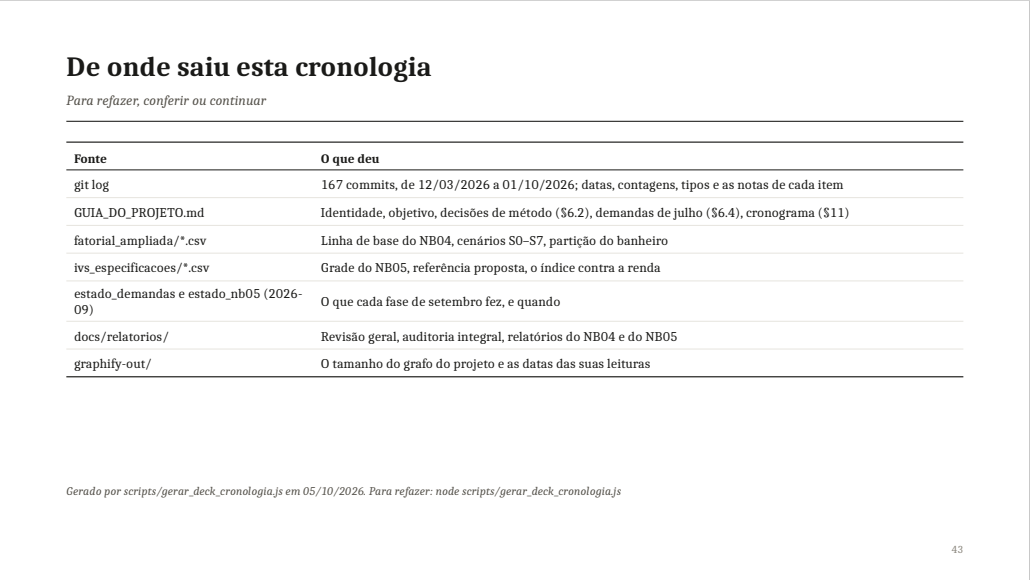
- **1. As escolhas da orientadora**: renda, rotação, pesos, lixo, banheiro, normalização e faixas — com os números do NB05 ao lado de cada pergunta. Tudo depende disto.
- **2. O IVS final fechado**: rodar a especificação escolhida, gravar o índice e as faixas de cada setor e conferir contra a referência proposta.
- **3. Os mapas temáticos**: o IVS e as faixas no mapa, município a município.
- **4. O artigo**: escrito na ordem do plano — tabelas, método, resultados, discussão, introdução e resumo —, seguindo o STROBE, uma lista de verificação internacional para relatar estudos observacionais.
- **5. O relatório final**: de dezembro a fevereiro, com a submissão do artigo em fevereiro de 2027.

COMO APRESENTAR

“O próximo passo não é meu: são as escolhas da orientadora. Com elas, o índice fecha, os mapas saem e o artigo começa.”

CRONOLOGIA · SLIDE 43

De onde saiu esta cronologia



De onde saiu esta cronologia

Para refazer, conferir ou continuar

Fonte	O que deu
git log	167 commits, de 12/03/2026 a 01/10/2026; datas, contagens, tipos e as notas de cada item
GUIA_DO_PROJETO.md	Identidade, objetivo, decisões de método (§6.2), demandas de julho (§6.4), cronograma (§11)
fatorial_ampliada/*.csv	Linha de base do NB04, cenários S0–S7, partição do banheiro
ivs_especificacoes/*.csv	Grade do NB05, referência proposta, o índice contra a renda
estado_demandas e estado_nb05 (2026-09)	O que cada fase de setembro fez, e quando
docs/relatorios/	Revisão geral, auditoria integral, relatórios do NB04 e do NB05
graphify-out/	O tamanho do grafo do projeto e as datas das suas leituras

Gerado por scripts/gerar_deck_cronologia.js em 05/10/2026. Para refazer: node scripts/gerar_deck_cronologia.js

43

> *As fontes de cada parte do deck e o comando para gerá-lo de novo.*

O QUE APARECE NO SLIDE

Uma tabela com duas colunas: a fonte e o que ela deu ao deck — o git (167 commits, de 12/03/2026 a 01/10/2026), o GUIA do projeto, as tabelas da fatorial ampliada e da grade do NB05, os arquivos de estado das fases, os relatórios e o grafo. Embaixo, a data em que o deck foi gerado e o comando para gerá-lo de novo.

O QUE ISSO QUER DIZER, DO ZERO

Este slide existe para a **rastreabilidade**: qualquer número ou data do deck pode ser seguido até a sua origem. O comando no pé (`node scripts/gerar_deck_cronologia.js`) roda o programa que monta o deck; `node` é o programa que executa código escrito em JavaScript.

COMO APRESENTAR

“Tudo o que vocês viram sai destas fontes, e o deck pode ser gerado de novo a qualquer momento, com os dados do dia.”

Parte C — As demandas de setembro, slide a slide

Demandas_Setembro_IVS_2026-10.pptx · 42 slides

O deck das demandas de setembro é a prestação de contas das últimas tarefas pedidas pela orientadora: as onze demandas de setembro e os nove itens que vieram em seguida. Ele vai do pedido à decisão, em dez partes: o que foi pedido e como foi lido; o ponto de partida (o NB04); as demandas 1 e 2; a fatorial ampliada (demandas 3 e 5 a 11); a revisão da apresentação (demanda 4); os testes seguintes e o banheiro graduado; a grade do IVS final (324 especificações); o que o índice acrescenta à renda; a referência proposta e por que desconfiar dela; e o que fica para a orientadora decidir.

Este é o deck mais técnico dos dois. Se ainda não leu a Parte A, leia antes as seções A.5 (índice composto), A.6 (análise fatorial), A.7 (validação) e A.9 (especificação e grade).

DEMANDAS DE SETEMBRO · SLIDE 1

As demandas de setembro



> *A capa: o deck responde às últimas demandas da orientadora, do pedido aos números, e deixa as escolhas de método com ela.*

O QUE APARECE NO SLIDE

A identificação do projeto no alto, o título "As demandas de setembro" e um subtítulo que resume o deck: o que foi pedido, como cada pedido foi lido, o que foi feito e o que os números dizem — da fatorial ampliada ao IVS final do Notebook 05. A última frase do subtítulo é a mais importante: as escolhas de método ficam com a orientadora, com os números ao lado de cada uma.

O QUE ISSO QUER DIZER, DO ZERO

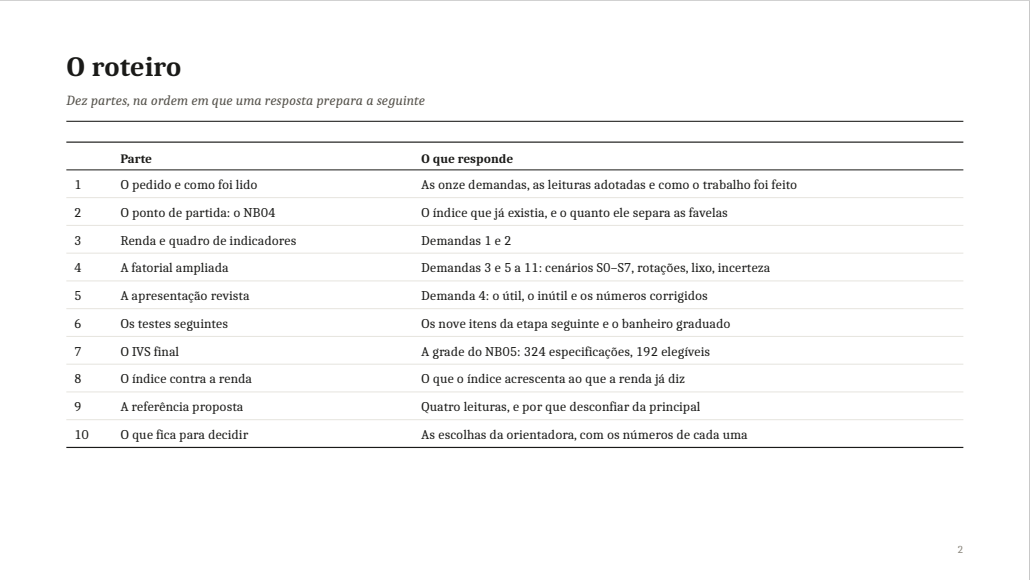
Uma **demanda** é um pedido de análise feito pela orientadora. Em setembro foram onze, e depois vieram mais nove itens de teste. O deck não toma as decisões de método: mostra o que cada opção muda. O **Notebook 05** (NB05) é o notebook que calcula o IVS final.

COMO APRESENTAR

“Este deck responde às demandas de setembro: o que foi pedido, como eu li cada pedido, o que foi feito e o que os números mostram. No fim, ficam as escolhas que são suas, cada uma com os números.”

DEMANDAS DE SETEMBRO · SLIDE 2

O roteiro



O roteiro

Dez partes, na ordem em que uma resposta prepara a seguinte

	Parte	O que responde
1	O pedido e como foi lido	As onze demandas, as leituras adotadas e como o trabalho foi feito
2	O ponto de partida: o NB04	O índice que já existia, e o quanto ele separa as favelas
3	Renda e quadro de indicadores	Demandas 1 e 2
4	A fatorial ampliada	Demandas 3 e 5 a 11: cenários S0–S7, rotações, lixo, incerteza
5	A apresentação revista	Demanda 4: o útil, o inútil e os números corrigidos
6	Os testes seguintes	Os nove itens da etapa seguinte e o banheiro graduado
7	O IVS final	A grade do NB05: 324 especificações, 192 elegíveis
8	O índice contra a renda	O que o índice acrescenta ao que a renda já diz
9	A referência proposta	Quatro leituras, e por que desconfiar da principal
10	O que fica para decidir	As escolhas da orientadora, com os números de cada uma

2

> *As dez partes do deck, na ordem em que cada resposta prepara a seguinte.*

O QUE APARECE NO SLIDE

Uma tabela de dez linhas: o número da parte, o nome e o que ela responde.

O QUE ISSO QUER DIZER, DO ZERO

A ordem segue uma lógica de argumento:

- primeiro, **o que foi pedido** e como cada pedido ambíguo foi interpretado (parte 1);
- depois, **o ponto de partida**: o índice que já existia, o do NB04 (parte 2);
- em seguida, as **respostas**: renda e quadro (parte 3), a fatorial ampliada (parte 4), a revisão da apresentação (parte 5) e os testes seguintes (parte 6);
- então, a **síntese**: todas as combinações de escolhas numa grade de 324 especificações (parte 7) e o que o índice acrescenta à renda (parte 8);
- por fim, a **proposta** e o **que falta decidir** (partes 9 e 10).

COMO APRESENTAR

“São dez partes. Começo pelo pedido e pelo ponto de partida, passo pelas respostas a cada demanda, junto tudo numa grade de especificações e termino nas escolhas que ficam com você.”

DEMANDAS DE SETEMBRO · SLIDE 3

O pedido e como foi lido



> *A divisória da parte 1: as onze demandas e os nove pontos que admitiam mais de uma leitura.*

O QUE APARECE NO SLIDE

O número 1 em vermelho, o título "O pedido e como foi lido" e o subtítulo: onze demandas de setembro; nove pontos com mais de uma leitura.

O QUE ISSO QUER DIZER, DO ZERO

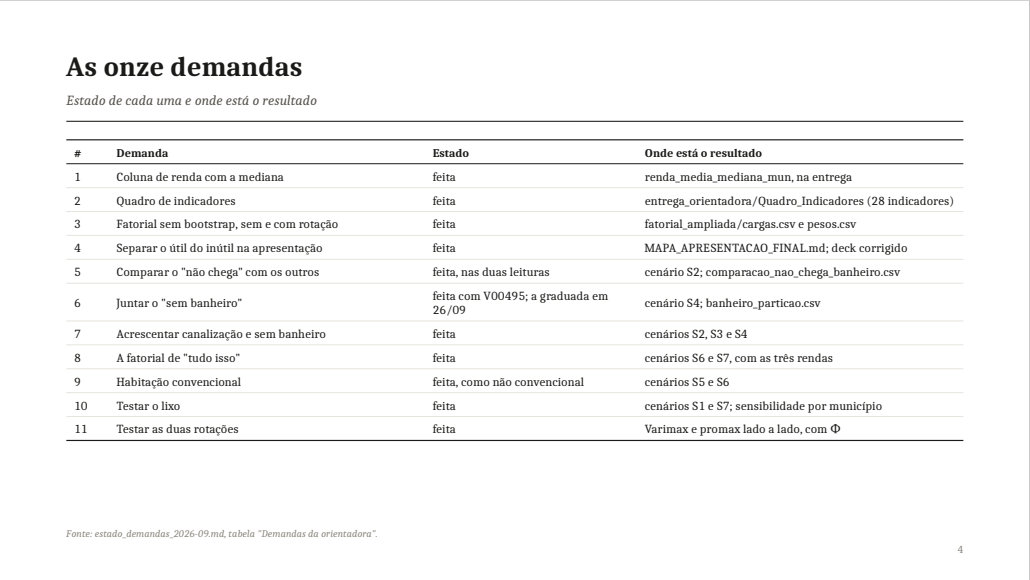
Pedido de análise raramente é preciso o bastante para virar conta sem interpretação. Esta parte deixa explícito como cada pedido foi lido — para que a orientadora possa corrigir a leitura antes de discutir os números.

COMO APRESENTAR

“A primeira parte é o pedido, e como eu o interpretei.”

DEMANDAS DE SETEMBRO · SLIDE 4

As onze demandas



As onze demandas

Estado de cada uma e onde está o resultado

#	Demanda	Estado	Onde está o resultado
1	Coluna de renda com a mediana	feita	renda_media_mediana_mun, na entrega
2	Quadro de indicadores	feita	entrega_orientadora/Quadro_Indicadores (28 indicadores)
3	Fatorial sem bootstrap, sem e com rotação	feita	fatorial_ampliada/cargas.csv e pesos.csv
4	Separar o útil do inútil na apresentação	feita	MAPA_APRESENTACAO_FINAL.md; deck corrigido
5	Comparar o "não chega" com os outros	feita, nas duas leituras	cenário S2; comparacao_nao_chega_banheiro.csv
6	Juntar o "sem banheiro"	feita com V00495; a graduada em 26/09	cenário S4; banheiro_particao.csv
7	Acrescentar canalização e sem banheiro	feita	cenários S2, S3 e S4
8	A fatorial de "tudo isso"	feita	cenários S6 e S7, com as três rendas
9	Habitação convencional	feita, como não convencional	cenários S5 e S6
10	Testar o lixo	feita	cenários S1 e S7; sensibilidade por município
11	Testar as duas rotações	feita	Varimax e promax lado a lado, com Φ

Fonte: estado_demandas_2026-09.md, tabela "Demandas da orientadora".

4

> *As onze demandas de setembro, o estado de cada uma — todas feitas — e onde está o resultado.*

O QUE APARECE NO SLIDE

Uma tabela de onze linhas com quatro colunas: o número da demanda, o que foi pedido, o estado e onde está o resultado (um arquivo ou um cenário).

O QUE ISSO QUER DIZER, DO ZERO

As onze demandas, em palavras simples:

- **1. Coluna de renda com a mediana**: trocar a renda do setor extremo de Belo Horizonte pela mediana (Parte A, A.5) e entregar isso como uma coluna nova.
- **2. Quadro de indicadores**: uma tabela única com todos os indicadores, como cada um é calculado e de que arquivo vem (28 indicadores).
- **3. Fatorial sem bootstrap, sem e com rotação**: refazer a análise fatorial mostrando lado a lado a solução sem rotação e as com rotação, e sem o bootstrap (A.8).
- **4. Separar o útil do inútil**: revisar a apresentação principal, tirando o que não serve.
- **5. Comparar o "não chega"**: comparar a variável de água que não chega encanada ao domicílio com as outras categorias de água e com os indicadores do índice.
- **6. Juntar o "sem banheiro"**: reunir as categorias de falta de banheiro numa variável só.
- **7. Acrescentar canalização e sem banheiro**: pôr essas variáveis novas na análise fatorial.
- **8. A fatorial de "tudo isso"**: uma análise com todas as variáveis novas juntas.
- **9. Habitação convencional**: incluir a variável de tipo de moradia.
- **10. Testar o lixo**: ver o que muda com e sem o lixo.
- **11. Testar as duas rotações**: Varimax e promax lado a lado (A.6).

Cada demanda virou um ou mais **cenários** — conjuntos de variáveis — chamados de S0 a S7, explicados no slide 13.

COMO APRESENTAR

“As onze demandas estão feitas. A tabela diz onde está cada resultado; a maioria virou um cenário da análise fatorial ampliada, que eu mostro na parte 4.”

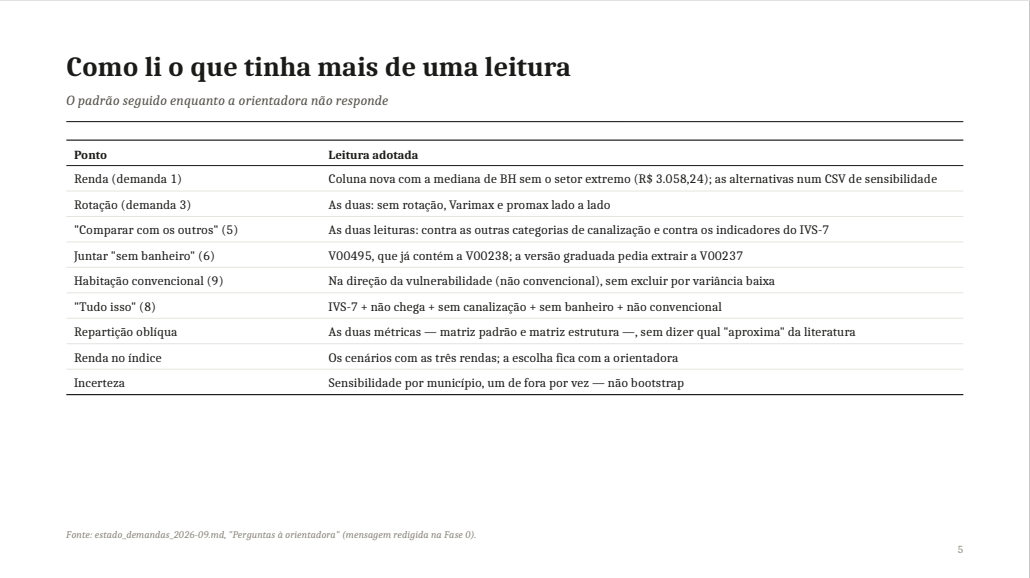
SE PERGUNTAREM

Por que a demanda 6 diz “a graduada em 26/09”?

Porque juntar o “sem banheiro” tinha duas leituras: usar a variável que já é a soma (V00495) ou criar uma versão em graus, que exigia extrair uma variável nova do Censo (V00237). A primeira foi feita em 25/09; a segunda, no dia seguinte.

DEMANDAS DE SETEMBRO · SLIDE 5

Como li o que tinha mais de uma leitura



Como li o que tinha mais de uma leitura

O padrão seguido enquanto a orientadora não responde

Ponto	Leitura adotada
Renda (demanda 1)	Coluna nova com a mediana de BH sem o setor extremo (R$ 3.058,24); as alternativas num CSV de sensibilidade
Rotação (demanda 3)	As duas: sem rotação, Varimax e promax lado a lado
"Comparar com os outros" (5)	As duas leituras: contra as outras categorias de canalização e contra os indicadores do IVS-7
Juntar "sem banheiro" (6)	V00495, que já contém a V00238; a versão graduada pedia extrair a V00237
Habitação convencional (9)	Na direção da vulnerabilidade (não convencional), sem excluir por variância baixa
"Tudo isso" (8)	IVS-7 + não chega + sem canalização + sem banheiro + não convencional
Repartição oblíqua	As duas métricas — matriz padrão e matriz estrutura —, sem dizer qual "aproxima" da literatura
Renda no índice	Os cenários com as três rendas; a escolha fica com a orientadora
Incerteza	Sensibilidade por município, um de fora por vez — não bootstrap

Fonte: estado_demandas_2026-09.md, "Perguntas à orientadora" (mensagem redigida na Fase 0).

5

Nove pontos ambíguos e a leitura adotada em cada um, enquanto a orientadora não responde.

O QUE APARECE NO SLIDE

Uma tabela de nove linhas: o ponto (com o número da demanda) e a leitura adotada.

O QUE ISSO QUER DIZER, DO ZERO

Cada ponto, explicado:

- **Renda (demanda 1)**: "a mediana" de quê? A mediana da renda dentro do próprio setor não existe nos dados publicados. A leitura adotada: uma coluna nova em que o setor extremo recebe a mediana de Belo Horizonte sem ele (R$ 3.058,24); as alternativas ficam registradas.
- **Rotação (demanda 3)**: qual rotação? As duas, e também a solução sem rotação, lado a lado.
- **"Comparar com os outros" (demanda 5)**: comparar com o quê? As duas leituras: com as outras categorias de canalização da água e com os indicadores do índice.
- **Juntar "sem banheiro" (demanda 6)**: usar a `V00495`, que já contém a `V00238`; a versão em graus exigia extrair a `V00237`.
- **Habitação convencional (demanda 9)**: entra virada para o lado da vulnerabilidade — a proporção de moradias *não* convencionais —, sem ser excluída por variar pouco.
- **"Tudo isso" (demanda 8)**: o IVS-7 mais as quatro variáveis novas.
- **Repartição oblíqua**: na promax há duas matrizes (A.6); as duas são mostradas, sem dizer qual é "a certa".
- **Renda no índice**: os cenários rodam com as três versões da renda; a escolha é da orientadora.
- **Incerteza**: sensibilidade por município em vez de bootstrap (A.8).

COMO APRESENTAR

“Nove pontos tinham mais de uma leitura. Em cada um, segui a leitura que está na tabela, e ela pode ser trocada sem refazer o trabalho: basta mudar o parâmetro do cenário e rodar de novo.”

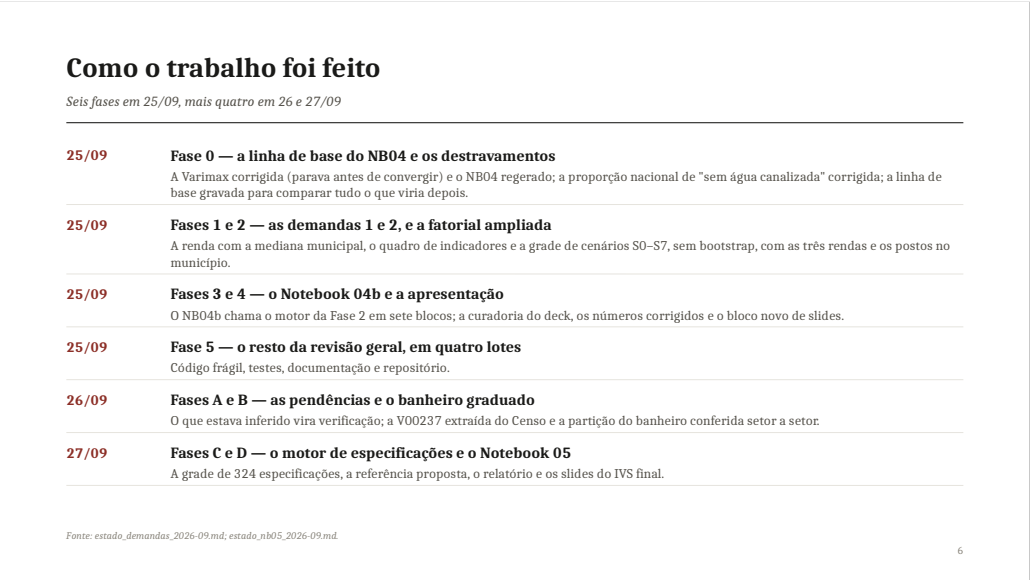
SE PERGUNTAREM

E se a orientadora tinha outra leitura em mente?

Então troca-se a leitura. Todas as análises são geradas por programa a partir de parâmetros; mudar uma leitura é mudar um parâmetro e rodar de novo.

DEMANDAS DE SETEMBRO · SLIDE 6

Como o trabalho foi feito



Como o trabalho foi feito

Seis fases em 25/09, mais quatro em 26 e 27/09

25/09	**Fase 0 — a linha de base do NB04 e os destravamentos**	A Varimax corrigida (parava antes de convergir) e o NB04 regerado; a proporção nacional de "sem água canalizada" corrigida; a linha de base gravada para comparar tudo o que viria depois.
25/09	**Fases 1 e 2 — as demandas 1 e 2, e a fatorial ampliada**	A renda com a mediana municipal, o quadro de indicadores e a grade de cenários S0–S7, sem bootstrap, com as três rendas e os postos no município.
25/09	**Fases 3 e 4 — o Notebook 04b e a apresentação**	O NB04b chama o motor da Fase 2 em sete blocos; a curadoria do deck, os números corrigidos e o bloco novo de slides.
25/09	**Fase 5 — o resto da revisão geral, em quatro lotes**	Código frágil, testes, documentação e repositório.
26/09	**Fases A e B — as pendências e o banheiro graduado**	O que estava inferido vira verificação; a V00237 extraída do Censo e a partição do banheiro conferida setor a setor.
27/09	**Fases C e D — o motor de especificações e o Notebook 05**	A grade de 324 especificações, a referência proposta, o relatório e os slides do IVS final.

Fonte: estado_demandas_2026-09.md; estado_nb05_2026-09.md.

6

> *As dez fases do trabalho em três dias: seis em 25/09, duas em 26/09 e duas em 27/09.*

O QUE APARECE NO SLIDE

Uma página de diário com seis entradas: 25/09 (Fase 0; Fases 1 e 2; Fases 3 e 4; Fase 5), 26/09 (Fases A e B) e 27/09 (Fases C e D).

O QUE ISSO QUER DIZER, DO ZERO

O trabalho foi dividido em fases, cada uma com um arquivo de estado que registra o que foi feito:

- **Fase 0**: a linha de base — os números do NB04 contra os quais tudo é comparado — e as correções que travavam o resto (a Varimax, a proporção nacional de água).
- **Fases 1 e 2**: as demandas 1 e 2 e a fatorial ampliada.
- **Fases 3 e 4**: o Notebook 04b, que roda a fatorial ampliada, e a revisão da apresentação.
- **Fase 5**: o resto da revisão geral do repositório.
- **Fases A e B**: as pendências e o banheiro graduado.
- **Fases C e D**: o motor de especificações e o Notebook 05.

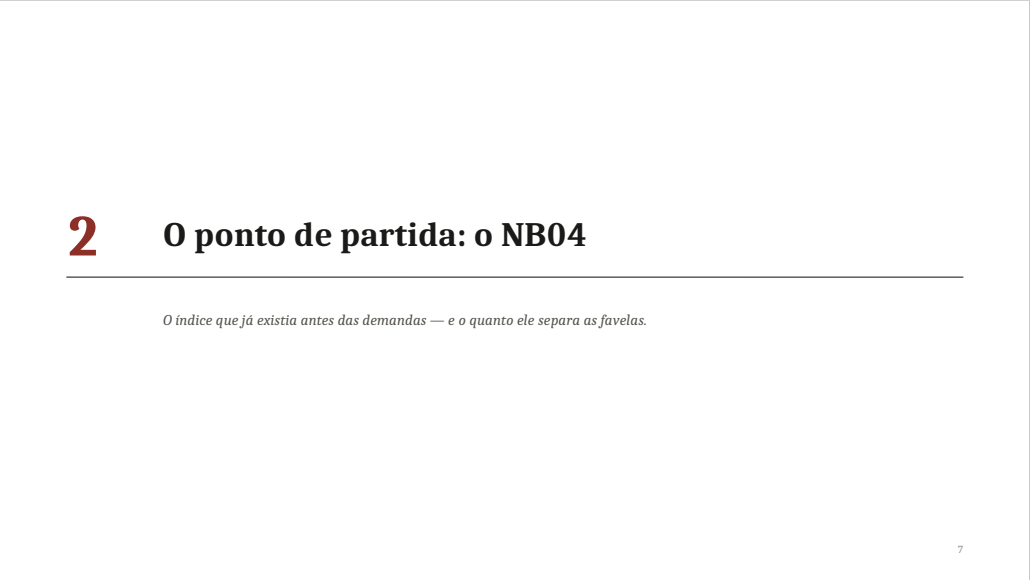
A cronologia (Parte B, slides 21 a 26) conta as mesmas fases com mais detalhe.

COMO APRESENTAR

“O trabalho foi feito em fases, cada uma registrada: em 25/09, as demandas; em 26 e 27/09, os testes de cada escolha e o IVS final.”

DEMANDAS DE SETEMBRO · SLIDE 7

O ponto de partida: o NB04



> *A divisória da parte 2: o índice que existia antes das demandas e o quanto ele separa as favelas.*

O QUE APARECE NO SLIDE

O número 2 em vermelho, o título "O ponto de partida: o NB04" e o subtítulo: o índice que já existia antes das demandas — e o quanto ele separa as favelas.

O QUE ISSO QUER DIZER, DO ZERO

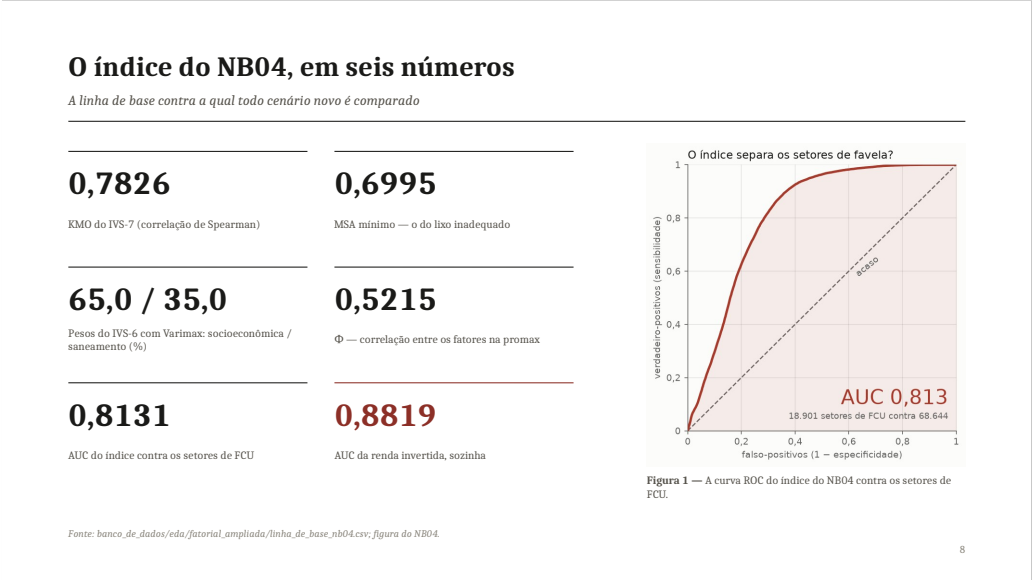
Toda mudança precisa de um ponto de comparação. Aqui ele é o NB04, o notebook da análise fatorial de 17/09, corrigido em 25/09.

COMO APRESENTAR

“Antes das respostas, o ponto de partida: o índice do NB04.”

DEMANDAS DE SETEMBRO · SLIDE 8

O índice do NB04, em seis números



> *Os seis números que resumem o NB04 — e o sexto, em vermelho, é o problema: a renda sozinha separa as favelas melhor que o índice.*

O QUE APARECE NO SLIDE

À esquerda, seis números grandes em duas colunas, cada um sobre um filete e com uma legenda embaixo: 0,7826, 0,6995, 65,0 / 35,0, 0,5215, 0,8131 e, em vermelho, 0,8819. À direita, a curva ROC do índice contra os setores de favela, com a área sombreada e a AUC escrita no canto.

O QUE ISSO QUER DIZER, DO ZERO

Os seis números, um por um:

- **KMO do IVS-7**: o quanto os dados servem para análise fatorial (A.6). Acima de 0,7 é bom.
- **MSA mínimo**: o KMO da variável que menos conversa com as outras. É o do lixo: ele está no limite.
- **Pesos do IVS-6 com Varimax**: sem o lixo, a análise acha dois fatores e reparte o peso entre eles — socioeconômico e saneamento.
- **Φ**: na rotação promax, a correlação entre os dois fatores. Moderada: as dimensões não são independentes.
- **AUC do índice**: o quanto o índice separa os setores de favela (A.7).
- **AUC da renda sozinha**: o mesmo, usando só a renda invertida. Está em vermelho porque é maior.

A **curva ROC**, à direita, mostra a separação de todos os jeitos possíveis de cortar o índice. O eixo de baixo é a proporção de setores *não* favela que o corte marcaria por engano; o eixo da esquerda, a proporção de favelas que ele acertaria. A diagonal tracejada é o acaso; quanto mais a curva sobe para o canto de cima, à esquerda, melhor.

COMO LER OS NÚMEROS

A AUC de 0,8131 quer dizer que, sorteando um setor de favela e um que não é, o índice dá o valor maior ao de favela em cerca de 81% dos pares. A renda sozinha faz isso em cerca de 88% (0,8819). A curva foi calculada sobre 18.901 setores de favela contra 68.644 que não são. Sem São Paulo, o peso socioeconômico cairia para 62,91% — o que mostra quanto um município grande pode pesar.

COMO APRESENTAR

“Este é o ponto de partida. Os dados servem para análise fatorial, a análise divide os pesos em aproximadamente dois terços socioeconômico e um terço saneamento, e o índice separa bem as favelas — mas a renda sozinha separa melhor. Guardem esse sexto número, porque ele volta.”

SE PERGUNTAREM

Uma AUC de 0,81 é boa?

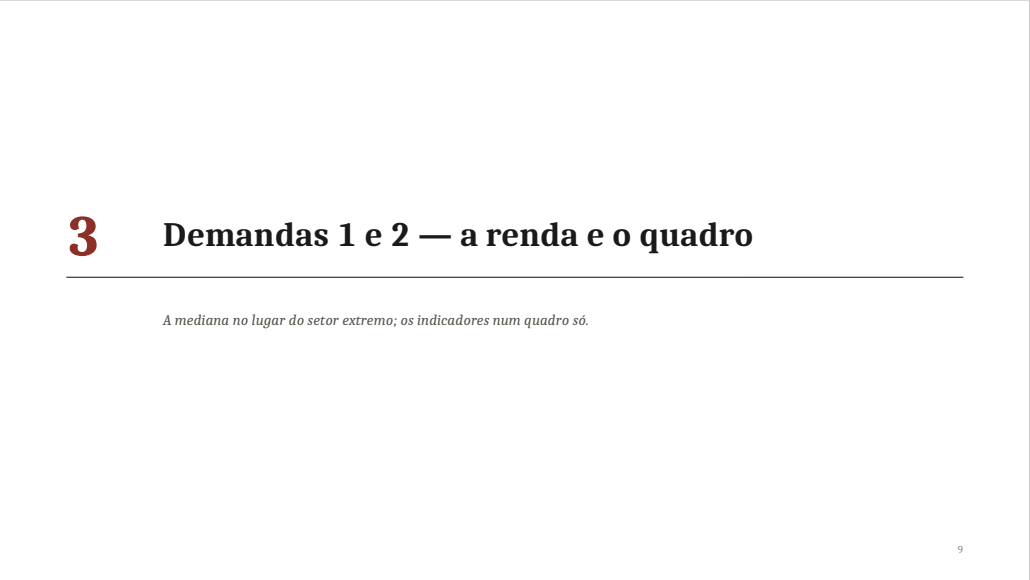
É boa: bem acima do acaso (0,5). O ponto não é que o índice seja ruim, e sim que a renda, sozinha, já é melhor nessa tarefa específica.

Por que comparar com a renda?

Porque a renda é o indicador mais simples e mais conhecido. Se o índice não superar a renda em nada, precisa justificar por que existe. A parte 8 mostra em que ele supera.

DEMANDAS DE SETEMBRO · SLIDE 9

Demandas 1 e 2 — a renda e o quadro



A divisória da parte 3: a renda com a mediana e o quadro de indicadores.

O QUE APARECE NO SLIDE

O número 3 em vermelho, o título "Demandas 1 e 2 — a renda e o quadro" e o subtítulo: a mediana no lugar do setor extremo; os indicadores num quadro só.

O QUE ISSO QUER DIZER, DO ZERO

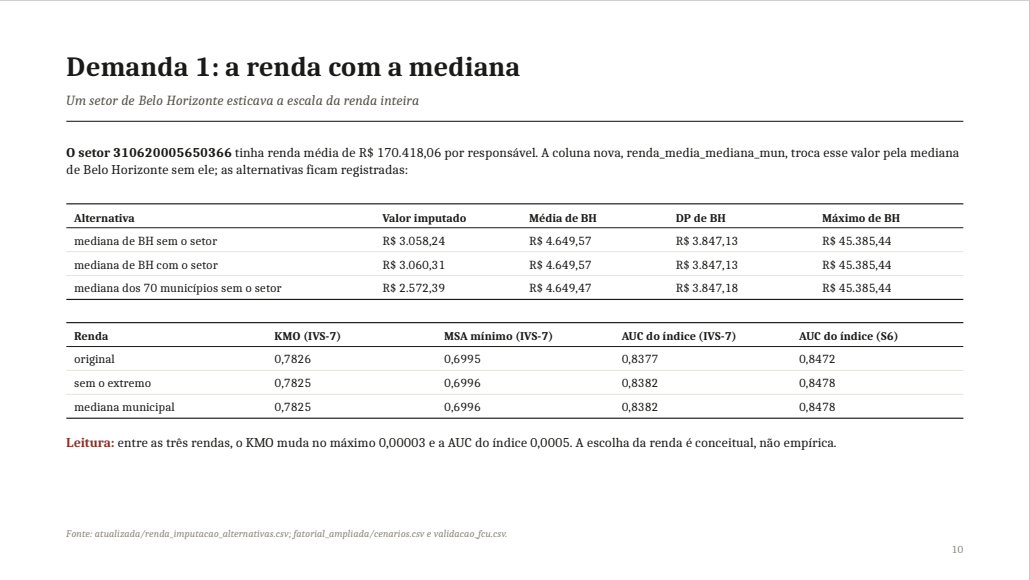
As duas primeiras demandas são de dados, não de análise: uma coluna nova de renda e uma tabela que documenta todos os indicadores.

COMO APRESENTAR

“A parte 3 responde às duas primeiras demandas.”

DEMANDAS DE SETEMBRO · SLIDE 10

Demanda 1: a renda com a mediana



Demanda 1: a renda com a mediana

Um setor de Belo Horizonte esticava a escala da renda inteira

O setor 310620005650366 tinha renda média de R$ 170.418,06 por responsável. A coluna nova, renda_media_mediana_mun, troca esse valor pela mediana de Belo Horizonte sem ele; as alternativas ficam registradas:

Alternativa	Valor imputado	Média de BH	DP de BH	Máximo de BH
mediana de BH sem o setor	R$ 3.058,24	R$ 4.649,57	R$ 3.847,13	R$ 45.385,44
mediana de BH com o setor	R$ 3.060,31	R$ 4.649,57	R$ 3.847,13	R$ 45.385,44
mediana dos 70 municípios sem o setor	R$ 2.572,39	R$ 4.649,47	R$ 3.847,18	R$ 45.385,44

Renda	KMO (IVS-7)	MSA mínimo (IVS-7)	AUC do índice (IVS-7)	AUC do índice (S6)
original	0,7826	0,6995	0,8377	0,8472
sem o extremo	0,7825	0,6996	0,8382	0,8478
mediana municipal	0,7825	0,6996	0,8382	0,8478

Leitura: entre as três rendas, o KMO muda no máximo 0,00003 e a AUC do índice 0,0005. A escolha da renda é conceitual, não empírica.

Fonte: atualizada/renda_imputacao_alternativas.csv; fatorial_ampliada/cenarios.csv e validacao_fcu.csv.

10

> *O setor de renda extrema recebe a mediana de Belo Horizonte, e as três versões da renda dão praticamente o mesmo resultado na análise fatorial.*

O QUE APARECE NO SLIDE

Uma frase de abertura sobre o setor `310620005650366` (R$ 170.418,06 de renda média). Depois, duas tabelas. A primeira tem as três alternativas de valor para pôr no lugar do extremo: a mediana de BH sem o setor (R$ 3.058,24), a mediana de BH com o setor (R$ 3.060,31) e a mediana dos 70 municípios sem o setor (R$ 2.572,39) — com a média, o desvio-padrão e o máximo de BH depois da troca. A segunda tem o efeito de cada versão da renda na análise fatorial: KMO, MSA mínimo e AUC do índice no IVS-7 e no cenário S6. Uma linha de leitura, em vermelho, fecha o slide.

O QUE ISSO QUER DIZER, DO ZERO

O problema é o **valor extremo**: um setor com renda média muito acima de todos os outros. Na normalização min-max (A.5), ele vira o máximo, e todos os outros setores ficam espremidos perto de zero.

A solução pedida é a **imputação pela mediana**: trocar o valor extremo pela mediana — o valor do meio de uma lista ordenada, que não é puxado por extremos. Três medianas foram consideradas:

- a de Belo Horizonte **sem** o setor (R$ 3.058,24) — a escolhida, porque o setor é de BH e a mediana não deve incluir o próprio valor que se quer corrigir;
- a de Belo Horizonte **com** o setor (R$ 3.060,31) — quase igual, porque a mediana é robusta a um valor extremo;
- a dos 70 municípios (R$ 2.572,39) — mais baixa, porque mistura cidades de renda menor.

Depois da troca, a média de BH fica em R$ 4.649,57, o desvio-padrão em R$ 3.847,13 e o máximo em R$ 45.385,44.

As três versões da renda no projeto passam a ser: a **original** (com o setor extremo), a **sem o extremo** (o setor fica sem valor) e a **mediana municipal** (o setor recebe a mediana de BH).

COMO LER OS NÚMEROS

A segunda tabela é a que importa para a decisão: entre as três versões, o KMO muda no máximo 0,00003 e a AUC do índice, 0,0005. São diferenças na terceira ou quarta casa decimal — na prática, nenhuma. Por isso a

conclusão do slide: a escolha da renda é conceitual (qual tratamento do extremo é mais defensável), não empírica (os números não decidem).

COMO APRESENTAR

"O setor extremo de Belo Horizonte recebeu a mediana da cidade sem ele, e as alternativas ficaram registradas. Na análise fatorial, as três versões da renda dão o mesmo resultado até a terceira casa. Então a escolha da renda é de princípio: qual tratamento do extremo você prefere defender."

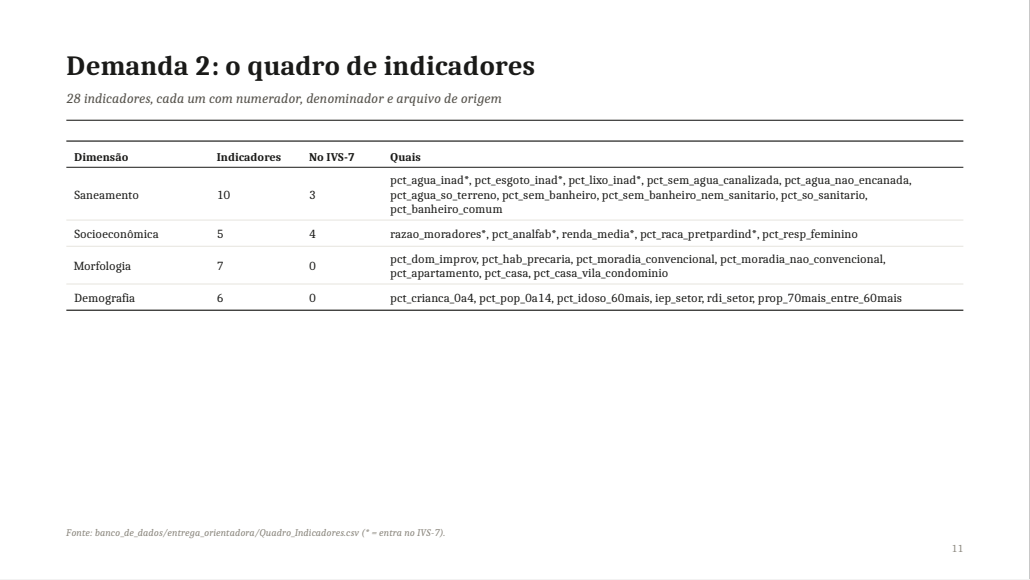
SE PERGUNTAREM

Por que o extremo quase não muda a fatorial, se muda tanto a normalização?

Porque a análise fatorial usa a correlação de Spearman, que trabalha com posições (A.6). O setor extremo é "o primeiro" com qualquer valor. Já a normalização min-max usa o valor em si — e aí ele distorce tudo.

DEMANDAS DE SETEMBRO · SLIDE 11

Demanda 2: o quadro de indicadores



Demanda 2: o quadro de indicadores

28 indicadores, cada um com numerador, denominador e arquivo de origem

Dimensão	Indicadores	No IVS-7	Quais
Saneamento	10	3	pct_agua_inad*, pct_esgoto_inad*, pct_lixo_inad*, pct_sem_agua_canalizada, pct_agua_nao_encanada, pct_agua_so_terreno, pct_sem_banheiro, pct_sem_banheiro_nem_sanitario, pct_so_sanitario, pct_banheiro_comum
Socioeconômica	5	4	razao_moradores*, pct_analfab*, renda_media*, pct_raca_pretpardind*, pct_resp_feminino
Morfologia	7	0	pct_dom_improv, pct_hab_precaria, pct_moradia_convencional, pct_moradia_nao_convencional, pct_apartamento, pct_casa, pct_casa_vila_condominio
Demografia	6	0	pct_crianca_0a4, pct_pop_0a14, pct_idoso_60mais, iep_setor, rdi_setor, prop_70mais_entre_60mais

Fonte: banco_de_dados/entrega_orientadora/Quadro_Indicadores.csv (= entra no IVS-7).*

11

Os 28 indicadores do projeto, por dimensão, com os 7 que entram no IVS-7 marcados com asterisco.

O QUE APARECE NO SLIDE

Uma tabela com quatro linhas, uma por dimensão: saneamento (10 indicadores), socioeconômica (5), morfologia (7) e demografia (6). Para cada uma, quantos indicadores, quantos entram no IVS-7 e a lista dos nomes; os do IVS-7 têm um asterisco.

O QUE ISSO QUER DIZER, DO ZERO

O quadro completo, na entrega à orientadora, tem para cada indicador: o que mede, o numerador, o denominador, se usa complemento, o arquivo de origem e uma observação. A tabela abaixo reproduz, do próprio quadro, o que cada nome quer dizer. Os indicadores fora do IVS-7 são **descritivos**: caracterizam o território (idade, tipo de moradia, chefia feminina), mas não entram na soma do índice.

Indicador	Dimensão	IVS-7	O que mede (do quadro)
`pct_agua_inad`	Saneamento	Sim	Proporção de domicílios com abastecimento de água inadequado ou ausente

Indicador	Dimensão	IVS-7	O que mede (do quadro)
pct_esgoto_inad	Saneamento	Sim	Proporção de domicílios com esgotamento sanitário inadequado ou ausente
pct_lixo_inad	Saneamento	Sim	Proporção de domicílios com destino do lixo inadequado ou ausente
razao_moradores	Socioeconômica	Sim	Razão de moradores por domicílio (reproduz o V0005 do IBGE)
pct_analfab	Socioeconômica	Sim	Taxa de analfabetismo entre pessoas de 15 anos ou mais
renda_media	Socioeconômica	Sim	Rendimento nominal médio mensal das pessoas responsáveis (R$)
pct_raca_pretpardind	Socioeconômica	Sim	Proporção de pessoas de cor/raça preta, parda ou indígena
pct_dom_improv	Morfologia	Não	Proporção de domicílios particulares improvisados
pct_hab_precaria	Morfologia	Não	Proporção de domicílios em habitação precária (cortiço, estrutura degradada, improvisados)
pct_moradia_convencional	Morfologia	Não	Proporção de moradias convencionais (casa, casa de vila/condomínio, apartamento)
pct_moradia_nao_convencional	Morfologia	Não	Proporção de moradias não convencionais (cortiço, maloca, estrutura degradada)
pct_apartamento	Morfologia	Não	Proporção de domicílios do tipo apartamento
pct_casa	Morfologia	Não	Proporção de domicílios do tipo casa
pct_casa_vila_condominio	Morfologia	Não	Proporção de domicílios do tipo casa de vila ou em condomínio
pct_sem_agua_canalizada	Saneamento	Não	Proporção de domicílios em que a água não chega encanada até dentro do domicílio (complemento de V00199; equivale a V00200+V00201 sobre V00001)
pct_agua_nao_encanada	Saneamento	Não	Proporção de domicílios em que a água não chega encanada ao domicílio (V00201)
pct_agua_so_terreno	Saneamento	Não	Proporção de domicílios em que a água chega encanada apenas ao terreno (V00200)
pct_sem_banheiro	Saneamento	Não	Proporção de domicílios sem banheiro de uso exclusivo com chuveiro e vaso sanitário
pct_sem_banheiro_nem_sanitario	Saneamento	Não	Proporção de domicílios sem banheiro nem sanitário
pct_so_sanitario	Saneamento	Não	Proporção de domicílios com apenas sanitário ou buraco para dejeções
pct_banheiro_comum	Saneamento	Não	Proporção de domicílios com apenas banheiro de uso comum
pct_resp_feminino	Socioeconômica	Não	Proporção de domicílios com pessoa responsável do sexo feminino
pct_crianca_0a4	Demografia	Não	Proporção de crianças de 0 a 4 anos na população residente
pct_pop_0a14	Demografia	Não	Proporção de pessoas com menos de 15 anos na população residente
pct_idoso_60mais	Demografia	Não	Proporção de pessoas de 60 anos ou mais na população residente

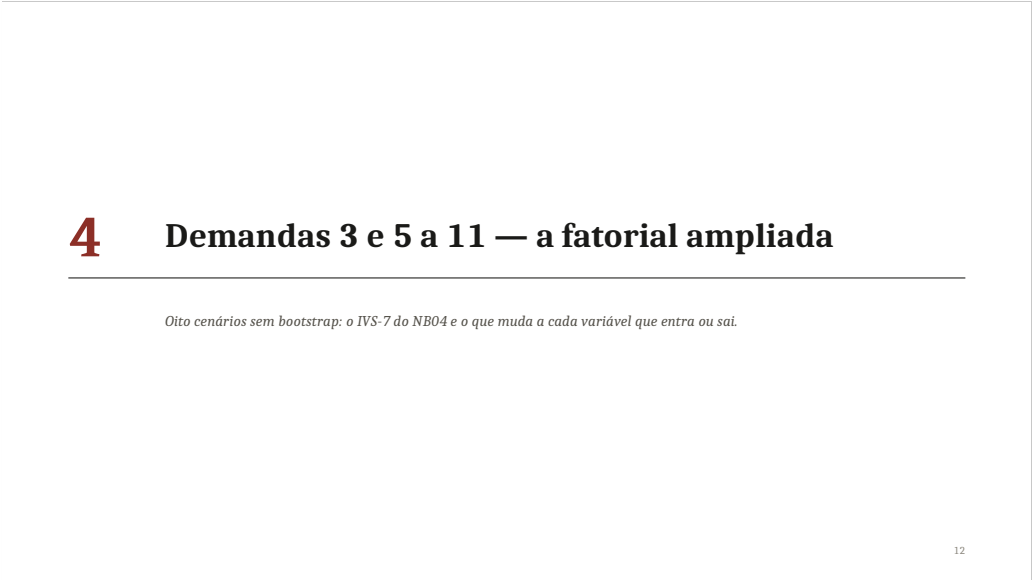
Indicador	Dimensão	IVS-7	O que mede (do quadro)
`iep_setor`	Demografia	Não	Índice de Envelhecimento Populacional: 60+ por 100 menores de 15 anos
`rdi_setor`	Demografia	Não	Razão de Dependência de Idosos: 60+ por 100 pessoas de 15 a 59 anos
`prop_70mais_entre_60mais`	Demografia	Não	Proporção de pessoas de 70+ entre os de 60+ (proxy de longevidade; NÃO é o LI, que exigiria a faixa 75+, inexistente nos agregados por setor)

COMO APRESENTAR

"O quadro documenta os 28 indicadores: como cada um é calculado e de onde vem. Sete entram no índice; os outros descrevem o território."

DEMANDAS DE SETEMBRO · SLIDE 12

Demandas 3 e 5 a 11 — a fatorial ampliada



> *A divisória da parte 4: a análise fatorial repetida em oito cenários, um para cada mudança pedida.*

O QUE APARECE NO SLIDE

O número 4 em vermelho, o título "Demandas 3 e 5 a 11 — a fatorial ampliada" e o subtítulo: oito cenários sem bootstrap, o IVS-7 do NB04 e o que muda a cada variável que entra ou sai.

O QUE ISSO QUER DIZER, DO ZERO

A maior parte das demandas pede para mudar o conjunto de variáveis da análise fatorial. Em vez de uma análise nova para cada pedido, a **fatorial ampliada** organiza tudo em **cenários**: cada cenário é uma análise fatorial completa, com um conjunto de variáveis, e todos são comparados com o S0 (o IVS-7 do NB04).

COMO APRESENTAR

"A parte 4 é a fatorial ampliada: oito cenários, um para cada mudança pedida."

DEMANDAS DE SETEMBRO · SLIDE 13

Os cenários: o que entra em cada um



Os cenários: o que entra em cada um

Cada linha é uma análise fatorial completa, sobre a mesma regra de setores

	O que entra	Demanda	Variáveis	Setores	KMO	MSA mín.	Fatores K/H	Var. 2 fat.
S0	IVS-7 (referência, reproduz o NB04)	—	7	87.545	0,783	0,700	2 / 2	62,1%
S1	IVS-6 (IVS-7 sem lixo)	10	6	87.545	0,787	0,715	1 / 1	70,0%
S2	IVS-7 + não chega	5, 7	8	78.256	0,780	0,693	3 / 3	58,5%
S3	IVS-7 + sem canalização	7	8	87.512	0,805	0,733	3 / 3	59,2%
S4	IVS-7 + sem banheiro (V00495)	6, 7	8	75.955	0,792	0,691	3 / 2	56,4%
S5	IVS-7 + não convencional	9	8	87.545	0,783	0,700	2 / 2	54,4%
S6	IVS-7 + as quatro ("tudo isso")	8	11	69.458	0,810	0,695	4 / 4	48,9%
S7	S6 sem lixo	8, 10	10	69.458	0,813	0,702	3 / 2	53,2%

Fonte: banco_de_dados/eda/fatorial_ampliada/cenarios.csv. K/H: fatores pelo critério de Kaiser e pelo de Horn.

13

> *Os oito cenários da fatorial ampliada, cada um com o número de variáveis e de setores e os resultados de adequação e de quantos fatores manter.*

O QUE APARECE NO SLIDE

Uma tabela de oito linhas (S0 a S7) e nove colunas: o nome, o que entra, a demanda que o cenário responde, o número de variáveis, o número de setores, o KMO, o MSA mínimo, os fatores pelas regras de Kaiser e de Horn (K/H) e a variância explicada por dois fatores.

O QUE ISSO QUER DIZER, DO ZERO

Os cenários:

- **S0**: o IVS-7, que reproduz o NB04 — o ponto de comparação;
- **S1**: o IVS-6, sem o lixo (demanda 10);
- **S2**: o IVS-7 mais a água que não chega encanada (demandas 5 e 7);
- **S3**: o IVS-7 mais a falta de água canalizada (demanda 7);
- **S4**: o IVS-7 mais a falta de banheiro, pela `V00495` (demandas 6 e 7);
- **S5**: o IVS-7 mais a moradia não convencional (demanda 9);
- **S6**: o IVS-7 mais as quatro novas — "tudo isso" (demanda 8);
- **S7**: o S6 sem o lixo (demandas 8 e 10).

As colunas de resultado (A.6): o **KMO** diz se os dados servem para análise fatorial; o **MSA mínimo**, qual variável conversa menos com as outras; **Fatores K/H**, quantos fatores as regras de Kaiser e de Horn mandam manter; e a **variância explicada por dois fatores**, quanto da informação das variáveis cabe em duas dimensões.

COMO LER OS NÚMEROS

Três leituras:

- Todos os cenários têm KMO acima de 0,7: todos servem para análise fatorial.
- Quando entram variáveis com muito sigilo, a base perde setores: o S6 fica com 69.458 setores, contra 87.545 do S0.

- Quanto mais variáveis, mais fatores as regras pedem e menos cabe em dois: no S6, as regras pedem 4 fatores e dois explicam 48,9% da variância, contra 62,1% no S0. O índice usa dois fatores — as duas dimensões do IVS-BH 2012 —, e esse número mostra o que se perde com isso.

COMO APRESENTAR

"Cada linha é uma análise fatorial completa. Todos os cenários servem para a técnica; o que muda é quantos setores sobram e quantas dimensões os dados pedem. Com tudo junto, os dados pedem mais de duas."

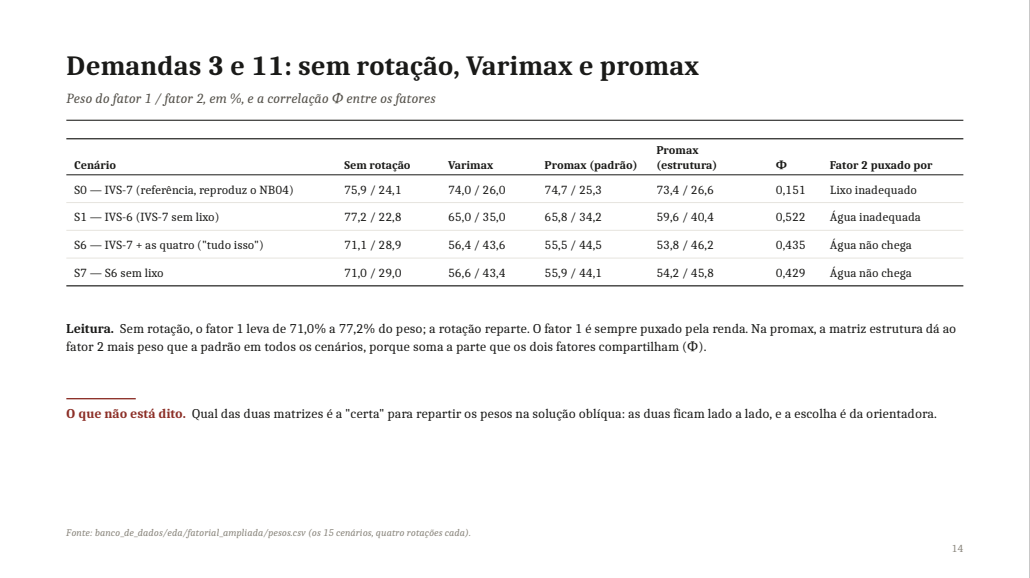
SE PERGUNTAREM

O que quer dizer "3 / 2" em fatores K/H?

Que a regra de Kaiser manda manter três fatores e a de Horn, mais exigente, dois. Quando as duas discordam, a de Horn costuma ser a mais confiável.

DEMANDAS DE SETEMBRO · SLIDE 14

Demandas 3 e 11: sem rotação, Varimax e promax



Demandas 3 e 11: sem rotação, Varimax e promax

Peso do fator 1 / fator 2, em %, e a correlação Φ entre os fatores

Cenário	Sem rotação	Varimax	Promax (padrão)	Promax (estrutura)	Φ	Fator 2 puxado por
S0 — IVS-7 (referência, reproduz o NB04)	75,9 / 24,1	74,0 / 26,0	74,7 / 25,3	73,4 / 26,6	0,151	Lixo inadequado
S1 — IVS-6 (IVS-7 sem lixo)	77,2 / 22,8	65,0 / 35,0	65,8 / 34,2	59,6 / 40,4	0,522	Água inadequada
S6 — IVS-7 + as quatro ("tudo isso")	71,1 / 28,9	56,4 / 43,6	55,5 / 44,5	53,8 / 46,2	0,435	Água não chega
S7 — S6 sem lixo	71,0 / 29,0	56,6 / 43,4	55,9 / 44,1	54,2 / 45,8	0,429	Água não chega

Leitura. Sem rotação, o fator 1 leva de 71,0% a 77,2% do peso; a rotação reparte. O fator 1 é sempre puxado pela renda. Na promax, a matriz estrutura dá ao fator 2 mais peso que a padrão em todos os cenários, porque soma a parte que os dois fatores compartilham (Φ).

O que não está dito. Qual das duas matrizes é a "certa" para repartir os pesos na solução oblíqua: as duas ficam lado a lado, e a escolha é da orientadora.

Fonte: banco_de_dados/eda/fatorial_ampliada/pesos.csv (os 15 cenários, quatro rotações cada).

14

Como os pesos se repartem entre os dois fatores em cada rotação — e a correlação entre os fatores quando se deixa que eles se correlacionem.

O QUE APARECE NO SLIDE

Uma tabela com quatro cenários (S0, S1, S6 e S7) e sete colunas: os pesos do fator 1 e do fator 2 sem rotação, com Varimax, com promax pela matriz padrão e com promax pela matriz estrutura; o Φ; e a variável que puxa o fator 2. Embaixo, dois blocos: a leitura e "o que não está dito".

O QUE ISSO QUER DIZER, DO ZERO

Cada célula como "74,0 / 26,0" quer dizer: o fator 1 leva 74,0% do peso e o fator 2, o resto. O **fator 1** é sempre puxado pela renda (é o socioeconômico); o **fator 2** é puxado pelo lixo no S0, pela água inadequada no S1 e pela água que não chega no S6 e no S7.

As rotações (A.6):

- **sem rotação**, o primeiro fator pega quase tudo: entre 71,0% e 77,2% do peso;
- a **Varimax** gira os eixos mantendo os fatores independentes e reparte melhor o peso;
- a **promax** deixa os fatores se correlacionarem; o **Φ** é essa correlação. A **matriz padrão** dá o efeito próprio de cada fator; a **matriz estrutura** soma a parte que os fatores compartilham — por isso, nela, o fator 2

sempre ganha um pouco mais de peso.

COMO LER OS NÚMEROS

O S1 (sem o lixo) é o que mais muda: sem rotação, 77,2 / 22,8; com Varimax, 65,0 / 35,0 (são os pesos do NB04); com promax padrão, 65,8 / 34,2; com promax estrutura, 59,6 / 40,4. O Φ do S1 é 0,522: as duas dimensões são bem correlacionadas. No S0, com o lixo, o Φ cai para 0,151 — porque o lixo, que puxa o fator 2, conversa pouco com o resto.

COMO APRESENTAR

"A rotação muda bastante a repartição dos pesos: sem rotação, o primeiro fator leva três quartos; com rotação, cerca de dois terços. E qual matriz usar na promax muda o resultado — essa escolha é sua."

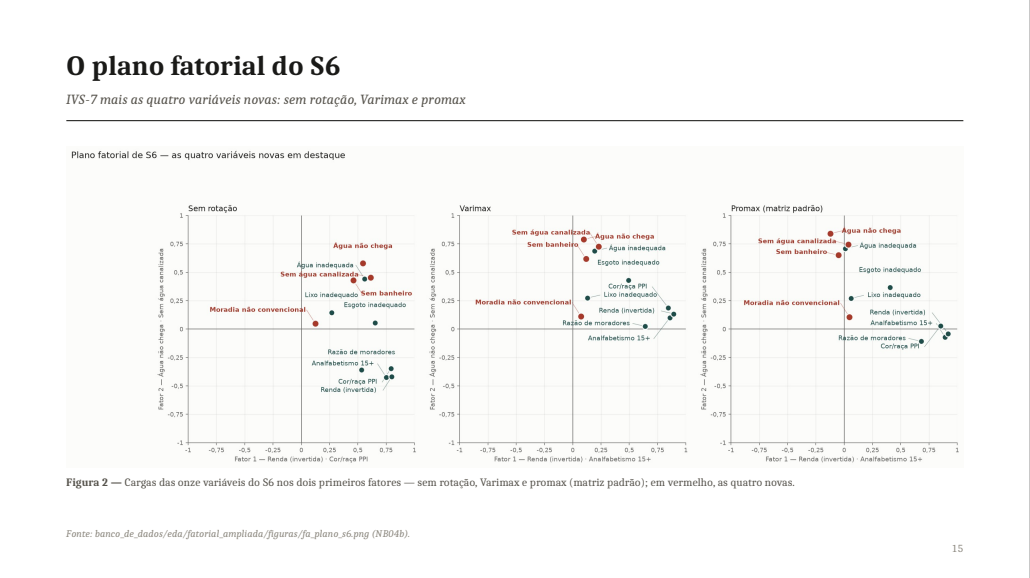
SE PERGUNTAREM

Qual rotação é a certa?

Não há uma certa. A Varimax supõe que as dimensões são independentes; a promax deixa que se correlacionem, o que é mais realista aqui (Φ de 0,52 no S1). Mas a escolha muda os pesos, e por isso está nas perguntas à orientadora.

DEMANDAS DE SETEMBRO · SLIDE 15

O plano fatorial do S6



Um mapa das onze variáveis do S6 nos dois primeiros fatores, em três versões: sem rotação, Varimax e promax.

O QUE APARECE NO SLIDE

Uma figura grande com três painéis lado a lado. Em cada um, cada ponto é uma variável: a posição na horizontal é a carga no fator 1 (renda e analfabetismo) e na vertical, a carga no fator 2 (água que não chega e sem água canalizada). As quatro variáveis novas estão em vermelho; as do IVS-7, em verde escuro.

O QUE ISSO QUER DIZER, DO ZERO

Este tipo de gráfico se chama **plano fatorial**. Lê-se assim: variável perto do eixo horizontal, à direita, pertence ao fator 1; perto do eixo vertical, em cima, pertence ao fator 2; perto do centro, não pertence a nenhum.

O que a figura mostra:

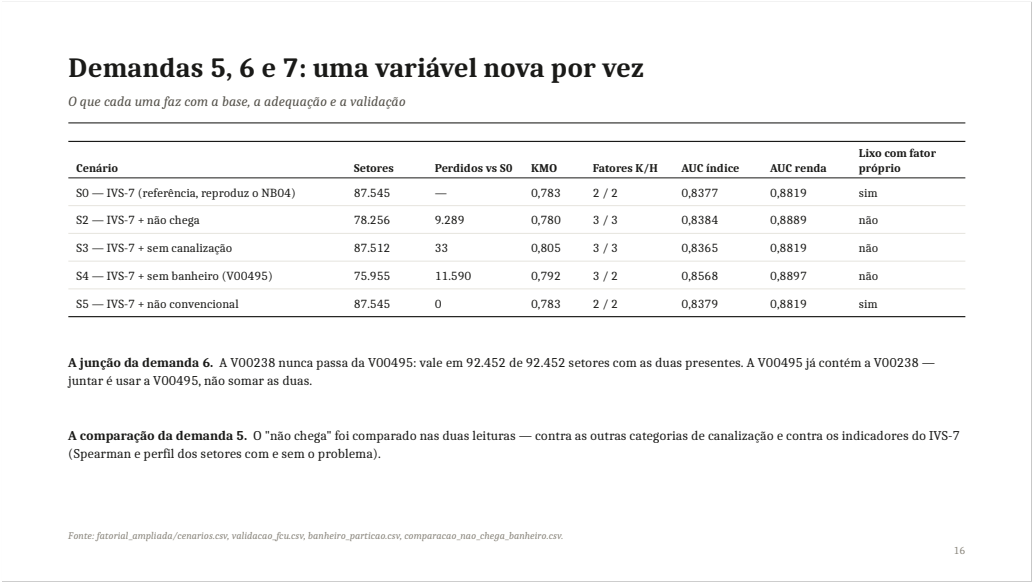
- **sem rotação**, todas as variáveis ficam à direita (o fator 1 pega tudo), e o fator 2 só separa as de saneamento (em cima) das socioeconômicas (embaixo);
- com **Varimax**, o quadro fica limpo: renda, analfabetismo, cor/raça e razão de moradores vão para a direita, embaixo (fator 1); as variáveis de água e banheiro sobem (fator 2);
- com **promax**, a separação é ainda mais nítida;
- em todas as versões, a **moradia não convencional** fica perto do centro — não pertence a nenhum fator (slide 17) —, e o **lixo** fica fraco nos dois.

COMO APRESENTAR

"O plano fatorial mostra as duas dimensões com clareza depois da rotação: a socioeconômica de um lado, a água e o banheiro do outro. A moradia não convencional fica no centro: não pertence a nenhuma."

DEMANDAS DE SETEMBRO · SLIDE 16

Demandas 5, 6 e 7: uma variável nova por vez



Demandas 5, 6 e 7: uma variável nova por vez

O que cada uma faz com a base, a adequação e a validação

Cenário	Setores	Perdidos vs S0	KMO	Fatores K/H	AUC índice	AUC renda	Lixo com fator próprio
S0 — IVS-7 (referência, reproduz o NB04)	87.545	—	0,783	2 / 2	0,8377	0,8819	sim
S2 — IVS-7 + não chega	78.256	9.289	0,780	3 / 3	0,8384	0,8889	não
S3 — IVS-7 + sem canalização	87.512	33	0,805	3 / 3	0,8365	0,8819	não
S4 — IVS-7 + sem banheiro (V00495)	75.955	11.590	0,792	3 / 2	0,8568	0,8897	não
S5 — IVS-7 + não convencional	87.545	0	0,783	2 / 2	0,8379	0,8819	sim

A junção da demanda 6. A V00238 nunca passa da V00495: vale em 92.452 de 92.452 setores com as duas presentes. A V00495 já contém a V00238 — juntar é usar a V00495, não somar as duas.

A comparação da demanda 5. O "não chega" foi comparado nas duas leituras — contra as outras categorias de canalização e contra os indicadores do IVS-7 (Spearman e perfil dos setores com e sem o problema).

Fonte: fatorial_ampliada/cenarios.csv, validacao_fcu.csv, banheiro_particao.csv, comparacao_nao_chega_banheiro.csv.

16

> *O que cada variável nova faz com a base de setores, com a adequação e com a separação das favelas — e a prova de que juntar a falta de banheiro é usar a V00495.*

O QUE APARECE NO SLIDE

Uma tabela com cinco cenários (S0, S2, S3, S4 e S5) e oito colunas: setores, setores perdidos em relação ao S0, KMO, fatores K/H, AUC do índice, AUC da renda e se o lixo forma fator próprio. Embaixo, dois blocos: a junção da demanda 6 e a comparação da demanda 5.

O QUE ISSO QUER DIZER, DO ZERO

As variáveis novas (o quadro do slide 11 tem as definições):

- **água não chega** (S2): domicílios em que a água não chega encanada (`V00201`);
- **sem água canalizada** (S3): domicílios em que a água não chega encanada até dentro de casa;
- **sem banheiro** (S4): domicílios sem banheiro de uso exclusivo (`V00495`);
- **moradia não convencional** (S5): cortiço, maloca, estrutura degradada.

"**Perdidos vs S0**" é quantos setores saem porque a variável nova está sob sigilo neles: 9.289 no S2, 33 no S3, 11.590 no S4 e 0 no S5.

A junção da demanda 6. A `V00238` (nem banheiro nem sanitário) é uma das partes da `V00495`. Para "juntar", basta usar a `V00495` — somar as duas contaria a `V00238` duas vezes. Prova: a `V00238` nunca passa da `V00495` em 92.452 de 92.452 setores com as duas presentes.

A comparação da demanda 5. A água que não chega foi comparada nas duas leituras do slide 5: com as outras categorias de água e com os indicadores do IVS-7 — pela correlação de Spearman e pelo perfil dos setores com e sem o problema.

COMO LER OS NÚMEROS

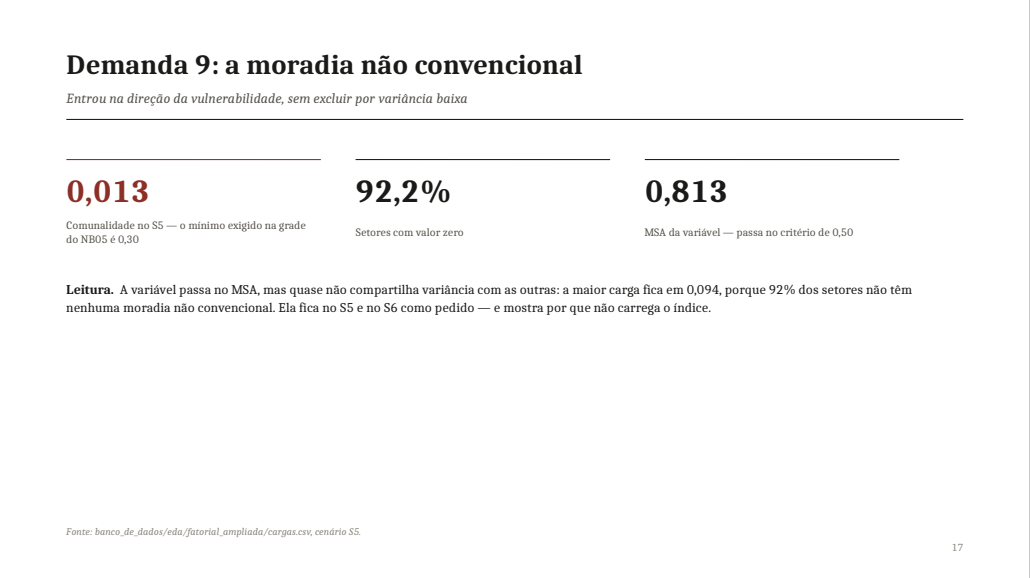
O S4 (com a falta de banheiro) tem a maior AUC do índice entre os cenários com uma variável a mais (0,8568), mas também perde mais setores (11.590). A AUC da renda muda de cenário para cenário porque a base de setores muda. E, em todos os cenários com variável de água ou banheiro, o lixo deixa de ter fator próprio.

COMO APRESENTAR

“Cada variável nova faz duas coisas: tira setores da base, por causa do sigilo, e redistribui os fatores. Juntar a falta de banheiro é usar a variável que já é a soma; as contas confirmam isso setor a setor.”

DEMANDAS DE SETEMBRO · SLIDE 17

Demanda 9: a moradia não convencional



> *A moradia não convencional entrou como pedido, mas quase não conversa com as outras variáveis: 92% dos setores não têm nenhuma.*

O QUE APARECE NO SLIDE

Três números grandes: a comunalidade da variável no S5 (0,013, em vermelho), a porcentagem de setores com valor zero (92,2%) e o MSA da variável (0,813). Embaixo, a leitura.

O QUE ISSO QUER DIZER, DO ZERO

A demanda 9 pedia a habitação convencional. Ela entrou virada para o lado da vulnerabilidade: a proporção de moradias *não* convencionais (cortiço, maloca, estrutura degradada).

O resultado mostra um contraste:

- o **MSA** de 0,813 passa no critério (0,50): a variável não atrapalha a análise;

- mas a **comunalidade** é de 0,013 — os fatores explicam pouco mais de 1% do que ela varia —, e a maior carga é 0,094. Ela não pertence a nenhum fator.

A razão é simples: em 92,2% dos setores, não há nenhuma moradia não convencional. Uma variável que é quase sempre zero tem pouca variação para dividir com as outras. A variável ficou no S5 e no S6, como pedido, e o resultado mostra por que ela não carrega o índice.

COMO APRESENTAR

"A moradia não convencional entrou, mas os fatores explicam só cerca de 1% dela: em mais de nove de cada dez setores, ela é zero. Não é um problema da variável — é que ela descreve um fenômeno raro e concentrado."

DEMANDAS DE SETEMBRO · SLIDE 18

Demanda 8: tudo isso junto

Demanda 8: tudo isso junto

S6 = IVS-7 + as quatro; S7 = S6 sem o lixo

Cenário	Var.	Setores	KMO	Fatores K/H	Var. 2 fat.
S6	11	69.458	0,810	4 / 4	48,9%
S7	10	69.458	0,813	3 / 2	53,2%
S6 renda sem extremo	11	69.457	0,810	4 / 4	48,9%
S6 renda mediana mun	11	69.458	0,810	4 / 4	48,9%
S6 postos mun	11	69.458	0,769	3 / 3	48,3%

Leitura. Com onze variáveis, Kaiser e Horn pedem 4 fatores, e dois fatores explicam só 48,9% da variância — contra 62,1% no IVS-7. A base perde setores: 69.458 contra 87.545. Com postos dentro do município, o MSA mínimo cai para 0,384.

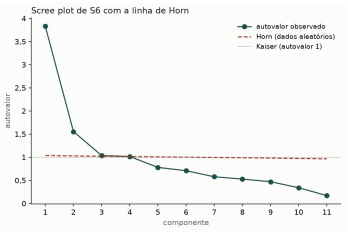


Figura 3 — Autovalores do S6 e a linha de Horn.

Fonte: fatorial_ampliada/cenarios.csv; figuras/fa_scree_s6.png.

18

> *Com as quatro variáveis novas juntas, os dados pedem quatro dimensões e dois fatores explicam menos da metade da informação.*

O QUE APARECE NO SLIDE

À esquerda, uma tabela com o S6, o S7 e três variantes do S6 (renda sem o extremo, renda com a mediana e postos no município), com o número de variáveis, de setores, o KMO, os fatores K/H e a variância explicada por dois fatores. À direita, o *scree plot* do S6. Embaixo, à esquerda, a leitura.

O QUE ISSO QUER DIZER, DO ZERO

O **scree plot** (A.6) mostra os autovalores em ordem: a linha com pontos é o que os dados dão; a linha tracejada vermelha é o que dados aleatórios dariam (a regra de Horn); a linha pontilhada em 1 é a regra de Kaiser. Ficam os fatores cujo ponto está acima das duas linhas. No S6, são quatro.

As variantes do S6 testam se o resultado depende da renda (não depende: as três rendas dão o mesmo) e da forma de medir. Os **postos no município** trocam cada valor pela posição do setor dentro da sua cidade — o que compara cada setor só com os vizinhos de município.

COMO LER OS NÚMEROS

Com onze variáveis, o KMO sobe (0,810), mas as regras pedem 4 fatores e dois explicam só 48,9% da variância (contra 62,1% no IVS-7). A base cai para 69.458 setores. Com postos no município, o MSA mínimo cai para 0,384, abaixo do critério de 0,50.

COMO APRESENTAR

“Juntando tudo, os dados pedem quatro dimensões, não duas, e perde-se uma parte grande da base. Se o índice continuar com duas dimensões, como no IVS de Belo Horizonte, vale lembrar que, com tudo junto, metade da informação fica de fora.”

DEMANDAS DE SETEMBRO · SLIDE 19

Demanda 10: o lixo

Demanda 10: o lixo

Com o lixo, ele forma um fator sozinho; sem ele, a fatorial pede um fator só

Cenário	Fatores K/H	Lixo com fator próprio (Varimax)	Municípios cuja saída muda o lixo de fator
S0 — IVS-7 (referência, reproduz o NB04)	2 / 2	sim	2 de 71
S1 — IVS-6 (IVS-7 sem lixo)	1 / 1	— (sem lixo)	0 de 71
S2 — IVS-7 + não chega	3 / 3	não	—
S3 — IVS-7 + sem canalização	3 / 3	não	—
S4 — IVS-7 + sem banheiro (V00495)	3 / 2	não	—
S5 — IVS-7 + não convencional	2 / 2	sim	—
S6 — IVS-7 + as quatro ("tudo isso")	4 / 4	não	0 de 71
S7 — S6 sem lixo	3 / 2	— (sem lixo)	—

Fonte: fatorial_ampliada/cenarios.csv (lixo_fator_proprio_varimax) e sensibilidade_municipios.csv (lixo_muda).

19

> *Com o lixo, ele forma uma dimensão sozinho; sem ele, a análise pede uma dimensão só — o lixo é que sustenta a estrutura em dois fatores no IVS-7.*

O QUE APARECE NO SLIDE

Uma tabela com os oito cenários e três colunas: fatores K/H, se o lixo forma fator próprio na Varimax e em quantos municípios a saída do município muda o lixo de fator.

O QUE ISSO QUER DIZER, DO ZERO

Desde junho se sabe que o lixo conversa pouco com as outras variáveis. A tabela mostra as consequências:

- no **S0** (IVS-7) e no **S5**, o lixo ocupa um fator sozinho;
- no **S1** (sem lixo), as regras pedem um fator só (1 por Kaiser e 1 por Horn): sem o lixo, a vulnerabilidade vira uma dimensão única;
- quando entram as variáveis de água e de banheiro (S2, S3, S4 e S6), o fator 2 passa a ser o da água, e o lixo perde o fator próprio;
- na sensibilidade, a saída de um município muda o lixo de fator em 2 das 71 rodadas do S0.

A última coluna só tem valores para S0, S1 e S6, os cenários em que a sensibilidade por município foi rodada.

COMO APRESENTAR

“O lixo é a variável que decide a estrutura: com ele, há duas dimensões, mas uma delas é só o lixo; sem ele, há uma. Se a orientadora tirar o lixo, vale discutir se o índice continua com duas dimensões.”

SE PERGUNTAREM

Então o lixo deve sair?

Os números não decidem sozinhos. A favor de tirar: ele forma um fator à parte e baixa a qualidade da fatorial. Contra: ele está no IVS-BH 2012, e tirá-lo quebra a comparação. É uma das escolhas da orientadora (slide 40).

DEMANDAS DE SETEMBRO · SLIDE 20

A incerteza: um município de fora por vez

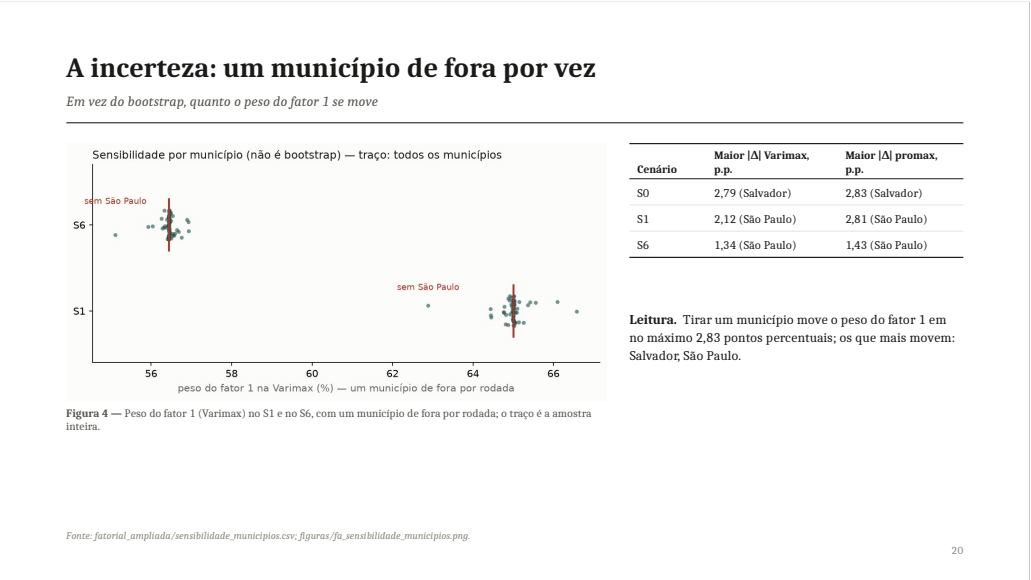


Figura 4 — Peso do fator 1 (Varimax) no S1 e no S6, com um município de fora por rodada; o traço é a amostra inteira.

Tirando um município por vez, o peso do fator 1 se move no máximo cerca de três pontos percentuais — e quem mais move são São Paulo e Salvador.

O QUE APARECE NO SLIDE

À esquerda, uma figura com duas faixas, S6 em cima e S1 embaixo: cada ponto é o peso do fator 1 numa rodada sem um município, e o traço vermelho é o peso com todos. O ponto que se afasta tem o rótulo "sem São Paulo". À direita, uma tabela com a maior variação, em pontos percentuais, na Varimax e na promax, para S0, S1 e S6, com o município responsável. Embaixo, a leitura.

O QUE ISSO QUER DIZER, DO ZERO

É a **sensibilidade por município** (A.8): a análise é refeita 71 vezes — uma com todos os municípios e uma sem cada um — e mede-se quanto o peso do fator 1 muda. "Maior |Δ|" é a maior mudança, em valor absoluto (sem sinal), medida em **pontos percentuais**.

Na figura, quase todos os pontos ficam colados no traço vermelho: tirar quase qualquer município não muda nada. As exceções são as metrópoles: sem São Paulo, o peso do fator 1 no S1 cai cerca de dois pontos.

COMO LER OS NÚMEROS

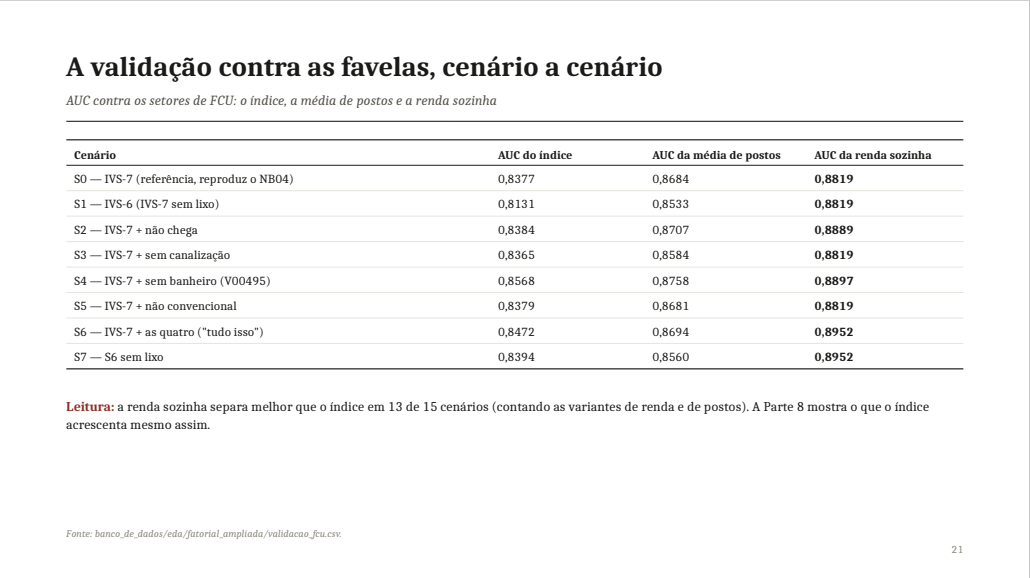
No S0, a maior mudança é 2,79 p.p., sem Salvador; no S1, 2,12 p.p., sem São Paulo; no S6, 1,34 p.p., sem São Paulo. O máximo de todas as rodadas, nas duas rotações, é 2,83 p.p. Em pesos de cerca de 60%, isso é uma variação pequena: o resultado não depende de um município só.

COMO APRESENTAR

“Em vez de bootstrap, tirei um município de cada vez. O peso do fator 1 se move no máximo uns três pontos, e só quando sai uma metrópole. O resultado é estável.”

DEMANDAS DE SETEMBRO · SLIDE 21

A validação contra as favelas, cenário a cenário



A validação contra as favelas, cenário a cenário

AUC contra os setores de FCU: o índice, a média de postos e a renda sozinha

Cenário	AUC do índice	AUC da média de postos	AUC da renda sozinha
S0 — IVS-7 (referência, reproduz o NB04)	0,8377	0,8684	**0,8819**
S1 — IVS-6 (IVS-7 sem lixo)	0,8131	0,8533	**0,8819**
S2 — IVS-7 + não chega	0,8384	0,8707	**0,8889**
S3 — IVS-7 + sem canalização	0,8365	0,8584	**0,8819**
S4 — IVS-7 + sem banheiro (V00495)	0,8568	0,8758	**0,8897**
S5 — IVS-7 + não convencional	0,8379	0,8681	**0,8819**
S6 — IVS-7 + as quatro ("tudo isso")	0,8472	0,8694	**0,8952**
S7 — S6 sem lixo	0,8394	0,8560	**0,8952**

Leitura: a renda sozinha separa melhor que o índice em 13 de 15 cenários (contando as variantes de renda e de postos). A Parte 8 mostra o que o índice acrescenta mesmo assim.

Fonte: banco_de_dados/eda/fatorial_ampliada/validacao_fcu.csv.

21

> *A AUC contra as favelas em cada cenário: a renda sozinha vence o índice em 13 de 15 cenários.*

O QUE APARECE NO SLIDE

Uma tabela com os oito cenários e três AUCs: a do índice, a da média simples dos postos e a da renda sozinha (em negrito). Embaixo, a leitura.

O QUE ISSO QUER DIZER, DO ZERO

As três colunas (A.7):

- a **AUC do índice**: o índice com os pesos da Varimax;
- a **AUC da média de postos**: ordenar os setores em cada indicador e tirar a média das posições, sem peso nenhum — um "índice ingênuo";
- a **AUC da renda sozinha**: só a renda invertida.

Em todos os oito cenários da tabela, a renda vence, e a média sem peso também fica acima do índice. Contando as variantes (as três rendas e os postos no município), a renda vence em 13 de 15; as exceções são S0 postos mun e S6 postos mun.

COMO APRESENTAR

“Em todos os cenários, a renda sozinha separa as favelas melhor que o índice. Isso não condena o índice: mostra que separar favelas não é a tarefa em que ele se destaca. A parte 8 mostra onde ele se destaca.”

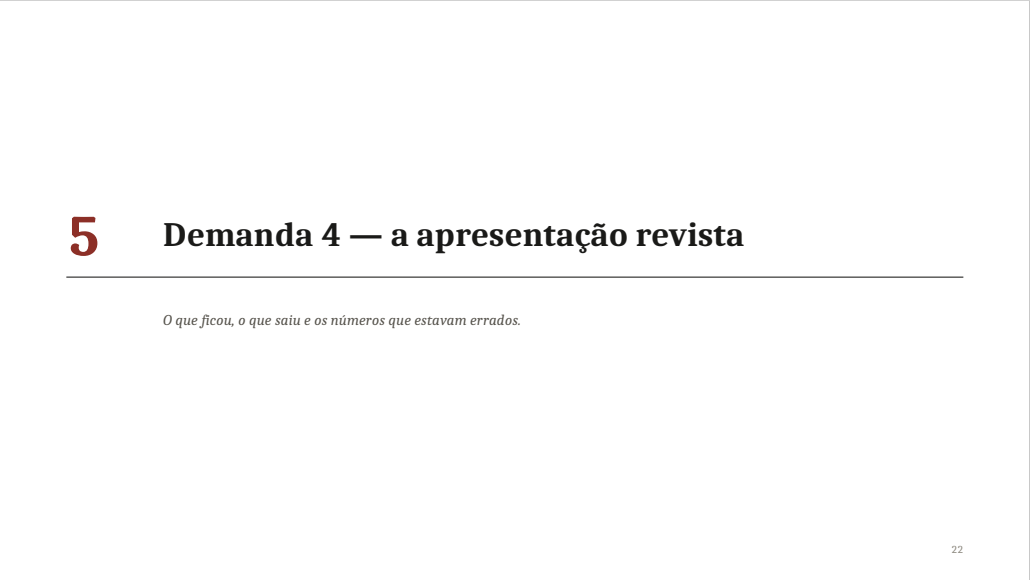
SE PERGUNTAREM

A validação contra favelas não está viciada?

Em parte, sim: o IBGE usa condições de infraestrutura para identificar favelas, e algumas delas estão no índice. Por isso a AUC é um dos três critérios de escolha, e não o único.

DEMANDAS DE SETEMBRO · SLIDE 22

Demanda 4 — a apresentação revista



> *A divisória da parte 5: a revisão da apresentação principal.*

O QUE APARECE NO SLIDE

O número 5 em vermelho, o título "Demanda 4 — a apresentação revista" e o subtítulo: o que ficou, o que saiu e os números que estavam errados.

O QUE ISSO QUER DIZER, DO ZERO

A demanda 4 pedia para separar, na apresentação principal, o que serve do que não serve.

COMO APRESENTAR

“A parte 5 é a revisão da apresentação.”

DEMANDAS DE SETEMBRO · SLIDE 23

Separar o útil do inútil



> *O deck principal foi inventariado, corrigido e ampliado — sem ser regerado.*

O QUE APARECE NO SLIDE

Quatro blocos: o inventário, os números corrigidos (com o filete vermelho), o bloco novo e o deck hoje.

O QUE ISSO QUER DIZER, DO ZERO

- **O inventário**: um programa listou todos os artefatos de apresentação, e um documento (`MAPA_APRESENTACAO_FINAL.md`) diz o que entra, o que sai e em que ordem.
- **Os números corrigidos**: três números errados nos slides e um no guia de apoio (16.548 no lugar de 16.563), todos relidos das tabelas. Os códigos (AUD-07, DEC-1, AUD-04, AUD-08) identificam cada achado nas auditorias.
- **O bloco novo**: os slides da fatorial ampliada e, depois, os do IVS final são gerados por programa e anexados ao deck principal por outro programa, o "juntador".
- **O deck hoje**: tem 114 slides, e a estrutura interna do arquivo foi conferida e consertada em 30/09.

Por que não regerar o deck principal? Porque ele tem marcações e anotações feitas à mão; regerá-lo apagaria esse trabalho. Os blocos novos entram por fora.

COMO APRESENTAR

“A apresentação principal foi inventariada e corrigida, e os blocos novos — a fatorial ampliada e o IVS final — foram anexados sem mexer no que já estava lá.”

DEMANDAS DE SETEMBRO · SLIDE 24

Os testes seguintes



> *A divisória da parte 6: os nove itens da etapa de 26/09 e o banheiro graduado.*

O QUE APARECE NO SLIDE

O número 6 em vermelho, o título "Os testes seguintes" e o subtítulo: os nove itens da etapa de 26/09 e o banheiro graduado.

O QUE ISSO QUER DIZER, DO ZERO

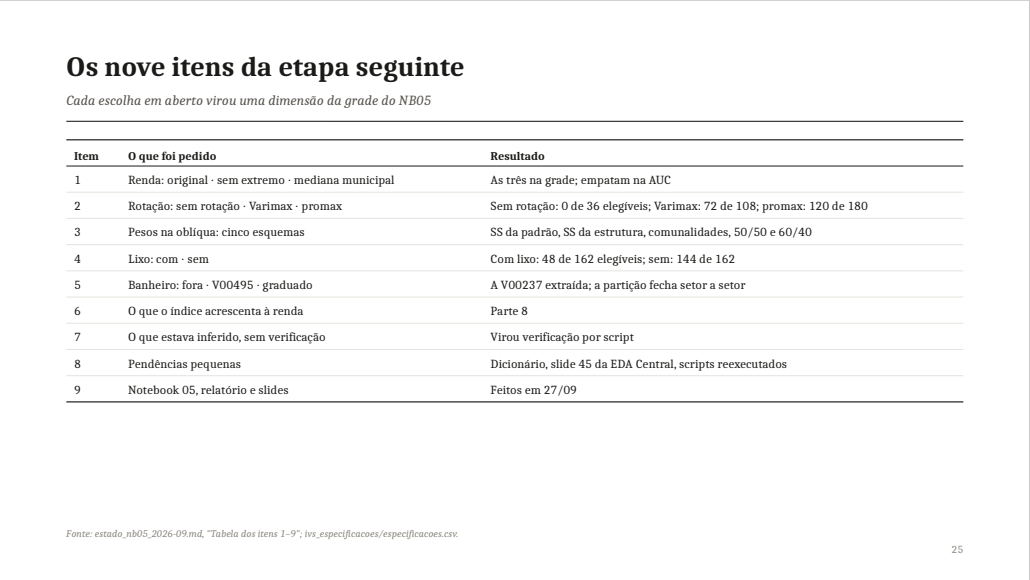
Depois das demandas, ficaram escolhas em aberto. A etapa seguinte transformou cada uma num teste.

COMO APRESENTAR

“A parte 6 são os testes que vieram depois das demandas.”

DEMANDAS DE SETEMBRO · SLIDE 25

Os nove itens da etapa seguinte



Os nove itens da etapa seguinte

Cada escolha em aberto virou uma dimensão da grade do NB05

Item	O que foi pedido	Resultado
1	Renda: original · sem extremo · mediana municipal	As três na grade; empatam na AUC
2	Rotação: sem rotação · Varimax · promax	Sem rotação: 0 de 36 elegíveis; Varimax: 72 de 108; promax: 120 de 180
3	Pesos na oblíqua: cinco esquemas	SS da padrão, SS da estrutura, comunalidades, 50/50 e 60/40
4	Lixo: com · sem	Com lixo: 48 de 162 elegíveis; sem: 144 de 162
5	Banheiro: fora · V00495 · graduado	A V00237 extraída; a partição fecha setor a setor
6	O que o índice acrescenta à renda	Parte 8
7	O que estava inferido, sem verificação	Virou verificação por script
8	Pendências pequenas	Dicionário, slide 45 da EDA Central, scripts reexecutados
9	Notebook 05, relatório e slides	Feitos em 27/09

Fonte: estado_nb05_2026-09.md, "Tabela dos itens 1–9"; ivs_especificacoes/especificacoes.csv.

25

> *Os nove itens de teste e o resultado de cada um: cada escolha em aberto virou uma dimensão da grade do NB05.*

O QUE APARECE NO SLIDE

Uma tabela de nove linhas: o item, o que foi pedido e o resultado.

O QUE ISSO QUER DIZER, DO ZERO

Os itens 1 a 5 são as escolhas em aberto; cada uma virou uma dimensão da grade (parte 7):

- **1. Renda**: as três versões entram na grade; empatam na AUC.
- **2. Rotação**: sem rotação, nenhuma especificação passa nos critérios (0 de 36); com Varimax, 72 de 108; com promax, 120 de 180.
- **3. Pesos na rotação oblíqua**: cinco esquemas — SS da matriz padrão, SS da estrutura, comunalidades, 50/50 e 60/40 (A.6).
- **4. Lixo**: com lixo, 48 de 162 passam; sem lixo, 144 de 162.
- **5. Banheiro**: fora, pela `V00495` ou graduado (slide 26).

Os outros itens: **6**, o que o índice acrescenta à renda (parte 8); **7**, transformar em verificação três afirmações que estavam escritas sem conta; **8**, pendências pequenas (o dicionário, um caminho citado num slide da EDA Central, a reexecução de scripts); **9**, o Notebook 05, o relatório e os slides.

COMO APRESENTAR

“Cada escolha em aberto virou um teste. As cinco primeiras viraram dimensões da grade que vem na parte 7; as outras foram verificações e pendências.”

DEMANDAS DE SETEMBRO · SLIDE 26

O banheiro graduado



O banheiro graduado

Três graus de inadequação, em vez de um "sem banheiro" só

Variável	Domicílios com...	Grau	Peso
V00236	apenas banheiro de uso comum	leve	1
V00237	apenas sanitário ou buraco para dejeções	intermediário	2
V00238	nem banheiro nem sanitário	grave	3
V00495	sem banheiro de uso exclusivo — a soma das três	—	—

Banheiro graduado = (1·V00236 + 2·V00237 + 3·V00238) ÷ (3·V00001)

91.199 de 91.199

Setores em que V00495 = V00236 + V00237 + V00238, sem resto

17.833

Setores da base ELSI com alguma das quatro variáveis ausente

Fonte: fatorial_ampliada/banheiro_particao.csv; a fórmula em scripts/ivs_especificacoes.py.

26

> *A falta de banheiro em três graus, cada um com um peso — e a prova de que as três partes somam o total em todos os setores.*

O QUE APARECE NO SLIDE

Uma tabela com as quatro variáveis — `V00236`, `V00237`, `V00238` e `V00495` —, o que cada uma conta, o grau e o peso. Embaixo, em negrito, a fórmula do banheiro graduado. Por fim, dois números: 91.199 de 91.199 (em vermelho) e 17.833.

O QUE ISSO QUER DIZER, DO ZERO

O Censo conta os domicílios sem banheiro de uso exclusivo (`V00495`) e divide esse total em três partes:

- `V00236` — só banheiro de uso comum (dividido com outras casas): grau leve, peso 1;
- `V00237` — só sanitário ou buraco para dejeções: grau intermediário, peso 2;
- `V00238` — nem banheiro nem sanitário: grau grave, peso 3.

O **banheiro graduado** soma as três com os pesos e divide pelo máximo possível (3 vezes o total de domicílios): (1·`V00236` + 2·`V00237` + 3·`V00238`) ÷ (3·`V00001`). Ele vai de 0 (todos com banheiro exclusivo) a 1 (todos sem banheiro nem sanitário).

COMO LER OS NÚMEROS

Exemplo: um setor com 100 domicílios, dos quais 4 só têm banheiro comum, 3 só têm sanitário e 1 não tem nada. O graduado é (4 + 2×3 + 3×1) ÷ 300 = 13 ÷ 300 ≈ 0,043. A versão simples (`V00495`) diria 8 ÷ 100 = 0,08, tratando os 8 casos como iguais.

Os dois números do slide: em 91.199 de 91.199 setores com as quatro variáveis presentes, as três partes somam exatamente o total — uma partição perfeita. Os 17.833 setores restantes têm alguma das quatro sob sigilo, e o graduado fica ausente neles.

COMO APRESENTAR

"O banheiro graduado distingue a gravidade: dividir um banheiro não é o mesmo que não ter nem sanitário. As contas confirmam que as três partes somam o total em todos os setores em que dá para conferir."

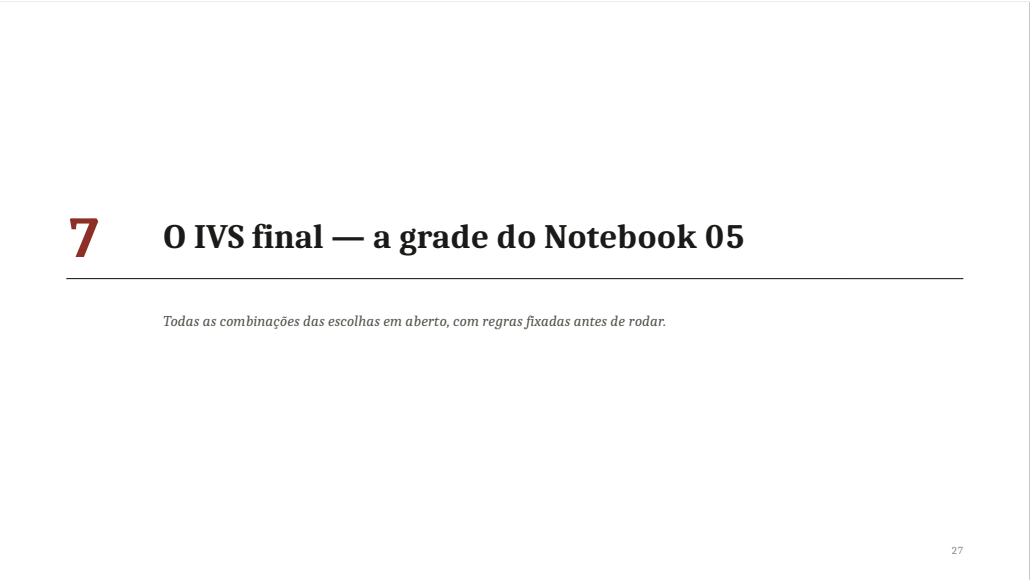
SE PERGUNTAREM

Por que os pesos 1, 2 e 3?

São a forma mais simples de ordenar a gravidade, sem inventar distâncias. Outros pesos são possíveis; esses ficaram documentados e podem ser trocados.

DEMANDAS DE SETEMBRO · SLIDE 27

O IVS final — a grade do Notebook 05



> *A divisória da parte 7: todas as combinações das escolhas em aberto, com regras fixadas antes de rodar.*

O QUE APARECE NO SLIDE

O número 7 em vermelho, o título "O IVS final — a grade do Notebook 05" e o subtítulo: todas as combinações das escolhas em aberto, com regras fixadas antes de rodar.

O QUE ISSO QUER DIZER, DO ZERO

Esta é a parte central do deck. Em vez de escolher uma especificação, o NB05 calcula todas e mostra o que cada escolha muda (A.9).

COMO APRESENTAR

“A parte 7 é o IVS final: todas as combinações, calculadas.”

DEMANDAS DE SETEMBRO · SLIDE 28

A grade: 324 especificações



> *De onde vêm as 324 especificações, quantas passam nos critérios (192) e como se escolhe a referência.*

O QUE APARECE NO SLIDE

Cinco números grandes em fila: 18 bases, 9 esquemas, 2 normalizações, 324 especificações e, em vermelho, 192 elegíveis. Embaixo, dois blocos: o critério de elegibilidade e o critério de escolha da referência.

O QUE ISSO QUER DIZER, DO ZERO

A conta da grade:

- **18 bases**: 3 versões da renda × 2 do lixo (com, sem) × 3 do banheiro (fora, `V00495`, graduado). Uma base é o conjunto de variáveis que vai para a análise fatorial;
- **9 esquemas**: sem rotação (um fator só); Varimax com SS, 50/50 e 60/40; promax com SS da padrão, SS da estrutura, comunalidades, 50/50 e 60/40;
- **2 normalizações**: no município ou global (A.5);
- $18 \times 9 \times 2 =$ **324 especificações**.

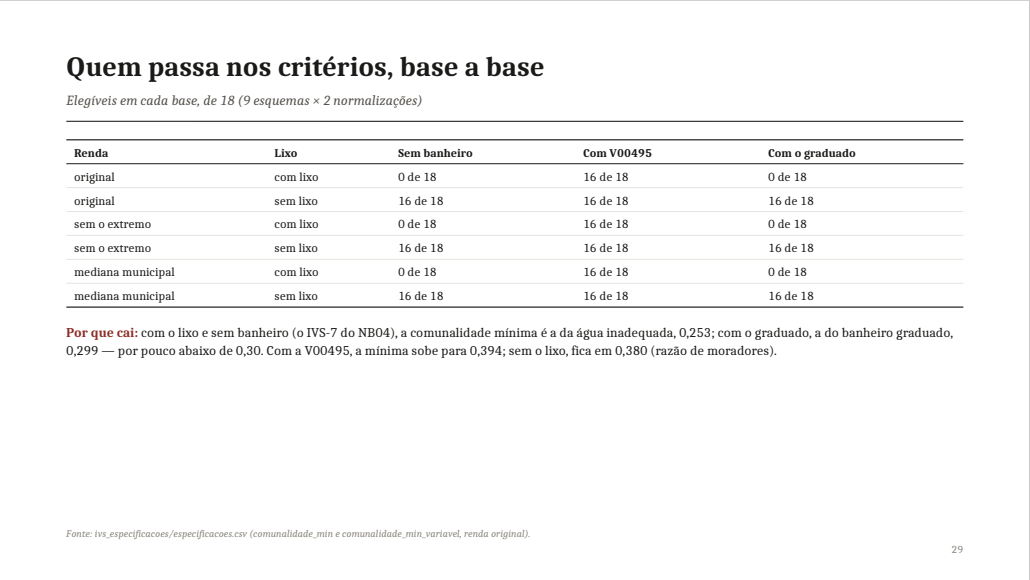
Uma especificação é **elegível** se passar nos quatro critérios (KMO, MSA, comunalidade, carga). Entre as elegíveis, a **referência** é a de melhor posição média em estabilidade, AUC no município e parcimônia (A.9). Os critérios foram escritos antes de rodar a grade.

COMO APRESENTAR

"São 324 especificações — todas as combinações de renda, lixo, banheiro, rotação, pesos e normalização. 192 passam nos critérios de qualidade, e entre elas os três critérios de escolha apontam uma referência."

DEMANDAS DE SETEMBRO · SLIDE 29

Quem passa nos critérios, base a base



Quem passa nos critérios, base a base

Elegíveis em cada base, de 18 (9 esquemas × 2 normalizações)

Renda	Lixo	Sem banheiro	Com V00495	Com o graduado
original	com lixo	0 de 18	16 de 18	0 de 18
original	sem lixo	16 de 18	16 de 18	16 de 18
sem o extremo	com lixo	0 de 18	16 de 18	0 de 18
sem o extremo	sem lixo	16 de 18	16 de 18	16 de 18
mediana municipal	com lixo	0 de 18	16 de 18	0 de 18
mediana municipal	sem lixo	16 de 18	16 de 18	16 de 18

Por que cai: com o lixo e sem banheiro (o IVS-7 do NB04), a comunalidade mínima é a da água inadequada, 0,253; com o graduado, a do banheiro graduado, 0,299 — por pouco abaixo de 0,30. Com a V00495, a mínima sobe para 0,394; sem o lixo, fica em 0,380 (razão de moradores).

Fonte: ivs_especificacoes/especificacoes.csv (comunalidade_min e comunalidade_min_variavel, renda original).

29

> *Em cada uma das 18 bases, quantas das 18 especificações passam — e por que as bases com o lixo caem.*

O QUE APARECE NO SLIDE

Uma tabela com seis linhas (renda × lixo) e três colunas de banheiro (fora, `V00495`, graduado). Cada célula diz quantas das 18 especificações daquela base são elegíveis (9 esquemas × 2 normalizações). Embaixo, em vermelho, "Por que cai".

O QUE ISSO QUER DIZER, DO ZERO

O padrão da tabela:

- a **renda não muda nada**: as três linhas de cada lixo são iguais;
- **sem lixo**, as três versões de banheiro passam (16 de 18 cada);
- **com lixo**, só passa a base com a `V00495`.

"16 de 18" e não 18: as 2 que caem em cada base são as do fator único (sem rotação, nas duas normalizações), que nunca passam.

COMO LER OS NÚMEROS

O motivo da queda é a **comunalidade mínima** (A.6), o critério de 0,30:

- com o lixo e sem banheiro — a base do IVS-7 do NB04 —, a comunalidade da água inadequada fica em 0,253: abaixo do mínimo;
- com o lixo e o banheiro graduado, a do banheiro graduado fica em 0,299: abaixo por um triz;
- com o lixo e a `V00495`, a mínima sobe para 0,394 e a base passa;
- sem o lixo, a mínima é 0,380 (da razão de moradores), e todas passam.

COMO APRESENTAR

“A renda não muda a elegibilidade. O lixo muda: com ele, a água fica com comunalidade baixa e o IVS-7 original não passa nos critérios. Sem o lixo, todas as versões de banheiro passam.”

SE PERGUNTAREM

O IVS-7 do NB04 não passa? Então o NB04 estava errado?

Não estava errado: o NB04 usou o IVS-6 (sem lixo) como base principal justamente por causa do lixo. O que a grade mostra é que, com os critérios fixados agora, o IVS-7 completo fica de fora pela comunalidade da água.

DEMANDAS DE SETEMBRO · SLIDE 30

Rotação e esquema de peso



Rotação e esquema de peso

Elegíveis por esquema, em toda a grade

Rotação	Esquema de peso	Elegíveis
sem rotação	fator único	0 de 36
Varimax	SS	24 de 36
Varimax	50/50	24 de 36
Varimax	60/40	24 de 36
promax	SS da padrão	24 de 36
promax	SS da estrutura	24 de 36
promax	comunalidades	24 de 36
promax	50/50	24 de 36
promax	60/40	24 de 36

Um fator ou dois. Kaiser e Horn indicam um fator no IVS-6, mas o fator único reprova na comunalidade em toda a grade: a comparação sempre usa dois.

Fonte: ivs_especificacoes/especificacoes.csv.

30

Em toda a grade, o fator único nunca passa; com dois fatores, todos os esquemas passam no mesmo número.

O QUE APARECE NO SLIDE

À esquerda, uma tabela com os nove esquemas (rotação e peso) e quantos são elegíveis de 36. À direita, com o filete vermelho, o bloco "Um fator ou dois".

O QUE ISSO QUER DIZER, DO ZERO

- **Sem rotação, fator único**: 0 de 36. Com um fator só, alguma variável fica sempre com comunalidade baixa.
- **Todos os outros esquemas**: 24 de 36 cada. A elegibilidade depende da base e da rotação, não de como os pesos são repartidos depois — por isso os cinco esquemas da promax passam no mesmo número.

Um fator ou dois? As regras de Kaiser e de Horn indicam um fator no IVS-6 (slide 19). Mas o fator único reprova em toda a grade pela comunalidade. Por isso as comparações usam sempre dois fatores — as duas dimensões do IVS-BH 2012.

COMO APRESENTAR

“Com um fator só, nada passa; com dois, todos os esquemas passam igualmente. Então o critério de qualidade não escolhe o esquema de pesos: essa escolha é de método.”

DEMANDAS DE SETEMBRO · SLIDE 31

Os pesos na solução oblíqua

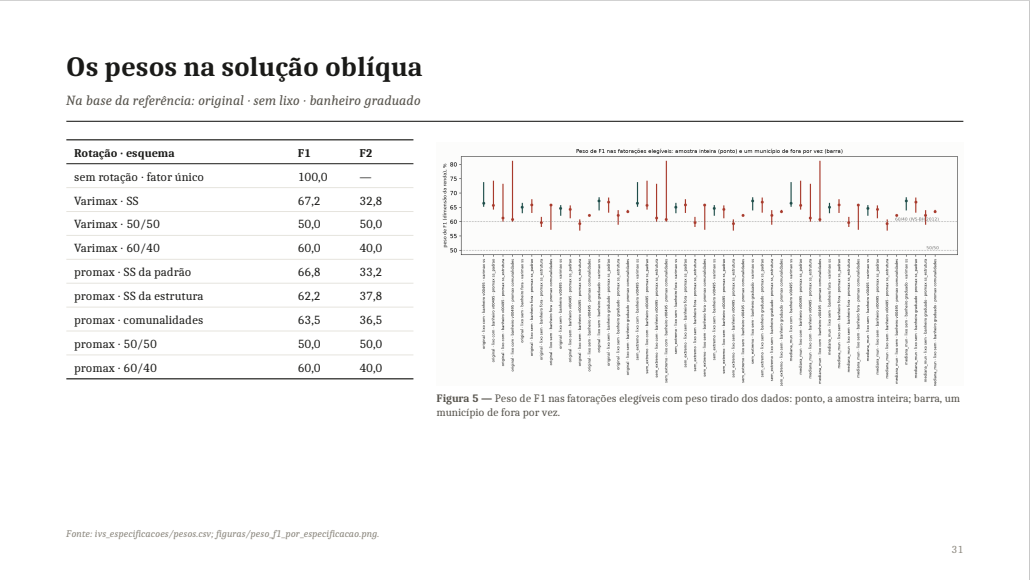


Figura 5 — Peso de F1 nas fatorações elegíveis com peso tirado dos dados: ponto, a amostra inteira; barra, um município de fora por vez.

> *Na base da referência, quanto pesa o fator 1 em cada esquema — e quanto esse peso oscila quando se tira um município.*

O QUE APARECE NO SLIDE

À esquerda, uma tabela com os nove esquemas e os pesos dos fatores F1 e F2 na base da referência (renda original, sem lixo, banheiro graduado). À direita, uma figura com o peso do fator 1 em cada especificação elegível cujo peso vem dos dados: o ponto é o peso com todos os municípios; a barra vertical, o intervalo quando se tira um município de cada vez. Duas linhas pontilhadas marcam 60% (o 60/40 do IVS-BH 2012) e 50%.

O QUE ISSO QUER DIZER, DO ZERO

Na tabela, **F1** é o fator socioeconômico e **F2**, o de saneamento. Os esquemas que dependem dos dados dão ao F1 entre 62,2% (promax, SS da estrutura) e 67,2% (Varimax, SS); os fixos dão 50% ou 60% por definição; o fator único dá 100%, porque só há um fator.

Na figura, barras curtas são especificações estáveis; barras longas, instáveis. As mais longas são as com o lixo e a `V00495` na promax por comunalidades, em que o peso do F1 pode ir de cerca de 60% a mais de 80% conforme o município que sai.

COMO LER OS NÚMEROS

Na base da referência: Varimax SS, 67,2%; promax SS da padrão, 66,8%; promax SS da estrutura, 62,2%; promax por comunalidades, 63,5%. Todos ficam acima de 60%: os dados dão à dimensão socioeconômica um pouco mais de peso do que o 60/40 fixo.

COMO APRESENTAR

“Os pesos que vêm dos dados dão ao fator socioeconômico entre 62% e 67% nesta base — um pouco mais que o 60/40 de Belo Horizonte. E a figura mostra quais especificações oscilam quando se tira um município.”

DEMANDAS DE SETEMBRO · SLIDE 32

A AUC de cada especificação

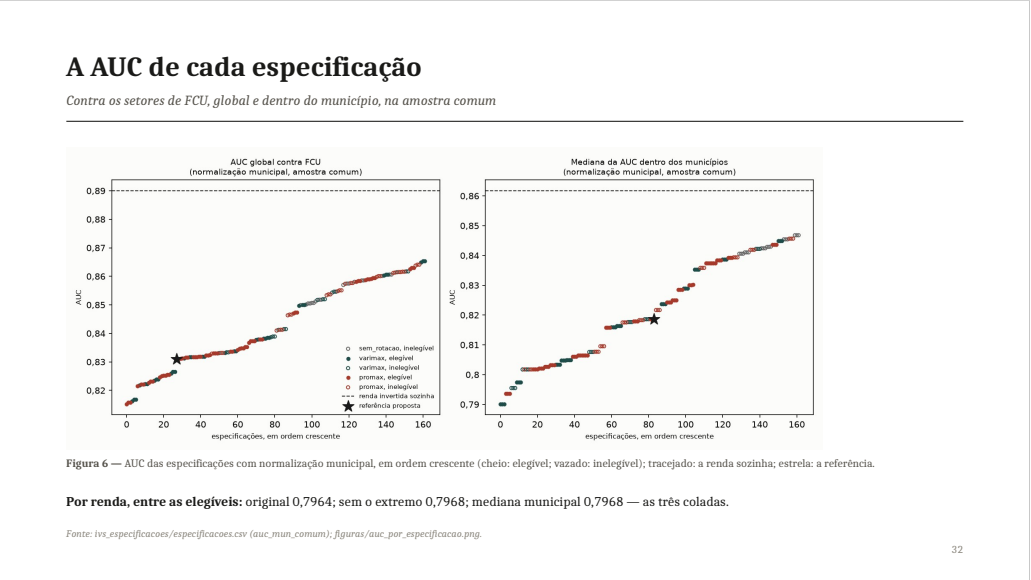


Figura 6 — AUC das especificações com normalização municipal, em ordem crescente (cheio: elegível; vazado: inelegível); tracejado: a renda sozinha; estrela: a referência.

Por renda, entre as elegíveis: original 0,7964; sem o extremo 0,7968; mediana municipal 0,7968 — as três coladas.

Fonte: ivs_especificacoes/especificacoes.csv (auc_mun_comum); figuras/auc_por_especificacao.png.

32

> *A AUC de cada especificação contra as favelas, em ordem — e a linha tracejada da renda sozinha, que nenhuma alcança.*

O QUE APARECE NO SLIDE

Uma figura com dois painéis. No da esquerda, a AUC global; no da direita, a mediana da AUC dentro dos municípios. Em cada painel, as 162 especificações com normalização no município aparecem em ordem crescente, com cores por rotação (ponto cheio: elegível; vazado: inelegível). A linha tracejada é a renda sozinha; a estrela, a referência proposta. Embaixo, a AUC média por versão de renda.

O QUE ISSO QUER DIZER, DO ZERO

Este gráfico, com os pontos em ordem crescente, mostra de uma vez a faixa de valores de todas as especificações. A AUC global compara todos os setores juntos; a mediana dentro dos municípios compara cada favela só com setores da mesma cidade (A.7).

O que se vê: a linha tracejada da renda sozinha fica acima de todos os pontos, nos dois painéis. A estrela (a referência) não está entre as melhores na AUC — ela foi escolhida pela posição média nos três critérios, não só por este.

COMO LER OS NÚMEROS

A AUC média dentro do município, entre as elegíveis, por versão de renda: original 0,7964, sem o extremo 0,7968, mediana municipal 0,7968. A diferença é de milésimos: a renda não decide nada aqui.

COMO APRESENTAR

“Nenhuma especificação alcança a renda sozinha na separação das favelas, em nenhuma das duas medidas. E as três versões da renda dão a mesma AUC.”

DEMANDAS DE SETEMBRO · SLIDE 33

O que o índice acrescenta à renda



> *A divisória da parte 8: se a renda separa melhor, o que o índice tem a mais?*

O QUE APARECE NO SLIDE

O número 8 em vermelho, o título "O que o índice acrescenta à renda" e o subtítulo: a renda sozinha separa melhor; dentro de cada faixa de renda, o índice acrescenta.

O QUE ISSO QUER DIZER, DO ZERO

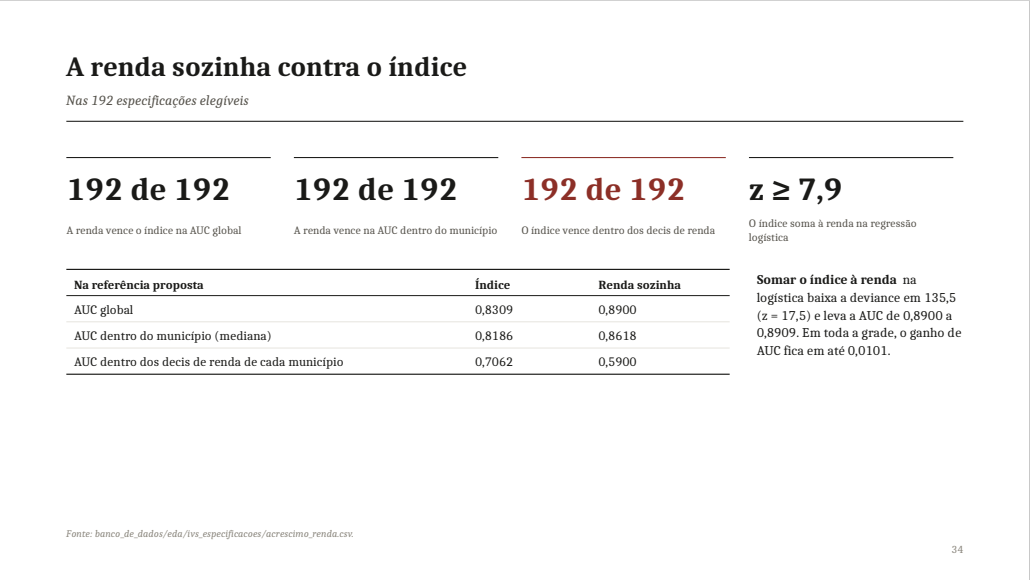
Esta parte responde à pergunta incômoda que atravessa os dois decks.

COMO APRESENTAR

“A parte 8 responde à pergunta que vocês devem estar fazendo: se a renda separa melhor, para que o índice?”

DEMANDAS DE SETEMBRO · SLIDE 34

A renda sozinha contra o índice



> *A renda vence o índice em todas as 192 especificações elegíveis; mas, entre setores de renda parecida, o índice vence em todas.*

O QUE APARECE NO SLIDE

Quatro números grandes: 192 de 192 (a renda vence na AUC global), 192 de 192 (a renda vence dentro do município), 192 de 192 em vermelho (o índice vence dentro dos decis de renda) e z ≥ 7,9 (o índice soma à renda na regressão logística). Embaixo, uma tabela com as três AUCs na referência proposta e um bloco sobre a regressão.

O QUE ISSO QUER DIZER, DO ZERO

A chave está nos **decis de renda** (A.7). Em cada município, os setores são divididos em dez grupos de renda parecida, e a AUC é calculada só entre setores do mesmo grupo. Ali a renda quase não varia, então ela não consegue separar — e o que o índice separa é informação que a renda não tem: água, esgoto, banheiro, analfabetismo, cor/raça, aperto.

A **regressão logística** (A.7) faz a mesma pergunta de outro jeito: um modelo prevê se o setor é favela pela renda; acrescenta-se o índice; se o modelo melhora, o índice traz informação nova. A **estatística z** mede se a melhora é maior que o acaso.

COMO LER OS NÚMEROS

Na referência proposta: AUC global do índice 0,8309 contra 0,8900 da renda; dentro do município, 0,8186 contra 0,8618; dentro dos decis de renda, 0,7062 contra 0,5900 — aqui o índice ganha com folga, e a renda cai para não muito acima do acaso (0,5).

Na regressão: somar o índice à renda reduz a deviance (o erro do modelo) em 135,5, com z = 17,5 — muito acima de 2 —, e leva a AUC do modelo de 0,8900 a 0,8909. Em toda a grade, o z fica entre 7,9 e 43,1, e o ganho de AUC, em até 0,0101. Ou seja: o índice acrescenta informação real, mas pouca, na tarefa de separar favelas.

COMO APRESENTAR

"A renda separa melhor no geral, mas o índice vence quando se compara setores de renda parecida. Ele mede o que a renda não mede — e isso é o que se espera de um índice de vulnerabilidade."

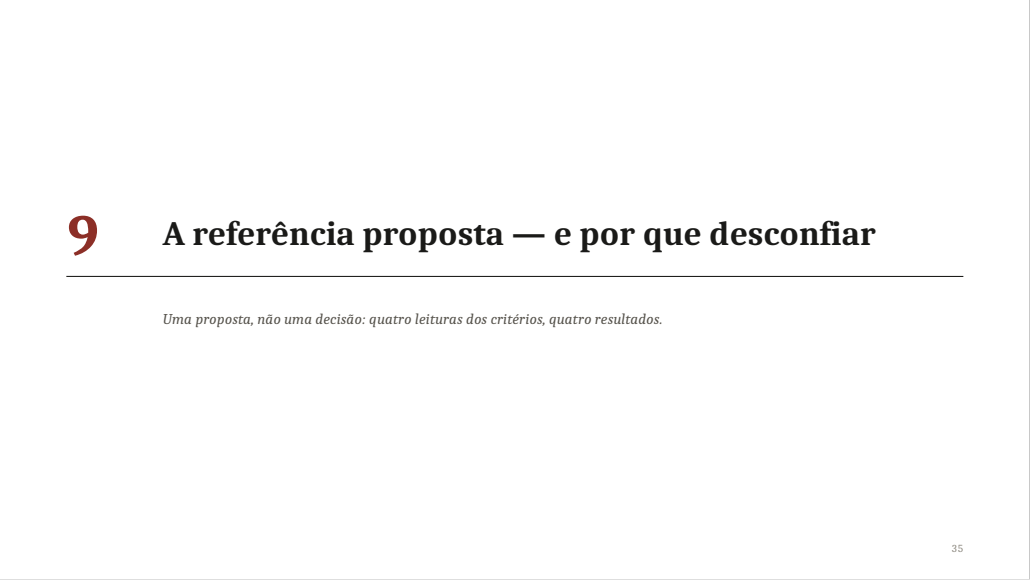
SE PERGUNTAREM

Se o ganho na regressão é tão pequeno, o índice vale a pena?

Para separar favelas, ele acrescenta pouco à renda. Mas o objetivo do índice é medir vulnerabilidade à saúde, não identificar favelas. O que os decis mostram é que ele ordena setores de renda parecida por outras condições — exatamente o que um índice composto deve fazer.

DEMANDAS DE SETEMBRO · SLIDE 35

A referência proposta — e por que desconfiar



A divisória da parte 9: a especificação que os critérios apontam, e as razões para tratá-la como proposta.

O QUE APARECE NO SLIDE

O número 9 em vermelho, o título "A referência proposta — e por que desconfiar" e o subtítulo: uma proposta, não uma decisão; quatro leituras dos critérios, quatro resultados.

O QUE ISSO QUER DIZER, DO ZERO

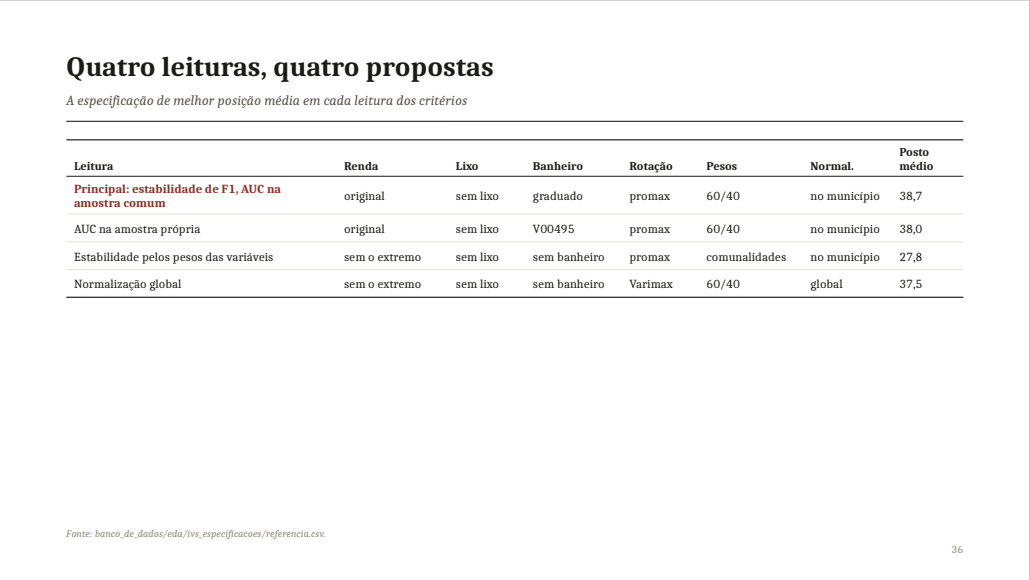
Os critérios de escolha admitem mais de uma leitura. Esta parte mostra a referência de cada leitura e os pontos frágeis da principal.

COMO APRESENTAR

“A parte 9 é a referência proposta — e por que eu não a trataria como decisão.”

DEMANDAS DE SETEMBRO · SLIDE 36

Quatro leituras, quatro propostas



Quatro leituras, quatro propostas

A especificação de melhor posição média em cada leitura dos critérios

Leitura	Renda	Lixo	Banheiro	Rotação	Pesos	Normal.	Posto médio
Principal: estabilidade de F1, AUC na amostra comum	original	sem lixo	graduado	promax	60/40	no município	38,7
AUC na amostra própria	original	sem lixo	V00495	promax	60/40	no município	38,0
Estabilidade pelos pesos das variáveis	sem o extremo	sem lixo	sem banheiro	promax	comunalidades	no município	27,8
Normalização global	sem o extremo	sem lixo	sem banheiro	Varimax	60/40	global	37,5

Fonte: banco_de_dados/eda/ivs_especificacoes/referencia.csv.

36

> *Cada leitura dos critérios aponta uma especificação diferente — e a principal fica, em média, só por volta do 39º lugar.*

O QUE APARECE NO SLIDE

Uma tabela com quatro linhas — as quatro leituras — e as escolhas de cada proposta: renda, lixo, banheiro, rotação, pesos e normalização, mais o posto médio. A primeira linha, a principal, está em vermelho.

O QUE ISSO QUER DIZER, DO ZERO

As quatro leituras:

- **Principal**: estabilidade medida pelo peso do fator 1; AUC na amostra comum. Aponta renda original, sem lixo, banheiro graduado, promax, 60/40, normalização no município.
- **AUC na amostra própria**: a mesma, mas com a AUC calculada na base de cada especificação. Troca o banheiro graduado pela `V00495`.
- **Estabilidade pelos pesos das variáveis**: mede a estabilidade pelo quanto oscila o peso de cada variável, e não só o do fator 1. Aponta renda sem o extremo, sem lixo, sem banheiro, promax por comunalidades.
- **Normalização global**: a melhor entre as de normalização global. Aponta renda sem o extremo, sem lixo, sem banheiro, Varimax, 60/40.

O **posto médio** é a média das posições da especificação nos três critérios; quanto menor, melhor. A principal fica com 38,7: entre as 96 elegíveis, ela não é a primeira em nada, mas é a que fica, em média, mais bem colocada. Nenhuma especificação é a melhor em tudo.

COMO LER OS NÚMEROS

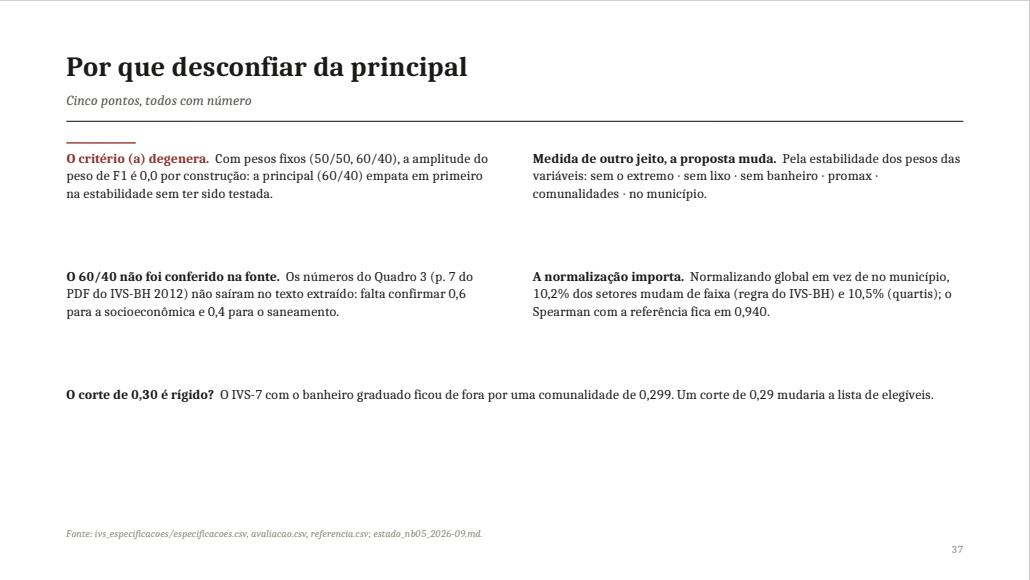
Postos médios: principal 38,7; amostra própria 38,0; estabilidade pelas variáveis 27,8; normalização global 37,5. As quatro concordam em duas coisas: **sem lixo** e **normalização no município** (salvo a leitura que, por construção, só olha a global).

COMO APRESENTAR

“Conforme a leitura dos critérios, a referência muda. Mas há dois consensos: todas tiram o lixo, e as que podem escolher normalizam dentro do município.”

DEMANDAS DE SETEMBRO · SLIDE 37

Por que desconfiar da principal



> *Cinco motivos, todos com número, para tratar a referência principal como proposta e não como decisão.*

O QUE APARECE NO SLIDE

Cinco blocos: o critério (a) degenera (com o filete vermelho); medida de outro jeito, a proposta muda; o 60/40 não foi conferido na fonte; a normalização importa; o corte de 0,30 é rígido?

O QUE ISSO QUER DIZER, DO ZERO

- **O critério de estabilidade degenera**. Ele mede quanto o peso do fator 1 muda ao tirar um município. Nos pesos fixos (50/50, 60/40), o peso não muda nunca — é fixado —, e a amplitude é 0,0 por construção. A principal é 60/40: ela ganha esse critério sem ter sido testada nele.
- **Medida de outro jeito, a proposta muda**. Pela estabilidade dos pesos das variáveis, a proposta passa a ser outra (slide 36).
- **O 60/40 não foi conferido na fonte**. Os números do Quadro 3 do documento do IVS-BH 2012 (página 7 do PDF) não saíram na extração do texto. Falta confirmar, no próprio PDF, que é 0,6 para a dimensão socioeconômica e 0,4 para o saneamento.
- **A normalização importa**. Normalizando de forma global em vez de no município, 10,2% dos setores mudam de faixa pela regra do IVS-BH e 10,5% pelos quartis; a correlação de Spearman entre as duas versões do índice fica em 0,940 — alta, mas um em cada dez setores muda de faixa.
- **O corte de 0,30 é rígido?** O IVS-7 com o banheiro graduado ficou de fora por uma comunalidade de 0,299, um milésimo abaixo do corte. Com um corte de 0,29, a lista de elegíveis mudaria.

COMO APRESENTAR

“A referência principal ganhou em parte por um critério que não a testou, depende de um 60/40 que ainda precisa ser conferido no documento original, e um corte de comunalidade aplicado ao pé da letra deixou de fora uma base por um milésimo. São cinco motivos para tratá-la como ponto de partida da discussão.”

DEMANDAS DE SETEMBRO · SLIDE 38

As faixas da referência

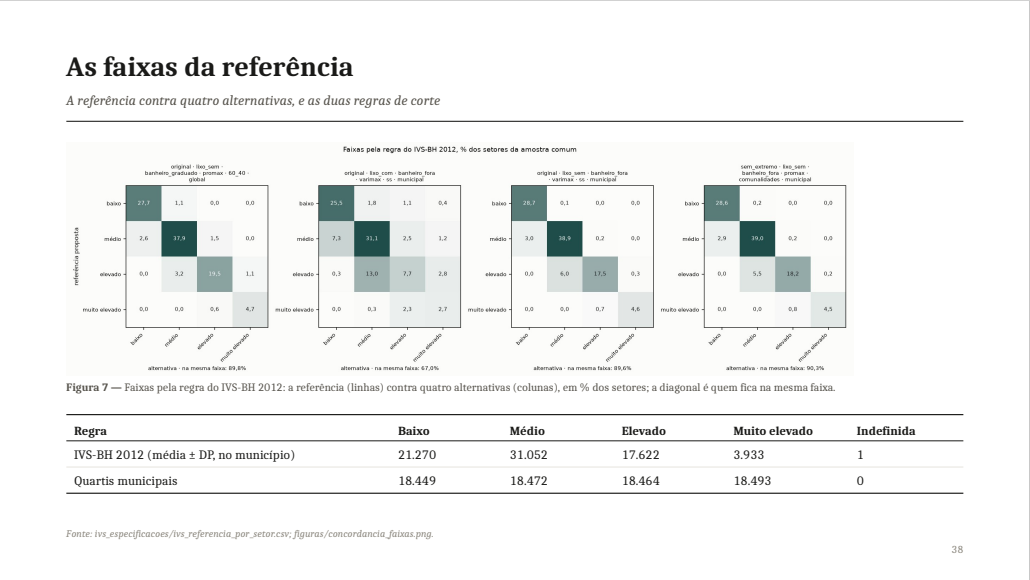


Figura 7 — Faixas pela regra do IVS-BH 2012: a referência (linhas) contra quatro alternativas (colunas), em % dos setores; a diagonal é quem fica na mesma faixa.

Regra	Baixo	Médio	Elevado	Muito elevado	Indefinida
IVS-BH 2012 (média ± DP, no município)	21.270	31.052	17.622	3.933	1
Quartis municipais	18.449	18.472	18.464	18.493	0

Fonte: ivs_especificacoes/ivs_referencia_por_setor.csv; figuras/concordancia_faixas.png.

> *Como a referência se divide em faixas pelas duas regras, e quanto ela concorda com quatro alternativas.*

O QUE APARECE NO SLIDE

Em cima, uma figura com quatro quadros (matrizes de concordância). Em cada um, as linhas são as faixas da referência proposta e as colunas, as faixas de uma alternativa, todas pela regra do IVS-BH 2012; cada célula é a porcentagem de setores. Embaixo, uma tabela com quantos setores caem em cada faixa pela regra do IVS-BH 2012 e pelos quartis municipais.

O QUE ISSO QUER DIZER, DO ZERO

Uma **matriz de concordância** cruza duas classificações. Na diagonal (de cima, à esquerda, para baixo, à direita) ficam os setores que caem na mesma faixa nas duas; fora dela, os que mudam. O rodapé de cada quadro diz quanto fica na mesma faixa:

- a mesma especificação com normalização global: 89,8%;
- o IVS-7 do NB04 (renda original, com lixo, sem banheiro, Varimax): 67,0% — a maior diferença;
- o IVS-6 com Varimax: 89,6%;
- a referência pela estabilidade das variáveis: 90,3%.

As duas regras de faixa (A.5): a do **IVS-BH 2012** usa a média e o desvio-padrão, dentro de cada município, e dá faixas de tamanhos diferentes; os **quartis** dividem cada município em quatro grupos iguais.

COMO LER OS NÚMEROS

Pela regra do IVS-BH 2012: baixo 21.270, médio 31.052, elevado 17.622 e muito elevado 3.933 (5,3% dos setores). Pelos quartis, cerca de um quarto em cada faixa (18.449, 18.472, 18.464 e 18.493). "Indefinida" é o setor que fica sozinho numa faixa do seu município, onde a regra não se aplica: 1 pela regra do IVS-BH.

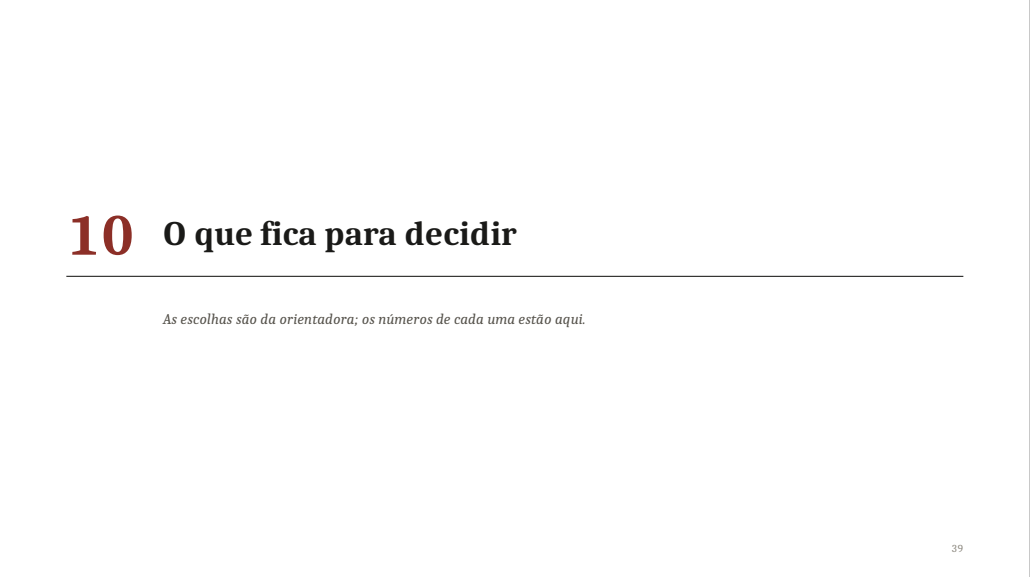
A regra do IVS-BH reserva o "muito elevado" para poucos setores, os que se destacam muito da média; os quartis põem um quarto de cada município nessa faixa. Para um gestor de saúde, a primeira aponta poucas prioridades; a segunda, muitas.

COMO APRESENTAR

“A referência concorda em cerca de 90% dos setores com as alternativas próximas, mas só em dois terços com o IVS-7 original. E a regra de faixas muda muito o tamanho do grupo de maior risco: poucos setores pela regra de Belo Horizonte, um quarto pelos quartis.”

DEMANDAS DE SETEMBRO · SLIDE 39

O que fica para decidir



> *A divisória da parte 10: as escolhas da orientadora, cada uma com os números.*

O QUE APARECE NO SLIDE

O número 10 em vermelho, o título "O que fica para decidir" e o subtítulo: as escolhas são da orientadora; os números de cada uma estão aqui.

O QUE ISSO QUER DIZER, DO ZERO

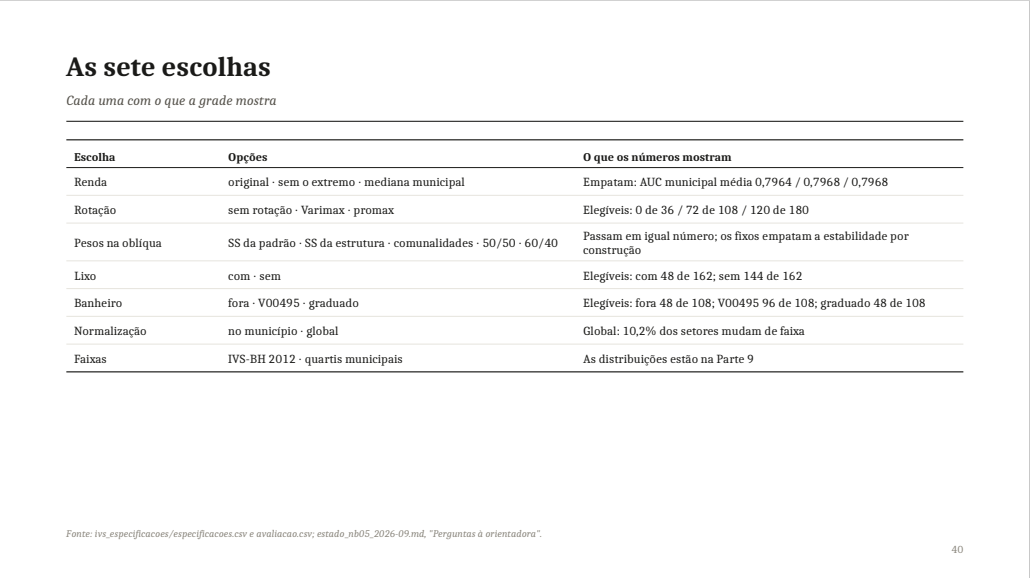
O fecho do deck é uma agenda de decisões.

COMO APRESENTAR

“Para fechar, o que fica para você decidir.”

DEMANDAS DE SETEMBRO · SLIDE 40

As sete escolhas



As sete escolhas

Cada uma com o que a grade mostra

Escolha	Opções	O que os números mostram
Renda	original · sem o extremo · mediana municipal	Empatam: AUC municipal média 0,7964 / 0,7968 / 0,7968
Rotação	sem rotação · Varimax · promax	Elegíveis: 0 de 36 / 72 de 108 / 120 de 180
Pesos na oblíqua	SS da padrão · SS da estrutura · comunalidades · 50/50 · 60/40	Passam em igual número; os fixos empatam a estabilidade por construção
Lixo	com · sem	Elegíveis: com 48 de 162; sem 144 de 162
Banheiro	fora · V00495 · graduado	Elegíveis: fora 48 de 108; V00495 96 de 108; graduado 48 de 108
Normalização	no município · global	Global: 10,2% dos setores mudam de faixa
Faixas	IVS-BH 2012 · quartis municipais	As distribuições estão na Parte 9

Fonte: ivs_especificacoes/especificacoes.csv e avaliacao.csv; estado_nb05_2026-09.md, "Perguntas à orientadora".

40

> *As sete escolhas de método, as opções de cada uma e o que a grade mostra sobre elas.*

O QUE APARECE NO SLIDE

Uma tabela de sete linhas e três colunas: a escolha, as opções e o que os números mostram.

O QUE ISSO QUER DIZER, DO ZERO

Cada escolha, com o resumo dos números:

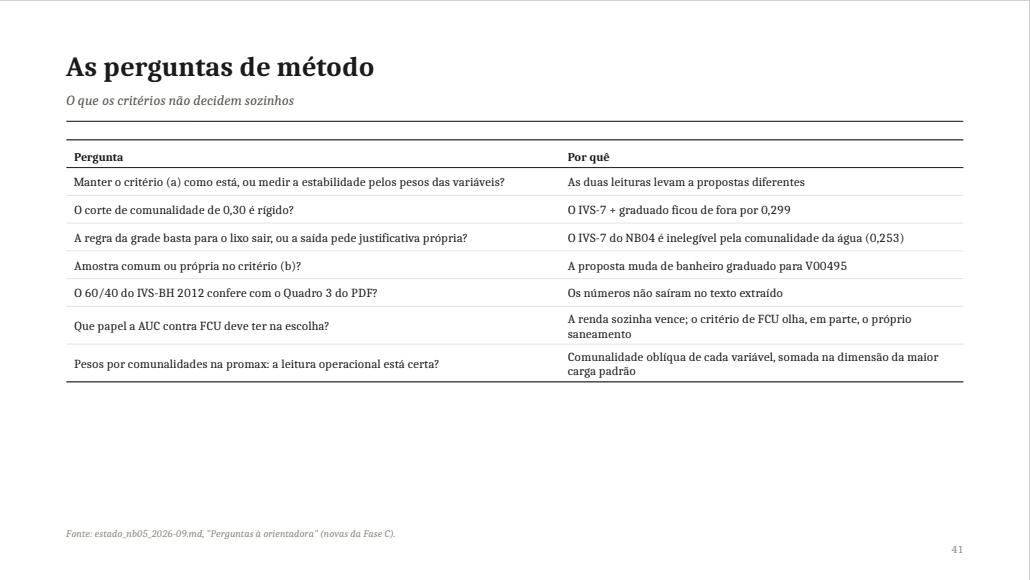
- **Renda** — original, sem o extremo ou mediana municipal: empatam (AUC média de 0,7964, 0,7968 e 0,7968). A escolha é de princípio.
- **Rotação** — sem rotação, Varimax ou promax: elegíveis 0 de 36, 72 de 108 e 120 de 180.
- **Pesos na oblíqua** — cinco esquemas: passam em igual número; os fixos empatam a estabilidade por construção.
- **Lixo** — com ou sem: elegíveis 48 de 162 com lixo e 144 de 162 sem.
- **Banheiro** — fora, `V00495` ou graduado: elegíveis 48 de 108, 96 de 108 e 48 de 108.
- **Normalização** — no município ou global: com a global, 10,2% dos setores mudam de faixa.
- **Faixas** — regra do IVS-BH 2012 ou quartis municipais: as distribuições estão no slide 38.

COMO APRESENTAR

“Estas são as sete escolhas. Para cada uma, a grade mostra o que muda. Algumas os números praticamente resolvem — a renda não faz diferença; com lixo, quase nada passa —, outras são de princípio.”

DEMANDAS DE SETEMBRO · SLIDE 41

As perguntas de método



As perguntas de método

O que os critérios não decidem sozinhos

Pergunta	Por quê
Manter o critério (a) como está, ou medir a estabilidade pelos pesos das variáveis?	As duas leituras levam a propostas diferentes
O corte de comunalidade de 0,30 é rígido?	O IVS-7 + graduado ficou de fora por 0,299
A regra da grade basta para o lixo sair, ou a saída pede justificativa própria?	O IVS-7 do NB04 é inelegível pela comunalidade da água (0,253)
Amostra comum ou própria no critério (b)?	A proposta muda de banheiro graduado para V00495
O 60/40 do IVS-BH 2012 confere com o Quadro 3 do PDF?	Os números não saíram no texto extraído
Que papel a AUC contra FCU deve ter na escolha?	A renda sozinha vence; o critério de FCU olha, em parte, o próprio saneamento
Pesos por comunalidades na promax: a leitura operacional está certa?	Comunalidade oblíqua de cada variável, somada na dimensão da maior carga padrão

Fonte: estado_nb05_2026-09.md, "Perguntas à orientadora" (novas da Fase C).

41

> *As sete perguntas que os critérios não respondem sozinhos.*

O QUE APARECE NO SLIDE

Uma tabela com duas colunas: a pergunta e o porquê dela.

O QUE ISSO QUER DIZER, DO ZERO

As perguntas, explicadas:

- **O critério de estabilidade fica como está, ou mede os pesos das variáveis?** As duas leituras dão propostas diferentes (slide 36).
- **O corte de comunalidade de 0,30 é rígido?** O IVS-7 com o banheiro graduado ficou de fora por 0,299.
- **A regra da grade basta para o lixo sair, ou a saída pede justificativa própria?** O IVS-7 do NB04 é inelegível pela comunalidade da água (0,253); tirar o lixo é uma decisão com peso no artigo.
- **Amostra comum ou própria no critério de AUC?** A proposta troca o banheiro graduado pela `V00495`.
- **O 60/40 confere com o Quadro 3 do PDF?** Os números não saíram na extração do texto.
- **Que papel a AUC contra favelas deve ter?** A renda sozinha vence, e o critério de favela do IBGE olha, em parte, o próprio saneamento (A.7).
- **Os pesos por comunalidades na promax estão certos?** A leitura operacional — a comunalidade de cada variável, somada na dimensão em que ela tem a maior carga — precisa ser confirmada.

COMO APRESENTAR

“E estas são as perguntas de método que surgiram ao rodar a grade. Nenhuma tem resposta técnica única; todas pedem uma decisão.”

DEMANDAS DE SETEMBRO · SLIDE 42

Onde está cada resultado



Onde está cada resultado

Para conferir qualquer número deste deck

Resultado	Onde
A entrega, com as três rendas e o banheiro graduado	banco_de_dados/entrega_orientadora/
A fatorial ampliada (S0–S7)	notebooks/Fase3_EDA_ELSI/04b_Analise_Fatorial_Ampliada.ipynb; banco_de_dados/eda/fatorial_ampliada/
A grade do IVS final	notebooks/Fase3_EDA_ELSI/05_Calculo_IVS_Final.ipynb; banco_de_dados/eda/ivs_especificacoes/
Os relatórios	docs/relatorios/Relatorio_IVS_Final_NB05.md; docs/relatorios/Relatorio_Analise_Fatorial_NB04.md
O deck principal	docs/Apresentacoes_IVS/Analise_Fatorial_NB04_2026-09.pptx (114 slides)
O registro de cada fase	estado_demandas_2026-09.md; estado_nb05_2026-09.md

Gerado por scripts/gerar_deck_demandas_setembro.js em 05/10/2026, a partir dos CSVs. Para refazer: node scripts/gerar_deck_demandas_setembro.js

42

> *Onde encontrar cada resultado do deck, para conferir qualquer número.*

O QUE APARECE NO SLIDE

Uma tabela com seis linhas: o resultado e onde ele está. No pé, a data em que o deck foi gerado e o comando para gerá-lo de novo.

O QUE ISSO QUER DIZER, DO ZERO

- A **entrega** à orientadora, com as três rendas e o banheiro graduado: `banco_de_dados/entrega_orientadora/`.
- A **fatorial ampliada**: o notebook `04b_Analise_Fatorial_Ampliada.ipynb` e as tabelas em `banco_de_dados/eda/fatorial_ampliada/`.
- A **grade do IVS final**: o notebook `05_Calculo_IVS_Final.ipynb` e as tabelas em `banco_de_dados/eda/ivs_especificacoes/`.
- Os **relatórios**: o do IVS final e o da análise fatorial, em `docs/relatorios/`.
- O **deck principal**: na raiz de `docs/Apresentacoes_IVS/`.
- O **registro de cada fase**: os arquivos de estado das demandas e do NB05.

O comando no pé (`node scripts/gerar_deck_demandas_setembro.js`) gera o deck de novo, lendo as tabelas do dia: se a orientadora escolher uma especificação e as tabelas mudarem, o deck acompanha.

COMO APRESENTAR

"Qualquer número deste deck pode ser conferido nestes arquivos, e o deck pode ser gerado de novo a qualquer momento."

Parte D — Glossário

Os termos dos dois decks, em ordem alfabética

Os termos que aparecem nos dois decks e neste guia, em ordem alfabética. Cada definição foi escrita para ser entendida sozinha; quando um termo depende de outro, o outro também está aqui.

50/50 e 60/40 — Pesos fixos para as duas dimensões do índice: metade para cada uma, ou 60% para a socioeconômica e 40% para o saneamento (a proporção atribuída ao IVS-BH 2012, ainda a confirmar no PDF original).

Agregados por setor — Os dados do Censo publicados como contagens por setor censitário, e não por pessoa.

Amostra comum — O conjunto de setores presente em todas as versões comparadas, para que a comparação não dependa de qual versão perdeu mais setores por dado ausente. Seu contrário é a amostra própria de cada versão.

Anotações do apresentador — O texto escondido embaixo de cada slide, visível só para quem apresenta.

Análise fatorial — Técnica que encontra, nos dados, grupos de variáveis que andam juntas (os fatores) e diz quanto cada variável pertence a cada grupo.

AUC — Área sob a curva ROC. Probabilidade de um setor de favela, sorteado, ter índice maior que um setor que não é favela, também sorteado. 0,5 é o acaso; 1 é a separação perfeita.

Autovalor — Quanto da informação das variáveis um fator resume. Autovalor 3: o fator vale por três variáveis.

Backup/ — A pasta do repositório com o legado: as versões antigas da pipeline (Fases 1 e 2), guardadas como histórico.

Bartlett (teste de) — Teste que verifica se as variáveis têm alguma correlação entre si. Sem correlação, não há fator para achar.

Base — Na grade do NB05, uma combinação de renda, lixo e banheiro — o conjunto de variáveis que vai para a análise fatorial. São 18 bases.

Bootstrap — Refazer uma análise muitas vezes com amostras sorteadas dos próprios dados, para medir a incerteza. Não foi usado aqui: o projeto trabalha com todos os setores, não com uma amostra.

Branch — Uma linha de trabalho dentro do repositório git. A principal se chama main.

Carga fatorial — O quanto uma variável pertence a um fator, de −1 a 1.

Caçamba — Contêiner comunitário de lixo (variável `V00398`). Pelo método do IVS-BH 2012, conta como destino inadequado: só a coleta porta a porta é adequada.

Censo Demográfico — A contagem de toda a população, feita pelo IBGE. A edição usada é a de 2022.

Cenário (S0 a S7) — Na fatorial ampliada, cada conjunto de variáveis testado: S0 é o IVS-7 do NB04, S1 é sem o lixo, S2 a S5 acrescentam uma variável cada, S6 junta as quatro e S7 é o S6 sem o lixo.

Commit — Registro de uma mudança no git, com data, autor e mensagem. É a unidade da cronologia.

Complemento — 1 menos uma proporção: se 92% têm água canalizada, o complemento, 8%, é a proporção sem.

Comunalidade — Quanto de uma variável os fatores explicam juntos, de 0 a 1. Abaixo de 0,30, a variável conversa pouco com as outras e a especificação deixa de ser elegível.

Correlação — Medida, de −1 a 1, de quanto duas variáveis andam juntas.

CSV — Tabela salva como texto, com os valores separados por vírgula ou ponto e vírgula.

Decil — Cada um dos dez grupos de mesmo tamanho em que se divide uma lista ordenada. "Decis de renda": os setores do município divididos em dez faixas de renda.

Deck — Uma apresentação de slides.

Denominador — O total pelo qual se divide para fazer uma proporção. Nos indicadores de domicílio do projeto, é `V00001`.

Desvio-padrão (DP) — O quanto os valores costumam se afastar da média.

Deviance — Medida do erro de um modelo estatístico; quanto menor, melhor o ajuste.

Dimensão — Um grande tema do índice: saneamento ou socioeconômica.

EDA — Análise exploratória de dados: descrever, medir e procurar problemas antes de modelar. A EDA Central teve duas rodadas, em agosto e setembro.

Elegível — Especificação que passa nos quatro critérios mínimos: KMO ≥ 0,70, MSA ≥ 0,50, comunalidade ≥ 0,30 e carga máxima ≥ 0,40.

ELSI-Brasil — Estudo Longitudinal da Saúde dos Idosos Brasileiros, coordenado pela Fiocruz, com participantes em 70 municípios.

Escore — A nota de cada setor em cada fator.

Especificação — Uma combinação completa de escolhas para calcular o IVS: renda, lixo, banheiro, rotação, esquema de peso e normalização.

Φ (fi) — A correlação entre os fatores numa rotação oblíqua (promax). Na Varimax é zero por construção.

Faixa de risco — Categoria do índice: baixo, médio, elevado ou muito elevado.

Fator — Uma dimensão escondida que explica por que várias variáveis andam juntas.

FCU — Favelas e Comunidades Urbanas: a classificação do IBGE para os setores que são favela ou comunidade urbana (campo `CD_TIPO` = 1).

Git — Programa que guarda o histórico de mudanças de uma pasta de projeto.

Grade — O conjunto de todas as especificações testadas — no NB05, 324.

Grafo do projeto — Um mapa do repositório em que cada conceito, arquivo ou função é um nó e cada relação é uma ligação; serve para achar onde cada coisa está.

Hash — O identificador curto de um commit, como `2d0c909`.

Heywood (caso de) — Comunalidade acima de 1, que é impossível: sinal de problema na estimação.

Horn (regra de) — Mantém só os fatores cujo autovalor supera o que dados aleatórios do mesmo tamanho dariam. Também chamada de análise paralela.

IBGE — Instituto Brasileiro de Geografia e Estatística, que faz o Censo.

Imputação — Preencher um valor que falta, ou que foi retirado, com uma estimativa — como a mediana.

Indicador — Uma conta que transforma contagens em algo comparável, em geral uma proporção.

IVS — Índice de Vulnerabilidade à Saúde.

IVS-7 e IVS-6 — O IVS com os sete indicadores do IVS-BH 2012, e o mesmo sem o lixo.

IVS-BH 2012 — O índice da Secretaria Municipal de Saúde de Belo Horizonte, feito com o Censo de 2010: a referência de método do projeto.

Kaiser (regra de) — Mantém os fatores com autovalor maior que 1.

KMO — Medida, de 0 a 1, de quanto os dados se prestam à análise fatorial. De 0,7 para cima é bom.

Mediana — O valor do meio de uma lista ordenada: metade fica abaixo, metade acima. Ao contrário da média, não é puxada por um extremo.

Min-max — Normalização que põe o pior valor em 1 e o melhor em 0.

MSA — O KMO de cada variável, separado.

Módulo — Código compartilhado por vários programas. O do projeto é `src/ivs_censo`.

NB01 a NB05 — Os notebooks da pipeline: extração e filtro (01), análise descritiva (02), análise fatorial (04), fatorial ampliada (04b) e IVS final (05).

Normalização — Pôr indicadores de escalas diferentes na mesma régua. No município: mínimo e máximo de cada cidade; global: de todos os setores juntos.

Notebook — Documento que mistura texto, código e resultados, na ordem da análise.

Numerador — A parte de cima de uma proporção: o que se quer medir.

Outlier (valor extremo) — Um valor muito distante dos demais, como o setor de Belo Horizonte com renda média de R$ 170.418,06.

p.p. (pontos percentuais) — A diferença entre duas porcentagens: de 65% para 63% são 2 p.p.

Parcimônia — Preferir o modelo mais simples, com menos variáveis, quando os outros não são claramente melhores.

Partição — Divisão de um total em partes que não se sobrepõem e somam o total. A falta de banheiro (`V00495`) se divide exatamente em `V00236`, `V00237` e `V00238`.

Peso — Quanto cada indicador ou dimensão conta na soma do índice.

Posto — A posição de um valor numa lista ordenada (primeiro, segundo…). Postos no município: a posição do setor dentro da sua cidade.

Posto médio — A média das posições de uma especificação nos três critérios de escolha; o menor é o melhor.

Promax — Rotação oblíqua: deixa os fatores se correlacionarem. Tem duas matrizes, a padrão e a estrutura.

Proporção — Numerador dividido pelo denominador, de 0 a 1.

Recorte urbano — Só os setores urbanos (`SITUACAO` = urbana): 104.108 nos 70 municípios.

Referência proposta — A especificação elegível de melhor posição média nos três critérios. É uma proposta: a escolha final é da orientadora.

Regressão logística — Modelo que estima a chance de algo acontecer (aqui: o setor ser favela) a partir de outras variáveis.

Renda invertida — A renda virada do avesso, para que, como nos outros indicadores, mais seja pior.

Repositório — A pasta do projeto, com todo o seu histórico no git.

ROC (curva) — Gráfico que mostra o quanto um índice separa dois grupos; a área sob ela é a AUC.

Rotação — Girar os eixos dos fatores para que cada variável fique perto de um só.

Scree plot — Gráfico dos autovalores em ordem decrescente, usado para decidir quantos fatores manter.

Script — Programa que roda sozinho e grava um resultado.

Sensibilidade por município — Refazer a análise tirando um município por vez, para ver quanto o resultado depende de cada um.

Setor censitário — A menor área com dados publicados pelo Censo, em geral poucos quarteirões na cidade.

Sigilo — O "X" que o IBGE põe no lugar de contagens pequenas. No projeto vira dado ausente, nunca zero.

Spearman (correlação de) — Correlação feita com as posições (postos) em vez dos valores, menos sensível a extremos.

SS — Soma dos quadrados das cargas de um fator: a sua força, usada para calcular os pesos.

Taxa e razão — Na taxa, o denominador contém o numerador (analfabetos ÷ todos de 15+), e ela nunca passa de 1. Na razão, não contém (analfabetos ÷ alfabetizados), e ela pode passar de 1.

Teste automático — Programa que confere se o código dá o resultado esperado. O projeto tem 103.

V00001 — Domicílios particulares permanentes ocupados: o denominador dos indicadores de domicílio.

Varimax — Rotação ortogonal: mantém os fatores independentes, com correlação zero entre eles.

Worktree — Uma cópia de trabalho paralela do repositório. As que ficaram esquecidas foram para a Lixeira em setembro.

z (estatística) — Mede se um efeito é maior do que o acaso explicaria; acima de 2 já é considerado significativo.

Índice composto — Um número que junta vários indicadores, cada um com um peso.

Como este guia foi feito

Este guia foi gerado em 05/10/2026 pelo programa `scripts/gerar_pdf_guia_decks_outubro.py`. Os textos estão em `scripts/guia_outubro_base.py`, `scripts/guia_outubro_cronologia.py` e `scripts/guia_outubro_demandas.py`. Os números vêm dos mesmos arquivos que alimentam os slides:

- o histórico do git, para as datas e as contagens de commits;
- `banco_de_dados/eda/fatorial_ampliada/`, para a linha de base do NB04, os cenários S0–S7, os pesos, a validação, a sensibilidade e a partição do banheiro;
- `banco_de_dados/eda/ivs_especificacoes/`, para a grade do NB05, a referência proposta, o índice contra a renda e as faixas;
- `banco_de_dados/entrega_orientadora/`, para o quadro de indicadores, a renda do setor extremo e o número de colunas da entrega;
- o próprio arquivo de cada deck, para as miniaturas e o número de slides.

Antes de montar o guia, o programa confere se o título de cada verbete aparece no slide de mesmo número. Se um deck for regerado e os slides mudarem de lugar, ele para e diz qual verbete não confere — em vez de explicar o slide errado. Para gerar de novo:

```
uv run --with reportlab --with pandas --with pypdf python scripts/gerar_pdf_guia_decks_outubro.py
```