

ROTEIRO DE APRESENTAÇÃO

A EDA Central

Índice de Vulnerabilidade da Saúde intraurbano · Censo Demográfico 2022 · 70 municípios do ELSI-Brasil

47 slides · duração estimada de 35 a 45 minutos · 104.108 setores censitários urbanos

Pedro Dias Soares · Iniciação Científica · Fiocruz Minas — Instituto René Rachou · agosto de 2026

Como usar este roteiro

Cada slide tem quatro blocos. "O que está na tela" descreve o conteúdo, para você reconhecer o slide sem precisar olhar. "O que dizer" traz a fala sugerida entre aspas e em itálico — não é para decorar nem ler, é para você saber qual é a ideia central e em que ordem ela se sustenta. "O que apontar" indica onde levar o olhar de quem assiste, especialmente nas figuras. "Se perguntarem" antecipa as objeções prováveis.

Uma regra vale para a apresentação inteira: sempre que citar um número, diga o recorte. A base tem dois — 104.108 setores urbanos elegíveis e 106.281 incluindo os rurais — e confundi-los foi um erro real que esta versão do deck corrigiu. Cada tabela traz o recorte impresso embaixo dela; se a pergunta vier, é só ler.

Antes de começar

- Deixe abertos: a pasta banco_de_dados/eda/ (61 tabelas) e o PDF do IBGE em docs/ — as duas perguntas mais prováveis se respondem abrindo um arquivo.
- Tenha à mão o número 63: é a quantidade de testes automatizados que passam. É a resposta curta para "como você sabe que isso está certo?".
- Se o tempo apertar, os slides que não podem cair são 7, 10, 18, 21, 24, 32, 37 e 46. Os divisores de seção (3, 6, 8, 17, 20, 28, 36, 40) podem passar em cinco segundos.
- Os slides 12, 13, 15, 18, 25 e 27 têm figura. Em cada um, resista a descrever a figura inteira: diga a única coisa que ela mostra e siga.

O arco da apresentação, em uma frase por seção

Seção	Slides	A ideia que precisa ficar
Abertura	1–2	Esta é a primeira vez que a EDA aparece inteira; as anteriores eram recortes.
1. Desenho	3–5	O objeto é o setor censitário, e o índice é intraurbano — isso decide todo o resto.
2. Quem entra	6–7	Cada exclusão é auditável e reversível; a base bruta guarda tudo.
3. As sete componentes	8–16	As distribuições são torcidas, e isso quebra a regra usual de outlier.
4. Correlação	17–19	Três variáveis medem quase a mesma coisa; chefia feminina mede outra.
5. Renda	20–27	O extremo não é renda alta, é erro de dado — e o dano está na escala, não na média.
6. Blocos descritivos	28–35	Tudo que ficou fora dos decks anteriores, agora no mesmo recorte.
7. Favelas	36–38	O critério foi validado contra a lista oficial do IBGE, com 100% de acerto.
8. Fechamento	39–47	Limitações declaradas, correções assumidas e o próximo passo definido.

Roteiro slide a slide

Slide 1 — Capa

Tempo sugerido: 30 segundos

O que está na tela

- Folha de rosto: título, subtítulo com o recorte e a assinatura.

O que dizer

“Esta é a análise exploratória completa do Censo 2022 nos 70 municípios do ELSI-Brasil. São 104 mil setores censitários urbanos, e é a primeira vez que apresento a EDA inteira num só lugar.”

Se perguntarem

P: Por que só agora?

R: Porque cada apresentação anterior foi montada em torno da pauta daquele mês. O próximo slide mostra exatamente o que se perdeu nisso.

Slide 2 — Por que esta apresentação existe

Tempo sugerido: 2 minutos

O que está na tela

- Tabela comparando os blocos de análise entre o deck de junho, o de agosto e este.
- Coluna "Agosto" tem três "caiu" em vermelho.

O que dizer

“A senhora notou que a chefia feminina não estava na última apresentação. Eu fui atrás, e achei o motivo. Ela estava sim no deck de junho, no slide 19. Sumiu quando remontei a apresentação de agosto em torno das sete demandas de julho — e chefia feminina tinha sido uma das seis demandas de junho, não de julho.”

“Não foi só ela. Habitação precária, morfologia do domicílio e a análise de banheiro caíram na mesma reescrita. E a causa é estrutural: nenhum script gerava as apresentações. A lista do que entra vivia na minha cabeça.”

“Este deck é gerado por script, e os números são lidos das tabelas na hora de gerar. Nenhum valor é digitado à mão.”

O que apontar

- Os três "caiu" da coluna Agosto — é o que motivou esta revisão.
- A coluna "Tabelas": os dados nunca sumiram, só o caminho até o slide.

Se perguntarem

P: Como você garante que não vai acontecer de novo?

R: A lista de blocos agora está num arquivo versionado. Dá para comparar o que o deck cobre com as 61 tabelas da pasta e ver o que ficou de fora.

Slide 3 — Divisor — O desenho do estudo

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção, só o número 1 e o título.

O que dizer

“Começo pelo desenho: a pergunta, o objeto e como o código está organizado.”

Slide 4 — A pergunta e o objeto

Tempo sugerido: 2 minutos

O que está na tela

- A pergunta de pesquisa, a definição do objeto e quatro números de dimensionamento.

O que dizer

“A pergunta é como a vulnerabilidade se distribui dentro das cidades, não entre elas. Isso parece detalhe, mas é a decisão que organiza a análise inteira.”

“O objeto é o setor censitário, a menor unidade do Censo. E o índice é intraurbano: ele compara setores dentro da mesma cidade. Sempre que eu tiver que escolher entre um critério nacional e um critério municipal ao longo desta apresentação, vou escolher o municipal — e é por causa desta definição.”

Números que sustentam a fala

- 104.108 setores urbanos elegíveis, em 70 municípios.
- 8 arquivos do Censo, 2,4 GB, 73 variáveis na base montada.
- O recorte reúne 61,4% de toda a população favelada do Brasil — número conferido contra a publicação oficial do IBGE, e que volta no slide 37.

Se perguntarem

P: Por que 70 municípios?

R: É a amostra do ELSI-Brasil, o estudo longitudinal da saúde dos idosos. O índice vai ser cruzado com desfechos dessa coorte.

Slide 5 — Como a pipeline está estruturada

Tempo sugerido: 2 minutos

O que está na tela

- Cinco etapas numeradas: módulo, Notebook 01, Notebook 02, scripts e testes.

O que dizer

“As fórmulas ficam num módulo só. Os dois notebooks e os quatro scripts leem dele — nenhuma fórmula é redigitada em outro lugar.”

“Isso não era assim até este mês. As fórmulas existiam em dois lugares e a lista de variáveis em três. Bastava corrigir de um lado e esquecer o outro para o recorte ELSI divergir do cálculo nacional em silêncio.”

Se perguntarem

P: Isso é reproduzível por outra pessoa?

R: Sim. São quatro comandos: criar o ambiente, rodar os dois notebooks e rodar os scripts. Está documentado no README, e a suíte de 63 testes confere o resultado.

Slide 6 — Divisor — Quem entra na análise

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 2.

O que dizer

“Agora, quem entra e quem fica de fora.”

Slide 7 — Do universo do Censo aos setores analisados

Tempo sugerido: 3 minutos

O que está na tela

- Tabela-funil: de 468.099 setores do país até 104.108 analisados.
- Dois parágrafos abaixo: a conferência da exclusão rural e a correção das massas d'água.

O que dizer

“Este funil é o slide que eu mais uso para responder pergunta. Cada linha é um corte, e cada corte tem critério escrito.”

“Da esquerda para a direita: os 468 mil setores do país, o filtro dos 70 municípios, e aí três exclusões. Setores sem população, setores com o denominador sigiloso, e setores inteiramente coletivos — asilos e presídios, que no nosso recorte não aparecem.”

“A última linha é o filtro urbano, que a senhora pediu em julho. Ele é aplicado na análise, não na extração: a base bruta continua com os 109 mil setores, então a exclusão é reversível e auditável.”

O que apontar

- A linha ZERADO — foi uma correção: 1.736 setores sem população apareciam como sigilosos porque a ordem das condições estava invertida.
- A linha do recorte urbano: 2.173 setores rurais saem.

Números que sustentam a fala

- 29 dos 70 municípios perdem mais de 10% dos setores com o filtro urbano, e 7 ficam com menos de 10 setores. Isso afeta a estabilidade das descritivas municipais e está declarado nas limitações.

Se perguntarem

P: Por que não excluir os rurais já na extração?

R: Porque aí a exclusão viraria irreversível e não daria para conferir quanto saiu. Do jeito atual, a tabela de conferência mostra município a município.

P: Nenhum setor coletivo mesmo?

R: Nenhum. A classe existe na regra e ficou vazia, então ninguém é excluído por ela. O que existe é uma assimetria: quem mora em domicílio coletivo entra na população do setor, o v0001, mas não entra no denominador domiciliar, o V00001. Ou seja, essa pessoa conta nos indicadores de cor/raça e de idade, e não conta nos de saneamento. É isso que está nas limitações.

Slide 8 — Divisor — As sete componentes

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 3.

O que dizer

“As sete variáveis que compõem o índice.”

Slide 9 — As sete componentes — fórmulas

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com numerador, denominador e dimensão de cada componente.
- Três parágrafos abaixo: denominador consolidado, analfabetismo corrigido, três não reprodutíveis.

O que dizer

“Estas são as sete. Três de saneamento e quatro socioeconômicas, adaptadas do IVS-BH de 2012.”

“Duas correções valem menção. A primeira: o denominador domiciliar é V00001, domicílios particulares permanentes ocupados. Antes usávamos V01042, que é contagem de pessoas, não de domicílios — e com isso algumas proporções passavam de 1,0, o que é impossível.”

“A segunda: a taxa de analfabetismo é V00901 dividido pela soma de V00900 e V00901, ou seja, pelo total de pessoas com 15 anos ou mais. Antes era V00901 sobre V00900, que é uma razão entre analfabetos e alfabetizados, não uma taxa.”

Se perguntarem

P: E as componentes do IVS-BH que não estão aqui?

R: Três não existem nos agregados por setor do Censo 2022: anos de estudo, faixas de renda e óbitos cardiovasculares. Cada uma foi substituída por um proxy declarado, e a substituição está documentada.

Slide 10 — As sete componentes em números

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com n, média, mediana, p75, máximo e assimetria das sete.

O que dizer

“Dois números desta tabela abrem as duas seções seguintes.”

“O primeiro é o n do analfabetismo: 87.556, contra 104 mil das outras. São 16.552 setores sem o dado, e a razão disso é o tema do slide 15.”

“O segundo é a assimetria da renda: 3,74, com máximo de 170 mil reais. É a distribuição mais torta da base, e é o tema da seção 5 inteira.”

O que apontar

- A coluna mediana: em três das sete ela é zero. Água, esgoto e lixo não têm inadequação medida na maioria dos setores urbanos — e é isso que vai quebrar a regra de outlier no slide 14. Cuidado com a palavra: em cerca de um quarto desses zeros alguma parcela veio sigilosa, então é ausência de medida, não adequação comprovada.
- A razão de moradores é a única com assimetria próxima de zero.

Se perguntarem

P: Por que reportar média e mediana juntas?

R: Porque a distância entre elas mede a assimetria. Na renda, média de 4.187 contra mediana de 2.572 — a média está sendo puxada pela cauda.

Slide 11 — As sete componentes por região

Tempo sugerido: 3 minutos

O que está na tela

- Tabela das sete componentes por região.
- Dois parágrafos: o padrão confirmado e duas exceções.

O que dizer

“Aqui está o gradiente Norte-Sul que a literatura prevê, e ele aparece em seis das sete.”

“Água inadequada no Norte é dezesseis vezes a do Sul. O esgoto, oito vezes. A razão de moradores acompanha: 3,19 no Norte contra 2,53 no Sul.”

“Mas há duas exceções, e elas são mais interessantes que a regra. O analfabetismo tem pico no Nordeste, não no Norte. E o lixo inadequado é maior no Nordeste e no Sudeste do que no Norte — o que é o contrário do esperado, e volta no slide 39.”

O que apontar

- A linha do lixo — é a única que não segue o gradiente. Guarde isso, porque no comparativo com o Brasil ela vai reaparecer.

Slide 12 — Como as sete variáveis se distribuem

Tempo sugerido: 2 minutos

O que está na tela

- Figura: nove histogramas em grade, um por componente.

O que dizer

“Esta figura existe para justificar uma decisão metodológica, não para descrever.”

“Cinco das sete têm essa forma: uma barra altíssima no zero e uma cauda longa à direita. Não é uma distribuição com dispersão em torno de um centro — é uma massa de setores adequados mais uma minoria com problema.”

O que apontar

- Aponte só um histograma, o da água. A forma se repete em esgoto e lixo.
- Depois aponte o da razão de moradores, que é o contraste: esse sim tem forma de sino.

Se perguntarem

P: Isso invalida as estatísticas?

R: Não, mas muda quais fazem sentido. A média sozinha engana nessas cinco, e a regra do IQR para outlier deixa de funcionar — é o slide 14.

Slide 13 — Distribuição por região

Tempo sugerido: 2 minutos

O que está na tela

- Figura: boxplots das sete componentes, com as cinco regiões em cada painel.

O que dizer

“A mesma informação da tabela anterior, agora visual. O que a tabela dá em média, o boxplot dá em dispersão.”

“Repare que no Norte as caixas de água e esgoto são largas: não é só que a média é pior, é que a variação interna é maior. Há setores muito adequados e muito inadequados na mesma região.”

O que apontar

- A largura das caixas do Norte comparada com a do Sul, no painel de água.

Slide 14 — Outliers: a regra do IQR não serve para o saneamento

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com quartis, limite superior, número de outliers e uma coluna "IQR serve?".

O que dizer

“Este slide é sobre um método que falha, e sobre por que é importante dizer isso em vez de aplicar mesmo assim.”

“A regra usual de outlier usa o intervalo interquartil. Só que quando a mediana e o primeiro quartil são zero — que é o caso de água, esgoto e lixo — o intervalo interquartil fica minúsculo, e qualquer setor com qualquer inadequação vira atípico.”

“O resultado é que cerca de 20% dos setores são classificados como outlier nessas três variáveis. Vinte por cento não é cauda. É a forma da distribuição sendo confundida com anomalia.”

O que apontar

- A coluna "IQR serve?" — três "não" e quatro "sim".
- Compare a linha da água (20,68% de outliers) com a da razão de moradores (3,49%).

Se perguntarem

P: Então como identificar outlier nessas variáveis?

R: Pelo percentil, que é o que a tabela também traz. Ou não identificar: se 20% dos setores têm inadequação, isso é o fenômeno, não ruído.

Slide 15 — Dados faltantes e o sigilo do IBGE

Tempo sugerido: 3 minutos

O que está na tela

- Figura: mapa de dados faltantes por município.
- Dois parágrafos à direita: a variável que concentra o problema, e o fato de não ser aleatório.

O que dizer

“Seis das sete componentes têm cobertura praticamente total — abaixo de 0,05% de ausentes. O problema está concentrado numa variável só.”

“O analfabetismo tem 15,9% dos setores sem dado: 16.552 no recorte urbano. E a causa é o sigilo do IBGE, que suprime contagens pequenas.”

“A parte importante é que essa supressão não é aleatória. Ela acontece onde há poucos analfabetos — ou seja, nos setores de melhor situação. O próximo slide prova isso.”

O que apontar

- A coluna do analfabetismo no mapa, que destoa de todas as outras.

Slide 16 — O sigilo depende do porte do setor

Tempo sugerido: 3 minutos

O que está na tela

- Tabela do sigilo por faixa de tamanho do setor: de 44,09% a 3,33%.
- Parágrafo abaixo com o intervalo da média verdadeira.

O que dizer

“Esta é a prova de que a supressão não é aleatória, e ela é limpa: 44% de sigilo nos setores menores, caindo monotonicamente até 3,3% nos maiores.”

“E isso permite fazer uma coisa melhor do que declarar a limitação e parar. Como os setores excluídos são os de menor analfabetismo, a média que eu observo é um teto, não uma estimativa central. E como o IBGE reporta os zeros — mais de nove mil setores declaram zero analfabetos —, o valor suprimido é necessariamente maior ou igual a um. Isso fecha o intervalo pelos dois lados.”

“A média verdadeira da amostra está entre 3,14% e 3,64%. Meio ponto percentual de largura.”

Números que sustentam a fala

- Setores sem o dado: renda mediana de R\$ 6.092,84. Setores com o dado: R\$ 2.313,89.
- População preta, parda ou indígena: 30,8% nos sem dado, 60,6% nos com dado.

Se perguntarem

P: Por que não imputar?

R: Preencher com zero achataria o analfabetismo justamente nas áreas menos vulneráveis, comprimindo o gradiente. Imputar pela mediana do município transferiria aos setores ricos o perfil dos pobres — erra na direção oposta. As duas trocam uma ausência honesta por um número inventado.

Slide 17 — Divisor — A estrutura de associação

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 4.

O que dizer

“Como as variáveis se relacionam entre si.”

Slide 18 — Matriz de correlação com dez variáveis

Tempo sugerido: 4 minutos

O que está na tela

- Figura: dois mapas de calor lado a lado, Pearson e Spearman, 10×10 .
- Uma linha preta separa as 7 componentes do IVS das 3 descritivas.

O que dizer

“Esta é a matriz que a senhora pediu ampliada. As três variáveis novas — idosos de 60 anos ou mais, menores de cinco anos e chefia feminina — estão abaixo e à direita da linha preta.”

“A linha está ali de propósito: sem ela, o mapa sugere que as dez são componentes do índice, e não são. As três são descritivas.”

“Duas leituras. Primeira: o bloco socioeconômico. Renda, cor/raça e analfabetismo se correlacionam entre si a menos 0,81, menos 0,76 e mais 0,63. Isso significa que se eu der peso igual às sete, três delas votam na mesma dimensão — e isso não seria uma escolha, seria um acidente.”

“Segunda: compare o Pearson com o Spearman na linha da renda. A diferença é grande, e a causa é a assimetria. Com a renda em log, o Pearson praticamente alcança o Spearman.”

O que apontar

- O quadrado escuro de renda $\times$ cor/raça, no canto do bloco socioeconômico.
- A linha preta divisória.
- A última linha, de chefia feminina: quase toda clara — é o próximo slide.

Se perguntarem

P: Por que Pearson e Spearman?

R: Pearson mede associação linear; Spearman, monotônica. Onde os dois discordam, é a assimetria falando. É o caso da renda.

Slide 19 — O que a matriz decidiu

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com as três descritivas, a maior correlação de cada uma e a média absoluta.
- Dois parágrafos: chefia feminina como candidata, idosos e crianças como espelhos.

O que dizer

“A pergunta que justifica ampliar a matriz não é “quanto elas se correlacionam”. É “alguma delas merece entrar no índice?”.”

“Chefia feminina tem média de correlação absoluta de 0,133 com as sete componentes. É baixa. Isso quer dizer que ela mede algo que nenhuma variável do índice captura — e é exatamente esse o argumento para promovê-la.”

“As outras duas correlacionam três vezes mais com o que já está lá. E entre si estão a menos 0,722: são os dois lados da mesma estrutura etária. Colocar as duas seria contar a mesma coisa duas vezes.”

Se perguntarem

P: Você recomenda incluir chefia feminina no índice?

R: Recomendo levar a decisão a sério, porque a evidência sustenta. Mas é decisão de metodologia, e o IVS-BH original não a tem — então é a senhora quem decide se vale afastar-se da fonte.

Slide 20 — Divisor — A renda sob auditoria

Tempo sugerido: 10 segundos

O que está na tela

- Página de seção 5.

O que dizer

“Esta é a seção mais longa. Cinco das demandas de agosto convergem aqui.”

Slide 21 — O caso que abriu o assunto

Tempo sugerido: 3 minutos

O que está na tela

- Ficha do setor: código, valor em destaque, identificação.
- Anotação circulada à mão sobre o valor.
- Dois parágrafos à direita.

O que dizer

“A senhora pediu para excluir a observação de 170 mil. Eu fui ver qual era.”

“É um setor de Belo Horizonte, no bairro Senhor dos Passos. E o campo CD_TIPO dele é 1, que no Censo significa Favela e Comunidade Urbana.”

“São 186 domicílios. A 170 mil reais de renda média por responsável, isso daria 31,7 milhões de reais circulando por mês numa favela de 186 casas. O perfil do setor não sustenta esse valor.”

“E o próprio arquivo do IBGE ajuda a dizer o que aconteceu. Ele traz o V06005, que é a variância do rendimento no setor. O coeficiente de variação aqui é 5,26, contra uma mediana nacional de 0,78. Se fosse só uma vírgula fora do lugar na média, esse coeficiente seria da ordem de 526. Então não é erro de digitação: a média está sendo puxada por uma ou poucas declarações enormes.”

O que apontar

- O CD_TIPO = 1, em vermelho: é o que torna o valor incompatível com o resto do perfil.
- A anotação circulada: o coeficiente de variação de 5,26 contra 0,78.

Se perguntarem

P: Você comunicou isso ao IBGE?

R: Não. É uma possibilidade — a tabela com os 66 casos está pronta e teria valor como retorno. Mas é decisão de vocês.

Slide 22 — Como separamos erro de dado de renda alta de verdade

Tempo sugerido: 4 minutos

O que está na tela

- Dois parágrafos com as decisões de método; tabela com as três classes.

O que dizer

“A senhora pediu para rastrear todos. Para isso eu precisei de um critério, e ele tem duas decisões dentro.”

“A primeira: a detecção é por município, não global. O índice é intraurbano, então 20 mil reais é comum em São Paulo e anômalo em Autazes. Um corte nacional mede a distância entre cidades, que não é o objeto.”

“A segunda, que é a que faz o método funcionar: o que levanta suspeita não é o valor, é a incoerência. Um setor no topo da renda do próprio município que também é favela, ou tem analfabetismo acima da mediana local, é internamente contraditório.”

“O resultado: 66 setores suspeitos e 3.292 extremos coerentes. E aqui eu preciso ser honesto sobre o que essa tabela mostra e o que ela não mostra: ser favela é um dos testes de incoerência, então nenhuma favela pode cair em EXTREMO por construção. A coluna da direita repete a regra, ela não a valida.”

O que apontar

- A coluna "São favela?" — 22 de 66 contra 0 de 3.292. Diga que esse contraste é consequência da regra, não evidência a favor dela.

Se perguntarem

P: Por que não excluir os 3.292 também?

R: Porque renda alta de verdade é informação, não ruído. Removê-la achataria a desigualdade que o índice existe para medir.

P: O critério não é arbitrário?

R: A escolha do limiar é, como toda escolha de limiar. O critério está escrito, versionado e coberto por testes. Duas fraquezas conhecidas: 40 dos 66 suspeitos são flagrados só por ter analfabetismo

acima da mediana do município, que é evento de metade por construção; e a regra é cega a erro de dado em bairro rico. O setor de São Paulo com 140 mil reais, 45 vezes a mediana da cidade, sai como EXTREMO porque o entorno sustenta renda alta. Por isso acrescentei a coluna `razao_implausivel`, que marca 13 desses casos.

Slide 23 — As duas análises exploratórias, lado a lado

Tempo sugerido: 4 minutos

O que está na tela

- Tabela do antes e depois em seis métricas.
- Dois parágrafos: excluir muda pouco, transformar muda muito.

O que dizer

“A senhora pediu as duas EDAs. Aqui estão, e o resultado contraria o que eu esperava.”

“Tirar os 66 suspeitos quase não muda a estatística. A média cai 0,21%, a mediana 0,05%. As correlações se movem no máximo 0,010, e o Spearman fica praticamente imóvel.”

“Mas passar a renda para logaritmo muda dez vezes mais. A correlação com analfabetismo vai de menos 0,42 para menos 0,59; com cor e raça, de menos 0,68 para menos 0,81.”

“A conclusão prática é que o problema da renda está na assimetria, e não no outlier. E isso importa diretamente para a análise fatorial, que roda sobre a matriz de Pearson: com a renda bruta, a carga dela sairia subestimada.”

Se perguntarem

P: Então não vale excluir?

R: Vale, mas por outro motivo — é o próximo slide.

Slide 24 — Onde a exclusão importa de verdade: a escala

Tempo sugerido: 4 minutos

O que está na tela

- Tabela com cinco municípios e o percentual de setores comprimidos no primeiro decil.
- Bloco de destaque sobre Autazes.

O que dizer

“O argumento para excluir está na normalização, que é o insumo do índice, e não na média nem na correlação.”

“Autazes tem 43 setores. Um valor ruim, e 81% da cidade colapsa no primeiro decil da escala de renda. Sem ele, cai para 14%. Sessenta e sete pontos percentuais de diferença.”

“Em Belo Horizonte são 98,8% dos setores espremidos no primeiro decil, com dois valores ruins numa cidade de cinco mil setores.” “E aqui vale dizer o que a tabela não resolve. Mesmo tirando os suspeitos, Belo Horizonte fica com 70,8% dos setores no primeiro decil, e Belém com 69,6%. O que quebra a escala não são os 66 valores: é aplicar min-max a uma variável com assimetria 3,74. Trocar a normalização global pela municipal reduz o problema e não o resolve. Transformar a variável, em log ou em posto, é a decisão que ainda está aberta.”

“Ou seja: mantido o outlier, a renda deixa de discriminar dentro da cidade — que é exatamente o que o índice precisa que ela faça. Vinte e três dos 63 municípios avaliados têm ao menos um suspeito.”

O que apontar

- A linha de Autazes, e a coluna "Ganho": 67,1 pontos percentuais.

Se perguntarem

P: Qual sua recomendação, então?

R: Que os 66 saiam do cálculo do índice e fiquem na EDA como achado de qualidade do dado. As duas versões continuam publicadas, então a decisão é defensável nos dois sentidos.

Slide 25 — Renda alta está mesmo nos setores pequenos?

Tempo sugerido: 3 minutos

O que está na tela

- Figura com dois painéis: dispersão renda × tamanho, e barras da taxa de suspeita por faixa.

O que dizer

“Esta era a demanda 2, e a resposta é sim e não — a distinção importa.”

“O painel da esquerda mostra que o valor não depende do tamanho. A correlação entre número de domicílios e renda é menos 0,031, ou seja, nula. O maior valor da base está num setor de 186 domicílios, que é o tamanho mediano.”

“Mas o painel da direita mostra outra coisa. A taxa de suspeita é 0,265% nos setores de até 50 domicílios contra 0,045% nos de 201 a 400. Seis vezes mais.”

“Então o mecanismo que a senhora descreveu existe e está medido: média de poucos domicílios oscila mais. Só não é ele que produz o maior valor.”

O que apontar

- A linha tracejada vertical no painel esquerdo: o corte de 50 domicílios.
- A escada descendente do painel direito — é a resposta da demanda.

Slide 26 — Sudeste e Norte: dois fenômenos com o mesmo rótulo

Tempo sugerido: 3 minutos

O que está na tela

- Tabela das cinco regiões com mediana, razão máximo/mediana, assimetria, extremos e suspeitos.

O que dizer

“A senhora pediu para olhar Sudeste e Norte. São coisas diferentes com o mesmo nome.”

“O Sudeste tem o extremo absoluto: 62 vezes a mediana da própria região. Mas a taxa de suspeita é baixa, 0,044%.”

“O Norte tem 26 vezes a taxa de suspeita do Sul. Não por ter mais rico — a mediana dele é a segunda mais baixa. É porque a distribuição é tão comprimida na base que qualquer setor de classe média já destoa. A assimetria de lá é 6,15, a maior do país.”

Números que sustentam a fala

- Um achado que não estava na pauta: o critério global inverte esse retrato. Ele marca 4,61% do Sudeste e só 1,32% do Norte, porque mede "este setor é rico para o Brasil", e não "é anômalo na própria cidade". Dos cerca de 4.000 setores marcados pelos dois critérios, apenas 1.673 coincidem.

Slide 27 — A distribuição da renda em cada uma das 70 cidades

Tempo sugerido: 3 minutos

O que está na tela

- Figura alta: boxplots das 70 cidades, em cinco painéis por região.
- Três parágrafos à esquerda explicando as escolhas de construção.

O que dizer

"Esta é a demanda 3. Setenta cidades num boxplot único é ilegível, então são painéis por região, com as cidades ordenadas pela mediana."

"O eixo é logarítmico. Com assimetria de 3,74, em escala linear sessenta das setenta caixas colapsam contra a margem esquerda e não se distingue nada."

"Os pontos vermelhos são os 66 suspeitos, cidade a cidade. Belo Horizonte, Belém e Salvador concentram os casos mais graves."

O que apontar

- O ponto vermelho isolado bem à direita, no painel do Sudeste: é Belo Horizonte.
- O painel do Sul, para contraste: caixas curtas e quase sem pontos vermelhos.

Se perguntarem

P: Dá para ver essa figura em tamanho maior?

R: Sim, ela está em `banco_de_dados/eda/figuras/`, em resolução cheia.

Slide 28 — Divisor — Os blocos descritivos

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 6.

O que dizer

"Agora tudo que ficou de fora dos decks anteriores."

Slide 29 — Os blocos descritivos, região a região

Tempo sugerido: 4 minutos

O que está na tela

- Tabela com sete indicadores descritivos por região.
- Três parágrafos abaixo.

O que dizer

“Estes são os blocos que caíram da apresentação anterior, e aqui estão todos na mesma tabela e no mesmo recorte — que é a parte que a versão anterior não garantia.”

“Habitação precária concentra-se no Centro-Oeste e no Sudeste. Isso é contraintuitivo e é um achado: precariedade habitacional é metropolitana, não rural do Norte. Saneamento e banheiro seguem o gradiente Norte-Sul; habitação improvisada não segue.”

“Chefia feminina é maioria: 52,81% no recorte urbano, com pico no Nordeste, em 55,4%.”

O que apontar

- A linha de habitação precária: Centro-Oeste com o maior valor, Sul com o menor.
- O contraste com a linha de banheiro logo abaixo, que tem o padrão oposto.

Se perguntarem

P: Por que esses indicadores não entram no índice?

R: Porque o IVS-BH tem sete componentes definidas, e estes são descritivos. Promovê-los é decisão metodológica — e a matriz de correlação do slide 19 é o insumo dessa decisão.

Slide 30 — Chefia feminina e envelhecimento

Tempo sugerido: 3 minutos

O que está na tela

- Tabela do envelhecimento por região; quatro números em destaque abaixo.
- Parágrafo em vermelho sobre a correção do IEP.

O que dizer

“O índice de envelhecimento da amostra é 92,7, com razão de dependência de idosos de 25,5.”

“Este número passou por uma correção que vale explicar. Antes ele dava 299, porque o denominador usava só a faixa de zero a quatro anos. O correto, seguindo Galvão e colaboradores, é usar todos os menores de quinze. Corrigido, dá 92,7.”

“Por região o contraste é grande: 56 no Norte contra 112 no Sul. O Sul já tem mais idosos que crianças.”

O que apontar

- A linha do IEP: a escada de 56 no Norte a 112 no Sul.
- O parágrafo em vermelho — é uma correção assumida, não um dado.

Slide 31 — Tipo de espécie do domicílio

Tempo sugerido: 2 minutos

O que está na tela

- Tabela com os onze tipos de espécie e a distribuição por região.

O que dizer

“Esta é a morfologia urbana: o que não é casa. Repare que o percentual aqui é sobre domicílios, não sobre setores — é outra unidade.”

“Apartamento vai de 15,7% no Norte a 36,9% no Sul. Cortiço e casa de cômodos, que é o tipo mais associado a precariedade, concentra-se no Centro-Oeste.”

O que apontar

- A linha do apartamento, que é o indicador que a senhora pediu em julho.
- A linha da maloca indígena, toda zerada: no recorte urbano dos 70 municípios não há.

Slide 32 — Canalização da água

Tempo sugerido: 4 minutos

O que está na tela

- Tabela por região com as três categorias, o total sem canalização e a coluna "suprimido".
- Dois parágrafos abaixo.

O que dizer

“Esta é a demanda 10. E o achado principal é que estas variáveis medem coisa diferente do que o índice já tem.”

“O indicador de água que está no IVS usa V00112 a V00118, que é a fonte da água: poço, nascente, carro-pipa, rio. As três variáveis novas medem a entrega: se a água chega encanada dentro do domicílio, só até o terreno, ou não chega. Um domicílio ligado à rede geral pode receber água só no terreno. O Spearman entre os dois eixos é 0,459: medem coisas próximas, mas não a mesma coisa.”

“O Norte tem 3,73% dos domicílios sem canalização contra 0,33% do Sul. Onze vezes.”

“E as três variáveis formam uma partição de V00001. Isso virou auditoria automática: elas somam exatamente o total de domicílios em 100% dos 81 mil setores em que as três estão presentes.”

O que apontar

- A coluna "Suprimido" — é a parcela que o sigilo tira das duas categorias pequenas. Ela está publicada em vez de escondida, e é o assunto do próximo slide.

Se perguntarem

P: Isso deveria entrar no índice?

R: Como componente, discrimina pouco: só 5% dos setores têm algum domicílio sem canalização. Como descritivo de contraste regional, funciona bem.

Slide 33 — O truque que salvou 21,9% dos setores

Tempo sugerido: 3 minutos

O que está na tela

- Duas colunas comparando as fórmulas, com 21,9% em vermelho e 0,04% em preto.
- Parágrafo de ressalva abaixo.

O que dizer

“Este slide é sobre uma decisão técnica que vale uma explicação.”

“A fórmula literal do que a senhora pediu é V00200 mais V00201 sobre o total. Só que essas duas são contagens pequenas — e contagem pequena é exatamente o que o IBGE suprime. Exigindo as duas, 21,9% dos setores ficam sem valor.”

“Como a trinca soma o total, dá para calcular a mesma coisa por um menos V00199 sobre o total. E V00199 é contagem grande, quase nunca sigilada: o ausente cai para 0,04%.”

“Mas há uma ressalva, e ela precisa constar do artigo: a identidade só é verificável onde as três estão presentes. Nos setores com sigilo, aplicá-la é extrapolação — justificada porque a partição é definida pelo IBGE, mas é suposição, não medição.”

Se perguntarem

P: Isso não é assumir demais?

R: É assumir algo, e por isso está declarado. A alternativa é perder um em cada cinco setores, de forma não aleatória. Escolhi a suposição declarada em vez da perda silenciosa.

Slide 34 — Cobertura integral de saneamento

Tempo sugerido: 2 minutos

O que está na tela

- Tabela por região; quatro números em destaque.

O que dizer

“Aqui a leitura é otimista: quantos setores têm cobertura integral, ou seja, nenhum domicílio na condição inadequada.”

“Água: 72,9%. Esgoto: 71,4%. Lixo: 61,7%. Mas os três juntos, só 41,6%.”

“Atenção ao recorte deste slide: ele é o que inclui os rurais, 106.281 setores. Está impresso embaixo da tabela.”

Números que sustentam a fala

- Contando a caçamba de serviço de limpeza como coleta, o lixo sobe de 61,7% para 91,5%. Essa diferença é o efeito de uma decisão metodológica — a caçamba é contada como inadequada por fidelidade ao IVS-BH 2012, e essa decisão está em revisão.

Slide 35 — Gravidade do saneamento em faixas

Tempo sugerido: 2 minutos

O que está na tela

- Tabela com três serviços em duas faixas cada, por região.

O que dizer

“Não basta saber quantos setores têm inadequação: importa quanto.”

“No Norte, 30,8% dos setores têm metade ou mais dos domicílios com água inadequada — contra 11,8% em situação totalmente adequada. No Sul e no Centro-Oeste a distribuição se inverte por completo.”

O que apontar

- As duas linhas da água: a de 0% e a de 50% ou mais, no Norte. Elas se cruzam em relação ao resto do país.

Slide 36 — Divisor — Favelas e Comunidades Urbanas

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 7.

O que dizer

“A demanda 5, e o que ela revelou.”

Slide 37 — A fonte oficial e a validação do critério

Tempo sugerido: 4 minutos

O que está na tela

- Dois parágrafos, tabela de representatividade e um bloco de limitação em vermelho.

O que dizer

“A senhora pediu para conferir um relatório do IBGE sobre favelas. Achei a publicação oficial de 2024, 171 páginas, e a definição com os quatro critérios está transcrita no relatório da EDA.”

“Mas o mais útil foi a planilha anexa, que lista as favelas por setor censitário. Com ela eu validei nosso critério: dos 109 mil setores da base completa, 19.507 estão na lista oficial — e são exatamente os 19.507 que o nosso código marca. Zero falso positivo, zero omissão. No recorte de análise são 19.452, que dão 18,7% dos 104.108.”

“A tabela mostra outra coisa que vale para o artigo: os 70 municípios do ELSI reúnem 61,4% de toda a população favelada do Brasil, sendo apenas 6,4% dos municípios que têm favela.”

“E a fonte revelou uma limitação que eu não conhecia. Na nota de rodapé da página 75, o IBGE diz que identificou 2.298 favelas com 21 a 50 domicílios que não receberam setor censitário próprio. Como nosso critério depende do setor, essas favelas são invisíveis na nossa base.”

O que apontar

- A linha da população em FCU: 61,4%. É um argumento de representatividade forte.
- O bloco em vermelho: a limitação das favelas pequenas.

Se perguntarem

P: Isso invalida a comparação favela × cidade?

R: Não invalida, mas enviesada nos dois sentidos: subestima a população favelada e contamina o grupo de comparação com ela. Está declarado nas limitações.

Slide 38 — Favela e restante da cidade, indicador a indicador

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com médias e medianas dentro e fora de favela, e a razão entre elas.

O que dizer

“A comparação direta. A última coluna é quantas vezes o valor médio no setor de favela supera o de fora.”

“Esgoto inadequado: 4,1 vezes. Lixo: 2,9. Água: 1,8.”

“Mas repare na razão de moradores: 1,11. Quase igual. Isso é coerente e vale dizer — adensamento domiciliar não é o eixo que separa favela do resto da cidade. O que separa é infraestrutura.”

O que apontar

- A coluna da razão: a escada do esgoto até a razão de moradores.

Slide 39 — A amostra ELSI comparada com o Brasil urbano

Tempo sugerido: 3 minutos

O que está na tela

- Tabela dos sete indicadores em Brasil urbano e ELSI-70, com a razão.
- Anotação circulada à mão na razão do lixo.

O que dizer

“Esta é a linha de base nacional: os mesmos indicadores calculados sobre os 468 mil setores do país inteiro.”

“Em seis dos sete, a amostra ELSI está melhor que o Brasil urbano. O esgoto é o contraste mais forte: 0,080 contra 0,155, quase metade.”

“A exceção é o lixo, e ela é diagnóstica. É a única variável em que estamos piores, razão de 1,21. Isso reforça a hipótese que apareceu no slide 11: o indicador de lixo pode estar medindo porte urbano em vez de vulnerabilidade, porque a caçamba de serviço de limpeza é mais comum em cidade grande.”

O que apontar

- A anotação circulada na razão 1,21 — é a única acima de 1.

Números que sustentam a fala

- A população nacional calculada pela nossa pipeline confere com o número oficial do Censo 2022: 203.080.756 pessoas. É a prova de que o cálculo nacional está correto.

Slide 40 — Divisor — Limitações e processo

Tempo sugerido: 5 segundos

O que está na tela

- Página de seção 8.

O que dizer

“Para fechar: o que não podemos afirmar, e o que vem agora.”

Slide 41 — O sigilo do analfabetismo — limitação aceita

Tempo sugerido: 2 minutos

O que está na tela

- Dois parágrafos e três números em destaque.

O que dizer

“A senhora decidiu aceitar esta limitação. Eu aceitei, mas quantifiquei — porque aceitar não é deixar sem número.”

“Já mostrei os detalhes no slide 16. O resumo: 16.552 setores sem o dado, e a média verdadeira entre 3,14% e 3,64%.”

Se perguntarem

P: Isso vai no artigo?

R: Sim, com essa mesma quantificação. Está escrito na seção 14.1 do relatório.

Slide 42 — As limitações da análise exploratória

Tempo sugerido: 3 minutos

O que está na tela

- Seis parágrafos, quatro em vermelho.

O que dizer

“Estas são as limitações que já estão escritas. As quatro primeiras são as que mais pesam.”

“A falácia ecológica é a mais importante e a mais fácil de esquecer: tudo aqui é agregado por setor. Nada nesta apresentação autoriza inferência sobre indivíduos.”

“As outras três eu já expliquei: o sigilo do analfabetismo, as favelas pequenas invisíveis, e os municípios que ficam com poucos setores depois do filtro urbano.”

“E a última: a EDA é descritiva. Nenhum teste de hipótese foi feito, e as correlações são exploratórias.”

Se perguntarem

P: Falta alguma limitação?

R: Faltam duas do roteiro de Lima-Costa e Barreto que ainda não redigi: viés de sobrevivência e a situação dos institucionalizados. Estão na fila.

Slide 43 — As correções desta rodada

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com seis correções, a forma como foram encontradas e o que se fez.

O que dizer

“Prefiro mostrar os erros a escondê-los, porque a forma como eles foram encontrados é o argumento de confiabilidade.”

“A primeira linha: eu tinha uma tabela regional de água que somava duas parcelas sigilosas, e o resultado dava 99,7% onde deveria dar 100%. Quem pegou foi um teste automatizado — não eu relendo o código. É exatamente o erro que a seção da água existe para alertar, e eu o cometi na agregação.”

“A segunda linha é sobre esta apresentação. A primeira versão dela tinha números digitados à mão, e três vieram do recorte errado. Agora o gerador lê as tabelas na hora de gerar.”

O que apontar

- A coluna do meio, "Como foi pego" — quatro das seis por teste ou conferência sistemática.

Se perguntarem

P: Quantos erros ainda devem existir?

R: Não sei, e é honesto dizer isso. O que posso dizer é que os testes cobrem as fórmulas e as contagens dos artefatos, e que a documentação foi varrida atrás de afirmações obsoletas.

Slide 44 — As demandas de agosto, uma a uma

Tempo sugerido: 3 minutos

O que está na tela

- Tabela com as onze demandas, onde cada entrega está e a situação.

O que dizer

“Dez cumpridas e uma planejada.”

“A que ficou planejada é a análise fatorial. O plano está pronto — transformar a renda, decidir o que fazer com os 16 mil setores sem analfabetismo, KMO, Bartlett, número de fatores, rotação varimax. Não executei porque a decisão de método precede a execução.”

Slide 45 — Por que estes números são confiáveis

Tempo sugerido: 2 minutos

O que está na tela

- Quatro números em destaque e quatro parágrafos de método.

O que dizer

“Se houver uma coisa para levar desta apresentação além dos resultados, é esta.”

“São 63 testes automatizados, todos passando. Eles não conferem só as fórmulas: leem os arquivos gerados e verificam contagens exatas.”

“E quando eu refatorei o Notebook 01 para ler as variáveis do módulo, comparei a base nova com a anterior antes de aceitar: 67 colunas em comum, zero diferenças, mesmos 109.032 setores. A refatoração foi provada neutra no dado, não no argumento.”

Slide 46 — A decisão dos pesos do índice

Tempo sugerido: 4 minutos

O que está na tela

- Veredito em destaque, três parágrafos de sustentação e dois de ressalva.

O que dizer

“Esta é a decisão em aberto mais importante, e eu a submeti a uma análise adversarial com cinco perspectivas independentes e revisão cega entre elas.”

“O veredito foi adotar 60/40 da literatura e tratar o peso como análise de sensibilidade, não como decisão central. Três razões. Primeira: com renda, cor/raça e analfabetismo colineares a 0,8, qualquer esquema razoável produz quase o mesmo ranking. Segunda: a fatorial não decide o que fazer com o lixo, ela esconde a decisão — com correlações de 0,10 a 0,20 ele carrega sozinho, e a escolha volta a ser manual. Terceira: o custo de errar é assimétrico.”

“Mas a parte mais valiosa foi o ponto cego, que só apareceu na revisão: a normalização por município mexe mais no ranking do que qualquer peso, e ninguém testou isso ainda.”

“E registro que a decisão é da senhora. O que eu trago é o que a evidência sustenta.”

Se perguntarem

P: O que exatamente é essa análise adversarial?

R: Cinco análises independentes da mesma questão, cada uma com um ângulo diferente, depois revisadas às cegas umas pelas outras. As cinco revisões escolheram a mesma resposta como a mais forte.

Slide 47 — O que vem agora

Tempo sugerido: 2 minutos

O que está na tela

- Cinco itens numerados.

O que dizer

“Cinco frentes. A primeira é a normalização por município, que o conselho apontou como dominante sobre a escolha dos pesos — e é mais barata que a fatorial.”

“A segunda fecha a questão dos pesos com uma tabela: calcular o índice com três esquemas e reportar a correlação entre os rankings.”

“A terceira é a fatorial, quando a senhora decidir.”

“A quarta são os estudos de renda que propus, e a quinta é terminar a redação das limitações.”

“Fico à disposição.”

Anexo A — As perguntas difíceis

Perguntas que não estão presas a um slide, e que podem vir a qualquer momento.

P: Como sei que os números estão certos?

R: Três camadas. Os 63 testes automatizados conferem as fórmulas contra dados sintéticos calculáveis na mão e as contagens dos arquivos gerados. Os números desta apresentação são lidos das tabelas na hora de gerar o arquivo, não digitados. E o cálculo nacional reproduz a população oficial do Censo: 203.080.756.

P: Por que dois recortes diferentes na mesma apresentação?

R: Porque algumas tabelas foram geradas antes do filtro urbano de julho e sustentam números já apresentados. Regerá-las no recorte novo mudaria os slides antigos. Cada tabela traz o recorte impresso embaixo, então a comparação nunca é feita às cegas.

P: Esse índice já pode ser usado por uma prefeitura?

R: Ainda não. Falta a normalização, os pesos e o cálculo final. O que existe hoje é a base analítica e a EDA que a sustenta.

P: Quanto disso é comparável com o IVS-BH 2012?

R: A estrutura é a mesma, mas três componentes foram substituídas por proxies porque não existem nos agregados por setor do Censo 2022. E o Censo 2022 redesenhou setores, o que limita comparação territorial direta com 2010.

P: Por que o lixo se comporta de forma estranha em toda a apresentação?

R: Porque a caçamba de serviço de limpeza é contada como destino inadequado, por fidelidade ao IVS-BH 2012. Há indício de que isso faz o indicador medir porte urbano: é a única variável em que estamos piores que o Brasil urbano. A decisão está registrada como em revisão.

P: Você usou inteligência artificial nisso?

R: Usei como ferramenta de trabalho, com verificação. Toda fórmula está em código versionado, toda tabela tem script que a gera, e o conjunto é coberto por 63 testes. Os erros que encontrei estão listados no slide 43, inclusive os meus.

Anexo B — O que NÃO afirmar

Frases que a base não sustenta, e que é fácil deixar escapar.

Não dizer: "Os setores mais vulneráveis têm mais idosos analfabetos."

Dizer: Falácia ecológica. Os dados são agregados por setor; não há informação sobre indivíduos.

Não dizer: "A favelização cresceu entre 2010 e 2022."

Dizer: O próprio IBGE restringe essa comparação. No estudo de área constante que eles fizeram, a população caiu 5,4%. O aumento no número de favelas vem em boa parte de melhoria no mapeamento.

Não dizer: "O analfabetismo na amostra é 3,64%."

Dizer: Esse é o teto. Diga "entre 3,14% e 3,64%", ou diga "3,64% entre os setores com o dado".

Não dizer: "X% dos setores são favela e vivem pior."

Dizer: A comparação é válida, mas as favelas pequenas não estão na base. Diga que a comparação é conservadora nos dois sentidos.

Não dizer: "O índice mostra que a região Norte é a mais vulnerável."

Dizer: O índice ainda não foi calculado. O que existe são as componentes, e o gradiente aparece em seis das sete.

Anexo C — Onde está cada dado

Slides	Arquivo
10, 11, 14	banco_de_dados/eda/descritivas_globais.csv · descritivas_por_regiao.csv · outliers.csv
12, 13, 15, 18	banco_de_dados/eda/figuras/ — histogramas, boxplots_por_regiao, missing_por_municipio, matriz_correlacao
16	banco_de_dados/eda/auditoria_analfabetismo_v00900_bins.csv
21–27	banco_de_dados/eda/renda_*.csv — oito tabelas, geradas por scripts/auditoria_renda.py
29–31	habitacao_precaria_* · inadequacao_banheiro_* · resp_feminino_* · tipo_domicilio_* · morfologia_*
32, 33	banco_de_dados/eda/agua_canalizada_*.csv
34, 35	cobertura_*.csv · saneamento_categorias_por_regiao.csv
37, 38	favelas_fcu_*.csv · dados/FavelasComunidadesUrbanas2022Setores_20250417.xlsx · docs/IBGE_Censo2022_Favelas_e_Comunidades_Urbanas.pdf
39	banco_de_dados/nacional/comparativo_brasil_vs_elsi.csv
41, 42	docs/Relatorio_EDA_Fase3_IVS_ELSI.md, seções 14, 14.1 e 14.2

Todos os números desta apresentação são extraídos por scripts/eda_central_dados.py, que lê as tabelas acima e grava banco_de_dados/eda/dados_deck.json. O gerador do deck apenas formata.

Anexo — A fonte do IBGE, transcrita, com orientação de uso

IBGE. Censo Demográfico 2022: Favelas e Comunidades Urbanas — Resultados do universo. Rio de Janeiro: IBGE, 2024. 171 p. O arquivo está em Projeto_IVS_Censo22/docs/IBGE_Censo2022_Favelas_e_Comunidades_Urbanas.pdf.

Estão transcritas aqui as passagens das páginas 46, 47, 73, 74 e 75 que sustentam alguma afirmação da apresentação. Cada uma vem seguida da orientação de quando e como usá-la. As transcrições são literais: se for citar no artigo, copie daqui.

Atenção à numeração das páginas. A página impressa no rodapé é a que se cita, e ela fica três à frente do número de página do leitor de PDF: impressa 46 = PDF 49. Todas as páginas indicadas abaixo são as impressas.

Página 46 — a mudança de nomenclatura não mudou o conteúdo

Contexto: em 2024 o IBGE trocou "Aglomerados Subnormais" por "Favelas e Comunidades Urbanas" e reescreveu os critérios. Estas duas frases são a garantia de que a série não quebrou.

Transcrição 1

"Cabe reforçar que a mudança de nomenclatura e redação dos critérios não afeta estruturalmente o mapeamento produzido para a pesquisa censitária de 2022, uma vez que não houve alterações efetivas, mas apenas uma mudança na redação dos elementos utilizados como referência."

Como usar. É a sua defesa se perguntarem se a mudança de nome comprometeu a comparação com a literatura anterior, que fala em aglomerado subnormal. A resposta é que o IBGE afirma explicitamente que não houve alteração efetiva de critério. Use no slide 37 e na resposta à pergunta "mudou alguma coisa em relação ao Aglomerado Subnormal?". Não use para dizer que os NÚMEROS de 2010 e 2022 são comparáveis: isso é outra coisa, e a própria publicação diz que não são. Ver página 73.

Transcrição 2

"Como dito, as mudanças dizem respeito à forma como o IBGE se refere a esses territórios e seus habitantes em seus materiais e em suas bases de divulgação, evitando estigmatizações e homogeneizações que possam afetá-los negativamente. O conteúdo essencial dos critérios utilizados para identificação e classificação dos então chamados Aglomerados Subnormais foi mantido."

Como usar. A segunda frase é a mais forte das duas e é a que vale citar no artigo, porque diz diretamente que o conteúdo do critério foi mantido. A primeira frase serve para explicar a MOTIVAÇÃO da mudança, que é evitar estigmatização. Se a conversa derivar para a escolha do termo "favela" no seu texto, é esta frase que justifica você seguir a nomenclatura oficial do IBGE em vez de inventar uma sua.

Páginas 46 e 47 — a definição oficial

A definição vem entre aspas na publicação, em quatro parágrafos. Começa na página 46 e termina na 47. Transcrita na íntegra abaixo.

Parágrafo 1 — a definição propriamente dita

"As Favelas e Comunidades Urbanas são territórios populares originados das diversas estratégias utilizadas pela população para atender, geralmente de forma autônoma e coletiva, às suas necessidades de moradia e usos associados (comércio, serviços, lazer, cultura, entre outros), diante da insuficiência e inadequação das políticas públicas e investimentos privados dirigidos à garantia do direito à cidade."

Como usar. É esta que você cita se pedirem a definição. Decore a espinha dela, não a frase inteira: território popular, originado de estratégia autônoma e coletiva da população, diante da insuficiência de política pública e investimento privado. Repare que a definição é sobre ORIGEM e PROCESSO, não sobre carência material — isso importa, porque a carência aparece só nos critérios operacionais da página 47. Se alguém disser que favela "é onde falta saneamento", esta frase mostra que a definição oficial é outra.

Parágrafo 2 — identidade comunitária

"Em muitos casos, devido à sua origem compartilhada, relações de vizinhança, engajamento comunitário e intenso uso de espaços comuns, constituem identidade e representação comunitária."

Como usar. Não use na apresentação. Está aqui para você saber que existe, porque é o parágrafo que justifica a palavra "Comunidades" no nome novo. Serve se a conversa for sobre nomenclatura, não sobre o índice.

Parágrafo 3 — os muitos nomes

"No Brasil, esses espaços se manifestam em diferentes formas e nomenclaturas, como favelas, ocupações, comunidades, quebradas, grotas, baixadas, alagados, vilas, ressacas, mocambos, palafitas, loteamentos"

informais, vilas de malocas, entre outros, expressando diferenças geográficas, históricas e culturais na sua formação."

Como usar. Este é o parágrafo que responde à demanda de julho, que foi formulada como "vilas e favelas". Ele mostra que vila e favela são dois dos muitos nomes de uma mesma categoria oficial, e que a sua marcação CD_TIPO = 1 cobre as duas. Se a orientadora perguntar por que você não separou vila de favela, a resposta é que o Censo não separa: são a mesma categoria.

Parágrafo 4 — vulnerabilidade e insegurança da posse

"Favelas e Comunidades Urbanas expressam a desigualdade socioespacial da urbanização brasileira. Retratam a incompletude - no limite, a precariedade - das políticas governamentais e investimentos privados de dotação de infraestrutura urbana, serviços públicos, equipamentos coletivos e proteção ambiental aos sítios onde se localizam, reproduzindo condições de vulnerabilidade. Estas se tornam agravadas com a insegurança jurídica da posse, que também compromete a garantia do direito à moradia e a proteção legal contra despejos forçados e remoções."

Como usar. Este é o parágrafo mais útil para o SEU argumento, e é o menos óbvio. A palavra "vulnerabilidade" aparece na definição oficial de favela do IBGE, ligada a infraestrutura urbana e serviços públicos — que é exatamente o que o seu índice mede. Use para justificar por que faz sentido comparar favela e resto da cidade usando o IVS: não é comparação arbitrária, é a própria definição da categoria que aponta para essas dimensões. Mas veja a ressalva na seção seguinte: é isso mesmo que torna a comparação parcialmente circular.

Página 47 — os quatro critérios de identificação

"Para identificação das Favelas e Comunidades Urbanas o IBGE utiliza os seguintes critérios:"

"i. Predominância de domicílios com graus diferenciados de insegurança jurídica da posse; e, pelo menos, um dos demais critérios abaixo:"

"ii. Ausência ou oferta incompleta e/ou precária de serviços públicos (iluminação elétrica pública e domiciliar, abastecimento de água, esgotamento sanitário, sistemas de drenagem e coleta de lixo regular) por parte das instituições competentes; e/ou"

"iii. Predomínio de edificações, arruamento e infraestrutura que usualmente são autoproduzidos e/ou se orientam por parâmetros urbanísticos e construtivos distintos dos definidos pelos órgãos públicos; e/ou"

"iv. Localização em áreas com restrição à ocupação definidas pela legislação ambiental ou urbanística, tais como faixas de domínio de rodovias e ferrovias, linhas de transmissão de energia e áreas protegidas, entre outras; ou em sítios urbanos caracterizados como áreas de risco ambiental (geológico, geomorfológico, climático, hidrológico e de contaminação)." (IBGE, 2024)

Como usar. A estrutura lógica é o que você precisa saber de cor: o critério i é OBRIGATÓRIO, e basta UM dos outros três. Ou seja, insegurança jurídica da posse mais qualquer uma das três carências. É a pergunta mais provável desta seção, e errar a estrutura lógica é pior do que não saber o texto.

Como usar. A ressalva metodológica que você deve levantar antes que perguntem: os critérios ii e iv são saneamento e risco ambiental, e o critério iii lista exatamente água, esgoto e lixo, que são três das sete componentes do seu índice. Isso significa que a sua comparação favela versus resto da cidade NÃO é validação externa independente — há sobreposição por construção entre o que define a categoria e o que o índice mede. Chame de checagem de coerência, não de validação. Levantar isso você mesmo vira maturidade metodológica; ser pego nisso é constrangedor.

Como usar. Repare também no que o critério i implica: a insegurança da posse é obrigatória e o seu índice não a mede, porque o Censo não publica posse por setor. Então há uma dimensão da definição oficial que o IVS não captura. Vale uma frase nas limitações.

Página 73 — a comparabilidade com 2010

Estas passagens abrem a seção "Considerações sobre a comparabilidade entre o Censo Demográfico 2010 e o Censo Demográfico 2022".

Transcrição 1 — a restrição

"Conforme mencionado na Introdução, as inovações gerenciais, metodológicas e tecnológicas entre os Censos Demográficos 2010 e 2022 implicam em restrições quanto à comparabilidade direta entre as informações coletadas nas Favelas e Comunidades Urbanas nos dois períodos."

Como usar. Use se alguém pedir uma comparação com 2010, em qualquer contexto. A restrição é do próprio IBGE, então você não está sendo conservador por conta própria: está seguindo a orientação da fonte.

Transcrição 2 — os números dos dois censos

"Em 2010, foram identificadas 6 329 Favelas e Comunidades Urbanas, onde residiam 11 425 644 pessoas. Já em 2022, o mapeamento resultou em 12 348 Favelas e Comunidades Urbanas, onde viviam 16 390 815 pessoas."

Como usar. Só cite estes números junto com a transcrição 3, nunca sozinhos. Sozinhos eles sugerem que a favelização dobrou, que é precisamente a leitura errada. Se precisar de um número isolado, use o de 2022.

Transcrição 3 — por que o aumento não é crescimento

"O aumento no número de Favelas e Comunidades Urbanas em 2022 e, conseqüentemente, de população residente nessas áreas, não se deve apenas ao surgimento de novas Favelas e Comunidades Urbanas no País, no período intercensitário. Os aprimoramentos operacionais, como os treinamentos mais específicos sobre a abordagem em Favelas e Comunidades Urbanas e o acompanhamento da coleta por meio dos dados georreferenciados referentes aos pontos de energia elétrica fornecidos pela ANEEL, por exemplo, somados ao engajamento das equipes locais com o tema e às inovações tecnológicas que resultaram na melhoria das imagens orbitais, são fatores que ajudam a explicar as diferenças observadas entre os anos de 2010 e 2022."

Como usar. É a passagem que sustenta a sua decisão de não afirmar nada sobre crescimento da favelização no artigo. O detalhe dos pontos da ANEEL é bom de mencionar em voz alta porque mostra leitura de verdade: o IBGE passou a cruzar coordenadas de ligações elétricas para achar domicílio que a coleta tinha perdido. Boa parte do "aumento" é isso, não gente nova.

Página 74 — o estudo de área constante

Para dar algum resultado comparável, o IBGE isolou os setores de 2010 cuja área inteira virou setor de FCU em 2022, e comparou só esses.

Transcrição — o resultado

"O conjunto de setores analisados corresponde a 77,9% dos setores de Favelas e Comunidades Urbanas de 2010, equivalentes a 46,5% dos setores de Favelas e Comunidades Urbanas de 2022. A análise comparativa mostrou que a população residente na área de estudo em 2010 era 8 793 856, que correspondia a 77,0% da população em Favelas e Comunidades Urbanas daquele ano. Em 2022, a população residente na mesma área investigada era 8 315 088, equivalente a 50,7% da população residente em Favelas e Comunidades Urbanas no mesmo ano. Esse resultado, que não representa a totalidade das áreas de Favelas e Comunidades Urbanas em 2010 e 2022, mostra uma redução de 5,4% no número de moradores em Favelas e Comunidades Urbanas que viviam na área delimitada pelo estudo."

Como usar. Este é o argumento decisivo, e é contraintuitivo: mantida a área constante, a população em favela caiu 5,4%. Guarde os dois números de cobertura, 77,9% e 46,5%, porque eles são a ressalva: o estudo cobre menos da metade dos setores de 2022, então também não

autoriza dizer que a favelização diminuiu. A conclusão correta é que a comparação entre censos não sustenta afirmação em nenhuma das duas direções.

Transcrição — o que ainda falta

"Um entendimento completo da variação da população em áreas de Favelas e Comunidades Urbanas entre 2010 e 2022 requer um estudo aprofundado que identifique as áreas classificadas como Favela e Comunidade Urbana em 2022 que já possuíam características que se enquadravam no conceito em 2010, denominado Aglomerado Subnormal, mas que não foram classificadas dessa maneira."

Como usar. Guarde para a pergunta "isso não daria um estudo?". O próprio IBGE aponta a lacuna e diz que a continuidade depende de recurso. Serve como sugestão de trabalho futuro no artigo, e mostra que você leu além do dado.

Página 75 — o total, e a nota 7

Transcrição — o total oficial, no corpo do texto

"O mapeamento das Favelas e Comunidades Urbanas procedente do Censo Demográfico 2022 resultou na identificação de 12 348 áreas presentes em 656 Municípios brasileiros."

Como usar. É o denominador da sua tabela de representatividade no slide 37. Os seus 5.899 saem de 47,8% deste 12.348, e os 42 municípios saem de 6,4% destes 656.

Transcrição — a nota de rodapé 7, a limitação que mais te afeta

"Como visto, além das 12 348 Favelas e Comunidades Urbanas classificadas em 656 Municípios, para as quais serão fornecidas informações resultantes da coleta do Censo Demográfico 2022, o IBGE identificou 2 298 Favelas e Comunidades Urbanas cujos quantitativos de domicílios, estimados previamente à coleta, variaram entre 21 e 50. Para essas áreas não serão disponibilizadas informações específicas, uma vez que elas não puderam ser definidas em setores censitários específicos de Favelas e Comunidades Urbanas. Esses critérios e procedimentos metodológicos estão descritos na seção Cartografia censitária para Favelas e Comunidades Urbanas."

Como usar. É a citação mais importante do anexo para o seu trabalho, e é a que sustenta o cartão de limitação do slide 37. O raciocínio a dizer em voz alta: como o critério da base é o setor censitário, e essas 2.298 favelas não têm setor próprio, os moradores delas caem em setores comuns. Logo a comparação favela versus cidade erra nos dois sentidos ao mesmo tempo — subestima a população favelada e contamina o grupo de comparação com ela. Diga "nos dois sentidos", porque é o que mostra que você entendeu a consequência e não só copiou a limitação.

Como usar. Cite como "nota 7, p. 75". A mesma informação aparece antes, na nota 3 da página 7, dentro da Apresentação. Se ela abrir o PDF pela introdução e vir a nota 3, as duas estão certas: é o mesmo texto repetido.

O que existe nessas páginas e não foi transcrito

Para você não ser pego de surpresa se ela olhar o PDF junto com você:

Na página 47, depois dos critérios, começa a seção "Procedimentos e inovações para a realização do Censo Demográfico 2022 em Favelas e Comunidades Urbanas", que trata dos processos de consulta à sociedade. Não toca no seu recorte.

No topo da página 73, antes da seção de comparabilidade, há um trecho sobre o Help Desk montado pelo IBGE para a rede de coleta. É operacional.

Na página 74, antes do resultado transcrito, há três marcadores descrevendo quais tipos de setor de 2010 foram considerados equivalentes aos de 2022: os que foram divididos, os que foram agregados e

os que mantiveram a geometria. É o detalhe metodológico do estudo de área constante. Se perguntarem como o IBGE definiu "mesma área", é esta a resposta.

Na página 75, depois da nota 7, começa a análise de resultados, com os cartogramas de Cariacica (ES) e Campina Grande (PB) como exemplos de favelas grandes e contíguas contra muitas favelas pequenas dispersas. Há também a nota 8, que apenas remete de volta à seção de comparabilidade.

Se ela perguntar sobre qualquer uma dessas partes, a resposta honesta é que você não entrou nelas porque não tocavam no recorte do trabalho. É melhor do que improvisar.